



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

Σχολή Εφαρμοσμένων Μαθηματικών και Φυσικών Επιστημών

Τομέας Μαθηματικών

**Πανοπτική κατάτμηση εικόνας με χρήση
βαθιών νευρωνικών δικτύων**

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

Νικόλα Ιωάννου

Επιβλέπων: Παναγιώτης Τσανάκας
Καθηγητής Ε.Μ.Π.

Συνεπιβλέπων: Γεώργιος Σιόλας
Ε.ΔΙ.Π. Ε.Μ.Π.



Εθνικό Μετσόβιο Πολυτεχνείο

Σχολή Εφαρμοσμένων Μαθηματικών και Φυσικών Επιστημών

Τομέας Μαθηματικών

Εργαστήριο Όρασης Υπολογιστών, Επικοινωνίας Λόγου και Επεξεργασίας
Σημάτων

Πανοπτική κατάτμηση εικόνας με χρήση βαθιών νευρωνικών δικτύων

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

Νικόλα Ιωάννου

Επιβλέπων: Παναγιώτης Τσανάκας
Καθηγητής Ε.Μ.Π.

Συνεπιβλέπων: Γεώργιος Σιόλας
Ε.ΔΙ.Π. Ε.Μ.Π.

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 1η Ιουλίου, 2025.

(Υπογραφή)

.....
Παναγιώτης Τσανάκας
Καθηγητής Ε.Μ.Π.

(Υπογραφή)

.....
Αντώνιος Συμβώνης
Καθηγητής Ε.Μ.Π.

(Υπογραφή)

.....
Γεώργιος Στάμιου
Καθηγητής Ε.Μ.Π.

Αθήνα, Ιούλιος 2025

.....
ΙΩΑΝΝΟΥ ΝΙΚΟΛΑΣ

*Διπλωματούχος σχολής Εφαρμοσμένων
Μαθηματικών και Φυσικών Επιστημών Ε.Μ.Π.*

© – All rights reserved. Με επιφύλαξη παντός δικαιώματος.
Νικόλας Ιωάννου, 2025.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικούς σκοπούς. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπούς μη κερδοσκοπικούς, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Στην

Abstract

in

Ευχαριστίες

Θα ήθελα να ευχαριστήσω τον κ.Γεώργιο Σιόλα για την επίβλεψη της παρούσας διπλωματικής εργασίας. Θα ήθελα να ευχαριστήσω επίσης την οικογένεια μου γιατί χωρίς αυτούς δεν θα μπορούσα να βρίσκομαι στην θέση την οποία βρίσκομαι τώρα.

Περιεχόμενα

Κατάλογος Σχημάτων	xiv
Κατάλογος Πινάκων	xvi
Εισαγωγή	1
1 Ορισμός και περιγραφή του προβλήματος	4
1.1 Κατάτμηση εικόνας	5
1.1.1 Σημασιολογική κατάτμηση εικόνας	5
1.1.2 Κατάτμηση αντικειμένων	6
1.1.3 Πανοπτική κατάτμηση εικόνας	7
1.2 Συναφή προβλήματα ανάλυσης εικόνας	8
2 Θεωρητικό υπόβαθρο	12
2.1 Ο νευρώνας	12
2.2 Το μοντέλο McCulloch-Pitts	13
2.2.1 Εναλλακτικές συναρτήσεις ενεργοποίησης	15
2.3 Νευρωνικά δίκτυα πολλών στρωμάτων	21
2.3.1 Το δίκτυο MLP	21
2.3.2 Εκπαίδευση νευρωνικών δικτύων	24
2.3.3 Ρύθμιση (Regularization)	31
2.4 Συνελκτικά νευρωνικά δίκτυα	34
2.4.1 Συνέλιξη με βήμα	37
2.4.2 Στρώμα υποδειγματοληψίας	37
2.4.3 Επέκταση με μηδενικά (Zero-padding)	38
2.4.4 Κανονικοποίηση τιμών (Normalization)	38
2.5 Μετασχηματιστές (Transformers)	42
2.5.1 Αρχιτεκτονική	43
3 Σύνολα δεδομένων και μετρικές αξιολόγησης πανοπτικής κατάτμησης εικόνας	47
3.1 Σύνολα δεδομένων πανοπτικής κατάτμησης εικόνας	47
3.1.1 Σύνολο δεδομένων COCO	47
3.1.2 Σύνολο δεδομένων Cityscapes	48
3.1.3 Σύνολο δεδομένων ADE20K	50
3.2 Μετρικές αξιολόγησης πανοπτικής κατάτμησης εικόνας	51
3.2.1 Πίνακας σύγχυσης (Confusion matrix)	51
3.2.2 Intersection over Union (Intersection over Union - IoU)	53
3.2.3 Μέσος Όρος Ακρίβειας (Average Precision - AP)	53

3.2.4	Πανοπτική ποιότητα (Panoptic Quality - PQ)	54
4	Σχετική έρευνα	58
4.1	State-of-the-art στο σύνολο δεδομένων COCO	58
4.1.1	Mask DINO	58
4.1.2	kMaX-DeepLab	59
4.2	State-of-the-art στο σύνολο δεδομένων Cityscapes	59
4.2.1	Scaling Wide Residual Networks	59
4.2.2	Naive-Student	61
4.3	State-of-the-art στο σύνολο δεδομένων ADE20K	62
4.3.1	OneFormer	62
4.3.2	OpenSeeD	62
4.4	Θεμελιώδεις έρευνες στην πανοπτική κατάτμηση εικόνας	63
4.4.1	Panoptic-DeepLab	63
4.4.2	UPNet	64
4.4.3	Max-DeepLab	65
5	Συμβολή της εργασίας	67
5.1	Visual Attention Network - VAN	67
6	Πειραματικά αποτελέσματα	70
6.1	Γενικό πλαίσιο	70
6.1.1	Παράμετροι εκπαίδευσης	70
6.2	Πειραματικά αποτελέσματα για διαφορετικές μεθόδους κανονικοποίησης τιμών	70
7	Συμπεράσματα και μελλοντικές επεκτάσεις	71
	Βιβλιογραφική αναφορά	72

Κατάλογος Σχημάτων

1.1.1 Αυθεντική εικόνα	6
1.1.2 Σημασιολογική κατάτμηση εικόνας	6
1.1.3 Κατάτμηση αντικειμένων	7
1.1.4 Πανοπτική κατάτμηση εικόνας	8
2.1.1 Δομή νευρώνα	12
2.2.1 Μοντέλο McCulloch και Pitts του νευρώνα	14
2.2.2 Σχηματική αναπαράσταση του νευρώνα	15
2.2.3 Γραφική μορφή βηματικής συνάρτησης $-1/1$	16
2.2.4 Γραφική μορφή σιγμοειδής συνάρτησης	17
2.2.5 Γραφική μορφή υπερβολικής εφαπτομένης	18
2.2.6 Γραφική μορφή συνάρτησης ReLU	19
2.2.7 Γραφική μορφή συνάρτησης GeLU	20
2.2.8 Γραφική μορφή γραμμικής συνάρτησης	21
2.3.1 Ταξινόμηση στον $\mathbb{R}^2$ μέσω δικτύου Perceptron	22
2.3.2 Γενική σχηματική μορφή δικτύου Perceptron πολλών στρωμάτων	23
2.3.3 Απεικόνιση της τεχνικής της απόρριψης: (a) Κατά την εκπαίδευση, κάθε μονάδα διατηρείται με πιθανότητα p . (b) Κατά τη δοκιμή, όλες οι μονάδες είναι ενεργές και τα βάρη κλιμακώνονται κατά p	33
2.4.1 Η αρχιτεκτονική ενός τυπικού συνελκτικού νευρωνικού δικτύου	35
2.4.2 Αναπαράσταση υπολογισμού νευρώνα y_{ij}^k του k -οστού χάρτη χαρακτηριστικών και στρώματος L	36
2.4.3 Εξαγωγή χαρακτηριστικών	36
2.5.1 Αρχιτεκτονική μετασχηματιστή	43
3.1.1 Κατηγορίες αντικειμένων συνόλου δεδομένων COCO	48
3.1.2 Αντικείμενα συνόλου δεδομένων Cityscapes	49
3.1.3 Αντικείμενα και υπο-αντικείμενα συνόλου δεδομένων ADE20K	50
3.2.1 Μορφή πίνακα σύγχυσης για δυαδική ταξινόμηση	51
3.2.2 Παράδειγμα διαχωρισμού των τμημάτων της κατηγορίας "person" στα σύνολα TP, FP και FN.	55
4.1.1 Αρχιτεκτονική μοντέλου Mask DINO	58
4.1.2 Μετα-αρχιτεκτονική μοντέλου kMaX-DeepLab	59
4.2.1 Αρχιτεκτονικές τεχνικών (a) Squeeze-and-Excitation, (b) Switchable Atrous Convolution	61
4.3.1 Αρχιτεκτονική OneFormer	62
4.3.2 Αρχιτεκτονική OpenSeed	63
4.4.1 Αρχιτεκτονική μοντέλου Panoptic-DeepLab	64
4.4.2 Αρχιτεκτονική μοντέλου UPSNet	65

4.4.3 Αρχιτεκτονική μοντέλου Max-DeepLab	66
5.1.1 Αποσύνθεση συνελκτικών πράξεων LKA για $K = 7$ και $d = 2$	68
5.1.2 Αρχιτεκτονική ενός σταδίου του VAN	69

Κατάλογος Πινάκων

1	Σύγκριση αρχιτεκτονικών Wide-ResNet-41 και SWideRNet	60
---	--	----

Εισαγωγή

Η ραγδαία ανάπτυξη της τεχνητής νοημοσύνης την έχει καταστήσει αναπόσπαστο κομμάτι της καθημερινότητας μας, με εφαρμογές σε αρκετούς τομείς της ζωής μας. Εξαίρεση σε αυτό δεν αποτελούν τομείς, όπου η ανάλυση και κατανόηση της οπτικής πληροφορίας είναι απαραίτητη. Ωστόσο, η κατανόηση της οπτικής πληροφορίας από τον άνθρωπο αποτελεί μια συχνά χρονοβόρα και επίπονη διαδικασία, η οποία διακατέχεται από υψηλό επίπεδο υποκειμενικότητας και δεν αποκλείει την εμφάνιση σφαλμάτων. Σε κρίσιμες εφαρμογές, όπως η ιατρική διάγνωση και η αυτόνομη οδήγηση, τα σφάλματα αυτά, όπως και η απουσία χρόνου αντίδρασης ενδέχεται να οδηγήσει σε σοβαρές ή ακόμα και μοιραίες συνέπειες. Για αυτό τον λόγο, η ύπαρξη μεθόδων οι οποίες μπορούν να κατανοήσουν με ακρίβεια, συνέπεια και ταχύτητα την οπτική πληροφορία είναι απαραίτητη. Το επιστημονικό πεδίο που ασχολείται με την ανάπτυξη μεθόδων και αλγορίθμων με σκοπό την κατανόηση, επεξεργασία και ανάλυση της οπτικής πληροφορίας από υπολογιστικά συστήματα είναι γνωστό ως όραση υπολογιστών. Περιλαμβάνει ένα ευρύ φάσμα εργασιών όπως η ανίχνευση αντικειμένων, η εκτίμηση βάθους και η ταξινόμηση οπτικής πληροφορίας. Μεταξύ αυτών αποτελεί και η κατάτμηση εικόνας, με την οποία καθίσταται δυνατή η λεπτομερής κατανόηση του περιεχομένου μιας εικόνας, κάτι που αποτελεί ιδιαίτερα χρήσιμο στην σύγχρονη εποχή με εφαρμογές από την ιατρική διάγνωση μέχρι και την ανάλυση δορυφορικών εικόνων.

Παρά την σημαντική πρόοδο των τελευταίων ετών, το πεδίο της όρασης υπολογιστών συνεχίζει να παρουσιάζει σημαντικές προκλήσεις. Η μεγάλη πολυπλοκότητα και μεταβλητότητα των σκηνών σε συνδυασμό με την αυξανόμενη ανάγκη για ανάλυση σε πραγματικό χρόνο καθιστούν το πρόβλημα ιδιαίτερα απαιτητικό. Παράγοντες όπως οι έντονες καιρικές συνθήκες, οι αλλαγές στον φωτισμό και η εξαιρετικά μεγάλη πολυπλοκότητα των λειτουργιών της βιολογικής όρασης καθιστούν το πρόβλημα εξαιρετικά δύσκολο. Ως εκ τούτου, καθίσταται η ανάγκη για διάκριση της όρασης σε πολλές κατηγορίες. Μεταξύ αυτών αποτελούν η εκτίμηση βάθους, η αναγνώριση προσώπων, η ταξινόμηση σκηνών και η κατάτμηση, η οποία διαδραματίζει ιδιαίτερα καθοριστικό ρόλο.

Η κατάτμηση εικόνας αποτελεί μια από της σημαντικότερες κατηγορίες στην όραση υπολογιστών και παράλληλα συνιστά πεδίο με έντονη ερευνητική δραστηριότητα. Ορίζεται ως η διαδικασία διαχωρισμού μιας εικόνας σε διακριτές περιοχές, με βάση το οπτικό περιεχόμενο που αναπαριστούν. Με αυτόν τον τρόπο καθίσταται δυνατή η λεπτομερής κατανόηση του περιεχομένου μιας εικόνας, πέρα από τη γενική αναγνώριση κατηγοριών. Η κατάτμηση επιτρέπει σε υπολογιστικά συστήματα να εντοπίζουν με ακρίβεια τα όρια των αντικειμένων, να αποδίδουν σε κάθε εικονοστοιχείο μια ετικέτα και να αναπαριστούν το οπτικό περιεχόμενο με τρόπο πιο κοντά στη βιολογική όραση. Έχει εφαρμογές σε τομείς όπως η αυτόνομη οδήγηση, η ιατρική και η ρομποτική. Διακρίνεται σε κατηγορίες με κάποιες εκ των σημαντικότερων εξ' αυτών να

αποτελούν την σημασιολογική κατάτμηση εικόνας, της κατάτμηση αντικειμένων και την πανοπτική κατάτμηση εικόνας. Ανάμεσα σε αυτές η πανοπτική κατάτμηση εικόνας, αν και ορίστηκε εργασία που αναπτύχθηκε σχετικά πρόσφατα παρουσιάζει έντονο ερευνητικό ενδιαφέρον.

Για πολλά χρόνια, η σημασιολογική κατάτμηση εικόνας και η κατάτμηση αντικειμένων ακολουθούσαν διαφορετικές πορείες. Η πρώτη επικεντρώθηκε στην ταξινόμηση κάθε εικονοστοιχείου της εικόνας σε κάποια σημασιολογική κατηγορία, ενώ η δεύτερη στον εντοπισμό και διαχωρισμό μεμονομένων αντικειμένων σε επίπεδο εικονοστοιχείου. Η διάκριση αυτή δεν αφορούσε μόνο τις μεθόδους που αναπτύχθηκαν αλλά είχε αντίκτυπο και στις αντίστοιχες μετρικές αξιολόγησης των μεθόδων, όπως και στα σύνολα δεδομένων. Ωστόσο, με την πρόοδο των νευρωνικών δικτύων, δημιουργήθηκαν οι προϋποθέσεις για ένα ενιαίο πλαίσιο. Αυτό το πλαίσιο επιχειρεί να γεφυρώσει τις δύο εργασίες, συνδυάζοντας τις. Η ανάγκη για μια τέτοια ενοποίηση οδήγησε στην εισαγωγή της πανοπτικής κατάτμησης εικόνας. Η πανοπτική κατάτμηση εικόνας, συνδυάζει τις εργασίες σημασιολογικής κατάτμησης και κατάτμησης αντικειμένων σε μια ενιαία θεώρηση. Επιδιώκει να δώσει μια πλήρη περιγραφή των περιεχομένων μιας εικόνας, αποδίδοντας σε κάθε εικονοστοιχείο μια σημασιολογική κατηγορία και διακρίνοντας για τα αντικείμενα που είναι στην ίδια. Η ενοποίηση των δύο εργασιών έθεσε νέες προκλήσεις, τόσο στην κατασκευή μεθόδων όσο και στον ορισμό νέων μετρικών αξιολόγησης. Παράλληλα οδήγησε στην τροποποίηση υπάρχοντων συνόλων δεδομένων, όπως και στην δημιουργία νέων, με στόχο την υποστήριξη της αυτής της εργασίας. Η πανοπτική κατάτμηση εικόνας ορίστηκε πλήρως για πρώτη φορά το 2018 στην δημοσίευση εν ονόματι "Panoptic Segmentation", στην οποία ορίστηκε και η κύρια μετρική αξιολόγησης της εργασίας αυτής εν ονόματι πανοπτική ποιότητα.

Η παρούσα εργασία επικεντρώνεται στην πανοπτική κατάτμηση εικόνας. Το ζητούμενο αποτελεί η μελέτη και η αξιολόγηση σύγχρονων μεθόδων βασισμένων στα βαθιά νευρωνικά δίκτυα, όπως και η τροποποίηση αυτών με σκοπό την βελτίωση της απόδοσης και την κατανόηση των περιορισμών τους. Η ερευνητική φύση της εργασίας δεν στοχεύει μόνο την αποτίμηση της αποτελεσματικότητας ορισμένων αρχιτεκτονικών αλλά και στην ανάδειξη των προκλήσεων που εξακολουθούν να υφίστανται. Ένα από τα βασικά εμπόδια αποτελεί το εξαιρετικά μεγάλο υπολογιστικό κόστος που απαιτείται στην εκπαίδευση και αξιολόγηση των μεθόδων, το οποίο απαιτεί σύγχρονο και συχνά απρόσιτο υλικό εξοπλισμό. Η παράμετρος αυτή καθιστά την έρευνα στον τομέα της υπολογιστικής όρασης αρκετά δύσκολη.

Το μέλλον της πανοπτικής κατάτμησης αναμένεται να είναι ιδιαίτερα δυναμικό, καθώς η έρευνα στρέφεται στην δημιουργία μεθόδων που συνδυάζουν υψηλή ακρίβεια με μειωμένο υπολογιστικό και αποθηκευτικό κόστος. Η χρήση ελαφρύτερων μοντέλων αναμένεται να διευρύνει ακόμα περισσότερο τις εφαρμογές της σε συσκευές που μέχρι πρότενος δεν μπορούσαν να την αξιοποιήσουν. Η ενσωμάτωση σε φορητές συσκευές, μικρά μη επανδρωμένα οχήματα και οχήματα χαμηλής ενεργειακής κατανάλωσης ανοίγει νέους δρόμους στην αξιοποίηση της

τεχνητής όρασης. Με αυτό τον τρόπο η πανοπτική κατάτμηση έχει την δυνατότητα να καταστεί μια θεμελιώδης τεχνολογία στην όραση υπολογιστών.

Η εργασία είναι δομημένη σε 7 κεφάλαια. Στο πρώτο κεφάλαιο το πρόβλημα ορίζεται απο την βάση του, την όραση υπολογιστών, έτσι ώστε ο αναγνώστης να κατανοήσει το πεδίο στο οποίο εντάσσεται η πανοπτική κατάτμηση. Παρουσιάζεται εκτενώς η κατάτμηση εικόνας, όπως και τα τρία βασικότερα παρακλάδια της, η σημασιολογική κατάτμηση εικόνας, η κατάτμηση αντικειμένων και η πανοπτική κατάτμηση. Παρουσιάζεται εκτενώς η κατάτμηση εικόνας, όπως και τα 3 βασικότερα παρακλάδια της, η σημασιολογική κατάτμηση εικόνας, η κατάτμηση αντικειμένων και η πανοπτική κατάτμηση εικόνας. Επιπλέον, περιγράφονται και άλλες εργασίες ανάλυσης εικόνας, όπως η εκτίμηση βάθους και η ανακατασκευή 3-διάστατης εικόνας, ώστε ο αναγνώστης να αποκτήσει μια πληρέστερη εικόνα του αντικειμένου. Στο δεύτερο κεφάλαιο δίνεται το απαιτούμενο θεωρητικό υπόβαθρο για τους σκοπούς της παρούσας εργασίας. Παρουσιάζονται οι βασικές αρχές των τεχνητών νευρωνικών δικτύων, όπως και οι σημαντικότερες αρχιτεκτονικές νευρωνικών δικτύων της πανοπτικής κατάτμηση εικόνας. Στο τρίτο κεφάλαιο παρουσιάζονται τα σημαντικότερα σύνολα δεδομένων και μετρικές αξιολόγησης στην πανοπτική κατάτμηση εικόνας, ενώ στο τέταρτο κεφάλαιο παρουσιάζονται ορισμένες απο της σημαντικότερες έρευνες του πεδίου, όπως και οι αποδοτικότερες μέθοδοι για κάθε ένα απο τα σύνολα δεδομένων που παρουσιάζονται. Σκοπός της σχετικής έρευνας είναι να προσφέρει στον αναγνώστη μια ολοκληρωμένη εικόνα της προόδου και των τάσεων που επικρατούν στο πεδίο. Στα κεφάλαια 5 και 6 παρουσιάζεται το προτεινόμενο μοντέλο, όπως και πειραματικά αποτελέσματα απο την εφαρμογή του. Σε αυτό το πλαίσιο, παρουσιάζονται και τα πειραματικά αποτελέσματα των δοκιμών που πραγματοποιήθηκαν, μέσω των οποίων διαμορφώθηκε η τελική πρόταση. Στο τελευταίο κεφάλαιο παρουσιάζονται τα συμπεράσματα που προέκυψαν απο την μελέτη, καθώς και μελλοντικές επεκτάσεις, οι οποίες θα μπορούσαν να αποτελέσουν αντικείμενο περαιτέρω έρευνας.

1 Ορισμός και περιγραφή του προβλήματος

Η όραση υπολογιστών [1] αποτελεί πεδίο της τεχνητής νοημοσύνης που επιχειρεί την προσομοίωση της βιολογικής όρασης, κάνοντας χρήση υπολογιστών και συναφούς τεχνολογικού εξοπλισμού. Αποσκοπεί στην κατανόηση της τρισδιάστατης δομής του περιβάλλοντος, μέσω της επεξεργασίας εικόνων και βίντεο και έχει ως απότερο σκοπό την κατανόηση του οπτικού περιεχομένου. Το πεδίο αυτό περιλαμβάνει μεταξύ άλλων την

- Επεξεργασία εικόνας (Image Processing)
- Αναγνώριση προτύπων (Pattern Recognition)
- Γεωμετρική μοντελοποίηση (Geometric Modeling)
- Αναγνώριση αντικειμένων (Recognition Processes)

Η όραση υπολογιστών μπορεί να εφαρμοσθεί σε ένα ευρύ φάσμα τομέων όπως η ιατρική στον εντοπισμό κακοήθων όγκων [2], η αυτόνομη οδήγηση για την κατανόηση του περιβάλλοντος χώρου του οχήματος [3] και η ρομποτική [4].

Η ιστορική της πορεία ξεκινά στις αρχές της δεκαετίας του 1960 όταν η έρευνα επικεντρώθηκε σε βασικές τεχνικές επεξεργασίας εικόνας, όπως το φιλτράρισμα (Filtering), η οριοθέτηση και η ανίχνευση ακμών. Αρχικά, ο στόχος αποτελούσε η ανάλυση των τιμών των εικονοστοιχείων, όπως και η αναγνώριση απλών σχημάτων. Κατά την διάρκεια της δεκαετίας του 1980 αναπτύχθηκαν πιο σύνθετες τεχνικές που επέτρεπαν την αναγνώριση πιο σύνθετων σχημάτων και την εξαγωγή χαρακτηριστικών. Τη δεκαετία του 1990 η όραση υπολογιστών πέρασε στην φάση της μηχανικής μάθησης, όπου υιοθετήθηκαν στατιστικές μέθοδοι όπως οι μηχανές διανυσμάτων υποστήριξης (Support Vector Machines) και τα τυχαία δάση (Random Forest). Σημείο καμπής αποτέλεσε η δεκαετία του 2010, κατά την οποία η ραγδαία αύξηση της υπολογιστικής ισχύος και η δημιουργία μεγάλου μεγέθους, επισημειωμένων συνόλων δεδομένων, άνοιξε την πόρτα σε αλγορίθμους βασισμένους στην βαθιά μάθηση και συγκεκριμένα στα νευρωνικά και συνελκτικά νευρωνικά δίκτυα, τα οποία σημείωσαν τεράστια πρόοδο. Χαρακτηριστικό παράδειγμα αποτελεί το AlexNet [5], ένα βαθύ συνελκτικό νευρωνικό δίκτυο που αναπτύχθηκε από τον Geoffrey E. Hinton και την ομάδα του, το οποίο κατέγραψε 15.3% top-5 error rate στο ILSVRC (ImageNet Large Scale Visual Recognition Challenge) [6]. Σήμερα, η όραση υπολογιστών επικεντρώνεται κυρίως στην ανάπτυξη μοντέλων ικανών να εξάγουν αποτελέσματα σε πραγματικό χρόνο χωρίς αισθητή χρονική καθυστέρηση, σε ηθικά ζητήματα όπως η αμεροληψία των αποτελεσμάτων όπως και σε ζητήματα ιδιωτικότητας [7].

Η όραση υπολογιστών περιλαμβάνει μια πληθώρα εργασιών, κάθε μια με διαφορετικό σκοπό και επίπεδο ανάλυσης της οπτικής πληροφορίας [8], [9]. Μεταξύ άλλων έχουμε την

- Κατάτμηση εικόνας (Image Segmentation)
- Ταξινόμηση εικόνας (Image Classification)
- Ανίχνευση αντικειμένων (Object Detection)
- Ανακατασκευή τρισδιάστασης εικόνας (3 Dimensional Image Reconstruction)
- Εκτίμηση βάθους (Depth Estimation)

1.1 Κατάτμηση εικόνας

Η κατάτμηση εικόνας αποτελεί εργασία της όρασης υπολογιστών που αφορά την διαίρεση εικόνων ή βίντεο σε διακριτές περιοχές ή αντικείμενα. Κατά την διάρκεια των ετών έχουν αναπτυχθεί πολυάριθμοι μέθοδοι που επιχειρούν να αντιμετωπίσουν το πρόβλημα αυτό. Οι πρώτες προσεγγίσεις βασίστηκαν σε μεθόδους, όπως η χρήση κατωφλίου (Threshold), η ομαδοποίηση βάσει ιστογράμματος (Histogram-based Clustering) και η ομαδοποίηση μέσω του αλγορίθμου K-means. Στη συνέχεια, εφαρμόστηκαν πιο προχωρημένες μέθοδοι όπως οι ενεργές καμπύλες (Active Contours), οι τομές γράφων (Graph Cuts), τα υπο συνθήκη και τυχαία πεδία Markov και μέθοδοι που βασίζονται στην αραιότητα (Sparsity-based Methods). Κατατάλλα, τα τελευταία χρόνια τα μοντέλα βαθιάς μάθησης (Deep Learning Models) έχουν οδηγήσει σε μια νέα γενιά μοντέλων κατάτμησης εικόνας με εντυπωσιακές επιδόσεις, συχνά επιτυγχάνοντας τις υψηλότερες επιδόσεις σε ευρέως χρησιμοποιούμενα σύνολα αναφοράς (Benchmarks) [10]. Η κατάτμηση εικόνας διακρίνεται μεταξύ άλλων στις εξής κατηγορίες.

- Σημασιολογική κατάτμηση εικόνας (Semantic Image Segmentation)
- Κατάτμηση αντικειμένων (Instance Segmentation)
- Πανοπτική κατάτμηση εικόνας (Panoptic Image Segmentation)


1.1.1 Σημασιολογική κατάτμηση εικόνας

Ζητούμενο της σημασιολογικής κατάτμησης εικόνας αποτελεί ο προσδιορισμός της σημασιολογικής κατηγορίας κάθε εικονοστοιχείου μιας εικόνας. Τυπικά, το πρόβλημα αντιμετωπίζεται ως πρόβλημα επιβλεπόμενης μάθησης (Supervised learning), δηλαδή απαιτείται ένα πλήρως επισημειωμένο σύνολο εκπαίδευσης. Στην σημασιολογική κατάτμηση εικόνας αυτό σημαίνει πως κάθε εικόνα του συνόλου εκπαίδευσης είναι πλήρως επισημειωμένη σε επίπεδο εικονοστοιχείου. Οι σημασιολογικές ετικέτες διακρίνονται σε δύο κατηγορίες, στα "αντικείμενα" (Things), όπως για παράδειγμα σκύλος, αυτοκίνητο, πεζός κ.ο.κ. και στα "σκηνικά" στοιχεία (Stuff), όπως ουρανός, βλάστηση, δρόμος κ.ο.κ. Οι δύο αυτοί όροι χρησιμοποιούνται εκτενώς στην κατάτμηση εικόνας. Η πρώτη κατηγορία αναφέρετε σε μετρήσιμα αντικείμενα, ενώ η δεύτερη

κατηγορία σχετίζεται με στοιχεία του σκηνικού χώρου [11]. Παρακάτω παρουσιάζεται ενδεικτικά ένα παράδειγμα σημασιολογικής κατάτμησης εικόνας.



Σχήμα 1.1.1: Αυθεντική εικόνα



Σχήμα 1.1.2: Σημασιολογική κατάτμηση εικόνας


Όπως μπορούμε να δούμε στο 1.1.2 κάθε εικονοστοιχείο της εικόνας αντιστοιχίζεται σε μια σημασιολογική κατηγορία. Μπορούμε να παρατηρήσουμε πως τα εικονοστοιχεία που αντιστοιχίζονται στην ίδια σημασιολογική κατηγορία αποτελούν τα εικονοστοιχεία τα οποία αντιστοιχούν στο ίδιο "αντικείμενο" ή "σκηνικό" στοιχείο.

Σημαντικές μετρικές αξιολόγησης της σημασιολογικής κατάτμησης εικόνας αποτελούν μεταξύ άλλων η Intersection over Union (IoU), όπως και η ακρίβεια εικονοστοιχείου (Pixel Accuracy - PA) [10]. Ενδεικτικά παραδείγματα σημείων αναφοράς (Benchmarks) που χρησιμοποιούνται για την ποσοτικοποίηση της απόδοσης μεθόδων σημασιολογικής κατάτμησης εικόνας είναι τα Cityscapes [12], PASCAL VOC [13] και ADE20K [14].

1.1.2 Κατάτμηση αντικειμένων

Η ανίχνευση αντικειμένων αποτελεί πρόβλημα στην όραση υπολογιστών, κατά το οποίο εντοπίζονται και ταξινομούνται τα "αντικείμενα" μιας εικόνας, προσδιορίζοντας την θέση τους μέσω

ορθογώνιων πλαισίων. Η σημασιολογική κατάτμηση εικόνας, όπως αναφέρθηκε παραπάνω προσδιορίζει την σημασιολογική κατηγορία κάθε εικονοστοιχείου μιας εικόνας, χωρίς όμως να διαχωρίζει μεταξύ διαφορετικών "αντικειμένων" της ίδιας κατηγορίας. Προχωρώντας ένα βήμα παραπέρα, η κατάτμηση αντικειμένων συνδυάζει αυτές τις δύο τεχνικές και παρέχει διαφορετικές ετικέτες για ξεχωριστές εμφανίσεις "αντικειμένων" που ανήκουν στην ίδια κατηγορία, αγνοώντας εντελώς τα "σκηνικά" στοιχεία [15].



Σχήμα 1.1.3: Κατάτμηση αντικειμένων

Όπως μπορούμε να δούμε στο 1.1.3, κατηγοριοποιούνται μόνο τα εικονοστοιχεία τα οποία αντιστοιχούν σε "αντικείμενα", αγνοώντας τα υπόλοιπα. Εύκολα μπορούμε να παρατηρήσουμε πως υπάρχει διάκριση μεταξύ των "αντικειμένων" που ανήκουν στην ίδια κατηγορία.

Μερικές από τις σημαντικότερες μετρικές αξιολόγησης στην κατάτμηση αντικειμένων αποτελούν ο μέσος όρος ακριβείας (Average Precision - AP) και ο μέσος όρος ακριβείας μάσκας (Mask AP) [15]. Ενδεικτικά σύνολα αναφοράς που χρησιμοποιούνται για την αξιολόγηση της απόδοσης μεθόδων κατάτμησης αντικειμένων αποτελούν τα COCO [16], Cityscapes [12] και ADE20K [14].

1.1.3 Πανοπτική κατάτμηση εικόνας

Η πανοπτική κατάτμηση εικόνας αποτελεί μια πιο σύνθετη εργασία σε σχέση με την σημασιολογική κατάτμηση και την κατάτμηση αντικειμένων, καθώς ενοποιεί τις δύο εργασίες σε ένα ενιαίο πλάσιο. Συγκεκριμένα, στην πανοπτική κατάτμηση εικόνας όλα τα εικονοστοιχεία της εικόνας κατηγοριοποιούνται, ανεξάρτητα εάν τα εικονοστοιχεία αντιστοιχούν σε "αντικείμενα" ή σε "σκηνικά" στοιχεία, ενώ παράλληλα πραγματοποιείται διαχωρισμός μεταξύ των "αντικειμένων" που αντιστοιχούν στην ίδια σημασιολογική κατηγορία [17].

Όπως μπορούμε να δούμε στο 1.1.4, κατηγοριοποιούνται όλα τα εικονοστοιχεία της εικόνας, ενώ ταυτόχρονα διαχωρίζονται τα "αντικείμενα" που ανήκουν στην ίδια σημασιολογική κατηγορία.



Σχήμα 1.1.4: Πανοπτική κατάτμηση εικόνας

Μερικές απο τις σημαντικότερες μετρικές αξιολόγησης της πανοπτικής κατάτμησης εικόνας είναι οι Panoptic Quality (PQ), Segmentation Quality (SQ) και Recognition Quality (RQ). Ωστόσο, δεδομένου πως η πανοπτική κατάτμηση εικόνας αποτελεί συνδυασμό των εργασιών κατάτμησης αντικειμένων και σημασιολογικής κατάτμησης εικόνας, χρησιμοποιούνται μετρικές που έχουν ως σκοπό την ποσοτικοποίηση της απόδοσης καθεμιάς απο τις δύο εργασίες ξεχωριστά. Συγκεκριμένα γίνεται χρήση των μετρικών αξιολόγησης Panoptic Quality Things (PQ_{th}) και Panoptic Quality Stuff (PQ_{st}) [17]. Ενδεικτικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται για την ποσοτικοποίηση της απόδοσης των μεθόδων πανοπτικής κατάτμησης εικόνας αποτελούν μεταξύ άλλων τα COCO [16], Cityscapes [12] και ADE20K [14].

1.2 Συναφή προβλήματα ανάλυσης εικόνας

Στην παρούσα υπο-ενότητα παρουσιάζονται και αναλύονται συνοπτικά διάφορα προβλήματα της όρασης υπολογιστών, τα οποία καλύπτουν διαφορετικά μέρη της κατανόησης οπτικής πληροφορίας, σε σχέση με την κατάτμηση εικόνας. Η ανάλυση αυτή αποσκοπεί στην σύγκριση της εργασίας της πανοπτικής κατάτμησης εικόνας με διάφορες άλλες εργασίες της όρασης υπολογιστών.

Ταξινόμηση εικόνας

Η ταξινόμηση εικόνας αποτελεί εργασία στην τεχνητή νοημοσύνη κατά την οποία μια εικόνα αντιστοιχίζεται σε μια ή περισσότερες κατηγορίες με βάση αυτό που απεικονίζει. Βρίσκει εφαρμογές σε ένα ευρύ φάσμα τομέων, όπως η υγεία, η βιομηχανική παραγωγή και η γεωργία [18].

Μερικές απο τις σημαντικότερες μετρικές αξιολόγησης της αποτελούν μεταξύ άλλων η ακρίβεια (Accuracy) ταξινόμησης των εικόνων και το F1-score [19], [20]. Μερικά απο τα σημα-

ντικότερα σύνολα αναφοράς που χρησιμοποιούνται αποτελούν τα σύνολα δεδομένων ImageNet [6] και COCO [16].

Ανίχνευση αντικειμένων

Ζητούμενο της ανίχνευσης αντικειμένων αποτελεί ο εντοπισμός και η κατηγοριοποίηση των "αντικειμένων" που εμφανίζονται σε μια εικόνα. Ο εντοπισμός πραγματοποιείται συνήθως μέσω ενός ορθογωνίου πλαισίου που περικλείει το "αντικείμενο", συνοδευόμενο από την προβλεπόμενη κατηγορία και τον δείκτη βεβαιότητας της πρόβλεψης. Η ανίχνευση αντικειμένων μπορεί να χρησιμοποιηθεί σε ένα πλήθος εφαρμογών όπως η αυτόνομη οδήγηση, η ρομποτική και η ιατρική. Αποτελεί βάση για διάφορες άλλες εργασίες στην όραση υπολογιστών, όπως η κατάτμηση και η παρακολούθηση αντικειμένων (Object Tracking).

Σημαντικές μετρικές απόδοσης της ανίχνευσης αντικειμένων αποτελούν μεταξύ άλλων, ο μέσος όρος ακριβείας (Average Precision) και η Intersection over Union (IoU) [21]. Μερικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται στην αξιολόγηση της ποιότητας των προβλέψεων είναι τα COCO [16] και PASCAL VOC [13].

Εκτίμηση βάθους

Η εκτίμηση βάθους αποτελεί εργασία κατά την οποία, για κάθε εικονοστοιχείο της εικόνας, εκτιμάται η απόσταση του αντίστοιχου τμήματος της σκηνής που απεικονίζει από το σημείο λήψης της φωτογραφίας. Η εργασία μπορεί να πραγματοποιηθεί χρησιμοποιώντας μια ή περισσότερες κάμερες, ανάλογα με την αντίστοιχη τεχνική που χρησιμοποιείται. Η εκτίμηση βάθους βρίσκει εφαρμογή σε τομείς όπως η ανακατασκευή τρισδιάστατης εικόνας, η εικονική πραγματικότητα και η αυτόνομη οδήγηση.

Μερικές από τις σημαντικότερες μετρικές απόδοσης της εκτίμησης βάθους αποτελούν, η ακρίβεια και η τετραγωνική ρίζα του μέσου τετραγωνικού σφάλματος (Root Mean Square Error - RMSE) [22]. Μερικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται στην αξιολόγηση της εκτίμησης αποτελούν μεταξύ άλλων τα KITTI [23] και Cityscapes [12].

Εκτίμηση στάσης

Η εκτίμηση στάσης αποτελεί εργασία κατά την οποία εντοπίζονται οι θέσεις των αρθρώσεων του σώματος κάθε ατόμου που εμφανίζεται σε μια εικόνα και στη συνέχεια χρησιμοποιούνται στην ανακατασκευή της αντίστοιχης αναπαράστασης του σκελετού του. Η εργασία μπορεί να

πραγματοποιηθεί σε δύο ή και τρεις διαστάσεις, κατά την οποία πραγματοποιείτε συνήθως με τη χρήση πολλαπλών καμερών ή επιπλέον αισθητήρων. Η εκτίμηση στάσης έχει εφαρμογές σε τομείς όπως η αλληλεπίδραση ανθρώπου υπολογιστή, η ρομποτική και η ιατρική.

Μεταξύ των σημαντικότερων μετρικών απόδοσης της εκτίμησης στάσης αποτελούν το ποσοστό σωστής εκτίμησης μελών (Percentage of Correct Parts - PCP) και το μέσο σφάλμα θέσης ανά άρθρωση (Mean Per Joint Position Error - MPJPE) [24]. Ενδεικτικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται αποτελούν μεταξύ άλλων το σύνολο δεδομένων COCO [16] και το σύνολο δεδομένων MuPoTS-3D [25].

Υπερ-ανάλυση εικόνας

Η υπερ-ανάλυση εικόνας αποτελεί εργασία κατά την οποία πραγματοποιείτε μετατροπή μιας εικόνας χαμηλής ανάλυσης σε μια εικόνα υψηλής ανάλυσης, με καλύτερη ποιότητα και πιο λεπτομερή χαρακτηριστικά. Το πρόβλημα θεωρείται αντίστροφο και υποκαθορισμένο, καθώς για την ίδια εικόνα χαμηλής ανάλυσης μπορεί να υπάρχουν πολλές πιθανές εκδοχές εικόνων υψηλής ανάλυσης. Η δυσκολία αυξάνεται όσο μεγαλώνει ο συντελεστής μεγέθυνσης, αφού η αποκατάσταση των χαμένων λεπτομερειών γίνεται πιο περίπλοκη και ενδέχεται να παραχθούν εσφαλμένες πληροφορίες. Η υπερ-ανάλυση εικόνας έχει εφαρμογές σε τομείς όπως η ιατρική, η ασφάλεια και η αστρονομία.

Κάποιες από τις σημαντικότερες μετρικές απόδοσης που χρησιμοποιούνται στην υπερ-ανάλυση εικόνας αποτελούν μεταξύ άλλων η τετραγωνική ρίζα μέσου τετραγωνικού σφάλματος και ο λόγος του μέγιστου σήματος ως προς τον θόρυβο (Peak Signal to Noise Ratio - PSNR) [26]. Μερικά από τα σημαντικότερα σύνολα αναφοράς που χρησιμοποιούνται αποτελούν μεταξύ άλλων το Set5 [27] και το Urban100 [28].

Ανακατασκευή 3-διάστατης εικόνας

Η τρισδιάστατη ανακατασκευή εικόνας αποτελεί εργασία που αποσκοπεί στην αναπαράσταση της τρισδιάστατης δομής μιας σκηνής, αξιοποιώντας δεδομένα όπως δισδιάστατες εικόνες, χάρτες βάθους και σύνολα σημείων τριών διαστάσεων. Η ανακατασκευή της τρισδιάστατης δομής μιας εικόνας έχει εφαρμογές σε τομείς όπως τα βιντεοπαιχνίδια, η ιατρική και η εικονική πραγματικότητα.

Κάποιες από τις σημαντικότερες μετρικές απόδοσης που χρησιμοποιούνται αποτελούν μεταξύ άλλων η τετραγωνική ρίζα του μέσου τετραγωνικού σφάλματος και το μέσο απόλυτο σφάλμα

(Mean Absolute Error) [29]. Μερικά απο τα σημαντικότερα σύνολα δεδομένων που χρησιμοποιούνται αποτελούν μεταξύ άλλων το σύνολο δεδομένων KITTI [23] και το σύνολο δεδομένων Cityscapes 3D [30].


2 Θεωρητικό υπόβαθρο

2.1 Ο νευρώνας

Η έρευνα σχετικά με τα τεχνητά νευρωνικά δίκτυα είναι εμπνευσμένη από την δομή και λειτουργία του εγκεφάλου. Βασικό δομικό του στοιχείο είναι οι νευρώνες. Κίνητρο για την μελέτη του νευρώνα είναι η ανακάλυψη ενός μοντέλου το οποίο θα προσομοιώνει την λειτουργία και τις δυνατότητες του εγκεφάλου. Ωστόσο, τα τεχνητά νευρωνικά δίκτυα χρησιμοποιούν πολύ απλοποιημένα μοντέλα νευρώνων, τέτοια ώστε να διατηρούν μόνο τα πολύ αδρά χαρακτηριστικά των λεπτομερών μοντέλων που χρησιμοποιούνται στη νευρολογία. Οι λεπτομέρειες πιστεύεται πως δεν παίζουν ιδιαίτερη σημασία στην κατανόηση της ευφυούς συμπεριφοράς των βιολογικών νευρωνικών συστημάτων. Ακόμα και αυτά τα απλά μοντέλα νευρώνων μπορούν να δημιουργήσουν ιδιαιτέρως ενδιαφέροντα δίκτυα, αρκεί να πληρούν δύο βασικά χαρακτηριστικά.

- Οι νευρώνες πρέπει να έχουν ρυθμιζόμενες παραμέτρους ώστε να διευκολύνεται η διαδικασία της μάθησης (Πλαστικότητα νευρώνα).
- Το δίκτυο πρέπει να αποτελείται από μεγάλο πλήθος νευρώνων ώστε να επιτυγχάνεται παραλληλισμός της επεξεργασίας και κατανομή της πληροφορίας.

Ο νευρώνας αποτελεί ένα μεγάλο σε μέγεθος κύτταρο το οποίο αποτελείται από τον πυρήνα, τους δενδρίτες, τον άξονα και τις συνάψεις που συνδέουν τις διακλαδώσεις του άξονα με τους δενδρίτες άλλων νευρώνων [31].



Σχήμα 2.1.1: Δομή νευρώνα

Λειτουργικά, τα τμήματα του νευρώνα παίζουν διαφορετικούς ρόλους. Οι δενδρίτες αποτελούν τις πύλες του νευρώνα και δέχονται ηλεκτρικά σήματα από άλλους νευρώνες. Ο άξονας αποτελεί την πύλη εξόδου του νευρώνα και στέλνει σήματα προς άλλους νευρώνες υπό μορφή

ηλεκτρικών παλμών σταθερού πλάτους και μεταβλητής συχνότητας. Τέλος, οι συνάψεις αποτελούν τα σημεία ενώσεως μεταξύ των διακλαδώσεων του άξονα του νευρώνα και των δενδριτών των νευρώνων που ενώνεται. Το πλάτος της σύναψης, η απόσταση της από τον δενδρίτη και η πυκνότητα του ηλεκτροχημικού υλικού επηρεάζουν την ευκολία με την οποία η ηλεκτρική δραστηριότητα διαδίδεται από τον άξονα στον δενδρίτη. Το ποσοστό της ηλεκτρικής δραστηριότητας που μεταδίδεται τελικά στον δενδρίτη ονομάζεται συναπτικό βάρος. Οι συνάψεις χωρίζονται σε ενισχυτικές (Excitatory) και ανασταλτικές (Inhibitory), ανάλογα με το αν το φορτίο που ελκύεται από τη σύναψη διεγείρει τον νευρώνα για να παράγει παλμούς ή αντίθετα τον αναστέλλει εμποδίζοντας τον.

Στους βιολογικούς νευρώνες, οι φορείς των πληροφοριών είναι οι ηλεκτρικοί παλμοί, που ταξιδεύουν στον άξονα κάθε νευρώνα και μέσω των συνάψεων διαδίδονται στους δενδρίτες των νευρώνων. Κάθε νευρώνας συλλέγει όλο το ηλεκτρικό φορτίο που δέχεται από κάθε σύναψη στους δενδρίτες του, σταθμίζοντας το εισερχόμενο φορτίο με το αντίστοιχο συναπτικό βάρος. Έτσι, όσο πιο ισχυρή είναι η συναπτική ζεύξη τόσο πιο πολύ συμμετέχει το συγκεκριμένο φορτίο ο εισόδου στο συνολικό άθροισμα. Αν το άθροισμα αυτό υπερβαίνει κάποιο κατώφλι, ο άξονας του νευρώνα αρχίζει να παράγει ηλεκτρικούς παλμούς με μεγάλη συχνότητα, αν όμως δεν υπερβαίνει το συγκεκριμένο όριο, τότε ο νευρώνας παράγει πολύ αραιά παλμούς σε τυχαίες χρονικές στιγμές (Αδρανής νευρώνας). Τελικά, οι παλμοί που παράγονται ταξιδεύουν κατά μήκος του άξονα και τροφοδοτούν τους άλλους νευρώνες με τους οποίους συνδέεται ο νευρώνας που παρήγαγε τον παλμό [32].

2.2 Το μοντέλο McCulloch-Pitts

Το μοντέλο McCulloch-Pitts αποτελεί το πρώτο μαθηματικό μοντέλο τεχνητού νευρώνα. Προτάθηκε το 1943 από τους Warren McCulloch και Walter Pitts και σχεδιάστηκε για να προσομοιώσει τη λειτουργία του βιολογικού νευρώνα, κάνοντας χρήση λογικών πράξεων. Η κατάσταση του νευρώνα περιγράφεται από ένα δυαδικό αριθμό y .

- $y = 0$, ο νευρώνας είναι αδρανής
- $y = 1$, ο νευρώνας πυροδοτεί παλμούς (Δεν είναι αδρανής)

Οι συνάψεις περιγράφονται από τα συναπτικά βάρη $w_i \in \mathbb{R}$, $i = 1, \dots, n$. Έστω πως $x_1, x_2, \dots, x_n$ οι εισόδοι του νευρώνα, ελέγχουμε εάν το άθροισμα $x_1 w_1 + \dots + x_n w_n$ του φορτίου που δέχεται ο νευρώνας είναι μεγαλύτερο από το κατώφλι θ . Εάν ισχύει τότε ο νευρώνας πυροδοτεί παλμούς. Διαφορετικά ο νευρώνας παραμένει αδρανής. Αυτό είναι ισοδύναμο με το εάν εάν η

ποσότητα

$$u = \sum_{i=1}^n w_i x_i - \theta \quad (2.1)$$


είναι μεγαλύτερη ή μικρότερη από το μηδέν, οπότε η έξοδος του νευρώνα ισούται με

$$y = f(u) = \begin{cases} 1 & \text{εάν } u > 0 \\ 0 & \text{εάν } u \leq 0 \end{cases} \quad (2.2)$$

Η συνάρτηση u καλείτε διέγερση του νευρώνα και η $f(\cdot)$ συνάρτηση ενεργοποίησης. Στο μοντέλο McCulloch-Pitts η συνάρτηση ενεργοποίησης είναι η βηματική συνάρτηση 0/1. Η διέγερση u μπορεί να γραφεί επίσης και με την παρακάτω συνοπτική μορφή.

$$u = \bar{w}^\top \bar{x} - \theta \quad (2.3)$$

Όπου $\bar{w} = [w_1, \dots, w_n]^\top$ είναι το διάνυσμα των συναπτικών βαρών και $\bar{x} = [x_1, \dots, x_n]^\top$ το διάνυσμα εισόδου. Το κατώφλι θ αποτελεί πραγματικό αριθμό όπως και τα $w_1, \dots, w_n$. Κατ'αυτή την έννοια μπορούμε να απλοποιήσουμε την εξίσωση θέτοντας $w_0 = -\theta$, το οποίο θα ονομάζεται πόλωση και θα είναι συνδεδεμένο με μια σταθερή είσοδο $x_0 = 1$ [32].




Σχήμα 2.2.1: Μοντέλο McCulloch και Pitts του νευρώνα

Συνεπώς, η εξίσωση 2.1 παίρνει την ακόλουθη μορφή.

$$u = \sum_{i=0}^n w_i x_i \quad (2.4)$$

2.2.1 Εναλλακτικές συναρτήσεις ενεργοποίησης

Υπάρχουν πολλές διαφορετικές μοντελοποιήσεις του νευρώνα που αποκλίνουν από το μοντέλο McCulloch-Pitts. Η πιο σημαντική διαφορά εντοπίζεται στη μορφή της μη γραμμικής συνάρτησης $f(\cdot)$ που χρησιμοποιείται. Στο 2.2.2 παρουσιάζεται η σχηματική αναπαράσταση της μοντελοποίησης του νευρώνα που περιγράφηκε.



Σχήμα 2.2.2: Σχηματική αναπαράσταση του νευρώνα


Η συνάρτηση ενεργοποίησης μπορεί να πάρει εναλλακτικά μεταξύ τις μορφές που περιγράφονται παρακάτω.

Βηματική συνάρτηση -1/1 (Step Function -1/1)

Η βηματική συνάρτηση -1/1, όπως και η βηματική συνάρτηση 0/1 αποτελούν ειδικές περιπτώσεις μιας οικογένειας συναρτήσεων που ονομάζονται βηματικές συναρτήσεις δύο επιπέδων (Binary Step Functions). Οι συναρτήσεις αυτού του τύπου, παραμένουν ανενεργές για τιμές μικρότερες ή ίσες του κατωφλίου (Στην περίπτωση που δίνεται παρακάτω το κατώφλι είναι ίσο με 0) και ενεργοποιούνται για τιμές μεγαλύτερες από αυτό. Η βηματική συνάρτηση -1/1 με τιμή κατωφλίου ίση με 0 δίνεται από την σχέση

$$y = f(u) = \begin{cases} 1 & \text{εάν } u > 0 \\ -1 & \text{εάν } u \leq 0 \end{cases} \quad (2.5)$$

Το σημαντικότερο μειονέκτημα των συναρτήσεων αυτής της οικογένειας είναι ότι σε όλα τα σημεία τους έχουν είτε μηδενική κλίση είτε δεν είναι διαφορίσιμες (Σημείο κατωφλίου). Αυτό το μειονέκτημα συνιστά σημαντικό εμπόδιο στην εκπαίδευση νευρωνικών δικτύων πολλών στρωμάτων (Κεφάλαιο 2.3.2). Για τον λόγο αυτό, συναρτήσεις της μορφής αυτής χρησιμοποιούνται αποκλειστικά σε νευρωνικά δίκτυα με ένα μόνο στρώμα [33]. Η γραφική μορφή της βηματικής συνάρτησης $-1/1$ δίνεται παρακάτω.



Σχήμα 2.2.3: Γραφική μορφή βηματικής συνάρτησης $-1/1$


Σιγμοειδής συνάρτηση (Sigmoid Function)

Αναφέρεται επίσης ως λογιστική συνάρτηση. Αποτελεί μη γραμμική συνάρτηση, που χρησιμοποιείται συνήθως στα νευρωνικά δίκτυα μιας κατεύθυνσης (Feedforward Neural Networks). Είναι φραγμένη και διαφορίσιμη με θετική παράγωγο για όλα τα σημεία του πεδίου ορισμού της (Γνησίως αύξουσα). Έχει πεδίο ορισμού το $\mathbb{R}$ και σύνολο τιμών το $(0,1)$. Δίνεται από την σχέση

$$f(u) = \frac{1}{1 + e^{-u}} \quad (2.6)$$

Η σιγμοειδής συνάρτηση εμφανίζεται συνήθως στο στρώμα εξόδου των δικτύων βαθιάς μάθησης όταν η έξοδος απαιτείται να είναι υπό μορφή πιθανότητας. Παρά τα πλεονεκτήματα της όπως η ευκολία κατανόησης και η καλή απόδοση της σε δίκτυα μικρού βάθους, παρουσιάζει μερικά σημαντικά μειονεκτήματα. Κάποια από αυτά περιλαμβάνουν την απότομη εξασθένιση των κλίσεων (Gradient) καθώς αυτές μεταφέρονται από τα βαθύτερα προς τα αρχικά στρώματα

κατά την διαδικασία οπισθοδιάδοσης (Backpropagation) (Κεφάλαιο 2.3.2), στον κορεσμό των κλίσεων λόγω των πολύ μικρών τιμών που λαμβάνει η συνάρτηση ενεργοποίησης για μικρές θετικές και μεγάλες αρνητικές τιμές της εισόδου, καθώς και στο πώς δεν είναι κεντραρισμένη στο μηδέν, γεγονός που μπορεί να οδηγήσει τις ανανεώσεις των βαρών να πραγματοποιούνται σε διαφορετικές κατευθύνσεις. Αυτά τα μειονεκτήματα ενδέχεται να προκαλέσουν προβλήματα κατά την διαδικασία της εκπαίδευσης του μοντέλου. Μεταξύ των προβλημάτων αυτών συγκαταλέγονται η αργή σύγκλιση και η αστάθεια εκπαίδευσης. [34]. Η γραφική μορφή της σιγμοειδούς συνάρτησης δίνεται παρακάτω.




Σχήμα 2.2.4: Γραφική μορφή σιγμοειδούς συνάρτησης

Υπερβολική εφαπτομένη (Hyperbolic Tangent)

Για την αντιμετώπιση ορισμένων από τα προβλήματα που εμφανίζονται χρησιμοποιώντας την σιγμοειδή συνάρτηση ως συνάρτηση ενεργοποίησης, προτάθηκε η εναλλακτική χρήση της υπερβολικής εφαπτομένης. Η υπερβολική εφαπτομένη αποτελεί συνάρτηση κεντραρισμένη στο μηδέν, με πεδίο ορισμού το $\mathbb{R}$ και σύνολο τιμών το $(-1,1)$. Αποτελεί προτιμότερη επιλογή σε σχέση με την σιγμοειδή συνάρτηση, καθώς διευκολύνει την εκπαίδευση νευρωνικών δικτύων πολλών στρωμάτων (Κεφάλαιο 2.3) περιορίζοντας φαινόμενα που μπορεί να εμφανιστούν χρησιμοποιώντας την σιγμοειδή συνάρτηση ως συνάρτηση ενεργοποίησης. Ωστόσο, η υπερβολική εφαπτομένη εξακολουθεί να είναι επιρρεπής στο πρόβλημα της εξασθένησης των κλίσεων, το οποίο παραμένει. Το βασικό της πλεονέκτημα αποτελεί πως παράγει έξοδο κεντραρισμένη στο μηδέν, κάτι που συμβάλλει στην διευκόλυνση της διαδικασίας εκπαίδευσης του μοντέλου. Δίνεται από την σχέση

$$f(u) = \tanh(u) = \frac{1 - e^{-u}}{1 + e^{-u}} \quad (2.7)$$

Σημαντικό στοιχείο της αποτελεί πως έχει κλίση ίση με ένα, μόνο όταν η τιμή της εισόδου είναι ίση με μηδέν. Αυτό έχει σαν αποτέλεσμα η συνάρτηση να παράγει "νεκρούς" νευρώνες. Ως "Νεκρός" νευρώνας ορίζεται η κατάσταση κατά την οποία ένας νευρώνας παραμένει ουσιαστικά ανενεργός κατά την διάρκεια της εκπαίδευσης, λόγω των σχεδόν μηδενικών κλίσεων. Μια αποτελεσματική λύση στο πρόβλημα αυτό έδωσε η συνάρτηση ράμπας (ReLU) [34]. Η γραφική μορφή της συνάρτησης υπερβολικής εφαπτομένης δίνεται παρακάτω.



Σχήμα 2.2.5: Γραφική μορφή υπερβολικής εφαπτομένης


Συνάρτηση ράμπας (ReLU)

Η συνάρτηση ράμπας αποτελεί την πιο ευρέως χρησιμοποιημένη συνάρτηση ενεργοποίησης στα μοντέλα βαθιάς μάθησης, παρουσιάζοντας κορυφαία αποτελέσματα. Επιτρέπει γρήγορη εκπαίδευση του μοντέλου και αποτελεί την πιο επιτυχημένη συνάρτηση ενεργοποίησης μέχρι και σήμερα. Έχει παρουσιάσει καλύτερη απόδοση από τη σιγμοειδή συνάρτηση και την συνάρτηση υπερβολικής εφαπτομένης σε μοντέλα βαθιάς μάθησης, ενώ παράλληλα προσφέρει καλύτερη ικανότητα γενίκευσης σε άγνωστα δεδομένα. Έχει πεδίο ορισμού το $\mathbb{R}$ και σύνολο τιμών το $[0, \infty)$. Δίνεται από την σχέση

$$y = f(u) = \begin{cases} u & \text{if } u > 0 \\ 0 & \text{if } u \leq 0 \end{cases} \quad (2.8)$$

Η ReLU χρησιμοποιείται κυρίως στα κρυφά στρώματα βαθιών νευρωνικών δικτύων, ενώ για τα στρώματα εξόδου γίνεται χρήση διαφορετικής συνάρτησης. Το βασικό της πλεονέκτημα αποτελεί πως επιτρέπει πολύ γρήγορους υπολογισμούς λόγω της πολύ μικρής πολυπλοκότητας υπολογισμού της, ενώ παράλληλα εισάγει αραιότητα στο μοντέλο, καθώς για τιμές μικρότερες ή ίσες του μηδενός, η έξοδος του αντίστοιχου νευρώνα μηδενίζεται, απλοποιώντας έτσι τη δομή

του δικτύου. Ωστόσο η συνάρτηση αυτή δεν στερείτε μειονεκτημάτων. Η συνάρτηση ράμπας είναι πιο επιρρεπής από την σιγμοειδή συνάρτηση στην υπερπροσαρμογή (Overfitting). Για την αντιμετώπιση αυτού του προβλήματος συχνά χρησιμοποιείται η τεχνική της απενεργοποίησης νευρώνων (Dropout) (Κεφάλαιο 2.3.3). Κατά την διάρκεια της διαδικασίας εκπαίδευσης ενδέχεται, λόγω μηδενισμού της εξόδου, να προκύψουν αρκετοί "νεκροί" νευρώνες, δηλαδή νευρώνες που τα βάρη τους έχουν σταματήσει να ενημερώνονται και δεν συμμετέχουν στην εκπαίδευση [34]. Η γραφική μορφή της συνάρτησης ράμπας δίνεται παρακάτω.



Σχήμα 2.2.6: Γραφική μορφή συνάρτησης ReLU

Μια πιο σύγχρονη παραλλαγή της συνάρτησης ράμπας αποτελεί η Gaussian Error Linear Unit (GELU). Η αυξημένη πολυπλοκότητα των βαθιών μη γραμμικών μοντέλων τα καθιστά ικανά να προσαρμόζονται υπερβολικά καλά στα δεδομένα, οδηγώντας τα σε υπερπροσαρμογή. Αυτό συχνά απαιτεί από τους σχεδιαστές των μοντέλων να κάνουν χρήση επιπλέον τεχνικών κανονικοποίησης, όπως η εισαγωγή θορύβου και η απενεργοποίηση νευρώνων. Οι τεχνικές αυτές δρούν συμπληρωματικά προς τις συναρτήσεις ενεργοποίησης και μπορούν να βελτιώσουν την ικανότητα γενίκευσης του μοντέλου. Η συνάρτηση GELU έχει σχεδιαστεί για να ενσωματώνει αυτή τη στοχαστική συμπεριφορά πιο φυσικά, προσφέροντας μια πιο πιθανοκρατική ερμηνεία της εξόδου του νευρώνα. Στην πράξη, έχει δείξει ίση ή και καλύτερη απόδοση από την ReLU σε ορισμένες εργασίες της όρασης υπολογιστών, της επεξεργασίας φυσικής γλώσσας και της αναγνώρισης ομιλίας. Η συνάρτηση GELU συνδυάζει χαρακτηριστικά της απενεργοποίησης νευρώνων, της συνάρτησης ράμπας και του zoneout. Το zoneout αποτελεί τεχνική κανονικοποίησης που με στοχαστικό τρόπο, διατηρεί κάποιες εξόδους νευρώνων ίδιες με το προηγούμενο πέρασμα. Η όλη ιδέα υλοποιείται πολλαπλασιάζοντας την είσοδο του νευρώνα με 0 ή 1, όπου η επιλογή πραγματοποιείται στοχαστικά και εξαρτάται από την τιμή της εισόδου. Συγκεκριμένα πολλαπλασιάζουμε την τιμή της εισόδου u με την κατανομή $m \sim \text{Bernoulli}(\Phi(u))$, όπου $\Phi(u) = P(X \leq u)$, $X \sim \mathcal{N}(0, 1)$. Επιλέχθηκε αυτή η κατανομή επειδή οι τιμές των εισόδων των νευρώνων τείνουν να ακολουθούν κανονική κατανομή. Στο πλαίσιο αυτό, όσο ελαττώνεται η τιμή της εισόδου, τόσο πιο πιθανό είναι να μηδενιστεί. Η διαδικασία είναι τυχαία, αλλά εξαρτάται από την ίδια την τιμή της εισόδου. Η τεχνική αυτή ουσιαστικά είτε μηδενίζει την

είσοδο είτε την αφήνει αμετάβλητη. Η συνάρτηση GeLU δίνεται απο την σχέση

$$f(u) = u \cdot P(X \leq u) = u \cdot \Phi(u) = u \cdot \frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{u}{\sqrt{2}}\right) \right]. \quad (2.9)$$

Όπου $X \sim \mathcal{N}(0, 1)$ και $\operatorname{erf}(\cdot)$ η συνάρτηση σφάλματος, η οποία δίνεται απο την σχέση

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt \quad (2.10)$$


Η συνάρτηση GELU προσεγγίζεται μέσω της σχέσης

$$f(u) \approx 0.5u \left(1 + \tanh \left[\sqrt{\frac{2}{\pi}} (u + 0.044715u^3) \right] \right) \quad (2.11)$$

ή μέσω της

$$f(u) \approx u\sigma(1.702u) \quad (2.12)$$

Όπου $\sigma(\cdot)$ η σιγμοειδής συνάρτηση.



Σχήμα 2.2.7: Γραφική μορφή συνάρτησης GeLU


Η προσεγγιστική μορφή της συνάρτησης GELU χρησιμοποιείται σε περίπτωση που ο ταχύτερος υπολογισμός αξίζει το κόστος της ακρίβειας [35]

Γραμμική συνάρτηση (Linear Function)

Η γραμμική ή αλλιώς ταυτοτική (Identity) συνάρτηση έχει πεδίο ορισμού και σύνολο τιμών το $\mathbb{R}$ και δίνεται από την σχέση

$$f(u) = u \quad (2.13)$$

Παρά την απλότητά της, παρουσιάζει σημαντικά μειονεκτήματα. Η χρήση της γραμμικής συνάρτησης ως συνάρτηση ενεργοποίησης περιορίζει το μοντέλο, καθώς λόγω της γραμμικής της μορφής αδυνατεί να εκπαιδευτεί σε πολύπλοκες μη γραμμικές σχέσεις [36]. Παράλληλα, η χρήση οπισθοδιάδοσης (Κεφάλαιο 2.3.2) στην εκπαίδευση του μοντέλου καθίσταται αδύνατη, καθώς η παράγωγος της γραμμικής συνάρτησης είναι σταθερή και δεν σχετίζεται με την τιμή της εισόδου u [37]. Η γραφική μορφή της γραμμικής συνάρτησης απεικονίζεται στο 2.2.8.



Σχήμα 2.2.8: Γραφική μορφή γραμμικής συνάρτησης

Η ειδική περίπτωση τεχνητού δικτύου που αποτελείται από ένα μόνο νευρώνα με συνάρτηση ενεργοποίησης την βηματική συνάρτηση καλείται δίκτυο Perceptron [38]. Το δίκτυο Perceptron είναι το πιο απλό νευρωνικό δίκτυο που μπορεί να σχεδιαστεί.

2.3 Νευρωνικά δίκτυα πολλών στρωμάτων


2.3.1 Το δίκτυο MLP

Στα γραμμικά μοντέλα όπως το δίκτυο Perceptron οι δυνατότητες αναπαράστασης διαχωριστικών επιφανειών είναι περιορισμένες, επειδή το δίκτυο μπορεί να αναπαραστήσει μόνο επίπεδες

επιφάνειες. Με άλλα λόγια το υπερεπίπεδο $u = 0$, χωρίζει τον χώρο $\mathbb{R}^n$ σε δύο μέρη, όπου στο ένα ισχύει $f(u) = 1$ και στο άλλο $f(u) = 0$ (Χρησιμοποιώντας την βηματική συνάρτηση 0/1). Η κατάσταση που προκύπτει μπορεί να οπτικοποιηθεί καλύτερα στις δύο διαστάσεις. Στον χώρο $\mathbb{R}^2$ η εξίσωση $u = w_1x_1 + w_2x_2 + b = 0$ ορίζει μια ευθεία κάθετη στο διάνυσμα των συναπτικών βαρών $\bar{w} = [w_1, w_2]^T$. Αυτή η ευθεία χωρίζει το επίπεδο σε δύο τμήματα.

- Το τμήμα προς την κατεύθυνση του $\bar{w}$ περιέχει τα $\bar{x}$ για τα οποία ισχύει $u > 0$ (και άρα $f(u) = 1$)
- Το τμήμα προς την αντίθετη κατεύθυνση του $\bar{w}$ περιέχει τα σημεία $\bar{x}$ για τα οποία ισχύει $u < 0$ (και άρα $f(u) = 0$)

Η απόσταση της ευθείας από την αρχή των αξόνων εξαρτάται από την τιμή της πόλωσης $w_0 = b$. Η σχηματική μορφή της ευθείας που περιγράφηκε δίνεται στο Σχήμα 2.3.1.




Σχήμα 2.3.1: Ταξινόμηση στον $\mathbb{R}^2$ μέσω δικτύου Perceptron

Ο περιορισμός αυτός αίρεται με τη χρήση περισσότερων νευρώνων. Η χρήση περισσότερων κρυφών νευρώνων, θα μπορούσε να ορίσει περισσότερες διαχωριστικές ευθείες. Ο συνδυασμός των ευθειών αυτών μπορεί να μας δώσει μεγάλη ποικιλία περιοχών που θα μπορούσαμε να διαχωρίσουμε στην έξοδο. Υπάρχουν άπειρα παραδείγματα τέτοιων σχηματισμών, τα οποία μπορούν να απεικονιστούν σε διαφορετικές διαστάσεις.

Σχηματισμοί αυτού του τύπου καλούνται δίκτυα Perceptron πολλών στρώματων (Multi-Layer Perceptron - MLP). Η γενική αρχιτεκτονική ενός δικτύου MLP με L στρώματα δίνεται παρακάτω. Το χαρακτηριστικό των δικτύων αυτών είναι πως οι νευρώνες του στρώματος l τροφοδοτούν αποκλειστικά τους νευρώνες του επόμενου στρώματος $l+1$ και τροφοδοτούνται

αποκλειστικά από τους νευρώνες του προηγούμενου στρώματος $l-1$.



Σχήμα 2.3.2: Γενική σχηματική μορφή δικτύου Perceptron πολλών στρωμάτων

Ένα δίκτυο MLP μπορεί να υλοποιήσει οποιαδήποτε διαχωριστική επιφάνεια σε n διαστάσεις, σε αντίθεση με το απλό δίκτυο Perceptron που μπορεί να υλοποιήσει μόνο ευθείες επιφάνειες [39]. Πράγματι, αν θέλουμε να προσεγγίσουμε οποιαδήποτε διαχωριστική επιφάνεια στον χώρο $\mathbb{R}^n$ χρησιμοποιώντας ένα MLP, αρκεί να βρούμε μια συνάρτηση $g(x)$ τέτοια ώστε για κάποιο κατώφλι θ , ο χώρος $\mathbb{R}^n$ χωρίζεται σε δύο τμήματα. Στο ένα τμήμα θα ισχύει $g(x) > \theta$, ενώ στο άλλο $g(x) < \theta$.

Ανάκληση

Αποτελεί την διαδικασία υπολογισμού των τιμών όλων των νευρώνων του δικτύου με δεδομένες τις τιμές των εισόδων. Ορίζουμε αρχικά ως

- L το πλήθος των στρωμάτων του δικτύου εκτός του στρώματος εισόδου.
- $N(l)$ είναι το πλήθος των νευρώνων του στρώματος l , $l = 0, \dots, L$.
- $\alpha_i(l)$ είναι οι ενεργοποιήσεις των νευρώνων του στρώματος l .
- $w_{ij}(l)$ είναι το συναπτικό βάρος που συνδέει τον νευρώνα $\alpha_j(l-1)$ του στρώματος $l-1$ με τον νευρώνα $\alpha_i(l)$ του στρώματος l .
- $w_{i0}(l)$ είναι η πόλωση του νευρώνα $\alpha_i(l)$ του στρώματος l .

- $x_i = \alpha_i(0)$ είναι οι είσοδοι του δικτύου.
- $y_i = \alpha_i(L)$ είναι οι έξοδοι του δικτύου.

Οι ενεργοποιήσεις των νευρώνων για κάθε στρώμα δίνονται από την σχέση

$$a_i(l) = f \left(\sum_{j=1}^{N(l-1)} w_{ij}(l) a_j(l-1) + w_{i0}(l) \right) \quad (2.14)$$

2.3.2 Εκπαίδευση νευρωνικών δικτύων

Η εκπαίδευση ενός δικτύου πολλών στρωμάτων αποτελεί την διαδικασία καθορισμού των συναπτικών βαρών του έτσι ώστε να ικανοποιείται κάποιο κριτήριο καταλληλότητας. Αυτός είναι και ο λόγος της εκπαίδευσης σε οποιοδήποτε νευρωνικό δίκτυο. Κυριότερος εκπρόσωπος των αλγορίθμων εκπαίδευσης MLP αποτελεί ο αλγόριθμος οπισθοδιάδοσης. Ο αλγόριθμος οπισθοδιάδοσης προτάθηκε από τον Paul Werbos στη δεκαετία του 1970 στα πλαίσια της ανάλυσης μοντέλων οικονομικής και πολιτικής πρόβλεψης. Στη δεκαετία του 1980 έγινε αντιληπτό πως η μέθοδος μπορούσε να μεταφερθεί αυτούσια στην εκπαίδευση νευρωνικών δικτύων πολλών στρωμάτων και έκτοτε έγινε η πιο γνωστή και η πιο διαδεδομένη μέθοδος για τον σκοπό αυτό.

Βασικό χαρακτηριστικό της μεθόδου αποτελεί η ύπαρξη στόχων. Συνεπώς, το μοντέλο ανήκει στην κατηγορία των δικτύων που εκπαιδεύονται με επίβλεψη. Έστω δίκτυο με L στρώματα, n εισόδους και m εξόδους. Ορίζουμε ως

- $\mathbf{x}^{(p)} = [x_1^{(p)}, \dots, x_n^{(p)}]^T$ το p -οστό διάνυσμα εισόδου
- $\mathbf{y}^{(p)} = [y_1^{(p)}, \dots, y_m^{(p)}]^T$ το p -οστό διάνυσμα εξόδου
- $\mathbf{t}^{(p)} = [t_1^{(p)}, \dots, t_m^{(p)}]^T$ το p -οστό διάνυσμα στόχων

Τα δεδομένα που απαιτούνται για να εκπαιδευτεί το δίκτυο είναι τα ζεύγη διανυσμάτων $\{\mathbf{x}^{(i)}, \mathbf{t}^{(i)}\}$, $i = 1, \dots, P$. Θα ήταν ιδανικό να πετυχέναμε τάνυση εξόδων και στόχων για κάθε πρότυπο εισόδου, ωστόσο αυτό μπορεί να μην είναι απολύτως εφικτό. Για αυτό τον λόγο επιζητούμε τη βέλτιστη προσέγγιση της επιθυμητής κατάστασης χρησιμοποιώντας κάποιο κριτήριο κόστους. Το κριτήριο κόστους σύμφωνα με το [40] ορίζεται ως ακολούθως.

Στα προβλήματα μηχανικής μάθησης, στόχος είναι η εκμάθηση μιας συνάρτησης $f : \Phi \rightarrow \mathcal{Y}$. Η συνάρτηση f προσεγγίζεται από ένα παραμετροποιημένο μοντέλο f_Θ , όπου Θ είναι το

σύνολο των παραμέτρων του μοντέλου. Η γενική μορφή της συνάρτησης κόστους είναι

$$L(f_{\Theta}) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(x_i), y_i) \quad (2.15)$$

Όπου $\{(x_i, y_i)\}_{i=1}^N$ το σύνολο δεδομένων εκπαίδευσης και $\mathcal{L}(f_{\Theta}(x_i), y_i)$ συνάρτηση, η οποία υπολογίζει την απόκλιση της πρόβλεψης $f_{\Theta}(x_i)$ από την πραγματική τιμή y_i . Η διαδικασία βελτιστοποίησης στοχεύει στην ελαχιστοποίηση του κόστους μεταβάλλοντας το Θ . Μαθηματικά, αυτό διατυπώνεται ως

$$\min_{\Theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(x_i), y_i) \quad (2.16)$$

Με την εισαγωγή ρυθμιστικού όρου (Regularization Term), το πρόβλημα μετασχηματίζεται σε

$$\min_{\Theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(x_i), y_i) + R(\Theta) \quad (2.17)$$

Η συνάρτηση κόστους, όπως και ο ρυθμιστικός όρος έχουν σύνολο τιμών το $\mathbb{R}$. Παρακάτω παρουσιάζονται οι σημαντικότερες συναρτήσεις κόστους για τους σκοπούς τις παρούσας εργασίας.

Συνάρτηση απώλειας διασταυρωμένης εντροπίας (Cross-Entropy Loss Function)

Η συνάρτηση απώλειας διασταυρωμένης εντροπίας αποτελεί συνάρτηση κόστους η οποία χρησιμοποιείται εκτενώς σε προβλήματα ταξινόμησης, ιδιαίτερα σε νευρωνικά δίκτυα που η έξοδος αποτελεί κατανομή πιθανοτήτων πάνω στις διακριτές κλάσεις του προβλήματος. Η μαθηματική της μορφή δίνεται παρακάτω.

$$\mathcal{L}_{CE} = - \sum_{k=1}^K y_k \log(p_k) \quad (2.18)$$

Όπου K ο αριθμός των κλάσεων του προβλήματος ταξινόμησης, $p = (p_1, \dots, p_K)$ η προβλεπόμενη κατανομή πιθανοτήτων και $y = (y_1, \dots, y_K)$ το διάνυσμα στόχος. Το διάνυσμα y είναι συνήθως one-hot κωδικοποιημένο, δηλαδή όλα του τα στοιχεία είναι μηδενικά, εκτός από ένα που είναι ίσο με 1. Το στοιχείο αυτό υποδεικνύει τη σωστή κλάση.

Για την απόδοση πιθανοτικής μορφής στις εξόδους, στο στρώμα εξόδου εφαρμόζεται η συνάρτηση Softmax. Η μαθηματική μορφή της συνάρτησης ενεργοποίησης Softmax είναι

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \quad (2.19)$$

Όπου z_k η είσοδος της συνάρτησης που αντιστοιχεί στην κλάση k , και K το πλήθος των κλάσεων του προβλήματος ταξινόμησης [41].

Συνάρτηση απώλειας ζαριών (Dice Loss Function)

Η συνάρτηση απώλειας ζαριών αποτελεί μια ευρέως χρησιμοποιημένη επιλογή σε προβλήματα κατάτμησης εικόνας, ιδίως όταν παρατηρείται έντονη ανισοροπία μεταξύ του πλήθους των εικονοστοιχείων των περιοχών της μάσκας που αντιστοιχούν στο "αντικείμενο" ενδιαφέροντος και των υπόλοιπων περιοχών. Με απλά λόγια αποτελεί καλή επιλογή όταν ζητούμενο είναι η ανίχνευση μικρών "αντικειμένων" στην εικόνα. Βασίζεται στον συντελεστή ζαριών (Dice Coefficient), ο οποίος ποσοτικοποιεί το μέγεθος της επικάλυψης του "αντικειμένου" ενδιαφέροντος στην μάσκα πρόβλεψης και στην μάσκα στόχου. Η μαθηματική της μορφή δίνεται παρακάτω.

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i f_{\theta}(\mathbf{x}_i) y_i}{\sum_i f_{\theta}(\mathbf{x}_i) + \sum_i y_i}, \quad (2.20)$$

Όπου $f_{\theta}(\mathbf{x}_i)$ η προβλεπόμενη πιθανότητα το εικονοστοιχείο i να ανήκει στο "αντικείμενο" ενδιαφέροντος και y_i η αντίστοιχη πραγματική τιμή.

Η συνάρτηση απώλειας ζαριών είναι συνεχής και διαφορίσιμη αλλά όχι κυρτή. Χρησιμοποιείται συχνά στην ιατρική σε εφαρμογές κατάτμησης εικόνας, όπου είναι κρίσιμο να εκτιμηθεί με ακρίβεια ο βαθμός επικάλυψης μεταξύ της προβλεπόμενης μάσκας και της μάσκας στόχου [40].

Βελτιστοποίηση (Optimization)

Η συνάρτηση κόστους επιτρέπει την αξιολόγηση της ποιότητας των εκτιμήσεων ενός μοντέλου για οποιοδήποτε σύνολο παραμέτρων. Ο στόχος της διαδικασίας βελτιστοποίησης αποτελεί η ελαχιστοποίηση της συνάρτησης κόστους μέσω της προσαρμογής των παραμέτρων του μοντέλου. Παρακάτω παρουσιάζονται ορισμένες από τις σημαντικότερες μεθόδους βελτιστοποίησης για τους σκοπούς της παρούσας εργασίας.

Στοχαστική κατάβαση δυναμικού (Stochastic Gradient Descent)

Σε αυτή την μέθοδο τα δεδομένα εκπαίδευσης χωρίζονται σε παρτίδες (Batches) (Κεφάλαιο 2.3.3), όπου κάθε μια από αυτές περιλαμβάνει B πρότυπα, συνοδευόμενα από τους αντίστοιχούς τους στόχους. Σε κάθε εποχή εκπαίδευσης γίνεται χρήση όλων των παρτίδων από ακριβώς μια φορά. Η διόρθωση των παραμέτρων του μοντέλου πραγματοποιείται αφού παρουσιαστούν όλα τα πρότυπα κάθε παρτίδας. Έστω $w_{ij}^{(k)}$ το βάρος που αντιστοιχεί στην σύνδεση μεταξύ του νευρώνα j και i κατά την k -οστή επανάληψη, J η συνάρτηση κόστους και β ο ρυθμός μάθησης (Learning Rate), ο οποίος αποτελεί υπερπαραμέτρο της μεθόδου. Η μαθηματική σχέση που εκφράζει την μέθοδο στοχαστικής κατάβασης δυναμικού δίνεται παρακάτω.

$$w_{ij}^{(k+1)} = w_{ij}^{(k)} - \beta \frac{\partial J}{\partial w_{ij}} \quad (2.21)$$

Adaptive Moment Estimation with decoupled Weight decay - ADAMW

Η μέθοδος ADAMW [42] αποτελεί βελτίωση της ADAM [43]. Η βελτιωμένη αυτή μορφή οδηγεί σε καλύτερη γενίκευση και πιο αξιόπιστα αποτελέσματα σε διάφορες εφαρμογές μηχανικής μάθησης. Η κύρια διαφοροποίηση έγκειται στην εισαγωγή ενός διαφορετικού τρόπου ενσωμάτωσης της αποδυνάμωσης βαρών (Weight Decay), αποσυνδέοντάς την από την συνάρτηση κόστους. Στην κλασική ADAM η αποδυνάμωση εφαρμόζεται προαιρετικά στη συνάρτηση κόστους μέσω της ρύθμισης $L2$, στην ADAMW εφαρμόζεται ως ξεχωριστό βήμα στο τέλος της ενημέρωσης των παραμέτρων. Η διαδικασία ενημέρωσης των παραμέτρων πραγματοποιείται μέσω των σταδίων υπολογισμού που περιγράφονται στην συνέχεια.

Στο πρώτο στάδιο, η κλίση της συνάρτησης κόστους J προκύπτει από τη σχέση

$$g_k = \nabla J_k(w_{k-1}) \quad (2.22)$$

Όπου w οι παραμέτροι του μοντέλου.

Στη συνέχεια υπολογίζονται οι εκθετικά κινητοί μέσοι όροι των παραγώγων, m_k και u_k όπως και οι διορθώσεις μεροληψίας τους, $\hat{m}_k$ και $\hat{u}_k$ αντίστοιχα. Οι τιμές β_1 και β_2 αποτελούν υπερ-παραμέτρους της μεθόδου.

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k, \quad \hat{m}_k = \frac{m_k}{1 - \beta_1^k} \quad (2.23)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2, \quad \hat{v}_k = \frac{v_k}{1 - \beta_2^k} \quad (2.24)$$

Τέλος, εφαρμόζεται η παρακάτω σχέση για την ενημέρωση των παραμέτρων.

$$w_k = w_{k-1} - \beta \left(\frac{\alpha \hat{m}_k}{\sqrt{\hat{v}_k} + \epsilon} + \lambda w_{k-1} \right) \quad (2.25)$$

Η μοναδική διαφορά που έχει η μέθοδος ADAM με την ADAMW εντοπίζεται στην μορφή της παραπάνω σχέσης, με τον όρο λw_{k-1} να μην εμφανίζεται.

Οπισθοδιάδοση (Backpropagation)

Στα νευρωνικά δίκτυα με πολλές παραμέτρους, η σχέση μεταξύ της συνάρτησης κόστους και των παραμέτρων του μοντέλου είναι δύσκολο να προσδιοριστεί. Λύση στο πρόβλημα αυτό δίνει ο αλγόριθμος οπισθοδιάδοσης [44], ο οποίος παρέχει ένα αποδοτικό τρόπο για τον υπολογισμό των μερικών παραγώγων της συνάρτησης κόστους ως προς τις παραμέτρους του μοντέλου κάθε στρώματος. Οι εν λόγω παραγωγοί αποτελούν απαραίτητο στοιχείο της διαδικασίας εκπαίδευσης του μοντέλου και χρησιμοποιούνται στις ανανεώσεις των παραμέτρων του μοντέλου μέσω της διαδικασίας βελτιστοποίησης [45]. Η μαθηματική μορφή του αλγορίθμου διατυπώνεται ως

ακολουθώς.

Αρχικά, ορίζεται η συνολική συνάρτηση κόστους της παρτίδας ως το άθροισμα των επιμέρους απωλειών κάθε δείγματος της. Η μαθηματική σχέση που την εκφράζει δίνεται από την εξίσωση

$$J(w) = \sum_{i=1}^m L_i(w) \quad (2.26)$$

Όπου $L_i(w)$ η επιμέρους απώλεια του δείγματος i και m το πλήθος των δειγμάτων της παρτίδας.

Για την ευκολότερη περιγραφή της διαδικασίας οπισθοδιάδοσης, η περιγραφή της μεθόδου θα πραγματοποιηθεί για την ειδική περίπτωση που η συνάρτηση κόστους είναι το μέσο τετραγωνικό σφάλμα (Mean Square Error). Το μέσο τετραγωνικό σφάλμα δίνεται από την σχέση

$$L_i = \frac{1}{2} \sum_k (\hat{y}_{ik} - y_{ik})^2 \quad (2.27)$$

Όπου $\hat{y}_{ik}$ συμβολίζει την έξοδο του νευρώνα k για το δείγμα i της παρτίδας, ενώ y_{ik} τον αντίστοιχο στόχο.

Έστω a_j η είσοδος του νευρώνα j και z_j η αντίστοιχη έξοδος. Ο υπολογισμός τους γίνεται μέσω των σχέσεων που δίνονται παρακάτω.

$$a_j = \sum_i w_{ji} z_i \quad (2.28)$$

$$z_j = h(a_j) \quad (2.29)$$

Όπου h η συνάρτηση ενεργοποίησης του νευρώνα και w_{ij} το συναπτικό από τον νευρώνα j στον νευρώνα i .

Μέσω του κανόνα αλυσίδας και των σχέσεων (2.28) και (2.29) υπολογίζεται η παράγωγος του

L_i ως προς το w_{ij} .

$$\frac{\partial L_i}{\partial w_{ij}} = \frac{\partial L_i}{\partial a_j} \cdot \frac{\partial a_j}{\partial w_{ij}} \quad (2.30)$$

Η μερική παράγωγος της (2.28) ως προς το w_{ij} δίνεται απο την σχέση

$$\frac{\partial a_j}{\partial w_{ij}} = z_i \quad (2.31)$$

Στην συνέχεια, ορίζεται η

$$\delta_j = \frac{\partial L_i}{\partial a_j} \quad (2.32)$$

που αποτελεί το σφάλμα του νευρώνα j . Μέσω του κανόνα αλυσίδας το σφάλμα για κάθε νευρώνα πλύν των νευρώνων του στρώματος εξόδου υπολογίζεται μέσω της παρακάτω σχέσης.

$$\delta_j = \frac{\partial L_i}{\partial a_j} = \sum_k \frac{\partial L_i}{\partial a_k} \cdot \frac{\partial a_k}{\partial a_j} = h'(a_j) \sum_k w_{kj} \delta_k \quad (2.33)$$

Για να είναι χρήσιμη η παραπάνω σχέση απαιτείται η γνώση των τιμών των σφαλμάτων κάθε νευρώνα εξόδου. Ο τρόπος υπολογισμού των τιμών αυτών καθορίζεται από την συνάρτηση κόστους που εφαρμόζεται. Ενδεικτικά, εάν η συνάρτηση κόστους του μοντέλου είναι το μέσο τετραγωνικό σφάλμα, τότε οι σχέσεις υπολογισμού των σφαλμάτων των νευρώνων εξόδου έχουν την εξής μορφή.

$$\delta_k = \hat{y}_k - y_k \quad (2.34)$$

Όπου $\hat{y}_k$ δηλώνει την έξοδο του νευρώνα k , ενώ y_k τον αντίστοιχο στόχο.

Τα βήματα του αλγορίθμου οπισθοδιάδοσης μπορούν να συνοψιστούν όπως παρακάτω:

1. Δίνεται είσοδος στο μοντέλο και μέσω των σχέσεων (2.28) και (2.29) υπολογίζονται οι τιμές των εξόδων των νευρώνων.
2. Υπολογίζονται οι τιμές των σφαλμάτων δ_k κάθε νευρώνα εξόδου.
3. Μέσω της σχέσης (2.33) υπολογίζονται οι τιμές των σφαλμάτων όλων των υπόλοιπων νευρώνων.
4. Μέσω της σχέσης $\frac{\partial L_i}{\partial w_{ij}} = \delta_j z_i$ υπολογίζονται όλες οι απαραίτητες παραγώγοι.

Η παράγωγος της συνολικής συνάρτησης κόστους J υπολογίζεται επαναλαμβάνοντας τα παραπάνω βήματα για κάθε δείγμα της παρτίδας και στη συνέχεια αθροίζοντας.

$$\frac{\partial J}{\partial w_{ij}} = \sum_m \frac{\partial L_m}{\partial w_{ij}} \quad (2.35)$$

2.3.3 Ρύθμιση (Regularization)

Ως ρύθμιση [46] ορίζεται οποιαδήποτε πρόσθετη τεχνική που εφαρμόζεται με σκοπό την βελτίωση της ικανότητας γενίκευσης του μοντέλου, δηλαδή την παραγωγή πιο αξιόπιστων προβλέψεων σε άγνωστα δεδομένα. Υπάρχει πλήθος τεχνικών για την εξυπηρέτηση αυτού του σκοπού, οι οποίες δύνανται να ταξινομηθούν ανάλογα με το εάν επιρεάζουν τα δεδομένα εκπαίδευσης, την αρχιτεκτονική του δικτύου, την συνάρτηση κόστους, τον ρυθμιστικό όρο ή την διαδικασία βελτιστοποίησης. Για τις ανάγκες της παρούσας εργασίας παρουσιάζονται μόνο οι σημαντικότερες τεχνικές ρύθμισης για αυτή.

Ρύθμιση L1 (L1 Regularization)

Η ρύθμιση L1 [47] αποτελεί τεχνική η οποία χρησιμοποιείται για την αποτροπή υπερπροσαρμογής και την επίτευξη αραίωσης του μοντέλου. Συγκεκριμένα, ένας όρος ποινής προστίθεται στην συνάρτηση κόστους, μέσω του ρυθμιστικού όρου, ο οποίος είναι ανάλογος με το άθροισμα των απόλυτων τιμών των βαρών και έχει ως σκοπό να τιμωρήσει τα μεγάλα βάρη. Η ρύθμιση L1 ευνοεί την ανάπτυξη μοντέλων στα οποία πολλές παράμετροι μηδενίζονται, οδηγώντας σε "αραιότερα" μοντέλα. Η μαθηματική της μορφή δίνεται παρακάτω.

$$R(w) = \frac{\lambda}{2} \|w\|_1 = \frac{\lambda}{2} \sum_i |w_i| \quad (2.36)$$

Όπου λ υπερπαράμετρος που καθορίζει την βαρύτητα της ποινής, w το διάνυσμα των παραμέτρων (βαρών) του μοντέλου και $\|\cdot\|_1$ η νόρμα ℓ_1 .

Ρύθμιση L2 (L2 Regularization)

Η ρύθμιση L2 [48] αποτελεί τεχνική που χρησιμοποιείται για την αποτροπή υπερπροσαρμογής κατά την διάρκεια της εκπαίδευσης ενός νευρωνικού δικτύου. Η βασική ιδέα αποτελεί η προσθήκη ενός όρου ποινής στην συνάρτηση κόστους μέσω του ρυθμιστικού όρου, ο οποίος τιμωρεί τα μεγάλα βάρη. Αυτό έχει ως αποτέλεσμα την κατασκευή απλούστερων μοντέλων με βελτιωμένες ικανότητες γενίκευσης σε νέα, άγνωστα δεδομένα. Η μαθηματική της μορφή δίνεται παρακάτω.

$$R(w) = \frac{\lambda}{2} \|w\|_2^2 = \frac{\lambda}{2} \sum_i w_i^2 \quad (2.37)$$

Όπου λ υπερπαράμετρος που καθορίζει την βαρύτητα της ποινής, w το διάνυσμα των παραμέτρων (βαρών) του μοντέλου και $\|\cdot\|_2^2$ η Ευκλείδεια νόρμα.

Απόρριψη (Dropout)

Παρά την υψηλή εκφραστικότητα των βαθιών νευρωνικών δικτύων με πολλές παραμέτρους, εξακολουθούν να είναι επιρρεπή σε προβλήματα όπως η υπερπροσαρμογή και η υψηλή υπολογιστική πολυπλοκότητα. Η τεχνική της απόρριψης συνιστά μια αποτελεσματική λύση για την αντιμετώπιση των παραπάνω προβλημάτων. Η κεντρική ιδέα αποτελεί η τυχαία απενεργοποίηση ορισμένων νευρώνων του μοντέλου, μαζί με τις συνδέσεις τους, κατά τη διάρκεια της εκπαίδευσης. Αυτό συνιστά στην αποτροπή της υπερβολικής εξάρτησης των νευρώνων μεταξύ τους, ενισχύοντας έτσι την ικανότητα γενίκευσης του μοντέλου σε νέα δεδομένα.


Κατά την διαδικασία εκπαίδευσης του μοντέλου, η τεχνική ισοδυναμεί με δειγματοληψία από ένα νέο, τυχαία "αραιωμένο" δίκτυο σε κάθε βήμα, καθώς κάθε φορά επιλέγεται διαφορετικό υποσύνολο ενεργών νευρώνων. Ο συνολικός αριθμός των πιθανών "αραιωμένων" δικτύων είναι εκθετικός σε σχέση με το πλήθος των νευρώνων. Η απόρριψη έχει αποδειχθεί εξαιρετικά αποτελεσματική στη μείωση της υπερπροσαρμογής και συχνά υπερτερεί έναντι άλλων μεθόδων κανονικοποίησης. Η εκπαίδευση του μοντέλου πραγματοποιείται κανονικά με χρήση οπισθοδιάδοσης, κατά την οποία σε κάθε επανάληψη μόνο οι νευρώνες που δεν έχουν απενεργοποιηθεί συμμετέχουν στην ενημέρωση των παραμέτρων.

Η μαθηματική διατύπωση της διαδικασίας προώθησης νευρωνικού δικτύου με απόρριψη παρουσιάζεται παρακάτω.

Έστω νευρωνικό δίκτυο με L κρυφά στρώματα και $l \in \{1, \dots, L\}$ οι αντίστοιχοι δείκτες. Έστω $y^{(l)}$ το διάνυσμα των εξόδων του επιπέδου l (Το $y^{(0)}$ είναι η είσοδος του δικτύου). Τα $W^{(l)}$ και $b^{(l)}$ αποτελούν τα βάρη και τις προκαταλήψεις του επιπέδου l . Για $f(\cdot)$ συνάρτηση ενεργοποίησης, p υπερπαραμέτρο και $\mathbf{r}_j^{(l)} \sim \text{Bernoulli}(p)$, η διαδικασία προώθησης κατά την εκπαίδευση του δικτύου έχει την ακόλουθη μορφή

$$y_i^{(l+1)} = f\left(\mathbf{w}_i^{(l+1)} (\mathbf{r}^{(l)} * \mathbf{y}^{(l)}) + b_i^{(l+1)}\right) \quad (2.38)$$

Κατά την φάση πρόβλεψης σε νευρωνικό δίκτυο με απόρριψη, μια θεωρητικά ακριβής προσέγγιση αποτελεί ο υπολογισμός του μέσου όρου των προβλέψεων όλων των πιθανών "αραιωμένων" δικτύων που θα μπορούσαν να προκύψουν. Ωστόσο, κάτι τέτοιο είναι πρακτικά αδύνατο, λόγω του τεράστιου υπολογιστικού κόστους που απαιτείται. Αντί αυτού, χρησιμοποιείται μια απλή και αποδοτική προσέγγιση κατά την οποία αξιοποιείται ένα μόνο πλήρες δίκτυο και συγκεκριμένα το δίκτυο που προκύπτει με το τέλος της εκπαιδευτικής διαδικασίας, με τις παραμέτρους του να έχουν κατάλληλα τροποποιηθεί μέσω μιας ντετερμινιστικής διαδικασίας. Συγκεκριμένα, εάν κατά την διαδικασία εκπαίδευσης κάθε νευρώνας διατηρείται με πιθανότητα p , τότε κατά την πρόβλεψη τα εξερχόμενα βάρη του κλιμακώνονται αναλόγως με τον παράγοντα αυτό. Με αυτό τον τρόπο διασφαλίζεται πως η αναμενόμενη έξοδος του δικτύου κατά την εκπαίδευση ισούται με την αντίστοιχη έξοδο του δικτύου κατά την πρόβλεψη. Ακολουθεί η σχηματική απεικόνιση της τεχνικής απόρριψης που περιγράφηκε παραπάνω, περιορισμένη στο επίπεδο ενός μεμονωμένου νευρώνα [49].



Σχήμα 2.3.3: Απεικόνιση της τεχνικής της απόρριψης: (a) Κατά την εκπαίδευση, κάθε μονάδα διατηρείται με πιθανότητα p . (b) Κατά τη δοκιμή, όλες οι μονάδες είναι ενεργές και τα βάρη κλιμακώνονται κατά p .

Μέγεθος Παρτίδας (Batch Size)

Το μέγεθος παρτίδας αποτελεί υπερπαραμέτρο που καθορίζει τον αριθμό των δειγμάτων που επεξεργάζεται το μοντέλο κατά την εκπαίδευση προτού πραγματοποιηθεί η ενημέρωση των παραμέτρων του. Το σύνολο δεδομένων εκπαίδευσης μπορεί να διαιρεθεί σε μια ή περισσότερες παρτίδες. Διακρίνονται συνολικά τρεις βασικές τεχνικές επιλογής του μεγέθους παρτίδας, οι οποίες παρουσιάζονται στη συνέχεια.

- Όταν το μέγεθος παρτίδας ισούται με το πλήθος των στοιχείων του συνόλου δεδομένων, τότε χρησιμοποιείται κατάβαση κλίσης όλου του συνόλου (Batch Gradient Descent)
- Όταν το μέγεθος παρτίδας ισούται με 1, τότε χρησιμοποιείται στοχαστική κατάβαση κλίσης (Stochastic Gradient Descent)
- Όταν δεν ισχύει κανένα από τα παραπάνω, χρησιμοποιείται κατάβαση κλίσης μικρών παρτίδων (Mini-Batch Gradient Descent)


Στην κατάβαση κλίσης μικρών παρτίδων τα πιο συνηθισμένα μεγέθη παρτίδων είναι 32, 64 και 128. Σε περίπτωση που το πλήθος των δειγμάτων του συνόλου δεδομένων εκπαίδευσης δεν διαιρείται ακριβώς με το μέγεθος παρτίδας, η τελευταία παρτίδα περιλαμβάνει μικρότερο αριθμό δειγμάτων [50].

Η επιλογή της τιμής της υπερπαραμέτρου αποτελεί κρίσιμο παράγοντα που μπορεί να επηρεάσει τόσο την αποδοτικότητα του μοντέλου όσο και την σταθερότητα της εκπαίδευσης. Από την μια πλευρά, μικρά μεγέθη παρτίδων ευνοούν την ικανότητα γενίκευσης του μοντέλου σε άγνωστα δεδομένα, ωστόσο όμως παρουσιάζουν προβλήματα σταθερότητας και είναι λιγότερο αποδοτικά από άποψη υπολογιστικού κόστους. Από την άλλη, μεγαλύτερα μεγέθη παρτίδων μειώνουν το υπολογιστικό κόστος εκπαίδευσης του μοντέλου αλλά ενδέχεται να οδηγήσουν σε χειρότερη ικανότητα γενίκευσης σε νέα δεδομένα [51].

2.4 Συνελικτικά νευρωνικά δίκτυα

Τα συνελικτικά νευρωνικά δίκτυα (Convolutional Neural Networks - CNNs) αποτελούν δίκτυα πολλών στρωμάτων κατάλληλα για λειτουργίες αναγνώρισης εικόνας. Προτάθηκαν αρχικά από τον LeCun την δεκαετία του 1980 και αποτελούνται από εναλλασσόμενα στρώματα συνέλιξης και υποδειγματοληψίας. Η αλληλουχία αυτή υλοποιεί ουσιαστικά ένα μετασχηματισμό της εικόνας σε χάρτη χαρακτηριστικών (Feature Map). Μετά το τελευταίο στρώμα συνέλιξης ή υποδειγματοληψίας ακολουθούν ένα ή περισσότερα πλήρως συνδεδεμένα στρώματα τα οποία λειτουργούν ως ένα υποδίκτυο ταξινομητή. Η αλληλουχία των στρωμάτων συνέλιξης και

υποδειγματοληψίας υλοποιεί ουσιαστικά ένα μετασχηματισμό της εικόνας εισόδου σε χάρτη χαρακτηριστικών. Κατόπιν, ο χάρτης αυτός εισάγεται ως είσοδος σε ένα ταξινομητή. Η αρχιτεκτονική ενός τυπικού συνελκτικού νευρωνικού δικτύου δίνεται παρακάτω.



Σχήμα 2.4.1: Η αρχιτεκτονική ενός τυπικού συνελκτικού νευρωνικού δικτύου


Η έξοδος ενός συνελκτικού στρώματος ή ενός στρώματος υποδειγματοληψίας αποτελεί μια σειρά από χάρτες χαρακτηριστικών. Κάθε χάρτης χαρακτηριστικών αποτελεί ένα διδιάστατο πλέγμα από νευρώνες όπου κάθε ένας διεγείρεται από μια μικρή περιοχή του προηγούμενου στρώματος. Αυτή η περιοχή καλείται τοπικό υποδεκτικό πεδίο του νευρώνα. Τα συναπτικά βάρη που συνδέουν ένα νευρώνα με τους νευρώνες του τοπικού του πεδίου είναι συλλογικά γνωστά ως μάσκα. Όλοι οι νευρώνες που βρίσκονται στον ίδιο χάρτη χαρακτηριστικών έχουν την ίδια μάσκα, οπότε προκύπτει επανάληψη βαρών. Η εκπαίδευση των παραμέτρων ενός συνελκτικού δικτύου πραγματοποιείται με την κλασική μέθοδο της οπισθοδιάδοσης. Όσον αφορά την δομή του δικτύου, οι νευρώνες των στρωμάτων συνέλιξης και υποδειγματοληψίας δεν συνδέονται απαραίτητα με όλους τους νευρώνες του προηγούμενου στρώματος. Αυτό έχει δύο βασικές συνέπειες.

- Το πλήθος των παραμέτρων του μοντέλου μειώνεται και η εκπαίδευση γίνεται ταχύτερα.
- Η επίδοση του μοντέλου βελτιώνεται, καθώς καθίσταται δυνατή η αναγνώριση χαρακτηριστικών ανεξάρτητα από τη θέση τους στην εικόνα.

Κάθε συνελκτικό στρώμα αποτελείται από ένα σύνολο χαρτών χαρακτηριστικών, έστω C . Κάθε χάρτης χαρακτηριστικών αποτελεί ένα διδιάστατο πλέγμα νευρώνων διαστάσεων $N \times N$. Επομένως, κάθε συνελκτικό στρώμα αποτελείται από συνολικά $N \times N \times C$ νευρώνες. Η έξοδος του νευρώνα που αντιστοιχεί στην θέση (i, j) του k -οστού χάρτη χαρακτηριστικών υπολογίζεται μέσω της παρακάτω σχέσης.


$$y_{ij}^k = f \left(\sum_{l=1}^{C'} \sum_{\alpha=1}^m \sum_{\beta=1}^m w_{\alpha,\beta,l}^k x_{i-\alpha,j-\beta}^l + b^k \right) \quad (2.39)$$

Υπολογίζει το άθροισμα των τιμών $x_{i-\alpha,j-\beta}^l$ των νευρώνων για όλους τους χάρτες χαρακτηριστικών $l = 1, \dots, C'$ του προηγούμενου στρώματος.



Σχήμα 2.4.2: Αναπαράσταση υπολογισμού νευρώνα y_{ij}^k του k -οστού χάρτη χαρακτηριστικών και στρώματος L

Ο τρισδιάστατος πίνακας $W^k = [w_{\alpha,\beta,l}^k]$ καλείται μάσκα ή φίλτρο του k -οστού χάρτη χαρακτηριστικών. Η $f(\cdot)$ αποτελεί την συνάρτηση ενεργοποίησης και η παράμετρος b^k την πόλωση του νευρώνα. Η πράξη εντός της παρένθεσης στο δεξιό μέλος της εξίσωσης (2.39) είναι γνωστή ως συνέλιξη. Η συνέλιξη λειτουργεί ως φίλτρο το οποίο σαρώνει όλη την εικόνα εισόδου και δίνει την μέγιστη απόκριση εκεί όπου εμφανίζεται ένα τοπικό χαρακτηριστικό όμοιο με το σχήμα της μάσκας. Αποτελεί ουσιαστικά ένα εξαγωγέα χαρακτηριστικών.



Σχήμα 2.4.3: Εξαγωγή χαρακτηριστικών

2.4.1 Συνέλιξη με βήμα

Διάφορες παραλλαγές της κλασικής συνέλιξης έχουν προταθεί. Δημοφιλέστερη εξ'αυτών αποτελεί η συνέλιξη με βήμα (Strided Convolution). Σε αυτή την παραλλαγή, η μάσκα w_{ij} δεν εφαρμόζεται σε κάθε δυνατή θέση (i,j) του χάρτη χαρακτηριστικών αλλά μετακινείται με βήμα s_i κατά την κατεύθυνση i και s_j κατά την κατεύθυνση j . Αυτή η παραλλαγή μπορεί να οδηγήσει σε σημαντική μείωση των υπολογισμών, χωρίς ιδιαίτερα μεγάλη μείωση της επίδοσης. Με μαθηματικούς όρους η συνέλιξη με βήμα ορίζεται ως

$$y_{i,j} = f \left(\sum_{a=1}^{f_h} \sum_{b=1}^{f_w} w_{a,b} x_{is_i-\alpha, js_j-b} \right) \quad (2.40)$$

Όπου $f(\cdot)$ συνάρτηση ενεργοποίησης. Ο πυρήνας είναι διαστάσεων $f_h \times f_w$.

Για είσοδο μεγέθους $x_h \times x_w$, πυρήνα διαστάσεων $f_h \times f_w$ και κατακόρυφο και οριζόντιο βήμα ίσο με s_h και s_w αντίστοιχα, προκύπτει έξοδος διαστάσεων $\left\lfloor \frac{x_h - f_h + s_h}{s_h} \right\rfloor \times \left\lfloor \frac{x_w - f_w + s_w}{s_w} \right\rfloor$.

2.4.2 Στρώμα υποδειγματοληψίας

Μετά απο κάθε συνελκτικό στρώμα συνηθίζεται η τοποθέτηση ενός στρώματος υποδειγματοληψίας. Σκοπός του στρώματος αποτελεί η μείωση την ευαισθησίας του μοντέλου σε μικρές μετατοπίσεις των αντικειμένων της εικόνας, καθώς και η αφαίρεση των λεπτομερειών χαμηλού επιπέδου, χωρίς ωστόσο την πρόκληση απώλειας της ικανότητας διαχωρισμού των αντικειμένων. Στο στρώμα υποδειγματοληψίας η έξοδος y_{ij} κάθε νευρώνα αποτελεί την σύνοψη των εξόδων των νευρώνων από μια συγκεκριμένη γειτονιά διαστάσεων $m \times m$ του προηγούμενου στρώματος. Μια απο τις απλούστερες μορφές υποδειγματοληψίας αποτελεί η υποδειγματοληψία μέσης τιμής. Δίνεται απο την σχέση

$$y_{ij} = \frac{1}{m^2} \sum_{a=0}^{m-1} \sum_{b=0}^{m-1} x_{im+\alpha, jm+b} \quad (2.41)$$

Για χάρτη χαρακτηριστικών διαστάσεων $N \times N$ και μάσκα υποδειγματοληψίας διαστάσεων $m \times m$, η εφαρμογή υποδειγματοληψίας μέσης τιμής οδηγεί σε χάρτη χαρακτηριστικών διαστάσεων $\frac{N}{m} \times \frac{N}{m}$. Μια άλλη δημοφιλής επιλογή αποτελεί η υποδειγματοληψία μέγιστης τιμής όπου αντί για τον μέσο όρο, λαμβάνεται η μέγιστη τιμή των τιμών των νευρώνων του υποδεκτικού πεδίου. Δίνεται απο την σχέση

$$y_{ij} = \max_{0 \leq a, b \leq m-1} x_{im+a, jm+b} \quad (2.42)$$

Είναι σημαντικό να αναφερθεί πως η διαδικασία υποδειγματοληψίας μπορεί να εφαρμοστεί σε πλήθος απο χάρτες χαρακτηριστικών και όχι απαραίτητα σε ένα μόνο χάρτη. Η χρήση υποδειγματοληψίας ταυτόχρονα σε πολλούς χάρτες χαρακτηριστικών από διαφορετικές συνελκτικές μάσκες μπορεί να χρησιμοποιηθεί ώστε τα εξαγόμενα χαρακτηριστικά να μην επηρεάζονται απο διάφορους μετασχηματισμούς. Για παράδειγμα, έστω τρεις συνελκτικές μάσκες που εφαρμόζονται στην ίδια εικόνα εισόδου και είναι εκπαιδευμένες να ανιχνεύουν το ίδιο σχήμα σε διαφορετικές γωνίες περιστροφής. Η απόκριση των χαρτών θα είναι υψηλή αν η εικόνα εισόδου εμφανίζει υψηλή συσχέτιση με την αντίστοιχη μάσκα. Κάνοντας χρήση αυτής της τεχνικής και χρησιμοποιώντας υποδειγματοληψία μέγιστης τιμής το στρώμα υποδειγματοληψίας είναι ικανό να αναγνωρίσει την ύπαρξη του σχήματος ανεξάρτητα απο την γωνιά περιστροφής.

2.4.3 Επέκταση με μηδενικά (Zero-padding)

Η επέκταση με μηδενικά αποτελεί τεχνική που χρησιμοποιείται στα συνελκτικά νευρωνικά δίκτυα και περιλαμβάνει την προσθήκη μηδενικών γύρω απο την είσοδο, πριν την εφαρμογή των συνελκτικών. Συμβάλλει στην διατήρηση των χωρικών διαστάσεων των χαρτών χαρακτηριστικών όσο το δίκτυο γίνεται βαθύτερο, ενώ παράλληλα επιτρέπει την εξαγωγή χαρακτηριστικών ακόμη και απο τα άκρα της εικόνας. Σύμφωνα με το [52] δίκτυα με επέκταση μηδενικών έχουν μεγαλύτερη εκφραστική ικανότητα, μπορούν δηλαδή να εκπαιδευτούν σε περισσότερα είδη μοτίβων σε σχέση με τα δίκτυα χωρίς επέκταση. Η επέκταση μηδενικών καθιστά τα συνελκτικά δίκτυα ισχυρότερα και καταλληλότερα για πολύπλοκες εφαρμογές. Για είσοδο διαστάσεων $x_h \times x_w$, πυρήνα διαστάσεων $f_h \times f_w$ και κατακόρυφη και οριζόντια επέκταση μηδενικών p_h και p_w αντίστοιχα, παράγεται έξοδος διαστάσεων $(x_h - f_h + 2p_h + 1) \times (x_w - f_w + 2p_h + 1)$.

2.4.4 Κανονικοποίηση τιμών (Normalization)

Η κανονικοποίηση αποτελεί τεχνική η οποία χρησιμοποιείται εκτενώς στην εκπαίδευση βαθιών νευρωνικών δικτύων και έχει σκοπό την σταθεροποίηση και επιτάχυνση της διαδικασίας εκπαίδευσης του μοντέλου. Στην πράξη, πρόκειται για μετασχηματισμό των δεδομένων με στόχο την απόκτηση ορισμένων στατιστικών ιδιοτήτων, όπως μέση τιμή ίση με 0, διασπορά ίση με 1 κ.ο.κ.. Η πιο διαδεδομένη της μορφή αποτελεί η κανονικοποίηση ανά παρτίδα (Batch Normalization), η οποία εφαρμόζεται στις ενεργοποιήσεις των νευρώνων κατά την διάρκεια της διαδικασίας εκπαίδευσης. Υπάρχουν και άλλες τεχνικές κανονικοποίησης, όπως για παρά-

δειγμα η κανονικοποίηση ανά στρώμα (Layer Normalization) και η κανονικοποίηση ανά δείγμα (Instance Normalization), οι οποίες προσαρμόζονται σε διαφορετικές αρχιτεκτονικές και προβλήματα. Η κανονικοποίηση επιτρέπει την αποτελεσματικότερη ρύθμιση των παραμέτρων του δικτύου και συχνά οδηγεί σε βελτίωση της ικανότητας γενίκευσης του μοντέλου [53]. Στη συνέχεια, παρουσιάζονται ορισμένες από τις σημαντικότερες τεχνικές κανονικοποίησης βαθιών νευρωνικών δικτύων.

Κανονικοποίηση ανά παρτίδα (Batch Normalization)

Η κανονικοποίηση ανά παρτίδα [54] αποτελεί τεχνική κατά την οποία τα δεδομένα κανονικοποιούνται ανά μικρή παρτίδα (Mini-Batch) κατά την διάρκεια της διαδικασίας εκπαίδευσης του δικτύου. Η διαδικασία αυτή ρυθμίζει τις τιμές ώστε να βρίσκονται σε παρόμοια κλίμακα, αποφεύγοντας ακραία μεγάλες ή πολύ μικρές τιμές [55]. Συγκεκριμένα, για κάθε μικρή παρτίδα υπολογίζεται η μέση της τιμή και η τυπική της απόκλιση και στη συνέχεια κάθε στοιχείο της κανονικοποιείται με βάση αυτά τα στατιστικά. Η μαθηματική σχέση που εφαρμόζεται σε κάθε στοιχείο x_i της παρτίδας είναι η εξής.

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \quad (2.43)$$

Όπου:

- μ_B αποτελεί την μέση τιμή της παρτίδας,
- σ_B^2 αποτελεί την διασπορά της παρτίδας,
- ε αποτελεί μια πολύ μικρή σταθερά για αποφυγή διαίρεσης με το μηδέν.

Στη συνέχεια εφαρμόζεται ένας επιπλέον γραμμικός μετασχηματισμός:

$$y_i = \gamma \hat{x}_i + \beta \quad (2.44)$$

Όπου οι παράμετροι γ και β μαθαίνονται για κάθε μικρή παρτίδα κατά την εκπαίδευση, επιτρέποντας στο δίκτυο να προσαρμόσει τη μορφή της εξόδου αν αυτό είναι απαραίτητο.

Κανονικοποίηση ανά ομάδα (Group Normalization)

Η κανονικοποίηση ανά παρτίδα αποτελεί καθοριστική τεχνική στην εξελικτική πορεία της βαθιάς μάθησης, καθώς συχνά επιτρέπει την ευκολότερη και αποδοτικότερη εκπαίδευση σύνθετων νευρωνικών δικτύων. Ωστόσο, εισάγει ορισμένα προβλήματα. Συγκεκριμένα, για μικρά μεγέθη παρτίδων, η ακρίβεια των στατιστικών που υπολογίζονται μειώνεται, οδηγώντας σε αύξηση του σφάλματος. Ως εκ τούτου, η τεχνική αυτή δεν είναι κατάλληλη σε σενάρια όπου απαιτούνται μικρές παρτίδες, όπως στην εκπαίδευση μοντέλων υπολογιστικής όρασης, όπου οι περιορισμοί μνήμης πολλές φορές δεν επιτρέπουν παρτίδες μεγάλου μεγέθους. Μια λύση στο πρόβλημα αυτό δίνεται μέσω της κανονικοποίησης ανά ομάδα [56], η οποία είναι ανεξάρτητη του πλήθους των δειγμάτων της παρτίδας. Στην τεχνική αυτή, αντί να υπολογίζονται τα στατιστικά κατά μήκος της διάστασης της παρτίδας, τα κανάλια κάθε δείγματος διαιρούνται σε ομάδες και για καθεμία από αυτές υπολογίζεται η μέση τιμή και διασπορά. Η κανονικοποίηση ανά ομάδα παρουσιάζει σταθερή απόδοση σε σενάρια με εξαιρετικά μικρές παρτίδες, γεγονός που την καθιστά ιδανική για εργασίες υπολογιστικής όρασης. Ακολουθεί η μαθηματική περιγραφή της κανονικοποίησης ανά ομάδα.

Έστω είσοδος (παρτίδα) διαστάσεων (N, C, H, W) , όπου

- N αποτελεί το πλήθος των δειγμάτων της παρτίδας,
- C είναι ο αριθμός καναλιών του δείγματος,
- $H \times W$ είναι οι χωρικές διαστάσεις του δείγματος.

Η κανονικοποίηση ανά ομάδα διαιρεί τα C κανάλια σε G ομάδες. Για κάθε στοιχείο x_i της εισόδου, η κανονικοποιημένη τιμή υπολογίζεται ως

$$\hat{x}_i = \frac{x_i - \mu_i}{\sigma_i} \quad (2.45)$$

Όπου η μέση τιμή μ_i και η τυπική απόκλιση σ_i υπολογίζονται εντός της ομάδας ως:

$$\mu_i = \frac{1}{m} \sum_{k \in S_i} x_k, \quad \sigma_i = \sqrt{\frac{1}{m} \sum_{k \in S_i} (x_k - \mu_i)^2 + \varepsilon} \quad (2.46)$$

Το ε αποτελεί μια πολύ μικρή σταθερά για την αποτροπή της περίπτωσης η διασπορά να ισούται με μηδέν. Το S_i είναι το σύνολο των στοιχείων που ανήκουν στο ίδιο δείγμα και στην ίδια

ομάδα καναλιών με το x_i .

$$S_i = \left\{ k \mid k_N = i_N, \left\lfloor \frac{k_C}{C/G} \right\rfloor = \left\lfloor \frac{i_C}{C/G} \right\rfloor \right\} \quad (2.47)$$

Όπου k_N, i_N είναι οι δείκτες του δείγματος στην παρτίδα για τα στοιχεία k και i αντίστοιχα και k_C, i_C οι αντίστοιχοι δείκτες καναλιών.

Τέλος, εφαρμόζεται μια γραμμική μετατροπή με παραμέτρους που μαθαίνονται για κάθε ομάδα κατά την εκπαίδευση.

$$y_i = \gamma \hat{x}_i + \beta \quad (2.48)$$

Κανονικοποίηση ανά παρτίδα και ομάδα (Batch Group Normalization)

Η κανονικοποίηση ανά παρτίδα παρουσιάζει ικανοποιητική απόδοση σε μεσαίου ή μεγάλου μεγέθους παρτίδες και γενικεύει αποδοτικά σε πληθώρα προβλημάτων υπολογιστικής όρασης. Ωστόσο, η απόδοσή της υποβαθμίζεται σημαντικά για πολύ μικρά ή και εξαιρετικά μεγάλα μεγέθη παρτίδων, γεγονός που αποδίδεται σε θόρυβο κατά τον υπολογισμό των στατιστικών μεγεθών. Η μέθοδος κανονικοποίησης ανά παρτίδα και ομάδα [57] προτείνεται για την αντιμετώπιση του παραπάνω φαινομένου. Ακολουθεί η μαθηματική της περιγραφή.

Έστω είσοδος (παρτίδα) διαστάσεων (N, C, H, W) . Στο πλαίσιο αυτής της τεχνικής, οι διαστάσεις C, H και W συγχωνεύονται σε μία ενιαία διάσταση.

$$D = C \cdot H \cdot W \quad (2.49)$$

Ως αποτέλεσμα, προκύπτει τανυστής διαστάσεων (N, D) . Η νέα διάσταση D διαιρείται σε G ομάδες, καθεμία από τις οποίες περιέχει $S = \frac{D}{G}$ στοιχεία.

Για κάθε ομάδα $g \in \{1, \dots, G\}$, υπολογίζεται ο μέσος όρος και η διασπορά κατά μήκος όλων των δειγμάτων και των στοιχείων της ομάδας:

$$\mu_g = \frac{1}{N \cdot S} \sum_{n=1}^N \sum_{d=(g-1)S+1}^{gS} f_{n,d} \quad (2.50)$$

$$\delta_g^2 = \frac{1}{N \cdot S} \sum_{n=1}^N \sum_{d=(g-1)S+1}^{gS} (f_{n,d} - \mu_g)^2 \quad (2.51)$$

Κατόπιν, κάθε στοιχείο κανονικοποιείται ως εξής:

$$\hat{f}_{n,d} = \frac{f_{n,d} - \mu_g}{\sqrt{\delta_g^2 + \varepsilon}} \quad (2.52)$$

όπου ε μια μικρή σταθερά για αριθμητική σταθερότητα.

Τέλος, εφαρμόζεται γραμμικός μετασχηματισμός με παραμέτρους που μαθαίνονται για κάθε ομάδα κατά την εκπαίδευση.

$$f'_{n,d} = \gamma \cdot \hat{f}_{n,d} + \beta \quad (2.53)$$

Η επιλογή της υπερπαραμέτρου G γίνεται λαμβάνοντας υπόψη το μέγεθος της παρτίδας.

- Για μικρό μέγεθος παρτίδας, χρησιμοποιείται μικρό G , έτσι ώστε να συμμετέχουν περισσότερα στοιχεία σε κάθε ομάδα και να αποφεύγεται ο θόρυβος στους υπολογισμούς.
- Για μεγάλο μέγεθος παρτίδας, χρησιμοποιείται μεγάλο G , έτσι ώστε να περιορίζεται η σύγχυση από υπερβολικά μεγάλο αριθμό στοιχείων στην ίδια ομάδα.


2.5 Μετασχηματιστές (Transformers)

Οι μετασχηματιστές [58] αποτελούν αρχιτεκτονική βαθιών νευρωνικών δικτύων, η οποία βασίζεται αποκλειστικά σε μηχανισμούς προσοχής (Attention Mechanism). Εισάχθηκαν για πρώτη φορά από τους Vaswani, Shazeer και τους συνεργάτες του το 2017 στα πλαίσια της διεργασίας

μετάφρασης κειμένου μεταξύ διαφορετικών γλωσσών. Σε αντίθεση με τα αναδρομικά νευρωνικά δίκτυα (Recurrent Neural Networks) [59] και τις παραλλαγές του, οι μετασχηματιστές είναι σε θέση να επεξεργαστούν πολλαπλές εισόδους ταυτόχρονα μέσω παράλληλης επεξεργασίας. Οι μετασχηματιστές έχουν αποδειχθεί ιδιαίτερα επιτυχείς σε εργασίες επεξεργασίας φυσικής γλώσσας και όρασης υπολογιστών.

2.5.1 Αρχιτεκτονική

Η αρχιτεκτονική τους αποτελείται από ένα κωδικοποιητή (Encoder) και ένα αποκωδικοποιητή (Decoder). Ο κωδικοποιητής παίρνει ως είσοδο μια ακολουθία $x = (x_1, \dots, x_n)$ από στοιχεία (π.χ. Λέξεις) και την μετατρέπει σε μια ακολουθία $z = (z_1, \dots, z_n)$, όπου $z_i \in \mathbb{R}, \forall i = 1, \dots, n$. Στη συνέχεια, ο αποκωδικοποιητής λαμβάνει ως είσοδο την ακολουθία z και παράγει την έξοδο.



Σχήμα 2.5.1: Αρχιτεκτονική μετασχηματιστή

Οι μετασχηματιστές ακολουθούν την αρχιτεκτονική του σχήματος 2.5.1, χρησιμοποιώντας διαδοχικά επίπεδα από μηχανισμούς αυτο-προσοχής και ανά στοιχείο πλήρως συνδεδεμένων

νευρωνικών διτύπων (Point-wise Fully Connected Neural Networks), τόσο στον κωδικοποιητή όσο και στον αποκωδικοποιητή. Τα ανά στοιχείο πλήρως συνδεδεμένα νευρωνικά δίκτυα εφαρμόζονται ξεχωριστά σε κάθε στοιχείο της ακολουθίας εισόδου, χωρίς να υφίσταται αλληλεπίδραση μεταξύ των στοιχείων. Ο κωδικοποιητής απεικονίζεται στα αριστερά του σχήματος, ενώ ο αποκωδικοποιητής στα δεξιά.

Ο κωδικοποιητής αποτελείται από N πανομοιότυπα διαδοχικά στρώματα. Κάθε στρώμα αποτελείται από δύο υπο-στρώματα. Το πρώτο αποτελείται από ένα μηχανισμό αυτο-προσοχής πολλών κεφαλών, ενώ το δεύτερο αποτελείται από ένα ανά στοιχείο πλήρως συνδεδεμένο δίκτυο. Σε κάθε υπο-στρώμα, αθροίζεται η είσοδος με την έξοδο του αντίστοιχου μηχανισμού. Στην συνέχεια, εφαρμόζεται κανονικοποίηση στρώματος (Layer Normalization). Η μαθηματική μορφή της διαδικασίας που περιγράφηκε δίνεται από την σχέση

$$\text{LayerNorm}(x + \text{Sublayer}(x)) \quad (2.54)$$

Όπου $\text{Sublayer}(x)$ συμβολίζει τον μηχανισμό που αντιστοιχεί στο εκάστοτε υπόστρωμα. Προκειμένου να δύναται να πραγματοποιηθεί άθροιση, απαιτείται τα υπο-επίπεδα του κωδικοποιητή καθώς και τα στρώματα ενσωμάτωσης (Embedding Layers) να παράγουν εξόδους ίδιας διάστασης. Στο πρωτότυπο άρθρο, στο οποίο παρουσιάστηκαν για πρώτη φορά οι μετασχηματιστές, η διάσταση αυτή ορίστηκε ως $d_{\text{model}} = 512$, ενώ ο αριθμός των διαδοχικών στρωμάτων ορίστηκε ίσος με $N = 6$.

Ο αποκωδικοποιητής, όπως και ο κωδικοποιητής αποτελείται από N πανομοιότυπα διαδοχικά στρώματα, όπου κάθε ένα από αυτά περιλαμβάνει τρία υπο-στρώματα. Τα πρώτα δύο είναι κοινά με του κωδικοποιητή, με την μόνη διαφορά πως στο πρώτο από αυτά ο μηχανισμός αυτο-προσοχής εφαρμόζεται αποκλειστικά στα στοιχεία που βρίσκονται σε θέσεις προηγούμενες της θέσης του στοιχείου του οποίου εξετάζουμε. Στο τρίτο υπό-στρώμα εφαρμόζεται μηχανισμός προσοχής πολλών κεφαλών. Όπως και στον κωδικοποιητή, έτσι και στον αποκωδικοποιητή η σχέση (2.54) εφαρμόζεται στην έξοδο κάθε υπο-στρώματος.

Πλήρως συνδεδεμένο δίκτυο

Το ίδιο νευρωνικό δίκτυο εφαρμόζεται ξεχωριστά σε κάθε στοιχείο της ακολουθίας εισόδου του επιπέδου, χωρίς να υπάρχει αλληλεπίδραση μεταξύ των στοιχείων. Αποτελείται από δύο γραμμικούς μετασχηματισμούς, με μια συνάρτηση ενεργοποίησης ReLU ανάμεσα τους. Η μαθηματική του μορφή περιγράφεται μέσω της σχέσης

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2.55)$$

Όπου W_1, W_2 οι πίνακες βαρών, b_1, b_2 τα διανύσματα μεροληψίας και x το διάνυσμα εισόδου.

Παρόλο που ο υπολογισμός είναι ο ίδιος για κάθε στοιχείο του επιπέδου, οι παράμετροι του δικτύου διαφέρουν μεταξύ των επιπέδων. Το δίκτυο περιλαμβάνει 512 νευρώνες στο στρώμα εισόδου, 2048 νευρώνες στο κρυφό, ενδιάμεσο στρώμα και 512 νευρώνες στο στρώμα εξόδου.

Αυτο-προσοχή (Self-Attention)

Αρχικά ορίζονται τρεις πίνακες, ο πίνακας query Q , ο πίνακας key K και ο πίνακας value V , οι οποίοι αρχικοποιούνται και των οποίων οι παραμέτροι προσαρμόζονται κατά την διάρκεια της διαδικασίας εκπαίδευσης του μοντέλου. Ο μηχανισμός υπολογίζει το εσωτερικό γινόμενο μεταξύ κάθε γραμμής του πίνακα Q και των αντίστοιχων γραμμών του πίνακα K , παράγοντας με αυτό τον τρόπο ένα πίνακα βαθμών ομοιότητας. Σε κάθε γραμμή του πίνακα που προκύπτει εφαρμόζεται η συνάρτηση Softmax, ώστε τα στοιχεία κάθε μιας από αυτές να αθροίζουν στην μονάδα. Με αυτό τον τρόπο κατασκευάζεται ένας πίνακας βαρών, ο οποίος χρησιμοποιείται στην παραγωγή του τελικού αποτελέσματος ως σταθμισμένος συνδυασμός των στοιχείων των στηλών του πίνακα V . Για την αποτροπή προβλημάτων αστάθειας, το εσωτερικό γινόμενο των γραμμών των πινάκων Q και K διαιρείται με την τετραγωνική ρίζα του πλήθους των στηλών του πίνακα K . Ο μηχανισμός αυτο-προσοχής εκφράζεται με μαθηματικούς όρους μέσω της παρακάτω σχέσης.

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.56)$$

Όπου d_k είναι ο αριθμός των στηλών του πίνακα K .

Έπειτα της περιγραφής του μηχανισμού αυτο-προσοχής μιας κεφαλής, ακολουθεί η γενίκευση του μέσω του αντίστοιχου μηχανισμού πολλαπλών κεφαλών, ο οποίος παρουσιάζεται στην συνέχεια. Ο μηχανισμός αυτο-προσοχής πολλών κεφαλών (Multi Head Self-Attention) επεκτείνει την απλή προσοχή μιας κεφαλής εφαρμόζοντας τον μηχανισμό αυτό σε h διαφορετικούς υποχώρους. Συγκεκριμένα, οι πίνακες Q , K και V , προβάλλονται σε μικρότερες διαστάσεις

μέσω των πινάκων W_i^Q , W_i^K και W_i^V αντίστοιχα. Ο δείκτης i λαμβάνει τιμές απο το 1 μέχρι και το h και αντιστοιχεί στην αντίστοιχη κεφαλή αυτο-προσοχής. Έπειτα, υπολογίζονται h ανεξάρτητοι μηχανισμοί αυτο-προσοχής μέσω παράλληλου υπολογισμού και στη συνέχεια τα αποτελέσματα τους συνενώνονται και προβάλλονται ξανά μέσω του πίνακα W^0 για την παραγωγή της τελικής εξόδου. Η μαθηματική μορφή του μηχανισμού αυτο-προσοχής πολλών κεφαλών δίνεται παρακάτω.

Κάθε κεφαλή αυτο-προσοχής υπολογίζεται μέσω της παρακάτω σχέσης.

$$h_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2.57)$$

Οι πίνακες $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ και $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ αρχικοποιούνται και προσαρμόζονται μέσω της διαδικασίας εκπαίδευσης του μοντέλου.

Οι κεφαλές αυτο-προσοχής συνδυάζονται μέσω της σχέσης

$$\text{MultiHead}(Q, K, V) = \text{Concat}(h_1, h_2, \dots, h_h)W^0 \quad (2.58)$$

Όπου $\text{Concat}(\cdot)$ συνάρτηση συνένωσης και $W^0 \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ πίνακας ο οποίος αρχικοποιείται και προσαρμόζεται κατά την διάρκεια της διαδικασίας εκπαίδευσης του μοντέλου.

Στο πρωτότυπο άρθρο [58] γίνεται χρήση των τιμών $h = 8$ και $d_k = d_v = d_{\text{model}}/h = 64$. Το συνολικό υπολογιστικό κόστος είναι αντίστοιχο με αυτό της προσοχής μίας κεφαλής. Αυτό οφείλεται στο γεγονός ότι η διάσταση κάθε κεφαλής αυτο-προσοχής είναι μειωμένη σε σύγκριση με εκείνη του μηχανισμού αυτο-προσοχής μίας μόνο κεφαλής. Παράλληλα, η χρήση πολλαπλών κεφαλών καθιστά τον μηχανισμό αυτο-προσοχής αποδοτικότερο.

3 Σύνολα δεδομένων και μετρικές αξιολόγησης πανοπτικής κατάτμησης εικόνας

Σε αυτό το κεφάλαιο παρουσιάζονται τα βασικά σύνολα δεδομένων της πανοπτικής κατάτμησης εικόνας, καθώς και ορισμένες από τις καθιερωμένες μετρικές αξιολόγησης που χρησιμοποιούνται. Γίνεται αναφορά τόσο στα χαρακτηριστικά των δεδομένων, όσο και των μετρικών απόδοσης με σκοπό την πληρέστερη κατανόηση της διαδικασίας εκπαίδευσης και αξιολόγησης της πανοπτικής κατάτμησης εικόνας.

3.1 Σύνολα δεδομένων πανοπτικής κατάτμησης εικόνας

Στην σύγχρονη εποχή η όραση υπολογιστών βασίζεται σχεδόν αποκλειστικά σε μεθόδους βαθιάς μάθησης. Γνωρίζουμε πως η λειτουργία τέτοιων μεθόδων απαιτεί ένα πολύ μεγάλο όγκο δεδομένων συνοδευόμενο με τις κατάλληλες επισημειώσεις. Για τον σκοπό αυτό έχουν δημιουργηθεί κατάλληλα σύνολα δεδομένων [7] που έχουν ως σκοπό την εκπαίδευση και ποσοτική αξιολόγηση της απόδοσης αυτών των μοντέλων. Ορισμένα από αυτά παρουσιάζονται στην συνέχεια.

3.1.1 Σύνολο δεδομένων COCO

Το COCO (Common Objects in Context) [16], αποτελεί σύνολο δεδομένων μεγάλου μεγέθους, το οποίο περιλαμβάνει εικόνες σκηνών της καθημερινότητας με ποικιλία "αντικειμένων" στα φυσικά τους περιβάλλοντα. Περιέχει συνολικά περισσότερες από 330.000 εικόνες και είναι διαθέσιμο σε δύο κύριες εκδόσεις, την COCO 2014 και COCO 2017, οι οποίες περιλαμβάνουν κατά μεγάλο βαθμό κοινές εικόνες αλλά διαφοροποιούνται ως προς τον διαχωρισμό τους σε σύνολα εκπαίδευσης και επικύρωσης. Το σύνολο δεδομένων είναι επισημειωμένο με 80 κατηγορίες "αντικειμένων" και 91 κατηγορίες "σκηνικών" στοιχείων και χωρίζεται σε δύο μέρη. Από την μια έχουμε τις εικόνες, ενώ από την άλλη τις αντίστοιχες επισημειώσεις. Οι εικόνες είναι οργανωμένες ιεραρχικά σε φακέλους, με τον φάκελο που βρίσκεται στο υψηλότερο επίπεδο να περιλαμβάνει τρεις υπο-φακέλους, οι οποίοι αντιστοιχούν στα σύνολα δεδομένων εκπαίδευσης, δοκιμής και επικύρωσης [60].

Οι επισημειώσεις είναι οργανωμένες σε JSON αρχεία, με κάθε αρχείο να αντιστοιχεί σε μια εικόνα. Κάθε τέτοιο αρχείο περιέχει:

- Το όνομα του αρχείου
- Το μέγεθος της εικόνας

- 5 ετικέτες που περιγράφουν την σκηνή
- Λίστα των "αντικειμένων" της εικόνας (Για κάθε "αντικείμενο" περιλαμβάνεται η κατηγορία, οι συντεταγμένες του ορθογωνίου που το περιβάλλει, τα εικονοστοιχεία που του αντιστοιχούν και τα σημεία κλειδιά του)

Το σύνολο δεδομένων COCO περιλαμβάνει επίσης την άδεια χρήσης, τις επισημειώσεις των "σκηνικών" στοιχείων και υπερκατηγορίες των "αντικειμένων" (Αποτελούν ευρύτερες κατηγορίες των "αντικειμένων" π.χ. dog $\subset$ animal). Το σύνολο δεδομένων COCO χρησιμοποιείται σε εργασίες όπως η ανίχνευση αντικειμένων, η σημασιολογική κατάτμηση εικόνας, η πανοπτική κατάτμηση εικόνας κ.ο.κ. [60].

Παρακάτω δίνονται όλες οι κατηγορίες "αντικειμένων" που περιέχονται στο σύνολο δεδομένων COCO.

person	fire hydrant	elephant	skis	wine glass	broccoli	dining table	toaster
bicycle	stop sign	bear	snowboard	cup	carrot	toilet	sink
car	parking meter	zebra	sports ball	fork	hot dog	tv	refrigerator
motorcycle	bench	giraffe	kite	knife	pizza	laptop	book
airplane	bird	backpack	baseball bat	spoon	donut	mouse	clock
bus	cat	umbrella	baseball glove	bowl	cake	remote	vase
train	dog	handbag	skateboard	banana	chair	keyboard	scissors
truck	horse	tie	surfboard	apple	couch	cell phone	teddy bear
boat	sheep	suitcase	tennis racket	sandwich	potted plant	microwave	hair drier
traffic light	cow	frisbee	bottle	orange	bed	oven	toothbrush


Σχήμα 3.1.1: Κατηγορίες αντικειμένων συνόλου δεδομένων COCO

Είναι σημαντικό να αναφερθεί πως το σύνολο δεδομένων COCO δεν περιέχει ισορροπημένο αριθμό "αντικειμένων" ανά κατηγορία κάτι που μπορεί να οδηγήσει σε μεροληψία. Όπως προαναφέρθηκε το COCO διατίθεται σε δύο κύριες εκδόσεις. Η COCO 2014 περιλαμβάνει 82.783 εικόνες στο σύνολο δεδομένων εκπαίδευσης, 40.504 εικόνες στο σύνολο δεδομένων επικύρωσης και 40.775 εικόνες στο σύνολο δεδομένων δοκιμής. Αντίστοιχα, το COCO 2017 περιλαμβάνει 118.287, 5.000 και 40.670 εικόνες στα αντίστοιχα σύνολα. [61].

3.1.2 Σύνολο δεδομένων Cityscapes

Η κατανόηση περίπλοκων αστικών σκηνών αποτελεί καθοριστικό παράγοντα για ένα ευρύ φάσμα εφαρμογών. Ωστόσο, δεν υπάρχουν πολλά σύνολα δεδομένων που να αποτυπώνουν επαρκώς την πολυπλοκότητα των σκηνών που παρουσιάζονται στον πραγματικό κόσμο. Το πρόβλημα αυτό επιχειρεί να αντιμετωπίσει το σύνολο δεδομένων Cityscapes [12].

Το σύνολο δεδομένων Cityscapes δημιουργήθηκε μέσω επιλεγμένων καρέ (Frame), τα οποία εξήχθησαν απο στερεοσκοπικές ακολουθίες βίντεο που καταγράφηκαν απο κινούμενο όχημα στους δρόμους 50 διαφορετικών πόλεων, κυρίως της Γερμανίας. Απο αυτές τις εικόνες, οι 5.000 διαθέτουν υψηλής ποιότητας επισημειώσεις σε επίπεδο εικονοστοιχείου, ενώ οι υπόλοιπες 20.000 χαμηλότερης ποιότητας, ώστε να υποστηρίζεται η εκπαίδευση μοντέλων σε μερικώς επισημειωμένα δεδομένα (Ασθενώς επιβλεπόμενη μάθηση). Απο τις 5.000 πλήρως επισημειωμένες εικόνες, οι 2.975 αποτελούν εικόνες του συνόλου δεδομένων εκπαίδευσης, οι 500 του συνόλου δεδομένων επικύρωσης και οι υπόλοιπες 1.525 του συνόλου δεδομένων δοκιμής. Οι πλήρως επισημειωμένες εικόνες εξήχθησαν χειροκίνητα απο 27 απο τις 50 πόλεις του συνόλου δεδομένων και συγκεκριμένα απο το 20ό καρέ αποσπασμάτων βίντεο διάρκειας 30 καρέ. Αντίθετα, οι ασθενώς επισημειωμένες εικόνες εξήχθησαν απο τις υπόλοιπες 23 πόλεις του συνόλου δεδομένων, μέσω εξαγωγής μιας εικόνας ανά 20 δευτερόλεπτα λήψης ή ανά 20 μέτρα οδήγησης, ανάλογα με πιο απο τα 2 συνέβαινε πρώτο. Όπως μπορούμε να δούμε παρακάτω, το σύνολο δεδομένων Cityscapes περιλαμβάνει συνολικά 30 κατηγορίες "αντικειμένων" ή "σκηνικών" στοιχείων, απο τις οποίες μόνο οι 19 χρησιμοποιούνται στην επικύρωση των αποτελεσμάτων [12].



Σχήμα 3.1.2: Αντικείμενα συνόλου δεδομένων Cityscapes


Το σύνολο δεδομένων περιλαμβάνει εικόνες καταγεγραμμένες κατά την διάρκεια της Άνοιξης, του Καλοκαιριού και του Φθινωπόρου καλύπτοντας αρκετούς μήνες του έτους. Ωστόσο, δεν περιλαμβάνει εικόνες σε δυσμενείς καιρικές συνθήκες, όπως έντονη βροχόπτωση ή χιόνι, καθώς οι συνθήκες αυτές απαιτούν την χρήση εξειδικευμένων τεχνικών και συνόλων δεδομένων. Όλες οι εικόνες είναι διαθέσιμες σε 8-bit (Low Dynamic Range) και 16-bit (High Dynamic Range). Πέρα απο εικόνες και επισημειώσεις, το σύνολο δεδομένων Cityscapes περιλαμβάνει δεδομένα ως προς την εξωτερική θερμοκρασία, την διαδρομή (GPS) του οχήματος και την οδομετρία του [12].

Το σύνολο δεδομένων Cityscapes χρησιμοποιείται σε εργασίες όπως η σημασιολογική κατάρτιση εικόνας, η πανοπτική κατάρτιση εικόνας, η εκτίμηση βάθους κ.ο.κ. [12], [62], [63].

3.1.3 Σύνολο δεδομένων ADE20K

Σε αντίθεση με την απλή κατανόηση του περιεχομένου μιας εικόνας, η κατανόηση σε επίπεδο ει-
κονοστοιχείου απαιτεί σύνολα δεδομένων με πολύ πιο πυκνές επισημειώσεις και ένα ευρύ σύνο-
λο "αντικειμένων". Ωστόσο, τα περισσότερα σύνολα δεδομένων παρουσιάζουν ένα περιορισμέ-
νο αριθμό "αντικειμένων" (π.χ. COCO [16], Pascal VOC [13]) και συχνά είτε περιλαμβάνουν
κατηγορίες που δεν είναι συνυφασμένες με τα πιο συνήθη "αντικείμενα" που συναντούμε στον
πραγματικό κόσμο είτε καλύπτουν ένα περιορισμένο φάσμα σκηνών (π.χ. Cityscapes [12]). Η
ανάγκη δημιουργίας ενός συνόλου δεδομένων, το οποίο να ανταποκρίνεται σε αυτά τα προβλή-
ματα οδήγησε στη δημιουργία του συνόλου δεδομένων ADE20K [14], [66].

Το ADE20K [14] αποτελεί ένα εκτενώς επισημειωμένο σύνολο δεδομένων, με την έννοια
πως για κάθε εικόνα παρέχονται λεπτομερείς ετικέτες των "αντικειμένων", όπως και σε ορισμέ-
νες περιπτώσεις των μερών που τα αποτελούν ("υπο-αντικείμενα"). Αποτελείται από συνολικά
25.210 εικόνες από τις οποίες οι 20.210 ανήκουν στο σύνολο δεδομένων εκπαίδευσης, οι 2.000
στο σύνολο δεδομένων επικύρωσης και οι υπόλοιπες 3.000 στο σύνολο δεδομένων δοκιμής. Πε-
ριλαμβάνει συνολικά 3169 κατηγορίες από τις οποίες οι 2693 αφορούν "αντικείμενα" ή "σκηني-
κά" στοιχεία, ενώ οι υπόλοιπες 476 μέρη μεγαλύτερων "αντικειμένων". Τα "υπο-αντικείμενα"
του συνόλου δεδομένων ADE20K φτάνουν σε επίπεδο βάθους το πολύ 3. Στο Σχήμα 3.1.3 α-
πεικονίζονται ορισμένα "αντικείμενα" του συνόλου μαζί με τα αντίστοιχα "υπο-αντικείμενα"
τους [66].



Σχήμα 3.1.3: Αντικείμενα και υπο-αντικείμενα συνόλου δεδομένων ADE20K

Το 76% των "αντικειμένων" του συνόλου δεδομένων ADE20K διαθέτει "υπο-αντικείμενα" με μέσο όρο πλήθους "υπο-αντικειμένων" ίσο με 3. Κατά μέσο όρο υπάρχουν 19.5 εμφανίσεις και 10.5 διαφορετικές κατηγορίες "αντικειμένων" σε κάθε εικόνα. Ο ελάχιστος αριθμός εμφανίσεων είναι ίσος με 5 με ορισμένες εικόνες να έχουν μέχρι και 273, εξαιρουμένων των "υπο-αντικειμένων". Εάν συμπεριληφθούν ο αριθμός αυτός φτάνει μέχρι και 419 [14], [66].

Το σύνολο δεδομένων ADE20K χρησιμοποιείται σε εργασίες όπως η σημασιολογική κατάρτιση εικόνας, η κατάρτιση αντικειμένων, η πανοπτική κατάρτιση εικόνας κ.ο.κ. [14], [62].

3.2 Μετρικές αξιολόγησης πανοπτικής κατάρτισης εικόνας

Οι μετρικές αξιολόγησης αποτελούν βασικό εργαλείο και διαδραματίζουν σημαντικό ρόλο στη σύγκριση της αποτελεσματικότητας διαφορετικών μεθόδων σε διάφορες εργασίες. Η πανοπτική κατάρτιση εικόνας, όπως έχει ήδη οριστεί αποτελεί συνδυασμό της σημασιολογικής κατάρτισης και της κατάρτισης αντικειμένων. Αν και οι υπάρχουσες μετρικές αυτών των εργασιών μπορούν σε κάποιο βαθμό να εφαρμοσθούν στην πανοπτική κατάρτιση εικόνας, δεν αρκούν από μόνες τους. Συνήθως, στην πανοπτική κατάρτιση εικόνας χρησιμοποιούνται μετρικές όπως η πανοπτική ποιότητα (Panoptic Quality - PQ), η ποιότητα κατάρτισης (Segmentation Quality - SQ) και η ποιότητα αναγνώρισης (Recognition Quality - RQ). Ωστόσο, μπορούν να χρησιμοποιηθούν πρόσθετες μετρικές για την αξιολόγηση των μεθόδων αυτών, όσον αφορά την επίδοσή τους στην σημασιολογική κατάρτιση και την κατάρτιση αντικειμένων, όπως ο περιορισμός των παραπάνω μετρικών αποκλειστικά σε "αντικείμενα" (Things) ή "σκηνικά" στοιχεία (Stuff). Άλλα ενδεικτικά παραδείγματα μετρικών που μπορούν να αξιοποιηθούν αποτελεί ο μέσος όρος ακρίβειας (Average Precision - AP) και η Intersection over Union (IoU) [17].

3.2.1 Πίνακας σύγχυσης (Confusion matrix)

Για να δύναται να οριστούν ορισμένες από τις μετρικές που αναφέρθηκαν παραπάνω, απαιτείται πρώτα ο ορισμός του πίνακα σύγχυσης. Ο πίνακας σύγχυσης αποτελεί εργαλείο αξιολόγησης της ικανότητας ταξινόμησης μιας μεθόδου, μέσω των τιμών True positive (TP), True negative (TN), False positive (FP) και False negative (FN). Πρόκειται για πίνακα διαστάσεων $N \times N$, όπου το N αποτελεί το πλήθος των κλάσεων ταξινόμησης. Τα κελιά του πίνακα αποτυπώνουν το πλήθος των δειγμάτων για κάθε συνδυασμό πραγματικής και προβλεπόμενης κλάσης. Για δυαδικό πρόβλημα ταξινόμησης η μορφή που παίρνει ο πίνακας σύγχυσης δίνεται παρακάτω.

		ACTUAL VALUES	
		POSITIVE	NEGATIVE
PREDICTED VALUES	POSITIVE	TP	FP
	NEGATIVE	FN	TN

Σχήμα 3.2.1: Μορφή πίνακα σύγχυσης για δυαδική ταξινόμηση

Οι στήλες αναπαριστούν τις πραγματικές και οι γραμμές τις προβλεπόμενες τιμές. Ακολουθεί η ερμηνεία των TP, FP, FN και TN.

TP : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην θετική κλάση (Positive) και προβλέφθηκαν σωστά.

TN : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην αρνητική κλάση (Negative) και προβλέφθηκαν σωστά.

FP : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην αρνητική κλάση και δεν προβλέφθηκαν σωστά. Αυτή η περίπτωση σφάλματος καλείται σφάλμα τύπου 1.

FN : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην θετική κλάση και δεν προβλέφθηκαν σωστά. Αυτή η περίπτωση σφάλματος καλείται σφάλμα τύπου 2.

Όταν το πρόβλημα ταξινόμησης δεν είναι δυαδικό, η ερμηνεία του πίνακα σύγκρισης διαφοροποιείται. Συγκεκριμένα οι τιμές των TP, FP, FN και TN, υπολογίζονται για κάθε κατηγορία, ενώ κάθε κελί (i, j) του πίνακα αποτυπώνει το πλήθος των δειγμάτων με πραγματική κλάση j και προβλεπόμενη κλάση i , όπου i και j αναπαριστούν αριθμητικούς δείκτες κλάσεων. Ακολουθεί η ερμηνεία των $TP_i, FP_i, FN_i, TN_i, \forall i = 1, \dots, N$.

TP_i : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην κλάση i και προβλέφθηκαν σωστά. Αντιστοιχεί στην τιμή του κελιού (i, i) του πίνακα.

TN_i : Αντιστοιχεί στο πλήθος των δειγμάτων που ούτε η προβλεπόμενη, ούτε η πραγματική τιμή αντιστοιχεί στην κλάση i . Ισούται με το άθροισμα $\sum_{p \neq i}^N \sum_{k \neq i}^N value(p, k)$, όπου $value(i, j)$ η τιμή του πίνακα σύγκρισης στο κελί (i, j) .

FP_i : Αντιστοιχεί στο πλήθος των δειγμάτων που η προβλεπόμενη τιμή αντιστοιχεί στην κλάση i , ενώ η πραγματική όχι. Ισούται με το άθροισμα $\sum_{p \neq i}^N value(i, p)$, όπου $value(i, j)$ η τιμή του πίνακα σύγκρισης στο κελί (i, j) .

FN_i : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην κλάση i και δεν προβλέφθηκαν σωστά. Ισούται με το άθροισμα $\sum_{p \neq i}^N value(p, i)$, όπου $value(i, j)$ η τιμή του πίνακα σύγκρισης στο κελί (i, j) .

Η μέθοδος ταξινόμησης είναι αποδοτική εάν το πλήθος των True Positive και True Negative είναι μεγάλο σε σχέση με το συνολικό πλήθος των δειγμάτων [67].

3.2.2 Intersection over Union (Intersection over Union - IoU)

Η μετρική IoU, γνωστή και ως δείκτης Jaccard αποτυπώνει το ποσοστό επικάλυψης μεταξύ των εικονοστοιχείων της περιοχής ενδιαφέροντος της μάσκας στόχου και της αντίστοιχης περιοχής της μάσκας πρόβλεψης [17]. Υπολογίζεται μέσω της παρακάτω σχέσης.

$$IoU = \frac{target \cap prediction}{target \cup prediction} \quad (3.1)$$

Όπου *target* τα εικονοστοιχεία της περιοχής ενδιαφέροντος της μάσκας στόχου και *prediction* τα αντίστοιχα εικονοστοιχεία της μάσκα πρόβλεψης.

Εύκολα μπορούμε να συμπεράνουμε πως $0 \leq IoU \leq 1$.

3.2.3 Μέσος Όρος Ακρίβειας (Average Precision - AP)

Ο μέσος όρος ακριβείας αποτελεί την πιο ευρέως χρησιμοποιούμενη μετρική αξιολόγησης στην κατάτμηση αντικειμένων [68]. Για την διατύπωση της, απαιτείται αρχικά ο ορισμός ορισμένων άλλων μετρικών. Η ακρίβεια (Precision) αποτελεί μετρική, η οποία υπολογίζει το ποσοστό των προβλέψεων που συνάδουν με την πραγματική τιμή. Στην κατάτμηση εικόνας υπολογίζεται για κάθε κλάση ξεχωριστά [69] και δίνεται απο την σχέση [70].

$$Precision_k = \frac{TP_k}{TP_k + FP_k} \quad (3.2)$$

Όπου k η αντίστοιχη κλάση.

Έπειτα ορίζεται μια άλλη μετρική, η ανάκληση (Recall). Η ανάκληση υπολογίζει το ποσοστό των δειγμάτων μιας κλάσης τα οποία προβλέφθηκαν σωστά [69]. Δίνεται απο την σχέση [70].

$$Recall_k = \frac{TP_k}{TP_k + FN_k} \quad (3.3)$$

Όπου k η αντίστοιχη κλάση.

Στη συνέχεια, ορίζεται η καμπύλη ακριβείας-ανάκλησης (Precision-Recall Curve). Σχηματίζεται απεικονίζοντας τις τιμές ακριβείας και ανάκλησης για όλες τις δυνατές τιμές του βαθμού εμπιστοσύνης. Ο μέσος όρος ακριβείας προκύπτει υπολογίζοντας το εμβαδόν κάτω της καμπύλης και δίνεται απο την σχέση

$$AP_k = \int_0^1 Precision(Recall) d(Recall) \quad (3.4)$$

Ο μέσος όρος ακριβείας είναι άμεσα συνδεδεμένος με την μετρική IoU, καθώς επηρεάζεται απο την τιμή του κατωφλίου IoU που ορίζεται. Η τιμή αυτή καθορίζει εαν μια πρόβλεψη θεωρείται σωστή ή λανθασμένη. Συγκεκριμένα, όταν το ποσοστό επικάλυψης μεταξύ της μάσκας στόχου και μάσκας πρόβλεψης είναι μεγαλύτερο του κατωφλίου, τότε η πρόβλεψη χαρακτηρίζεται ως σωστή. Αντίστοιχα εάν το ποσοστό επικάλυψης είναι μικρότερο χαρακτηρίζεται ως λανθασμένη [71]. Με αυτό τον τρόπο επηρεάζεται η σύνθεση των συνόλων TP_k , FP_k και FN_k . Κατά συνέπεια, για διαφορετικές τιμές κατωφλίου προκύπτουν διαφορετικές καμπύλες ακριβείας-ανάκλησης.

Η μετρική mAP αποτελεί την μέση τιμή των μέσων όρων ακριβείας (AP) κάθε κλάσης για μια δεδομένη τιμή κατωφλίου της IoU. Υπολογίζεται μέσω της σχέσης

$$mAP = \frac{1}{n} \sum_{k=1}^n AP_k \quad (3.5)$$

Για τον υπολογισμό του τελικού mAP υπολογίζεται η μέση τιμή των mAP για διαφορετικές τιμές του κατωφλίου της IoU. Ενδεικτικά στον διαγωνισμό ανίχνευσης αντικειμένων COCO 2017 [16] η αξιολόγηση βασίστηκε σε συνολικά 10 διαφορετικές τιμές κατωφλίου απο 0.5 εώς 0.95 με βήμα 0.05, καθώς και σε 101 τιμές βαθμών εμπιστοσύνης απο 0 μέχρι 1 με βημα 0.01 [72].


3.2.4 Πανοπτική ποιότητα (Panoptic Quality - PQ)

Σε αντίθεση με τις μετρικές που παρουσιάστηκαν προηγουμένως, η πανοπτική ποιότητα αξιολογεί την πανοπτική κατάτμηση εικόνας στο σύνολο της. Όπως και στον μέσο όρο ακριβείας, έτσι και στην πανοπτική ποιότητα ο καθορισμός σωστών και λανθασμένων προβλέψεων βασίζεται στην ίδια ακριβώς συνθήκη, σύμφωνα με την οποία μια πρόβλεψη θεωρείται σωστή όταν

η επικάλυψη μεταξύ της μάσκας στόχου και της μάσκας πρόβλεψης υπερβαίνει μια προκαθορισμένη τιμή κατωφλίου IoU. Σε αντίθετη περίπτωση χαρακτηρίζεται ως λανθασμένη. Έτσι επηρεάζονται οι τιμές των TP , FP , FN . Η συνθήκη αυτή σε συνδυασμό με την ιδιότητα της μη επικάλυψης εξασφαλίζει μονοσήμαντη αντιστοίχιση μεταξύ των масκών πρόβλεψης και στόχου [71].

Η πιο συνηθισμένη τιμή κατωφλίου που ορίζεται είναι 0.5. Για χαμηλότερες τιμές του κατωφλίου της IoU απαιτούνται διαφορετικές τεχνικές αντιστοίχισης. Ωστόσο, στην πράξη ταιριάσματα με $IoU \leq 0.5$ είναι σπάνια, επομένως χαμηλότερα κατώφλια είναι περιττά.

Η πανοπτική ποιότητα προσδιορίζεται αρχικά για κάθε κατηγορία ξεχωριστά και στη συνέχεια υπολογίζεται ο μέσος όρος κατά μήκος των κατηγοριών. Με αυτό τον τρόπο, καθίσταται ανεπηρέαστη απο ανισοροπία μεταξύ των κλάσεων. Στο σύνολο TP_k περιλαμβάνονται τα ζευγάρια πραγματικών και προβλεπόμενων масκών κλάσης k που αντιστοιχίστηκαν μεταξύ τους. Αντίστοιχα, στο σύνολο FP_k περιλαμβάνονται οι προβλεπόμενες μάσκες κλάσης k που δεν αντιστοιχίστηκαν με καμία μάσκα στόχο, ενώ στο σύνολο FN_k περιλαμβάνονται οι μάσκες στόχοι κλάσης k που δεν αντιστοιχίστηκαν με καμία μάσκα πρόβλεψης. Στο Σχήμα 3.2.2 παρουσιάζεται ενδεικτικό παράδειγμα διαχωρισμού των масκών της κατηγορίας "person" στα σύνολα TP , FN και FP .



Σχήμα 3.2.2: Παράδειγμα διαχωρισμού των τμημάτων της κατηγορίας "person" στα σύνολα TP , FP και FN .

Η πανοπτική ποιότητα ορίζεται για κάθε κατηγορία μέσω της παρακάτω σχέσης.

$$PQ = \frac{\sum_{(p,g) \in TP} IoU(p, g)}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|} \quad (3.6)$$

Η τιμή $\frac{\sum_{(p,g) \in TP} IoU(p, g)}{|TP|}$, αποτελεί τον μέσο όρο των τιμών IoU των ταιριασμένων τμημάτων, ενώ ο όρος $\frac{1}{2}|FP| + \frac{1}{2}|FN|$ προστίθεται στον παρονομαστή για την επιβολή ποινής στα τμήμα-

τα που δεν έχουν ταίριασμα. Παρατηρείται πως κάθε αντιστοιχισμένο τμήμα συμβάλλει το ίδιο στον υπολογισμό της πανοπτικής ποιότητας, ανεξάρτητα από τον αριθμό των εικονοστοιχείων που καταλαμβάνει. Πολλαπλασιάζοντας και διαιρώντας την μετρική με $|TP|$, η πανοπτική ποιότητα μπορεί να γραφεί ως το γινόμενο της ποιότητας κατάτμησης (Segmentation Quality - SQ) και της ποιότητας αναγνώρισης (Recognition Quality - RQ) [71].

$$PQ = \underbrace{\frac{\sum_{(p,g) \in TP} \text{IoU}(p, g)}{|TP|}}_{\text{segmentation quality (SQ)}} \times \underbrace{\frac{|TP|}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}}_{\text{recognition quality (RQ)}} \quad (3.7)$$

Προκειμένου να υπολογιστεί η συνολική πανοπτική ποιότητα, υπολογίζεται ο μέσος όρος της πανοπτικής ποιότητας κατά μήκος όλων των κατηγοριών [71].

$$PQ_{\text{overall}} = \frac{1}{C} \sum_{c=1}^C PQ_c \quad (3.8)$$

Περιορίζοντας τις μετρικές PQ, SQ και RQ αποκλειστικά στις κατηγορίες "αντικειμένων", προκύπτουν οι μετρικές PQ_{th} , SQ_{th} και RQ_{th} . Αντίστοιχα, περιορίζοντας στις κατηγορίες "σκηνικών" στοιχείων προκύπτουν οι PQ_{st} , SQ_{st} και RQ_{st} . Οι μετρικές αυτές χρησιμοποιούνται για την αξιολόγηση της απόδοσης στην σημασιολογική κατάτμηση και την κατάτμηση αντικειμένων [17].

Οι κενές ετικέτες (Void Labels) δηλώνουν σε επίπεδο εικονοστοιχείου τις περιοχές της εικόνας που δεν αντιστοιχούν σε κάποιο "αντικείμενο" ή "σκηνικό" στοιχείο. Στις επισημειωμένες εικόνες, οι κενές ετικέτες αποδίδονται είτε σε εικονοστοιχεία που είναι ασαφή και είναι δύσκολο να ταξινομηθούν, είτε σε εικονοστοιχεία που δεν υπάγονται σε καμία από τις κατηγορίες "αντικειμένων" ή "σκηνικών" στοιχείων του προβλήματος. Αυτά τα εικονοστοιχεία δεν λαμβάνονται υπόψη στην αξιολόγηση. Συγκεκριμένα, κατά την διαδικασία αντιστοίχισης μεταξύ των масκών πρόβλεψης και στόχου, τα κενά εικονοστοιχεία αφαιρούνται και δεν λαμβάνονται υπόψη στον υπολογισμό της IoU. Επιπλέον, οι μάσκες πρόβλεψης που δεν αντιστοιχίστηκαν με καμία μάσκα στόχο και για τις οποίες το ποσοστό των εικονοστοιχείων τους που αντιστοιχούν σε κενές ετικέτες στην εικόνα αναφοράς υπερβαίνει το κατώφλι IoU, εξαιρούνται και δεν λαμβάνονται υπόψη στην αξιολόγηση. Εκτός από τις επισημειωμένες εικόνες, κενές ετικέτες μπορούν να εμφανιστούν και στις προβλέψεις. Η περίπτωση αυτή αντιστοιχεί σε εικονοστοιχεία στα οποία η μέθοδος δεν απέδωσε καμία κατηγορία "αντικειμένου" ή "σκηνικού" στοιχείου. Τα εικονοστοιχεία αυτά εξαιρούνται από τη διαδικασία αξιολόγησης.


Οι ετικέτες ομάδας (Group Labels) δηλώνουν σε επίπεδο εικονοστοιχείου περιοχές της εικόνας όπου υπάρχει πλήθος όμοιων "αντικειμένων" συγκεντρωμένο και είναι δύσκολος ο διαχωρισμός τους σε ξεχωριστά "αντικείμενα". Στην πανοπτική ποιότητα αντιμετωπίζονται με τον ίδιο ακριβώς τρόπο όπως και οι κενές ετικέτες [71].

4 Σχετική έρευνα

4.1 State-of-the-art στο σύνολο δεδομένων COCO

4.1.1 Mask DINO


Το Mask DINO [73] συνιστά μοντέλο βασισμένο στους μετασχηματιστές και αποτελεί επέκταση του DINO [74]. Το DINO είχε αρχικά σχεδιαστεί για ανίχνευση αντικειμένων και δεν αποδείχθηκε ιδιαίτερα αποδοτικό σε εργασίες κατάτμησης εικόνας. Αντίστοιχα, εξειδικευμένα μοντέλα κατάτμησης εικόνας όπως το Mask2Former [62] δεν παρουσίασαν την ίδια αποδοτικότητα σε εργασίες ανίχνευσης αντικειμένων. Σε αντίθεση με αυτά, το Mask DINO επέτρεψε πέρα από την ανίχνευση αντικειμένων, την αποδοτική εκτέλεση εργασιών όπως η σημασιολογική κατάτμηση εικόνας, η κατάτμηση αντικειμένων και η πανοπτική κατάτμηση εικόνας, μέσω μιας ενιαίας αρχιτεκτονικής. Στο πλαίσιο αυτό, το Mask DINO ενσωματώνει ένα μηχανισμό παραγωγής μασκών, ο οποίος δύναται να παράγει μάσκες για κάθε εργασία κατάτμησης εικόνας. Ο μηχανισμός αυτός χρησιμοποιεί τις ενσωματώσεις (Embeddings) του πίνακα query και τις συγκρίνει στη συνέχεια με κάθε χάρτη χαρακτηριστικών που παράγεται από τον εξαγωγέα χαρακτηριστικών. Με αυτό τον τρόπο, για κάθε query κατασκευάζεται μια μάσκα πιθανότητας, η οποία υποδεικνύει ποια εικονοστοιχεία της εικόνας σχετίζονται με την κλάση που εκπροσωπεί. Στην εργασία της πανοπτικής κατάτμησης εικόνας το Mask DINO σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Swin-L [75] πέτυχε πανοπτική ποιότητα ίση με 59.5 στο σύνολο δεδομένων δοκιμής του COCO [16].



Σχήμα 4.1.1: Αρχιτεκτονική μοντέλου Mask DINO

4.1.2 kMaX-DeepLab

Το kMaX-DeepLab [76] αποτελεί μοντέλο βασισμένο στους μετασχηματιστές, το οποίο επαναπροσδιορίζει την σχέση μεταξύ των διανυσμάτων χαρακτηριστικών των εικονοστοιχείων και των queries του πίνακα query, μέσα από την οπτική του αλγόριθμου ομαδοποίησης k-means. Ο επαναπροσδιορισμός αυτός βασίζεται στην ισχυρή ομοιότητα που παρουσιάζεται μεταξύ του αλγορίθμου k-means και της διασταυρούμενης προσοχής (Cross-Attention), εάν θεωρηθούν τα queries ως κέντρα ομάδων. Με βάση αυτή την παρατήρηση, στο kMaX-DeepLab αντικαθίσταται η συνάρτηση Softmax που χρησιμοποιείται στην διασταυρούμενη προσοχή με την συνάρτηση argmax, η οποία εφαρμόζεται στην διάσταση των κεντρών των ομάδων, όπως γίνεται στην ανάθεση ενός στοιχείου σε ομάδα στον αλγόριθμο k-means. Στη συνέχεια, τα κέντρα των ομάδων ενημερώνονται με βάση τα διανύσματα χαρακτηριστικών των εικονοστοιχείων που τους έχουν ανατεθεί, με τρόπο όμοιο με την ενημέρωση των κεντρών στον αλγόριθμο k-means. Η μετα-αρχιτεκτονική του μοντέλου kMaX-DeepLab αποτελείται από ένα κωδικοποιητή εικονοστοιχείων, ένα αποκωδικοποιητή εικονοστοιχείων και τον αποκωδικοποιητή kMaX. Ο κωδικοποιητής εικονοστοιχείων μπορεί να είναι οποιοσδήποτε εξαγωγέας χαρακτηριστικών, ενώ ο αποκωδικοποιητής kMaX αντιστοιχεί στον μηχανισμό που περιγράφηκε παραπάνω. Τέλος, ο αποκωδικοποιητής εικονοστοιχείων προβάλλει τα διανύσματα χαρακτηριστικών σε χώρους μεγαλύτερης διάστασης, βελτιώνοντας με αυτό τον τρόπο την εκφραστικότητα τους. Στα πλαίσια της πανοπτικής κατάτμησης εικόνας, το μοντέλο kMaX-DeepLab σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών ConvNeXt-L [77] πέτυχε πανοπτική ποιότητα ίση με 58.5 στο σύνολο δεδομένων δοκιμής του COCO [16].



Σχήμα 4.1.2: Μετα-αρχιτεκτονική μοντέλου kMaX-DeepLab

4.2 State-of-the-art στο σύνολο δεδομένων Cityscapes


4.2.1 Scaling Wide Residual Networks

Το Scaling Wide Residual Network (SWideRNet) [78] αποτελεί μοντέλο σχεδιασμένο για την εργασία της πανοπτικής κατάτμησης εικόνας και συνιστά παραλλαγή του δικτύου Wide Residual

Network (Wide-ResNet) [79]. Συγκεκριμένα, η αρχιτεκτονική του βασίζεται στο Wide-ResNet-41 [79] στο οποίο ενσωματώνει δύο βελτιώσεις, την Squeeze-and-Excitation η οποία εισάγει προσοχή κατά μήκος των καναλιών του χάρτη χαρακτηριστικών και την συνέλιξη με δυναμικά επιλέξιμη διάτρηση (Switchable Atrous Convolution), η οποία επιτρέπει δυναμική επιλογή της διάτρησης της συνελκτικής πράξης μέσω προσαρμογής του πεδίου αποδοχής του πυρήνα. Η συνέλιξη αυτή, αποτελεί παραλλαγή της κλασικής συνέλιξης, καθώς εισάγει κενά μεταξύ των στοιχείων του πυρήνα, επιτρέποντας την αύξηση του πεδίου αποδοχής χωρίς την προσθήκη επιπλέον παραμέτρων. Απο αυτή την βάση, το δίκτυο μπορεί να κλιμακωθεί ανά πλάτος, μεταβάλλοντας τον αριθμό των καναλιών των residual blocks και ανά βάθος, μεταβάλλοντας το πλήθος τους. Η δυνατότητα αυτή δημιουργεί ένα μεγάλο χώρο σχεδιασμού, ο οποίος εξερευνάται μέσω αναζήτησης πλέγματος (Grid Search) με σκοπό τον εντοπισμό των βέλτιστων αρχιτεκτονικών σε δύο διακριτές κατηγορίες. Η πρώτη κατηγορία δίνει μεγαλύτερη προτεραιότητα στην ταχύτητα διατηρώντας παράλληλα υψηλή ακρίβεια, ενώ η δεύτερη επικεντρώνεται στην ακρίβεια του μοντέλου. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας το Scaling Wide Residual Network χρησιμοποιείται ως εξαγωγέας χαρακτηριστικών και σε συνδυασμό με το Panoptic DeepLab [81] έχει πετύχει πανοπτική ποιότητα ίση με 68.5 στο σύνολο δεδομένων δοκιμής του Cityscapes [12].

Στάδιο	Διαστάσεις εισόδου	Διαστάσεις εξόδου	WR-41	SWideRNet- (w_1, w_2, ℓ)
conv1	224×224	112×112	$3 \times 3, 64, \text{stride } 2$	$3 \times 3, 64 \times w_1, \text{stride } 2$
conv2	112×112	56×56	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 3$	$\begin{bmatrix} 3 \times 3, 128 \times w_1 \\ 3 \times 3, 128 \times w_1 \end{bmatrix} \times 3$
			$3 \times 3 \text{ max-pool, stride } 2$	
conv3	56×56	28×28	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 3 \times 3, 256 \times w_2 \\ 3 \times 3, 256 \times w_2 \\ SE \end{bmatrix} \times 3\ell$
conv4	28×28	14×14	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 6$	$\begin{bmatrix} 3 \times 3, 512 \times w_2 \\ 3 \times 3, 512 \times w_2 \\ SE \end{bmatrix} \times 6\ell$
conv5	14×14	7×7	$\begin{bmatrix} 3 \times 3, 1024 \\ 3 \times 3, 1024 \end{bmatrix} \times 3$	$\begin{bmatrix} 3 \times 3, 1024 \times w_2 \\ 3 \times 3, 1024 \times w_2 \\ SE \end{bmatrix} \times 3\ell$
conv6	7×7	7×7	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 1024 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \times w_2 \\ 3 \times 3 \text{ SAC, } 1024 \times w_2 \\ 1 \times 1, 2048 \times w_2 \\ SE \end{bmatrix} \times 3\ell$
	7×7	1×1	average-pool, 1000-d fc, softmax	

Πίνακας 1: Σύγκριση αρχιτεκτονικών Wide-ResNet-41 και SWideRNet



Σχήμα 4.2.1: Αρχιτεκτονικές τεχνικών (a) Squeeze-and-Excitation, (b) Switchable Atrous Convolution


4.2.2 Naive-Student

Η Naive-Student [82] αποτελεί μέθοδο εκπαίδευσης, η οποία αξιοποιεί τόσο δεδομένα με ετικέτες, όσο και δεδομένα χωρίς ετικέτες. Στόχος της αποτελεί η βελτίωση της διαδικασίας εκπαίδευσης στις εργασίες κατάτμησης εικόνας, σε περιπτώσεις που το σύνολο εκπαίδευσης αποτελείται από ακολουθίες βίντεο αστικών σκηνών. Πολλές φορές στα σύνολα δεδομένων βίντεο, μόνο ένα μικρό μέρος των καρέ είναι επισημειωμένο, ενώ ο υπόλοιπος όγκος παραμένει αναξιοποίητος. Η αξιοποίηση αυτού του ανεκμετάλλευτου όγκου δεδομένων μπορεί να βελτιώσει σημαντικά την αποδοτικότητα των μεθόδων. Μια προσέγγιση για την αξιοποίηση τους αποτελεί η Naive-Student. Η μέθοδος ξεκινά με την εκπαίδευση ενός μοντέλου Δασκάλου στα διαθέσιμα επισημειωμένα δεδομένα, το οποίο στη συνέχεια χρησιμοποιείται για την παραγωγή "ψευδο"-ετικετών για τα καρέ τα οποία δεν είναι επισημειωμένα. Έπειτα, ένα μοντέλο Μαθητής, συνήθως με ισχυρότερη αρχιτεκτονική, εκπαιδεύεται αξιοποιώντας ολόκληρο το διαθέσιμο σύνολο δεδομένων και στη συνέχεια βελτιστοποιείται αποκλειστικά με βάση τα επισημειωμένα δείγματα. Στην επόμενη επανάληψη το μοντέλο Μαθητής αντικαθιστά το μοντέλο Δάσκαλος, με στόχο να παράξει βελτιωμένες "ψευδο"-ετικέτες για τα ήδη "ψευδο"-επισημειωμένα δεδομένα. Η διαδικασία αυτή επαναλαμβάνεται, βελτιώνοντας σταδιακά την ποιότητα των επισημειώσεων, όπως και την απόδοση του μοντέλου. Με το πέρας των επαναλήψεων, το τελικό μοντέλο Μαθητής αποτελεί το αποτέλεσμα της μεθόδου. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας η μέθοδος εκπαίδευσης Naive-Student σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Xception-71 [83] ως μοντέλο Δάσκαλο, τον εξαγωγέα χαρακτηριστικών Wide ResNet-41 [78] ως μοντέλο Μαθητή και το Panoptic-DeePLab [81] ως κεφαλή πανοπτικής κατάτμησης πέτυχε πανοπτική ποιότητα ίση με 67.8 στο σύνολο δεδομένων δοκιμής του Cityscapes [12].

4.3 State-of-the-art στο σύνολο δεδομένων ADE20K

4.3.1 OneFormer

Το OneFormer [84] αποτελεί μοντέλο βασισμένο στους μετασχηματιστές, το οποίο είναι σε θέση να εκτελέσει και τις τρεις βασικές εργασίες κατάρτισης εικόνας, μέσω μιας ενιαίας αρχιτεκτονικής, ενός ενιαίου μοντέλου και μιας ενιαίας διαδικασίας εκπαίδευσης. Η ενιαία αυτή διαδικασία εκπαίδευσης και για τις τρεις βασικές εργασίες κατάρτισης εικόνας μειώνει σημαντικά το υπολογιστικό κόστος, όπως και τον απαιτούμενο αποθηκευτικό χώρο. Η αρχιτεκτονική του OneFormer περιλαμβάνει μεταξύ άλλων ένα εξαγωγέα χαρακτηριστικών και ένα αποκωδικοποιητή εικονοστοιχείων, οι οποίοι έχουν ως σκοπό την εξαγωγή χαρακτηριστικών πολλαπλών διαστάσεων από την εικόνα. Αφού πραγματοποιηθεί η εξαγωγή χαρακτηριστικών, παράγονται queries αντίστοιχα τις εργασίες που πραγματοποιείται, τα οποία στη συνέχεια επεξεργάζεται ο αποκωδικοποιητής μετασχηματισμού (Transformer Decoder). Για την τελική πρόβλεψη το μοντέλο παράγει με δυναμικό τρόπο μάσκες και κατηγορίες προσαρμοσμένες στην εκάστοτε εργασία. Στο πλαίσιο της πανοπτικής κατάρτισης εικόνας το OneFormer σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών InternImage-H [85] πέτυχε πανοπτική ποιότητα ίση με 54.5 στο σύνολο δεδομένων επικύρωσης του ADE20K [66].




Σχήμα 4.3.1: Αρχιτεκτονική OneFormer

4.3.2 OpenSeeD

Το OpenSeeD [86] αποτελεί μοντέλο βασισμένο στους μετασχηματιστές, σχεδιασμένο με τρόπο που του επιτρέπει την εκτέλεση όλων των βασικών εργασιών κατάρτισης εικόνας, καθώς και ανίχνευση αντικειμένων. Δύναται να εκπαιδευτεί τόσο από δεδομένα ανίχνευσης αντικειμένων όσο και από δεδομένα κατάρτισης εικόνας και βασική του ιδιότητα αποτελεί η δυνατότητα αξιοποίησης των δεδομένων της μιας εργασίας για την εκπαίδευση όχι μόνο της ίδιας αλλά και της άλλης. Η δυνατότητα αυτή επιτρέπει στο μοντέλο την αναγνώριση και τμηματοποίηση στοιχείων της εικόνας, πέρα από το κλειστό λεξιλόγιο του συνόλου εκπαίδευσης. Αποτελείται από ένα κωδικοποιητή εικόνας (Image Encoder), ένα κωδικοποιητή κειμένου (Text Encoder)

και ένα αποκωδικοποιητή, ο οποίος μπορεί να χειριστεί τόσο "αντικείμενα" όσο και "σκηνικά" στοιχεία, ενώ έχει την δυνατότητα παραγωγής δυαδικών масκών για τα "αντικείμενα" που προκύπτουν απο τα πλαίσια του συνόλου δεδομένων ανίχνευσης, αξιοποιώντας μηχανισμούς αυτοπροσοχής και διασταυρούμενης προσοχής. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας το OpenSeeD σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Swin-L [75] πέτυχε πανοπτική ποιότητα ίση με 53.7 στο σύνολο δεδομένων επικύρωσης του ADE20K [66].




Σχήμα 4.3.2: Αρχιτεκτονική OpenSeed

4.4 Θεμελιώδεις έρευνες στην πανοπτική κατάτμηση εικόνας

4.4.1 Panoptic-DeepLab

Το Panoptic-DeepLab [81] αποτελεί μοντέλο πανοπτικής κατάτμησης εικόνας και μια απο της σημαντικότερες εργασίες στον τομέα αυτό. Τα περισσότερα μοντέλα πανοπτικής κατάτμησης της περιόδου βασίζονταν στην αρχική ανίχνευση αντικειμένων και στην εν συνέχεια ανάθεση κάθε εικονοστοιχείου της εικόνας σε κάποιο "αντικείμενο" ή "σκηνικό" στοιχείο. Σε αντίθεση με αυτό, το Panoptic-DeepLab δεν προσεγγίζει την εργασία με αυτό τον τρόπο. Το Panoptic-DeepLab ξεκινά με την απόδοση σημασιολογικών κατηγοριών σε κάθε εικονοστοιχείο της εικόνας και στη συνέχεια πραγματοποιεί διάκριση μεταξύ των "αντικειμένων" που ανήκουν στην ίδια κατηγορία. Συγκεκριμένα, για κάθε εικονοστοιχείο που αντιστοιχεί σε "αντικείμενο" προβλέπει το κέντρο του αντίστοιχου "αντικειμένου", όπως και την μετατόπιση που πρέπει να κάνει για να φτάσει εκεί. Η αρχιτεκτονική του Panoptic-DeepLab αποτελείται απο 4 βασικά μέρη. Πρώτα χρησιμοποιείται ένας εξαγωγέας χαρακτηριστικών κωδικοποιητή (Encoder Backbone) ο οποίος αξιοποιείται τόσο στη σημασιολογική κατάτμηση όσο και στην κατάτμηση αντικειμένων. Μετέπειτα αυτού, η διαδικασία χωρίζεται σε 2 διακριτές διακλαδώσεις, με την μία να είναι υπεύθυνη για την εκτέλεση σημασιολογικής κατάτμησης και την άλλη για την εκτέλεση κατάτμησης αντικειμένων. Κάθε διακλάδωση αποτελείται απο ένα μηχανισμό Atrous Spatial Pyramid Pooling, που έχει ως σκοπό την εξαγωγή χαρακτηριστικών απο τις εικόνες σε διαφορετικές κλίμακες μέσω διατρητών συνελίξεων, ένα αποκωδικοποιητή ο οποίος προβάλλει τα


χαρακτηριστικά του χάρτη χαρακτηριστικών σε υψηλότερες διαστάσεις και μια κεφαλή πρόβλεψης, από τις οποίες η μια παράγει τον χάρτη σημασιολογικής πρόβλεψης ενώ η άλλη προβλέπει τα κέντρα των "αντικειμένων" και τα διανύσματα μετατόπισης των εικονοστοιχείων προς αυτά. Τέλος, τα αποτελέσματα των 2 διακλαδώσεων συνδυάζονται για την παραγωγή της πανοπτικής κατάτμησης.



Σχήμα 4.4.1: Αρχιτεκτονική μοντέλου Panoptic-DeepLab

4.4.2 UPSNet


Το UPSNet [87] αποτελεί μοντέλο πανοπτικής κατάτμησης εικόνας. Οι πλειοψηφία των μοντέλων πανοπτικής κατάτμησης που προηγήθηκαν του μοντέλου αυτού βασίζονταν συνήθως στον συνδυασμό των εξόδων ενός μοντέλου σημασιολογικής κατάτμησης εικόνας και της εξόδου ενός μοντέλου κατάτμησης αντικειμένων, μέσω κάποιων προκαθορισμένων κανόνων συνδυασμού, οι οποίοι δεν αποτελούσαν μέρος του μοντέλου αλλά εφαρμόζονταν ως ξεχωριστό στάδιο επεξεργασίας. Έτσι, ο συνδυασμός αυτός δεν μπορούσε να βελτιστοποιηθεί μέσω εκπαίδευσης, περιορίζοντας έτσι τις δυνατότητες και την ταχύτητα αυτών των συστημάτων. Το UPSNet εισήγαγε μια ενιαία αρχιτεκτονική, η οποία παρόλο που διατήρησε τις διακλαδώσεις των δύο μοντέλων σημασιολογικής κατάτμησης και κατάτμησης αντικειμένων συνδυάζει τα αποτελέσματά τους μέσω μιας πανοπτικής κεφαλής, επιτρέποντας έτσι ταχύτερη εξαγωγή αποτελεσμάτων. Η αρχιτεκτονική του UPSNet αποτελείται από τον εξαγωγέα χαρακτηριστικών, που στην συνέχεια χωρίζεται σε 2 διακλαδώσεις, στην διακλάδωση της σημασιολογικής κατάτμησης εικόνας και στην διακλάδωση της κατάτμησης αντικειμένων. Η διακλάδωση κατάτμησης αντικειμένων αντιστοιχεί στην κεφαλή του Mask R-CNN [88]. Ο εξαγωγέας χαρακτηριστικών είναι ενιαίος για τις 2 εργασίες και βασίζεται στην αρχιτεκτονική των Residual Networks (ResNets) [80], όπου σε συνδυασμό με το Feature Pyramid Network [89] παράγει πολυκλιμακωτά χαρακτηριστικά. Τέλος, τα αποτελέσματα των 2 διακλαδώσεων συνδυάζονται μέσω μιας πανοπτικής κεφαλής, χωρίς παραμέτρους η οποία παράγει την πανοπτική κατάτμηση της εικόνας.



Σχήμα 4.4.2: Αρχιτεκτονική μοντέλου UPSNet

4.4.3 Max-DeepLab

Το Max-DeepLab [90] αποτελεί ένα από τα σημαντικότερα μοντέλα στην πανοπτική κατάτμηση εικόνας. Τα κλασικά συστήματα της περιόδου αυτής ήταν κυρίως βασισμένα σε διαδικασίες με πολλά ενδιάμεσα βήματα, όπως η ανίχνευση των πλαισίων των "αντικειμένων" και ο συνδυασμός των διαφόρων βημάτων μεταξύ τους, ώστε να παραχθεί το τελικό αποτέλεσμα. Αν και κάθε στάδιο μπορούσε να βελτιστοποιηθεί μεμονωμένα, η προσέγγιση αυτή δεν επέτρεπε την ταυτόχρονη, συνολική βελτιστοποίηση του συστήματος. Το Max-DeepLab διαφοροποιείται από αυτά τα συστήματα εισάγοντας μια ενιαία αρχιτεκτονική κατάτμησης εικόνας, η οποία δεν συμπεριλαμβάνει πολύπλοκα ενδιάμεσα στάδια. Η αρχιτεκτονική του περιλαμβάνει ένα μετασχηματιστή διπλής διαδρομής (Dual-Path Transformer), ένα αποκωδικοποιητή και μια κεφαλή εξόδου, η οποία προβλέπει τις μάσκες και κλάσεις της εικόνας εισόδου. Το μοντέλο αποτελείται από 2 διακλάδωσεις, την διακλάδωση των εικονοστοιχείων, η οποία εξάγει λεπτομερή χαρακτηριστικά χαμηλού επιπέδου όπως σχήματα και ακμές και την διακλάδωση μνήμης, η οποία εξάγει πληροφορίες από την εικόνα σε επίπεδο αντικειμένου. Αυτές οι 2 διακλάδωσεις επικοινωνούν μέσω των μετασχηματιστών διπλής διαδρομής. Η διακλάδωση εικονοστοιχείων ενημερώνει την διακλάδωση μνήμης με πιο λεπτομερείς πληροφορίες ενώ η διακλάδωση μνήμης την διακλάδωση εικονοστοιχείων για το ποιο αντικείμενο αντιστοιχεί σε κάθε συνδυασμό σχημάτων, ακμών κ.ο.κ.. Ο αποκωδικοποιητής λειτουργεί συνδυάζοντας χαρακτηριστικά πολλών κλιμάκων της εικόνας και προβάλλοντας τα σε μεγαλύτερες διαστάσεις, με σκοπό την αποκατάσταση των λεπτομερειών και τον σαφή διαχωρισμό των σχημάτων και των ορίων τους στην εικόνα. Τέλος, οι κεφαλές εξόδου αποτελούν το τελευταίο στάδιο του μοντέλου και είναι υπεύθυνες για τη μετατροπή της επεξεργασμένης πληροφορίας σε τελικές προβλέψεις. Συγκεκριμένα, η μία κεφαλή αξιοποιεί τις ενσωματώσεις στην διακλάδωση μνήμης για να αποδώσει σε κάθε στοιχείο την αντίστοιχη κατηγορία, ενώ η άλλη χρησιμοποιεί τα χαρακτηριστικά που παράγονται από τον αποκωδικοποιητή για να καθορίσει ποια εικονοστοιχεία της εικόνας συνδέονται με κάθε κατηγορία. Συνδυάζοντας τις εξόδους των δύο κεφαλών προκύπτει το τελικό αποτέλεσμα.



Σχήμα 4.4.3: Αρχιτεκτονική μοντέλου Max-DeepLab

5 Συμβολή της εργασίας

Η εργασία βασίζεται στον εξαγωγέα χαρακτηριστικών Visual Attention Network (VAN). Για τον λόγο αυτό, αρχικά θα παρουσιαστεί εκτενώς η αρχιτεκτονική και τα βασικά του στοιχεία, ώστε να γίνει κατανοητή η λειτουργία του. Στη συνέχεια, θα περιγραφούν αναλυτικά οι τροποποιήσεις και οι επεκτάσεις που υλοποιήθηκαν στο πλαίσιο της παρούσας εργασίας.

5.1 Visual Attention Network - VAN


Το Visual Attention Network [91] αποτελεί εξαγωγέα χαρακτηριστικών (Feature Extractor) στην όραση υπολογιστών, σχεδιασμένο για να συνδυάζει τα πλεονεκτήματα των συνελκτικών νευρωνικών δικτύων και των μηχανισμών αυτο-προσοχής, αποφεύγοντας όμως τα μειονεκτήματά τους. Το δίκτυο αυτό δημιουργήθηκε γύρω από έναν νέο μηχανισμό αυτο-προσοχής που ονομάζεται Large Kernel Attention (LKA). Η αυτο-προσοχή, παρόλο που είχε σχεδιαστεί για να αντιμετωπίσει προβλήματα επεξεργασίας φυσικής γλώσσας, στη συνέχεια χρησιμοποιήθηκε ευρέως σε πολλές εργασίες της όρασης υπολογιστών. Ωστόσο, λόγω της δισδιάστατης φύσης των εικόνων, η εισαγωγή της αυτο-προσοχής σε οπτικά δεδομένα συνοδεύτηκε από συγκεκριμένα προβλήματα.

- Η αντιμετώπιση των εικόνων ως μονοδιάστατες ακολουθίες αγνοεί την δισδιάστατη φύση τους.
- Η υπολογιστική πολυπλοκότητα $O(n^2)$ των μηχανισμών αυτο-προσοχής είναι υπερβολικά υψηλή για εικόνες υψηλής ανάλυσης.
- Οι συμβατικοί μηχανισμοί αυτο-προσοχής εστιάζουν αποκλειστικά στη χωρική αλληλεπίδραση μεταξύ των εικονοστοιχείων, αγνοώντας τη σημασία της αλληλεπίδρασης μεταξύ διαφορετικών καναλιών. Συχνά, διαφορετικά κανάλια σε μια εικόνα αναπαριστούν διαφορετικά αντικείμενα.

Λύση στα παραπάνω προβλήματα επιχειρεί να δώσει ο Large Kernel Attention που παρόλο που μπορεί να λειτουργεί ως μηχανισμός αυτο-προσοχής, δεν κληρονομεί τα αντίστοιχα προβλήματα. Η βασική ιδέα πίσω από αυτό αποτελεί η χρήση συνέλιξης μεγάλου πυρήνα έτσι ώστε να μπορούμε να υπολογίσουμε τις σχέσεις μεταξύ εικονοστοιχείων που έχουν μεγάλη απόσταση μεταξύ τους και στην συνέχεια να κατασκευάσουμε τον χάρτη προσοχής (Attention map). Ωστόσο, η χρήση συνέλιξης με μεγάλο πυρήνα απαιτεί μεγάλη υπολογιστική πολυπλοκότητα και σημαντικό αριθμό παραμέτρων. Για την αντιμετώπιση αυτού του προβλήματος το Large Kernel Attention χρησιμοποιεί μια αποσυνθεμένη μορφή της συνέλιξης έτσι ώστε να

αποφευχθεί η μεγάλη υπολογιστική πολυπλοκότητα που απαιτείται. Συγκεκριμένα, μια συνελκτική πράξη μπορεί να αποσυντεθεί σε τρία μέρη, μια χωρική συνέλιξη μικρών διαστάσεων για την καταγραφή των τοπικών συσχετίσεων, μια διευρυμένη χωρική συνέλιξη για την καταγραφή μακρινών σχέσεων και μια συνελκτική πράξη μεταξύ των καναλιών, η οποία καταγράφει την συσχέτιση μεταξύ των καναλιών.

Πιο συγκεκριμένα, με βάση το [91] μια συνελκτική πράξη με μεγάλο πηρύνια διαστάσεων $K \times K$ αποσυντίθεται σε μια $\lceil \frac{K}{d} \rceil \times \lceil \frac{K}{d} \rceil$ χωρική συνέλιξη με συντελεστή απόστασης d , μια $(2d - 1) \times (2d - 1)$ χωρική συνέλιξη και μια 1×1 συνέλιξη η οποία λαμβάνει την συσχέτιση μεταξύ των καναλιών. Μέσω αυτής της αποσύνθεσης δύναται να ληφθούν συσχετίσεις μεταξύ στοιχείων που έχουν μεγάλη απόσταση μεταξύ τους χωρίς όμως να επιβαρύνεται σημαντικά η υπολογιστική πολυπλοκότητα ή να αυξάνεται ο αριθμός των παραμέτρων του μοντέλου.



Σχήμα 5.1.1: Αποσύνθεση συνελκτικών πράξεων LKA για $K = 7$ και $d = 2$

Η μέθοδος που περιγράφηκε παραπάνω μπορεί να γραφεί με τρόπο που φαίνεται στην συνέχεια.


$$Attention = \text{Conv}_{1 \times 1}(\text{DW-D-Conv}(\text{DW-Conv}(F))) \quad (5.1)$$

$$Output = Attention \otimes F \quad (5.2)$$

όπου $F \in \mathbb{R}^{C \times H \times W}$ η είσοδος. Ισχύει πως $Attention \in \mathbb{R}^{C \times H \times W}$ και αντιστοιχεί στον χάρτη προσοχής (Attention Map). Η τιμή σε κάθε θέση του χάρτη εκφράζει το πόσο σημαντικό είναι το αντίστοιχο χαρακτηριστικό. Ο τελεστής $\otimes$ αντιστοιχεί στον πολλαπλασιασμό ανά στοιχείο.

Στη συνέχεια θα ορίσουμε το Visual Attention Network. Ο μηχανισμός LKA που περιγράψαμε παραπάνω αποτελεί επιμερές στοιχείο του VAN. Το VAN αποτελείται από 4 στάδια. Έστω $H \times W$ οι χωρικές διαστάσεις της εικόνας εισόδου. Πριν από κάθε στάδιο οι χωρικές διαστάσεις της εισόδου μειώνονται μέσω μιας συνελκτικής πράξης με βήμα. Η μείωση των χωρικών

διαστάσεων εξαρτάται απο το στάδιο το οποίο βρίσκεται το μοντέλο. Συγκεκριμένα, οι χωρικές διαστάσεις της εικόνας μειώνονται πριν απο το πρώτο στάδιο σε $\frac{H}{4} \times \frac{W}{4}$, πριν απο το δεύτερο σε $\frac{H}{8} \times \frac{W}{8}$, πριν απο το τρίτο σε $\frac{H}{16} \times \frac{W}{16}$ και πριν απο το τέταρτο σε $\frac{H}{32} \times \frac{W}{32}$. Ο αριθμός των καναλιών C εξαρτάται απο τον τύπο VAN που χρησιμοποιείται. Υπάρχουν 7 διαφορετικοί τύποι VAN. Ενδεικτικά για το VAN-B0 έχουμε στο πρώτο στάδιο C = 32, στο δεύτερο C = 64, στο τρίτο C = 160 και στο τέταρτο C = 256. Μετά την μείωση των διαστάσεων της εισόδου, καθόλη την διάρκεια του σταδίου τόσο οι χωρικές διαστάσεις όσο και η διάσταση των καναλιών C παραμένουν σταθερές. Μετά απο κάθε μείωση διαστάσεων της εισόδου, η έξοδος περνά μέσα απο L διαδοχικές ομάδες όπου η κάθε μια περιλαμβάνει στοιχεία όπως κανονικοποίηση παρτίδας, συνελίξεις, συνάρτηση ενεργοποίησης GeLU, μηχανισμό προσοχής και πλήρως συνδεδεμένο δίκτυο. Οι L αυτές ομάδες συγκροτούν ένα πλήρες στάδιο του Visual Attention Network. Ο αριθμός L εξαρτάται απο το παρών στάδιο όπως και απο τον τύπο του μοντέλου VAN που χρησιμοποιείται. Ενδεικτικά για το VAN-B0 στο πρώτο και στο δεύτερο στάδιο ορίζεται η τιμή L = 3, στο τρίτο L = 5 και στο τέταρτο L = 2. Ένα πλήρες στάδιο VAN παρουσιάζεται στην εικόνα παρακάτω.



Σχήμα 5.1.2: Αρχιτεκτονική ενός σταδίου του VAN

Στο συγκεκριμένο άρθρο χρησιμοποιείται η τιμή K = 21 ως προεπιλογή. Για την τιμή αυτή το πλήθος των παραμέτρων ελαχιστοποιείτε ορίζοντας d = 3. Ο συνδυασμός αυτός αντιστοιχεί σε μια 5 x 5 χωρική συνέλιξη και μια 7 x 7 χωρική συνέλιξη με συντελεστή απόστασης ίσο με 3.

6 Πειραματικά αποτελέσματα

Για την επίτευξη του τελικού μοντέλου πραγματοποιήθηκε πλήθος πειραμάτων για διάφορες παραλλαγές του VAN. Οι παραλλαγές αυτές περιελάβαναν τροποποιήσεις στην αρχιτεκτονική, όπως και στην αρχικοποίηση των παραμέτρων, με σκοπό την διερεύνηση της επίδρασης τους στην απόδοση. Μέσα από την συγκριτική αξιολόγηση των αποτελεσμάτων εντοπίστηκαν οι πλέον αποτελεσματικές εκδοχές, οι οποίες αξιοποιήθηκαν για τη διαμόρφωση του τελικού μοντέλου.

6.1 Γενικό πλαίσιο

Τα πειραματικά αποτελέσματα βασίστηκαν στον πηγαίο κώδικα του Mask2Former, το οποίο κάνει χρήση της βιβλιοθήκης Detectron2. Τα πειράματα πραγματοποιήθηκαν στο σύνολο δεδομένων Cityscapes.

6.1.1 Παράμετροι εκπαίδευσης

Στην αυθεντική υλοποίηση γίνεται χρήση 8 καρτών γραφικών και μέγεθος παρτίδας ίσο με 16. Ωστόσο, λόγω περιορισμένης υπολογιστικής ισχύς, στην παρούσα υλοποίηση χρησιμοποιήθηκε 1 κάρτα γραφικών και μέγεθος παρτίδας ίσο με 2. Η κάρτα γραφικών που χρησιμοποιείται είναι η NVIDIA GeForce RTX 4070. Στην αυθεντική υλοποίηση ο ρυθμός μάθησης είναι ίσος με 10^{-5} με αποδυνάμωση βαρών ίση με 0.05. Ωστόσο, λόγω της μείωσης του μέγεθους παρτίδας διά 8, ο ρυθμός μάθησης ορίστηκε ίσος με 3535×10^{-8} . Ο βελτιστοποιητής που χρησιμοποιήθηκε είναι ο ADAMW, ενώ για την ρύθμιση του ρυθμού μάθησης εφαρμόστηκε ο poly. Λόγω περιορισμένης υπολογιστικής ισχύος τα πειράματα πραγματοποιήθηκαν για 148800 επαναλήψεις ή αντίστοιχα 100 εποχές εκπαίδευσης. Εξάιρεση αποτελεί το τελικό μοντέλο το οποίο εκπαιδεύτηκε για συνολικά 297600 επαναλήψεις ή αντίστοιχα 200 εποχές εκπαίδευσης. Στην αυθεντική υλοποίηση τα πειράματα ήταν ορισμένα για 90000 επαναλήψεις. Στο τελικό μοντέλο εξετάστηκε η χρήση δύο επιπλέον τιμών ρυθμών μάθησης, συγκεκριμένα οι τιμές 10^{-4} και 10^{-5} .

6.2 Πειραματικά αποτελέσματα για διαφορετικές μεθόδους κανονικοποίησης τιμών

7 Συμπεράσματα και μελλοντικές επεκτάσεις

Βιβλιογραφική αναφορά

- [1] K. Gao, G. Mei, F. Piccialli, S. Cuomo, J. Tu, and Z. Huo, “Julia language in machine learning: Algorithms, applications, and open issues,” *Computer Science Review*, vol. 37, p. 100254, Aug. 2020.
- [2] A. Esteva, K. Chou, S. Yeung, N. Naik, A. Madani, A. Mottaghi, Y. Liu, E. Topol, J. Dean, and R. Socher, “Deep learning-enabled medical computer vision,” *npj Digital Medicine*, vol. 4, no. 1, p. 5, 2021.
- [3] X. Dong and M. Cappuccio, “Applications of computer vision in autonomous vehicles: Methods, challenges and future directions,” 11 2023.
- [4] M. T. Shahria, M. S. Sunny, I. Islam, J. Ghommam, S. Ahamed, and M. Rahman, “A comprehensive review of vision-based robotic applications: Current state, components, approaches, barriers, and potential solutions,” *Robotics*, vol. 11, 12 2022.
- [5] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems* (F. Pereira, C. Burges, L. Bottou, and K. Weinberger, eds.), vol. 25, Curran Associates, Inc., 2012.
- [6] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, “Imagenet large scale visual recognition challenge,” 2015.
- [7] E. Chris, J. Kate, and A. Juliet, “The evolution of computer vision: From pixels to perception,” 12 2025.
- [8] G. Boesch, “Computer vision tasks (comprehensive 2025 guide),” October 2024.
- [9] L. Zhou, G. Wu, Y. Zuo, X. Chen, and H. Hu, “A comprehensive review of vision-based 3d reconstruction methods,” *Sensors*, vol. 24, p. 2314, April 2024.
- [10] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, “Image segmentation using deep learning: A survey,” *CoRR*, vol. abs/2001.05566, 2020.
- [11] G. Csurka, R. Volpi, and B. Chidlovskii, “Semantic image segmentation: Two decades of research,” 2023.
- [12] M. Cordts, M. Omran, S. Ramos, T. Rehfeld, M. Enzweiler, R. Benenson, U. Franke, S. Roth, and B. Schiele, “The cityscapes dataset for semantic urban scene understanding,” *CoRR*, vol. abs/1604.01685, 2016.

- [13] M. Everingham, L. V. Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The pascal visual object classes (voc) challenge,” *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.
- [14] B. Zhou, H. Zhao, X. Puig, S. Fidler, A. Barriuso, and A. Torralba, “Scene parsing through ade20k dataset,” in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5122–5130, 2017.
- [15] A. M. Hafiz and G. M. Bhat, “A survey on instance segmentation: state of the art,” *International Journal of Multimedia Information Retrieval*, vol. 9, p. 171–189, July 2020.
- [16] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays, P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár, “Microsoft coco: Common objects in context,” 2015.
- [17] O. Elharrouss, S. Al-Maadeed, N. Subramanian, N. Ottakath, N. Almaadeed, and Y. Himeur, “Panoptic segmentation: A review,” 2021.
- [18] S. Kholin and A. Bitkina, “Image classification: 6 industries & 26 use cases you can try,” 2024.
- [19] A. Singh and P. Singh, “Image classification: A survey,” *Journal of Informatics Electrical and Electronics Engineering (JIEEE)*, vol. 1, pp. 1–9, 11 2020.
- [20] O. Rainio, J. Teuho, and R. Klén, “Evaluation metrics and statistical tests for machine learning,” *Scientific Reports*, 2024.
- [21] Z. Zou, K. Chen, Z. Shi, Y. Guo, and J. Ye, “Object detection in 20 years: A survey,” 2023.
- [22] A. Rohan, M. J. Hasan, and A. Petrovski, “A systematic literature review on deep learning-based depth estimation in computer vision,” 2025.
- [23] A. Geiger, P. Lenz, C. Stiller, and R. Urtasun, “Vision meets robotics: The KITTI dataset,” *The International Journal of Robotics Research*, vol. 32, no. 11, pp. 1231–1237, 2013.
- [24] C. Zheng, W. Wu, C. Chen, T. Yang, S. Zhu, J. Shen, N. Kehtarnavaz, and M. Shah, “Deep learning-based human pose estimation: A survey,” 2023.
- [25] D. Mehta, O. Sotnychenko, F. Mueller, W. Xu, S. Sridhar, G. Pons-Moll, and C. Theobalt, “Single-shot multi-person 3d pose estimation from monocular rgb,” 2018.
- [26] S. Anwar, S. Khan, and N. Barnes, “A deep journey into super-resolution: A survey,” 2020.
- [27] M. Bevilacqua, A. Roumy, C. Guillemot, and M.-L. Alberi-Morel, “Low-complexity single image super-resolution based on nonnegative neighbor embedding,” 09 2012.

- [28] J.-B. Huang, A. Singh, and N. Ahuja, “Single image super-resolution from transformed self-exemplars,” in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5197–5206, 2015.
- [29] L. Zhou, G. Wu, Y. Zuo, X. Chen, and H. Hu, “A comprehensive review of vision-based 3d reconstruction methods,” *Sensors*, vol. 24, no. 7, 2024.
- [30] N. Gährlert, N. Jourdan, M. Cordts, U. Franke, and J. Denzler, “Cityscapes 3d: Dataset and benchmark for 9 dof vehicle detection,” 2020.
- [31] J. Zhang, “Basic neural units of the brain: Neurons, synapses and action potential,” 2019.
- [32] □. Μπότσης and □. Διαμαντάρας, *Μηχανική μάθηση*. Εκδόσεις Κλειδάριθμος.
- [33] A. Navlani, “Activation functions,” 2022.
- [34] C. Nwankpa, W. Ijomah, A. Gachagan, and S. Marshall, “Activation functions: Comparison of trends in practice and research for deep learning,” 2018.
- [35] D. Hendrycks and K. Gimpel, “Gaussian error linear units (gelus),” 2023.
- [36] S. M. K, “Linear activation function,” 2023.
- [37] P. Baheti, “Activation functions in neural networks [12 types & use cases],” 2021.
- [38] F. Rosenblatt, “The perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [39] K. Hornik, M. Stinchcombe, and H. White, “Multilayer feedforward networks are universal approximators,” *Neural Networks*, vol. 2, no. 5, pp. 359–366, 1989.
- [40] L. Ciampiconi, A. Elwood, M. Leonardi, A. Mohamed, and A. Rozza, “A survey and taxonomy of loss functions in machine learning,” 2024.
- [41] C. Hughes, “A brief overview of cross entropy loss,” 2024.
- [42] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” 2019.
- [43] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” 2017.
- [44] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [45] C. F. Higham and D. J. Higham, “Deep learning: An introduction for applied mathematicians,” 2018.
- [46] J. Kukačka, V. Golkov, and D. Cremers, “Regularization for deep learning: A taxonomy,” 2017.

- [47] M. Schmidt, G. Fung, and R. Rosaless, “Optimization methods for ℓ_1 -regularization,” tech. rep., University of British Columbia, 2009.
- [48] A. Lewkowycz and G. Gur-Ari, “On the training dynamics of deep networks with l_2 regularization,” 2021.
- [49] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
- [50] J. Brownlee, “What is the difference between a batch and an epoch in a neural network,” *Machine learning mastery*, vol. 20, no. 1, pp. 1–15, 2018.
- [51] F. Sarikaya, “Batch size selection in deep learning: A comprehensive analysis of training dynamics and performance optimization,” 11 2024.
- [52] Z. Han, B. Liu, S.-B. Lin, and D.-X. Zhou, “Deep convolutional neural networks with zero-padding: Feature extraction and learning,” 2023.
- [53] J. Sun, X. Cao, H. Liang, W. Huang, Z. Chen, and Z. Li, “New interpretations of normalization methods in deep learning,” 2020.
- [54] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” 2015.
- [55] X. Lian and J. Liu, “Revisit batch normalization: New understanding from an optimization view and a refinement via composition optimization,” 2018.
- [56] Y. Wu and K. He, “Group normalization,” 2018.
- [57] X.-Y. Zhou, J. Sun, N. Ye, X. Lan, Q. Luo, B.-L. Lai, P. Esperanca, G.-Z. Yang, and Z. Li, “Batch group normalization,” 2020.
- [58] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2023.
- [59] J. L. Elman, “Finding structure in time,” *Cognitive Science*, vol. 14, no. 2, pp. 179–211, 1990.
- [60] D. Shah, “Coco dataset: All you need to know to get started,” 2023.
- [61] Z. Fan, Y. Wang, Y. Zhu, and J. Zhao, “Preparing state-of-the-art models for classification and object detection with nvidia tao toolkit,” February 2021. Accessed: 2025-06-24.
- [62] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, “Masked-attention mask transformer for universal image segmentation,” 2022.

- [63] P. Taghavi, R. Langari, and G. Pandey, “Swinmtl: A shared architecture for simultaneous depth estimation and semantic segmentation from monocular camera images,” 2024.
- [64] R. Mottaghi, X. Chen, X. Liu, N.-G. Cho, S.-W. Lee, S. Fidler, R. Urtasun, and A. Yuille, “The role of context for object detection and semantic segmentation in the wild,” in *2014 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 891–898, 2014.
- [65] J. Xiao, J. Hays, K. A. Ehinger, A. Oliva, and A. Torralba, “Sun database: Large-scale scene recognition from abbey to zoo,” in *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pp. 3485–3492, 2010.
- [66] B. Zhou, H. Zhao, X. Puig, T. Xiao, S. Fidler, A. Barriuso, and A. Torralba, “Semantic understanding of scenes through the ade20k dataset,” 2018.
- [67] A. Bhandari, “Confusion matrix in machine learning,” 2025.
- [68] V. Kookna, “Semantic vs. instance vs. panoptic segmentation,” 2022.
- [69] B. T., “Comprehensive guide to multiclass classification metrics,” 2021.
- [70] M. Grandini, E. Bagli, and G. Visani, “Metrics for multi-class classification: an overview,” 2020.
- [71] A. Kirillov, K. He, R. Girshick, C. Rother, and P. Dollar, “Panoptic segmentation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.
- [72] D. Shah, “Mean average precision (map) explained: Everything you need to know,” 2022.
- [73] F. Li, H. Zhang, H. xu, S. Liu, L. Zhang, L. M. Ni, and H.-Y. Shum, “Mask dino: Towards a unified transformer-based framework for object detection and segmentation,” 2022.
- [74] H. Zhang, F. Li, S. Liu, L. Zhang, H. Su, J. Zhu, L. M. Ni, and H.-Y. Shum, “Dino: Detr with improved denoising anchor boxes for end-to-end object detection,” 2022.
- [75] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, “Swin transformer: Hierarchical vision transformer using shifted windows,” 2021.
- [76] Q. Yu, H. Wang, S. Qiao, M. Collins, Y. Zhu, H. Adam, A. Yuille, and L.-C. Chen, “kmax-deeplab: k-means mask transformer,” 2023.
- [77] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, “A convnet for the 2020s,” 2022.
- [78] L.-C. Chen, H. Wang, and S. Qiao, “Scaling wide residual networks for panoptic segmentation,” 2021.

- [79] S. Zagoruyko and N. Komodakis, “Wide residual networks,” 2017.
- [80] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” 2015.
- [81] B. Cheng, M. D. Collins, Y. Zhu, T. Liu, T. S. Huang, H. Adam, and L.-C. Chen, “Panoptic-deeplab: A simple, strong, and fast baseline for bottom-up panoptic segmentation,” 2020.
- [82] L.-C. Chen, R. G. Lopes, B. Cheng, M. D. Collins, E. D. Cubuk, B. Zoph, H. Adam, and J. Shlens, “Naive-student: Leveraging semi-supervised learning in video sequences for urban scene segmentation,” 2020.
- [83] F. Chollet, “Xception: Deep learning with depthwise separable convolutions,” 2017.
- [84] J. Jain, J. Li, M. Chiu, A. Hassani, N. Orlov, and H. Shi, “Oneformer: One transformer to rule universal image segmentation,” 2022.
- [85] W. Wang, J. Dai, Z. Chen, Z. Huang, Z. Li, X. Zhu, X. Hu, T. Lu, L. Lu, H. Li, X. Wang, and Y. Qiao, “Internimage: Exploring large-scale vision foundation models with deformable convolutions,” 2023.
- [86] H. Zhang, F. Li, X. Zou, S. Liu, C. Li, J. Gao, J. Yang, and L. Zhang, “A simple framework for open-vocabulary segmentation and detection,” 2023.
- [87] Y. Xiong, R. Liao, H. Zhao, R. Hu, M. Bai, E. Yumer, and R. Urtasun, “Upsnet: A unified panoptic segmentation network,” 2019.
- [88] K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask r-cnn,” 2018.
- [89] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, “Feature pyramid networks for object detection,” 2017.
- [90] H. Wang, Y. Zhu, H. Adam, A. Yuille, and L.-C. Chen, “Max-deeplab: End-to-end panoptic segmentation with mask transformers,” 2021.
- [91] M.-H. Guo, C.-Z. Lu, Z.-N. Liu, M.-M. Cheng, and S.-M. Hu, “Visual attention network,” 2022.