



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

Σχολή Εφαρμοσμένων Μαθηματικών και Φυσικών Επιστημών

Τομέας Μαθηματικών

**Πανοπτική κατάτμηση εικόνας με χρήση
βαθιών νευρωνικών δικτύων**

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

Νικόλα Ιωάννου

Επιβλέπων: Παναγιώτης Τσανάκας
Καθηγητής Ε.Μ.Π.

Συνεπιβλέπων: Γεώργιος Σιόλας
Ε.ΔΙ.Π. Ε.Μ.Π.



Εθνικό Μετσόβιο Πολυτεχνείο

Σχολή Εφαρμοσμένων Μαθηματικών και Φυσικών Επιστημών

Τομέας Μαθηματικών

Εργαστήριο Όρασης Υπολογιστών, Επικοινωνίας Λόγου και Επεξεργασίας
Σημάτων

Πανοπτική κατάτμηση εικόνας με χρήση βαθιών νευρωνικών δικτύων

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

Νικόλα Ιωάννου

Επιβλέπων: Παναγιώτης Τσανάκας
Καθηγητής Ε.Μ.Π.

Συνεπιβλέπων: Γεώργιος Σιόλας
Ε.ΔΙ.Π. Ε.Μ.Π.

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 1η Ιουλίου, 2025.

(Υπογραφή)

.....
Παναγιώτης Τσανάκας
Καθηγητής Ε.Μ.Π.

(Υπογραφή)

.....
Αντώνιος Συμβώνης
Καθηγητής Ε.Μ.Π.

(Υπογραφή)

.....
Γεώργιος Στάμου
Καθηγητής Ε.Μ.Π.

Αθήνα, Ιούλιος 2025

.....
ΙΩΑΝΝΟΥ ΝΙΚΟΛΑΣ

*Διπλωματούχος σχολής Εφαρμοσμένων
Μαθηματικών και Φυσικών Επιστημών Ε.Μ.Π.*

© – All rights reserved. Με επιφύλαξη παντός δικαιώματος.
Νικόλας Ιωάννου, 2025.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικούς σκοπούς. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπούς μη κερδοσκοπικούς, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η ραγδαία εξέλιξη της τεχνολογίας αφενός και αφετέρου η ανάγκη του σύγχρονου ανθρώπου να προοδεύσει αποτέλεσαν πρόσφορο έδαφος για την εδραίωση και ανάπτυξη της τεχνητής νοημοσύνης. Η τεχνητή νοημοσύνη αποτελεί πλέον αναπόσπαστο κομμάτι της ανθρώπινης καθημερινότητας, καθώς και ένα ιδιαίτερα υποσχόμενο πεδίο, με εφαρμογές που εκτείνονται σχεδόν σε όλες τις πτυχές της ανθρώπινης δραστηριότητας. Τομείς όπου χρήζει η ανάλυση και κατανόηση της οπτικής πληροφορίας δεν αποτελούν εξαίρεση. Η όραση υπολογιστών αποτελεί πεδίο της τεχνητής νοημοσύνης, που επιχειρεί την ανάπτυξη μεθόδων και αλγορίθμων που αποσκοπούν στην κατανόηση, επξεργασία και ανάλυση της οπτικής πληροφορίας από υπολογιστικά συστήματα. Η παρούσα διπλωματική εργασία επικεντρώνεται στην πανοπτική κατάτμηση εικόνας, ένα κλάδο της όρασης υπολογιστών, ο οποίος αποσκοπεί στην παροχή μιας ολοκληρωμένης αναπαράστασης του οπτικού περιεχομένου των εικόνων.

Η πανοπτική κατάτμηση εικόνας αποτελεί ένα σχετικά πρόσφατα αναπτυσσόμενο κλάδο της όρασης υπολογιστών. Στόχος της αποτελεί η απόδοση μιας σημασιολογικής κατηγορίας σε κάθε εικονοστοιχείο της εικόνας και παράλληλα η διάκριση μεταξύ των διακριτών αντικειμένων που ανήκουν στην ίδια κατηγορία. Επιλύεται σχεδόν αποκλειστικά με την χρήση βαθιών νευρωνικών δικτύων, τα οποία έχουν πλέον κυριαρχήσει. Στο πλαίσιο αυτό, σκοπός της εργασίας αποτελεί η κατανόηση του πεδίου, καθώς και η μελέτη και αξιολόγηση των αντίστοιχων μεθόδων που βασίζονται στα βαθιά νευρωνικά δίκτυα.

Εξετάζεται το μοντέλο πανοπτικής κατάτμησης Mask2Former σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Visual Attention Network. Υπό αυτήν την προσέγγιση διερευνώνται οι δυνατότητες τους και αξιολογείτε η απόδοση τους. Στη συνέχεια, εισάγετε ο εξαγωγέας χαρακτηριστικών VANmb, ο οποίος προκύπτει με την εισαγωγή πολυκλαδικής εκδοχής στον μηχανισμό αυτο-προσοχής του Visual Attention Network. Το μοντέλο VANmb σε συνδυασμό με την κεφαλή πανοπτικής κατάτμησης Mask2Former πέτυχε πανοπτική ποιότητα ίση με 59.795 στο σύνολο δεδομένων επικύρωσης του Cityscapes. Ο πηγαίος κώδικας της εργασίας είναι διαθέσιμος στο GitHub, στον σύνδεσμο <https://github.com/Nikolasioan/Panoptic-Segmentation-with-Deep-Neural-Networks>.

Λέξεις Κλειδιά — Τεχνητή νοημοσύνη, Όραση υπολογιστών, Πανοπτική κατάτμηση εικόνας, Νευρωνικά δίκτυα, Αυτο-προσοχή, Mask2Former, Visual Attention Network, Cityscapes

Abstract

The rapid development of technology, along with the need for human progress, has created the perfect conditions for the consolidation and development of artificial intelligence. AI is now an integral part of our everyday life and a particularly promising field, with applications extending to almost all areas of human activities. This also includes areas where the analysis and understanding of visual information is required. Computer vision is an area of artificial intelligence that aims at developing methods and algorithms to enable computer systems to understand, process and analyze visual information. This thesis focuses on panoptic image segmentation, a branch of computer vision that aims at providing a comprehensive representation of the visual content of images.

Panoptic image segmentation is a relatively recently developed area of computer vision. Its aim is to assign a semantic category to each pixel in an image, while at the same time distinguishing between distinct objects belonging to the same category. This aim is achieved almost exclusively through the use of deep neural networks, which have now become dominant. In this context, the purpose of this thesis is to gain an understanding of the field, as well as to study and evaluate the relevant methods based on deep neural networks.

The Mask2Former panoptic segmentation model is examined in conjunction with the Visual Attention Network feature extractor. Under this approach, their capabilities are explored and their performance is evaluated. Afterwards, the VANmb feature extractor is introduced, which is obtained by introducing a multi-branch version into the self-attention mechanism of the Visual Attention Network. The VANmb model combined with the Mask2Former panoptic segmentation head achieved a panoptic quality score of 59.795 on the Cityscapes validation dataset. The source code for this work is available on GitHub at <https://github.com/Nikolasioan/Panoptic-Segmentation-with-Deep-Neural-Networks>.

Keywords — Artificial intelligence, Computer vision, Panoptic image segmentation, Neural networks, Self-attention, Mask2Former, Visual Attention Network, Cityscapes

Ευχαριστίες

Θα ήθελα να ευχαριστήσω πρωτίστως τους επιβλέποντες καθηγητές μου, κύριο Παναγιώτη Τσανάκα και κύριο Γεώργιο Σιόλα, για την ανάθεση της παρούσας διπλωματικής εργασίας και για την εμπιστοσύνη που μου έδειξαν κατά τη διάρκεια της εκπόνησης της. Οφείλω επίσης να ευχαριστήσω την οικογένεια μου γιατί χωρίς αυτή δεν θα μπορούσα να βρίσκομαι στη θέση την οποία βρίσκομαι τώρα. Τέλος, θα ήθελα να ευχαριστήσω τους φίλους μου, που με στηρίζουν σε κάθε μου βήμα.

Περιεχόμενα

Κατάλογος Σχημάτων	xiii
Κατάλογος Πινάκων	xv
Εισαγωγή	1
1 Ορισμός και περιγραφή του προβλήματος	5
1.1 Κατάτμηση εικόνας	6
1.1.1 Σημασιολογική κατάτμηση εικόνας	6
1.1.2 Κατάτμηση αντικειμένων	7
1.1.3 Πανοπτική κατάτμηση εικόνας	8
1.2 Συναφή προβλήματα ανάλυσης εικόνας	9
2 Θεωρητικό υπόβαθρο	13
2.1 Ο νευρώνας	13
2.2 Το μοντέλο McCulloch-Pitts	14
2.2.1 Εναλλακτικές συναρτήσεις ενεργοποίησης	16
2.3 Νευρωνικά δίκτυα πολλών στρωμάτων	22
2.3.1 Το δίκτυο MLP	22
2.3.2 Εκπαίδευση νευρωνικών δικτύων	25
2.3.3 Ρύθμιση (Regularization)	32
2.4 Συνελκτικά νευρωνικά δίκτυα	35
2.4.1 Συνέλιξη με βήμα	38
2.4.2 Στρώμα υποδειγματοληψίας	38
2.4.3 Επέκταση με μηδενικά (Zero-padding)	39
2.4.4 Κανονικοποίηση τιμών (Normalization)	39
2.5 Μετασχηματιστές (Transformers)	43
2.5.1 Αρχιτεκτονική	44
3 Σύνολα δεδομένων και μετρικές αξιολόγησης πανοπτικής κατάτμησης εικόνας	49
3.1 Σύνολα δεδομένων πανοπτικής κατάτμησης εικόνας	49
3.1.1 Σύνολο δεδομένων COCO	49
3.1.2 Σύνολο δεδομένων Cityscapes	50
3.1.3 Σύνολο δεδομένων ADE20K	52
3.2 Μετρικές αξιολόγησης πανοπτικής κατάτμησης εικόνας	53
3.2.1 Πίνακας σύγχυσης (Confusion Matrix)	53
3.2.2 Intersection over Union (IoU)	55
3.2.3 Μέσος Όρος Ακρίβειας (Average Precision - AP)	55

3.2.4	Πανοπτική ποιότητα (Panoptic Quality - PQ)	56
4	Σχετική έρευνα	61
4.1	State-of-the-art στο σύνολο δεδομένων COCO	61
4.1.1	Mask DINO	61
4.1.2	kMaX-DeepLab	62
4.2	State-of-the-art στο σύνολο δεδομένων Cityscapes	62
4.2.1	Scaling Wide Residual Networks	62
4.2.2	Naive-Student	64
4.3	State-of-the-art στο σύνολο δεδομένων ADE20K	65
4.3.1	OneFormer	65
4.3.2	OpenSeeD	65
4.4	Θεμελιώδεις έρευνες στην πανοπτική κατάτμηση εικόνας	66
4.4.1	Panoptic-DeepLab	66
4.4.2	UPNet	67
4.4.3	Max-DeepLab	68
5	Συμβολή της εργασίας	71
5.1	Visual Attention Network	71
5.2	Visual Attention Network multi-branch	74
6	Πειραματικά αποτελέσματα	77
6.1	Γενικό πλαίσιο	77
6.1.1	Παράμετροι εκπαίδευσης	77
6.2	Αρχικοποίηση παραμέτρων	77
6.3	Εναλλακτικές μέθοδοι κανονικοποίησης τιμών	78
6.4	Αντικατάσταση σημειακής συνέλιξης με MLP	80
6.5	Χρήση LKA πολλαπλών κλάδων	82
7	Συμπεράσματα και μελλοντικές επεκτάσεις	85
	Βιβλιογραφική αναφορά	87
	Παράρτημα	93

Κατάλογος Σχημάτων

1.1.1 Αυθεντική εικόνα	7
1.1.2 Σημασιολογική κατάτμηση εικόνας	7
1.1.3 Κατάτμηση αντικειμένων	8
1.1.4 Πανοπτική κατάτμηση εικόνας	9
2.1.1 Δομή νευρώνα	13
2.2.1 Μοντέλο McCulloch και Pitts του νευρώνα	15
2.2.2 Σχηματική αναπαράσταση του νευρώνα	16
2.2.3 Γραφική μορφή βηματικής συνάρτησης $-1/1$	17
2.2.4 Γραφική μορφή σιγμοειδής συνάρτησης	18
2.2.5 Γραφική μορφή υπερβολικής εφαπτομένης	19
2.2.6 Γραφική μορφή συνάρτησης ReLU	20
2.2.7 Γραφική μορφή συνάρτησης GeLU	21
2.2.8 Γραφική μορφή γραμμικής συνάρτησης	22
2.3.1 Ταξινόμηση στον $\mathbb{R}^2$ μέσω δικτύου Perceptron	23
2.3.2 Γενική σχηματική μορφή δικτύου Perceptron πολλών στρωμάτων	24
2.3.3 Απεικόνιση της τεχνικής της απόρριψης: (a) Κατά την εκπαίδευση, κάθε μονάδα διατηρείται με πιθανότητα p . (b) Κατά τη δοκιμή, όλες οι μονάδες είναι ενεργές και τα βάρη κλιμακώνονται κατά p	34
2.4.1 Η αρχιτεκτονική ενός τυπικού συνελκτικού νευρωνικού δικτύου	36
2.4.2 Αναπαράσταση υπολογισμού νευρώνα y_{ij}^k του k -οστού χάρτη χαρακτηριστικών και στρώματος L	37
2.4.3 Εξαγωγή χαρακτηριστικών	37
2.5.1 Αρχιτεκτονική μετασχηματιστή	44
3.1.1 Κατηγορίες αντικειμένων συνόλου δεδομένων COCO	50
3.1.2 Αντικείμενα συνόλου δεδομένων Cityscapes	51
3.1.3 Αντικείμενα και υπο-αντικείμενα συνόλου δεδομένων ADE20K	52
3.2.1 Μορφή πίνακα σύγχυσης για δυαδική ταξινόμηση	53
3.2.2 Παράδειγμα διαχωρισμού των τμημάτων της κατηγορίας "person" στα σύνολα TP , FP και FN	57
4.1.1 Αρχιτεκτονική μοντέλου Mask DINO	61
4.1.2 Μετα-αρχιτεκτονική μοντέλου kMaX-DeepLab	62
4.2.1 Αρχιτεκτονικές τεχνικών (a) Squeeze-and-Excitation, (b) Switchable Atrous Convolution	64
4.3.1 Αρχιτεκτονική OneFormer	65
4.3.2 Αρχιτεκτονική OpenSeed	66
4.4.1 Αρχιτεκτονική μοντέλου Panoptic-DeepLab	67
4.4.2 Αρχιτεκτονική μοντέλου UPSNet	68

4.4.3 Αρχιτεκτονική μοντέλου Max-DeepLab	69
5.1.1 Αποσύνθεση συνέλιξης μεγάλου πυρήνα για $K = 7$ και $d = 2$	72
5.1.2 Αρχιτεκτονική ενός σταδίου του VAN	73
5.2.1 Αρχιτεκτονική ενός σταδίου του VANmb	74
6.2.1 Σύγκριση πανοπτικής ποιότητας για διαφορετικές αρχικοποιήσεις των βαρών του εξαγωγέα χαρακτηριστικών.	78
6.3.1 Σύγκριση πανοπτικής ποιότητας για διαφορετικές μεθόδους κανονικοποίησης. BN: Κανονικό VAN-B0. GN: Παραλλαγή VAN-B0 με κανονικοποίηση ανά ομάδα. BGN: Παραλλαγή VAN-B0 με κανονικοποίηση ανά παρτίδα και ομάδα.	79
6.4.1 Σύγκριση πανοπτικής ποιότητας για διαφορετικά πλήθη νευρώνων σε κάθε κρυφό στρώμα του MLP. MLP3: Πλήθος νευρώνων ίσο με το τριπλάσιο του πλήθους των καναλιών του χάρτη χαρακτηριστικών. MLP4: Τετραπλάσιο MLP5: Πενταπλάσιο.	80
6.4.2 Σύγκριση πανοπτικής ποιότητας της παραλλαγής MLP4 του VAN για διαφορετικές μεθόδους κανονικοποίησης. MLP4-BN: Παραλλαγή MLP4 με κανονικοποίηση ανά παρτίδα. MLP4-GN: Παραλλαγή MLP4 με κανονικοποίηση ανά ομάδα. MLP4-BGN: Παραλλαγή MLP4 με κανονικοποίηση ανά παρτίδα και ομάδα.	81
6.5.1 Σύγκριση πανοπτικής ποιότητας για διαφορετικές τιμές των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας. VAN-20000: Πλήθος επαναλήψεων ίσο με 20000. VAN-40000: Πλήθος επαναλήψεων ίσο με 40000.	82
6.5.2 Σύγκριση πανοπτικής ποιότητας για διαφορετικές τιμές του ρυθμού μάθησης.	83

Κατάλογος Πινάκων

1	Σύγκριση αρχιτεκτονικών Wide-ResNet-41 και SWideRNet	63
2	Σύγκριση αποτελεσμάτων για διαφορετικές αρχικοποιήσεις των βαρών του VAN-B0. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K, ενώ η απουσία του τυχαία αρχικοποίηση παραμέτρων.	78
3	Σύγκριση αποτελεσμάτων VAN-B0 με διαφορετικές μεθόδους κανονικοποίησης. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.	79
4	Σύγκριση αποτελεσμάτων για διαφορετικά πλήθη νευρώνων σε κάθε κρυφό στρώμα του MLP. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.	81
5	Σύγκριση αποτελεσμάτων της παραλλαγής MLP4 του VAN για διαφορετικές μεθόδους κανονικοποίησης. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.	82
6	Σύγκριση αποτελεσμάτων του VANmb για διαφορετικές τιμές των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.	83
7	Αποτελέσματα Mask2former (VANmb-20000 [†]) για 297600 επαναλήψεις εκπαίδευσης και ρυθμό μάθησης ίσο με 10^{-5} . Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.	83
8	Αποτελέσματα Mask2former (VANmb-20000 [†]) για 297600 επαναλήψεις εκπαίδευσης και ρυθμό μάθησης ίσο με 3535×10^{-8} . Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.	84
9	Απόδοση του Mask2Former [1] με διαφορετικούς εξαγωγείς χαρακτηριστικών στο σύνολο δεδομένων επικύρωσης του Cityscapes [2]	85
10	Αποτελέσματα VAN-B0 με τυχαία αρχικοποίηση βαρών.	93
11	Αποτελέσματα VAN-B0 με βάρη προεκπαιδευμένα στο ImageNet-1K.	93
12	Αποτελέσματα VAN-B0 με αντικατάσταση της κανονικοποίησης ανά παρτίδα από την κανονικοποίηση ανά ομάδα. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	94
13	Αποτελέσματα VAN-B0 με αντικατάσταση της κανονικοποίησης ανά παρτίδα από την κανονικοποίηση ανά παρτίδα και ομάδα. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	94
14	Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τριπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	95

15	Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τετραπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	95
16	Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων πενταπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	96
17	Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP και κανονικοποίησης ανά παρτίδα με κανονικοποίηση ανά ομάδα. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τετραπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	96
18	Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP και κανονικοποίησης ανά παρτίδα με κανονικοποίηση ανά παρτίδα και ομάδα. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τετραπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	97
19	Αποτελέσματα VANmb-B0. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 40000. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	97
20	Αποτελέσματα VANmb-B0. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 20000 και ο ρυθμός μάθησης με 10^{-5} . Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	98
21	Αποτελέσματα VANmb-B0. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 20000 και ο ρυθμός μάθησης με 3535×10^{-8} . Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.	99

Εισαγωγή

Κατά την τελευταία δεκαετία, έχει παρατηρηθεί σημαντική εξέλιξη στον τομέα της τεχνητής νοημοσύνης, καθιστώντας την αναπόσπαστο κομμάτι της σύγχρονης καθημερινότητας, με εφαρμογές σε πολλούς τομείς στη ζωή του ανθρώπου, με σκοπό τη διευκόλυνση της. Μέσω της τεχνητής νοημοσύνης έχουν πλέον αναπτυχθεί καινοτόμες λύσεις σε θέματα που αφορούν την καθημερινότητα. Τομείς όπου χρήζει η ανάλυση και κατανόηση της οπτικής πληροφορίας, δεν αποτελούν εξαίρεση μιας και η ανάπτυξη και εξέλιξη σχετικών μεθόδων δύναται να ελαχιστοποιήσει τα ανθρώπινα σφάλματα και την ύπαρξη υποκειμενικότητας, αλλά και να μειώσει τον χρόνο που απαιτεί η ανάλυση της. Είναι γνωστό πως τομείς, όπως η ιατρική, όπου η άμεση διάγνωση και ανταπόκριση είναι συχνά κρίσιμη, η ελαχιστοποίηση των σφαλμάτων και η άμεση λήψη αποφάσεων είναι ύψιστης σημασίας. Επιπλέον, πρόσφατα εξελισσόμενοι τομείς, όπως για παράδειγμα η αυτόνομη οδήγηση, έρχονται να αλλάξουν τον παραδοσιακό τρόπο ζωής. Για να είναι όμως επιτεύξιμο, απαιτείται η εξέλιξη μεθόδων οι οποίες εξασφαλίζουν ακρίβεια, συνέπεια και ταχύτητα στην επεξεργασία της πληροφορίας. Το επιστημονικό πεδίο που ασχολείται με την ανάπτυξη μεθόδων και αλγορίθμων που αποσκοπούν στην κατανόηση, επεξεργασία και ανάλυση της οπτικής πληροφορίας από υπολογιστικά συστήματα, είναι γνωστό ως όραση υπολογιστών. Ο κλάδος αυτός περιλαμβάνει, μεταξύ άλλων, την κατάτμηση εικόνας, την ανίχνευση και ταξινόμηση αντικειμένων και την εκτίμηση βάθους. Οι λειτουργίες αυτές αποσκοπούν στην λεπτομερή κατανόηση της οπτικής πληροφορίας και βρίσκουν εφαρμογή σε τομείς όπως η ιατρική (π.χ. ιατρικές διαγνώσεις) και η ρομποτική.

Κατά τα τελευταία χρόνια, η όραση υπολογιστών, έχει σημειώσει σημαντική πρόοδο, με την ανάπτυξη πολλαπλών μεθόδων και μοντέλων, κάθε ένα από τα οποία εξειδικεύεται σε συγκεκριμένες εργασίες. Ωστόσο, οι προκλήσεις που συνδέονται με την όραση υπολογιστών δεν είναι αμελητέες. Η οπτική πληροφορία (π.χ. εικόνες, βίντεο) ενδέχεται να παρουσιάζει μεγάλη πολυπλοκότητα και χαρακτηρίζεται από υψηλή μεταβλητότητα των σκηνών. Επιπλέον, παράγοντες που συνδέονται με τον σύγχρονο τρόπο ζωής, όπως για παράδειγμα η ανάγκη για ανάλυση των δεδομένων σε μικρό χρονικό διάστημα, ή ακόμα και σε πραγματικό χρόνο, αλλά και παράγοντες που δυσχεραίνουν την ανάλυση της οπτικής πληροφορίας, όπως οι έντονες καιρικές συνθήκες κατά την λήψη της, καθιστούν το πρόβλημα ιδιαίτερα απαιτητικό. Η απαιτητική φύση του προβλήματος, δημιούργησε την ανάγκη κατασκευής εξειδικευμένων μοντέλων, που ανταποκρίνονται στις εκάστοτε συνθήκες του προβλήματος.

Η κατάτμηση εικόνας αποτελεί μια από τις σημαντικότερες υποκατηγορίες όσον αφορά τις εφαρμογές της στη σύγχρονη πραγματικότητα, ενώ παράλληλα συνιστά πεδίο με έντονη ερευνητική δραστηριότητα. Ορίζεται ως η διαδικασία διαχωρισμού μιας εικόνας σε διακριτές περιοχές, σε επίπεδο εικονοστοιχείου, με βάση το οπτικό περιεχόμενο που αναπαριστά. Η εργασία αυτή, επιτρέπει σε υπολογιστικά συστήματα να εντοπίζουν με ακρίβεια τα όρια των διακριτών

στοιχείων της εικόνας και να αναπαριστούν το οπτικό περιεχόμενο με τρόπο αντίστοιχο της βιολογικής όρασης. Η κατάτμηση εικόνας διακρίνεται σε υποκατηγορίες. Μερικές εξ αυτών αποτελούν η σημασιολογική κατάτμηση εικόνας, η κατάτμηση αντικειμένων και η πανοπτική κατάτμηση εικόνας. Η τελευταία, αν και αποτελεί σχετικά πρόσφατο αντικείμενο μελέτης, παρουσιάζει έντονο ερευνητικό ενδιαφέρον.

Για πολλά χρόνια, η σημασιολογική κατάτμηση εικόνας και η κατάτμηση αντικειμένων ακολουθούσαν διαφορετικές εξελικτικές πορείες. Η πρώτη επικεντρώνεται στην ταξινόμηση κάθε εικονοστοιχείου μιας εικόνας σε μια σημασιολογική κατηγορία, ενώ η δεύτερη στον εντοπισμό, διαχωρισμό και ταξινόμηση μεμονωμένων αντικειμένων της εικόνας σε επίπεδο εικονοστοιχείου. Η διάκριση αυτή δεν περιοριζόταν μόνο στις μεθόδους, αλλά επηρέαζε τις αντίστοιχες μετρικές αξιολόγησης και σύνολα δεδομένων. Ωστόσο, με την πρόοδο των νευρωνικών δικτύων δημιουργήθηκαν οι προϋποθέσεις για την ανάπτυξη ενός ενιαίου πλαισίου, στο οποίο οι δύο εργασίες συνδυάζονται. Έτσι, προέκυψε η πανοπτική κατάτμηση εικόνας, η οποία επιχειρεί την ενοποίηση των δύο εργασιών σε ένα ενιαίο πλαίσιο, δίνοντας μια πλήρη περιγραφή των περιεχομένων της εικόνας, αποδίδοντας σε κάθε εικονοστοιχείο μια σημασιολογική κατηγορία και παράλληλα διαχωρίζοντας τα επιμέρους αντικείμενα που ανήκουν στην ίδια κατηγορία. Η ενοποίηση των δύο εργασιών έθεσε νέες προκλήσεις, τόσο στην κατασκευή μεθόδων όσο και στον ορισμό νέων μετρικών αξιολόγησης. Παράλληλα οδήγησε στην τροποποίηση υπαρχόντων συνόλων δεδομένων, όπως και στην δημιουργία νέων που ανταποκρίνονται στις ανάγκες της πανοπτικής κατάτμησης. Το 2018, παρουσιάστηκε η πρώτη επίσημη διατύπωση της πανοπτικής κατάτμησης εικόνας από τον Alexander Kirillov και τους συνεργάτες του στη δημοσίευση "Panoptic Segmentation" [3]. Στην ίδια δημοσίευση παρουσιάστηκε, επίσης, και η κύρια μετρική αξιολόγησης της εργασίας, γνωστή ως πανοπτική ποιότητα.

Η παρούσα εργασία επικεντρώνεται στην πανοπτική κατάτμηση εικόνας και συγκεκριμένα στη μελέτη και αξιολόγηση των αντίστοιχων μεθόδων που βασίζονται στα βαθιά νευρωνικά δίκτυα. Σκοπός της αποτελεί η αποτίμηση της αποτελεσματικότητας και η κατανόηση των περιορισμών που παρουσιάζουν αυτές οι μέθοδοι, καθώς και η αναζήτηση τρόπων βελτίωσης της απόδοσής τους. Η ερευνητική φύση της εργασίας δεν στοχεύει μόνο την αποτίμηση της αποτελεσματικότητας ορισμένων μεθόδων αλλά και στην ανάδειξη των προκλήσεων που εξακολουθούν να υφίστανται. Ένα από τα βασικότερα εμπόδια αποτελεί το εξαιρετικά μεγάλο υπολογιστικό κόστος που απαιτεί η εκπαίδευση και αξιολόγηση των μεθόδων, γεγονός που καθιστά την έρευνα στον τομέα της υπολογιστικής όρασης ιδιαίτερα δύσκολη.

Το μέλλον της πανοπτικής κατάτμησης προδιαγράφεται δυναμικό, μιας και η έρευνα στρέφεται στην δημιουργία μεθόδων που συνδυάζουν υψηλή ακρίβεια με μειωμένο υπολογιστικό και αποθηκευτικό κόστος. Η χρήση ελαφρύτερων μοντέλων αναμένεται να διευρύνει ακόμα περισσότερο τις εφαρμογές της πανοπτικής κατάτμησης σε συσκευές οι οποίες μέχρι πρότινος

δεν μπορούσαν να την αξιοποιήσουν. Η δυνατότητα για ενσωμάτωση της σε φορητές συσκευές, μικρά μη επανδρωμένα οχήματα και οχήματα χαμηλής ενεργειακής κατανάλωσης διευρύνει τους ορίζοντες στην αξιοποίηση της τεχνητής όρασης και συμβάλλει στην καθιέρωση της ως θεμελιώδους τεχνολογίας στον τομέα της όρασης υπολογιστών.

Η παρούσα εργασία αποτελείται από επτά κεφάλαια. Το πρώτο κεφάλαιο αφορά τη θεμελίωση των εννοιών και έχει ως στόχο την κατανόηση του πεδίου στο οποίο εντάσσεται η πανοπτική κατάτμηση εικόνας. Πραγματοποιείται εκτενής παρουσίαση της κατάτμησης εικόνας και των επιμέρους κατηγοριών της (σημασιολογική κατάτμηση εικόνας, κατάτμηση αντικειμένων, πανοπτική κατάτμηση), καθώς και πρόσθετων εργασιών ανάλυσης εικόνας, ενισχύοντας έτσι την κατανόηση του αντικειμένου από τον αναγνώστη. Στο δεύτερο κεφάλαιο παρουσιάζεται το απαιτούμενο θεωρητικό υπόβαθρο για την παρούσα εργασία. Παρουσιάζονται οι βασικές αρχές των τεχνητών νευρωνικών δικτύων, καθώς και οι πιο διαδεδομένες αρχιτεκτονικές που εφαρμόζονται στην πανοπτική κατάτμηση. Ακολούθως, στο τρίτο κεφάλαιο, περιγράφονται τα κυριότερα σύνολα δεδομένων και μετρικές αξιολόγησης για τους σκοπούς της παρούσας εργασίας, ενώ στο τέταρτο κεφάλαιο παρουσιάζονται οι σχετικές ερευνητικές εργασίες, προκειμένου ο αναγνώστης να αποκτήσει πλήρη εικόνα της προόδου και των τάσεων του πεδίου. Στο πέμπτο κεφάλαιο πραγματοποιείται εκτενής περιγραφή του προτεινόμενου μοντέλου, ενώ στο έκτο κεφάλαιο παρουσιάζονται τα πειραματικά αποτελέσματα, βάσει των οποίων προέκυψε η τελική μορφή του. Τέλος, στο έβδομο κεφάλαιο παρουσιάζονται τα συμπεράσματα που εξήχθησαν, καθώς και μελλοντικές επεκτάσεις που μπορούν να εξεταστούν για την βελτίωση του προτεινόμενου μοντέλου και περαιτέρω διερεύνηση των δυνατοτήτων του.

1 Ορισμός και περιγραφή του προβλήματος

Η όραση υπολογιστών [4] αποτελεί πεδίο της τεχνητής νοημοσύνης που επιχειρεί την προσομοίωση της βιολογικής όρασης, κάνοντας χρήση υπολογιστών και συναφούς τεχνολογικού εξοπλισμού. Αποσκοπεί στην κατανόηση της τρισδιάστατης δομής του περιβάλλοντος, μέσω της επεξεργασίας εικόνων και βίντεο και έχει ως απώτερο σκοπό την κατανόηση του οπτικού περιεχομένου. Το πεδίο αυτό περιλαμβάνει μεταξύ άλλων την

- Επεξεργασία εικόνας (Image Processing)
- Αναγνώριση προτύπων (Pattern Recognition)
- Γεωμετρική μοντελοποίηση (Geometric Modeling)
- Αναγνώριση αντικειμένων (Object Recognition)

Η όραση υπολογιστών μπορεί να εφαρμοσθεί σε ένα ευρύ φάσμα τομέων όπως η ιατρική στον εντοπισμό κακοήθων όγκων [5], η αυτόνομη οδήγηση για την κατανόηση του περιβάλλοντος χώρου του οχήματος [6] και η ρομποτική [7].

Η ιστορική της πορεία ξεκινά στις αρχές της δεκαετίας του 1960 όταν η έρευνα επικεντρώθηκε σε βασικές τεχνικές επεξεργασίας εικόνας, όπως το φιλτράρισμα (Filtering), η οριοθέτηση και η ανίχνευση ακμών. Αρχικά, ο στόχος αποτελούσε η ανάλυση των τιμών των εικονοστοιχείων, όπως και η αναγνώριση απλών σχημάτων. Κατά την διάρκεια της δεκαετίας του 1980 αναπτύχθηκαν πιο σύνθετες τεχνικές που επέτρεπαν την αναγνώριση πιο σύνθετων σχημάτων και την εξαγωγή χαρακτηριστικών. Τη δεκαετία του 1990 η όραση υπολογιστών πέρασε στην φάση της μηχανικής μάθησης, όπου υιοθετήθηκαν στατιστικές μέθοδοι όπως οι μηχανές διανυσμάτων υποστήριξης (Support Vector Machines) και τα τυχαία δάση (Random Forest). Σημείο καμπής αποτέλεσε η δεκαετία του 2010, κατά την οποία η ραγδαία αύξηση της υπολογιστικής ισχύος και η δημιουργία μεγάλου μεγέθους, επισημασμένων συνόλων δεδομένων, άνοιξε την πόρτα σε αλγορίθμους βασισμένους στην βαθιά μάθηση και συγκεκριμένα στα νευρωνικά και συνελκτικά νευρωνικά δίκτυα, τα οποία σημείωσαν τεράστια πρόοδο. Χαρακτηριστικό παράδειγμα αποτελεί το AlexNet [8], ένα βαθύ συνελκτικό νευρωνικό δίκτυο που αναπτύχθηκε από τον Geoffrey E. Hinton και την ομάδα του, το οποίο κατέγραψε 15.3% top-5 error rate στο ILSVRC (ImageNet Large Scale Visual Recognition Challenge) [9]. Σήμερα, η όραση υπολογιστών επικεντρώνεται κυρίως στην ανάπτυξη μοντέλων ικανών να εξάγουν αποτελέσματα σε πραγματικό χρόνο χωρίς αισθητή χρονική καθυστέρηση, σε ηθικά ζητήματα όπως η αμεροληψία των αποτελεσμάτων όπως και σε ζητήματα ιδιωτικότητας [10].

Η όραση υπολογιστών περιλαμβάνει μια πληθώρα εργασιών, κάθε μια με διαφορετικό σκοπό και επίπεδο ανάλυσης της οπτικής πληροφορίας [11], [12]. Μεταξύ άλλων έχουμε την

- Κατάτμηση εικόνας (Image Segmentation)
- Ταξινόμηση εικόνας (Image Classification)
- Ανίχνευση αντικειμένων (Object Detection)
- Ανακατασκευή τρισδιάστατης εικόνας (3D Image Reconstruction)
- Εκτίμηση βάθους (Depth Estimation)

1.1 Κατάτμηση εικόνας

Η κατάτμηση εικόνας αποτελεί εργασία της όρασης υπολογιστών που αφορά την διαίρεση εικόνων ή βίντεο σε διακριτές περιοχές ή αντικείμενα. Κατά την διάρκεια των ετών έχουν αναπτυχθεί πολυάριθμοι μέθοδοι που επιχειρούν να αντιμετωπίσουν το πρόβλημα αυτό. Οι πρώτες προσεγγίσεις βασίστηκαν σε μεθόδους, όπως η χρήση κατωφλίου (Threshold), η ομαδοποίηση βάσει ιστογράμματος (Histogram-based Clustering) και η ομαδοποίηση μέσω του αλγορίθμου K-means. Στη συνέχεια, εφαρμόστηκαν πιο προχωρημένες μέθοδοι όπως οι ενεργές καμπύλες (Active Contours), οι τομές γράφων (Graph Cuts), τα υπό συνθήκη και τυχαία πεδία Markov και μέθοδοι που βασίζονται στην αραιότητα (Sparsity-based Methods). Κατά τ' άλλα, τα τελευταία χρόνια τα μοντέλα βαθιάς μάθησης (Deep Learning Models) έχουν οδηγήσει σε μια νέα γενιά μοντέλων κατάτμησης εικόνας με εντυπωσιακές επιδόσεις, συχνά επιτυγχάνοντας τις υψηλότερες επιδόσεις σε ευρέως χρησιμοποιούμενα σύνολα αναφοράς (Benchmarks) [13]. Η κατάτμηση εικόνας διακρίνεται μεταξύ άλλων στις εξής κατηγορίες.

- Σημασιολογική κατάτμηση εικόνας (Semantic Image Segmentation)
- Κατάτμηση αντικειμένων (Instance Segmentation)
- Πανοπτική κατάτμηση εικόνας (Panoptic Image Segmentation)


1.1.1 Σημασιολογική κατάτμηση εικόνας

Ζητούμενο της σημασιολογικής κατάτμησης εικόνας αποτελεί ο προσδιορισμός της σημασιολογικής κατηγορίας κάθε εικονοστοιχείου μιας εικόνας. Τυπικά, το πρόβλημα αντιμετωπίζεται ως πρόβλημα επιβλεπόμενης μάθησης (Supervised Learning), δηλαδή απαιτείται ένα πλήρως επισημασμένο σύνολο εκπαίδευσης. Στην σημασιολογική κατάτμηση εικόνας αυτό σημαίνει πως κάθε εικόνα του συνόλου εκπαίδευσης είναι πλήρως επισημασμένη σε επίπεδο εικονοστοιχείου. Οι σημασιολογικές ετικέτες διακρίνονται σε δύο κατηγορίες, στα "αντικείμενα" (Things), όπως για παράδειγμα σκύλος, αυτοκίνητο, πεζός κ.ο.κ. και στα "σκηνικά" στοιχεία (Stuff), όπως ουρανός, βλάστηση, δρόμος κ.ο.κ. Οι δύο αυτοί όροι χρησιμοποιούνται εκτενώς στην κατάτμηση εικόνας. Η πρώτη κατηγορία αναφέρεται σε μετρήσιμα αντικείμενα, ενώ η δεύτερη κατηγορία

σχετίζεται με στοιχεία του σκηνικού χώρου [14]. Παρακάτω παρουσιάζεται ενδεικτικά ένα παράδειγμα σημασιολογικής κατάτμησης εικόνας.



Σχήμα 1.1.1: Αυθεντική εικόνα



Σχήμα 1.1.2: Σημασιολογική κατάτμηση εικόνας


Όπως μπορούμε να δούμε στο 1.1.2 κάθε εικονοστοιχείο της εικόνας αντιστοιχίζεται σε μια σημασιολογική κατηγορία. Μπορούμε να παρατηρήσουμε πως τα εικονοστοιχεία που αντιστοιχίζονται στην ίδια σημασιολογική κατηγορία αποτελούν τα εικονοστοιχεία τα οποία αντιστοιχούν στο ίδιο "αντικείμενο" ή "σκηνικό" στοιχείο.

Σημαντικές μετρικές αξιολόγησης της σημασιολογικής κατάτμησης εικόνας αποτελούν μεταξύ άλλων η Intersection over Union (IoU), όπως και η ακρίβεια εικονοστοιχείου (Pixel Accuracy - PA) [13]. Ενδεικτικά παραδείγματα σημείων αναφοράς (Benchmarks) που χρησιμοποιούνται για την ποσοτικοποίηση της απόδοσης μεθόδων σημασιολογικής κατάτμησης εικόνας είναι τα Cityscapes [2], PASCAL VOC [15] και ADE20K [16].

1.1.2 Κατάτμηση αντικειμένων

Η ανίχνευση αντικειμένων αποτελεί πρόβλημα στην όραση υπολογιστών, κατά το οποίο εντοπίζονται και ταξινομούνται τα "αντικείμενα" μιας εικόνας, προσδιορίζοντας την θέση τους μέσω

ορθογώνιων πλαισίων. Η σημασιολογική κατάτμηση εικόνας, όπως αναφέρθηκε παραπάνω προσδιορίζει την σημασιολογική κατηγορία κάθε εικονοστοιχείου μιας εικόνας, χωρίς όμως να διαχωρίζει μεταξύ διαφορετικών "αντικειμένων" της ίδιας κατηγορίας. Προχωρώντας ένα βήμα παραπέρα, η κατάτμηση αντικειμένων συνδυάζει αυτές τις δύο τεχνικές και παρέχει διαφορετικές ετικέτες για ξεχωριστές εμφανίσεις "αντικειμένων" που ανήκουν στην ίδια κατηγορία, αγνοώντας εντελώς τα "σκηνικά" στοιχεία [17].



Σχήμα 1.1.3: Κατάτμηση αντικειμένων

Όπως μπορούμε να δούμε στο 1.1.3, κατηγοριοποιούνται μόνο τα εικονοστοιχεία τα οποία αντιστοιχούν σε "αντικείμενα", αγνοώντας τα υπόλοιπα. Εύκολα μπορούμε να παρατηρήσουμε πως υπάρχει διάκριση μεταξύ των "αντικειμένων" που ανήκουν στην ίδια κατηγορία.

Μερικές από τις σημαντικότερες μετρικές αξιολόγησης στην κατάτμηση αντικειμένων αποτελούν ο μέσος όρος ακριβείας (Average Precision - *AP*) και ο μέσος όρος ακριβείας μάσκας (*Mask AP*) [17]. Ενδεικτικά σύνολα αναφοράς που χρησιμοποιούνται για την αξιολόγηση της απόδοσης μεθόδων κατάτμησης αντικειμένων αποτελούν τα COCO [18], Cityscapes [2] και ADE20K [16].

1.1.3 Πανοπτική κατάτμηση εικόνας

Η πανοπτική κατάτμηση εικόνας αποτελεί μια πιο σύνθετη εργασία σε σχέση με την σημασιολογική κατάτμηση και την κατάτμηση αντικειμένων, καθώς ενοποιεί τις δύο εργασίες σε ένα ενιαίο πλαίσιο. Συγκεκριμένα, στην πανοπτική κατάτμηση εικόνας όλα τα εικονοστοιχεία της εικόνας κατηγοριοποιούνται, ανεξάρτητα εάν τα εικονοστοιχεία αντιστοιχούν σε "αντικείμενα" ή σε "σκηνικά" στοιχεία, ενώ παράλληλα πραγματοποιείται διαχωρισμός μεταξύ των "αντικειμένων" που αντιστοιχούν στην ίδια σημασιολογική κατηγορία [19].

Όπως μπορούμε να δούμε στο 1.1.4, κατηγοριοποιούνται όλα τα εικονοστοιχεία της εικόνας, ενώ ταυτόχρονα διαχωρίζονται τα "αντικείμενα" που ανήκουν στην ίδια σημασιολογική κατηγορία.



Σχήμα 1.1.4: Πανοπτική κατάτμηση εικόνας

Μερικές από τις σημαντικότερες μετρικές αξιολόγησης της πανοπτικής κατάτμησης εικόνας είναι οι Panoptic Quality (PQ), Segmentation Quality (SQ) και Recognition Quality (RQ). Ωστόσο, δεδομένου πως η πανοπτική κατάτμηση εικόνας αποτελεί συνδυασμό των εργασιών κατάτμησης αντικειμένων και σημασιολογικής κατάτμησης εικόνας, χρησιμοποιούνται μετρικές που έχουν ως σκοπό την ποσοτικοποίηση της απόδοσης καθεμιάς από τις δύο εργασίες ξεχωριστά. Συγκεκριμένα γίνεται χρήση των μετρικών αξιολόγησης Panoptic Quality Things (PQ_{th}) και Panoptic Quality Stuff (PQ_{st}) [19]. Ενδεικτικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται για την ποσοτικοποίηση της απόδοσης των μεθόδων πανοπτικής κατάτμησης εικόνας αποτελούν μεταξύ άλλων τα COCO [18], Cityscapes [2] και ADE20K [16].

1.2 Συναφή προβλήματα ανάλυσης εικόνας

Στην παρούσα υποενότητα παρουσιάζονται και αναλύονται συνοπτικά διάφορα προβλήματα της όρασης υπολογιστών, τα οποία καλύπτουν διαφορετικά μέρη της κατανόησης οπτικής πληροφορίας, σε σχέση με την κατάτμηση εικόνας. Η ανάλυση αυτή αποσκοπεί στην σύγκριση της εργασίας της πανοπτικής κατάτμησης εικόνας με διάφορες άλλες εργασίες της όρασης υπολογιστών.

Ταξινόμηση εικόνας

Η ταξινόμηση εικόνας αποτελεί εργασία στην τεχνητή νοημοσύνη κατά την οποία μια εικόνα αντιστοιχίζεται σε μια ή περισσότερες κατηγορίες με βάση αυτό που απεικονίζει. Βρίσκει εφαρμογές σε ένα ευρύ φάσμα τομέων, όπως η υγεία, η βιομηχανική παραγωγή και η γεωργία [20].

Μερικές από τις σημαντικότερες μετρικές αξιολόγησης της αποτελούν μεταξύ άλλων η ακρίβεια (Accuracy) ταξινόμησης των εικόνων και το F1-score [21], [22]. Μερικά από τα σημα-

ντικότερα σύνολα αναφοράς που χρησιμοποιούνται αποτελούν τα σύνολα δεδομένων ImageNet [23] και COCO [18].

Ανίχνευση αντικειμένων

Ζητούμενο της ανίχνευσης αντικειμένων αποτελεί ο εντοπισμός και η κατηγοριοποίηση των "αντικειμένων" που εμφανίζονται σε μια εικόνα. Ο εντοπισμός πραγματοποιείται συνήθως μέσω ενός ορθογωνίου πλαισίου που περικλείει το "αντικείμενο", συνοδευόμενο από την προβλεπόμενη κατηγορία και τον δείκτη βεβαιότητας της πρόβλεψης. Η ανίχνευση αντικειμένων μπορεί να χρησιμοποιηθεί σε ένα πλήθος εφαρμογών όπως η αυτόνομη οδήγηση, η ρομποτική και η ιατρική. Αποτελεί βάση για διάφορες άλλες εργασίες στην όραση υπολογιστών, όπως η κατάτμηση και η παρακολούθηση αντικειμένων (Object Tracking).

Σημαντικές μετρικές αξιολόγησης της ανίχνευσης αντικειμένων αποτελούν μεταξύ άλλων, ο μέσος όρος ακριβείας (Average Precision) και η Intersection over Union (*IoU*) [24]. Μερικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται στην αξιολόγηση της ποιότητας των προβλέψεων είναι τα COCO [18] και PASCAL VOC [15].

Εκτίμηση βάθους

Η εκτίμηση βάθους αποτελεί εργασία κατά την οποία, για κάθε εικονοστοιχείο της εικόνας, εκτιμάται η απόσταση του αντίστοιχου τμήματος της σκηνής που απεικονίζει από το σημείο λήψης της φωτογραφίας. Η εργασία μπορεί να πραγματοποιηθεί χρησιμοποιώντας μια ή περισσότερες κάμερες, ανάλογα με την αντίστοιχη τεχνική που χρησιμοποιείται. Η εκτίμηση βάθους βρίσκει εφαρμογή σε τομείς όπως η ανακατασκευή τρισδιάστατης εικόνας, η εικονική πραγματικότητα και η αυτόνομη οδήγηση.

Μερικές από τις σημαντικότερες μετρικές αξιολόγησης της εκτίμησης βάθους αποτελούν, η ακρίβεια και η τετραγωνική ρίζα του μέσου τετραγωνικού σφάλματος (Root Mean Square Error - *RMSE*) [25]. Μερικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται στην αξιολόγηση της εκτίμησης αποτελούν μεταξύ άλλων τα KITTI [26] και Cityscapes [2].

Εκτίμηση στάσης

Η εκτίμηση στάσης αποτελεί εργασία κατά την οποία εντοπίζονται οι θέσεις των αρθρώσεων του σώματος κάθε ατόμου που εμφανίζεται σε μια εικόνα και στη συνέχεια χρησιμοποιούνται στην ανακατασκευή της αντίστοιχης αναπαράστασης του σκελετού του. Η εργασία μπορεί να

πραγματοποιηθεί σε δύο ή και τρεις διαστάσεις, κατά την οποία πραγματοποιείται συνήθως με τη χρήση πολλαπλών καμερών ή επιπλέον αισθητήρων. Η εκτίμηση στάσης έχει εφαρμογές σε τομείς όπως η αλληλεπίδραση ανθρώπου υπολογιστή, η ρομποτική και η ιατρική.

Μεταξύ των σημαντικότερων μετρικών αξιολόγησης της εκτίμησης στάσης αποτελούν το ποσοστό σωστής εκτίμησης μελών (Percentage of Correct Parts - *PCP*) και το μέσο σφάλμα θέσης ανά άρθρωση (Mean Per Joint Position Error - *MPJPE*) [27]. Ενδεικτικά παραδείγματα συνόλων αναφοράς που χρησιμοποιούνται αποτελούν μεταξύ άλλων το σύνολο δεδομένων COCO [18] και το σύνολο δεδομένων MuPoTS-3D [28].

Υπερανάλυση εικόνας

Η υπερανάλυση εικόνας αποτελεί εργασία κατά την οποία πραγματοποιείται μετατροπή μιας εικόνας χαμηλής ανάλυσης σε μια εικόνα υψηλής ανάλυσης, με καλύτερη ποιότητα και πιο λεπτομερή χαρακτηριστικά. Το πρόβλημα θεωρείται αντίστροφο και υποκαθορισμένο, καθώς για την ίδια εικόνα χαμηλής ανάλυσης μπορεί να υπάρχουν πολλές πιθανές εκδοχές εικόνων υψηλής ανάλυσης. Η δυσκολία αυξάνεται όσο μεγαλώνει ο συντελεστής μεγέθυνσης, αφού η αποκατάσταση των χαμένων λεπτομερειών γίνεται πιο περίπλοκη και ενδέχεται να παραχθούν εσφαλμένες πληροφορίες. Η υπερανάλυση εικόνας έχει εφαρμογές σε τομείς όπως η ιατρική, η ασφάλεια και η αστρονομία.

Κάποιες από τις σημαντικότερες μετρικές αξιολόγησης που χρησιμοποιούνται στην υπερανάλυση εικόνας αποτελούν μεταξύ άλλων η τετραγωνική ρίζα μέσου τετραγωνικού σφάλματος και ο λόγος του μέγιστου σήματος ως προς τον θόρυβο (Peak Signal to Noise Ratio - *PSNR*) [29]. Μερικά από τα σημαντικότερα σύνολα αναφοράς που χρησιμοποιούνται αποτελούν μεταξύ άλλων το Set5 [30] και το Urban100 [31].

Ανακατασκευή τρισδιάστατης εικόνας

Η τρισδιάστατη ανακατασκευή εικόνας αποτελεί εργασία που αποσκοπεί στην αναπαράσταση της τρισδιάστατης δομής μιας σκηνής, αξιοποιώντας δεδομένα όπως δισδιάστατες εικόνες, χάρτες βάθους και σύνολα σημείων τριών διαστάσεων. Η ανακατασκευή της τρισδιάστατης δομής μιας εικόνας έχει εφαρμογές σε τομείς όπως τα βιντεοπαιχνίδια, η ιατρική και η εικονική πραγματικότητα.

Κάποιες από τις σημαντικότερες μετρικές αξιολόγησης που χρησιμοποιούνται αποτελούν μεταξύ άλλων η τετραγωνική ρίζα του μέσου τετραγωνικού σφάλματος και το μέσο απόλυτο

σφάλμα (Mean Absolute Error) [32]. Μερικά από τα σημαντικότερα σύνολα δεδομένων που χρησιμοποιούνται αποτελούν μεταξύ άλλων το σύνολο δεδομένων KITTI [26] και το σύνολο δεδομένων Cityscapes 3D [33].


2 Θεωρητικό υπόβαθρο

2.1 Ο νευρώνας

Η έρευνα σχετικά με τα τεχνητά νευρωνικά δίκτυα είναι εμπνευσμένη από την δομή και λειτουργία του εγκεφάλου. Βασικό δομικό του στοιχείο είναι οι νευρώνες. Κίνητρο για την μελέτη του νευρώνα είναι η ανακάλυψη ενός μοντέλου το οποίο θα προσομοιώνει την λειτουργία και τις δυνατότητες του εγκεφάλου. Ωστόσο, τα τεχνητά νευρωνικά δίκτυα χρησιμοποιούν πολύ απλοποιημένα μοντέλα νευρώνων, τέτοια ώστε να διατηρούν μόνο τα πολύ αδρά χαρακτηριστικά των λεπτομερών μοντέλων που χρησιμοποιούνται στη νευρολογία. Οι λεπτομέρειες πιστεύεται πως δεν παίζουν ιδιαίτερη σημασία στην κατανόηση της ευφυούς συμπεριφοράς των βιολογικών νευρωνικών συστημάτων. Ακόμα και αυτά τα απλά μοντέλα νευρώνων μπορούν να δημιουργήσουν ιδιαίτερος ενδιαφέροντα δίκτυα, αρκεί να πληρούν δύο βασικά χαρακτηριστικά.

- Οι νευρώνες πρέπει να έχουν ρυθμιζόμενες παραμέτρους ώστε να διευκολύνεται η διαδικασία της μάθησης (Πλαστικότητα Νευρώνα).
- Το δίκτυο πρέπει να αποτελείται από μεγάλο πλήθος νευρώνων ώστε να επιτυγχάνεται παραλληλισμός της επεξεργασίας και κατανομή της πληροφορίας.

Ο νευρώνας αποτελεί ένα μεγάλο σε μέγεθος κύτταρο το οποίο αποτελείται από τον πυρήνα, τους δενδρίτες, τον άξονα και τις συνάψεις που συνδέουν τις διακλαδώσεις του άξονα με τους δενδρίτες άλλων νευρώνων [34].



Σχήμα 2.1.1: Δομή νευρώνα

Λειτουργικά, τα τμήματα του νευρώνα παίζουν διαφορετικούς ρόλους. Οι δενδρίτες αποτελούν τις πύλες του νευρώνα και δέχονται ηλεκτρικά σήματα από άλλους νευρώνες. Ο άξονας αποτελεί την πύλη εξόδου του νευρώνα και στέλνει σήματα προς άλλους νευρώνες υπό μορφή

ηλεκτρικών παλμών σταθερού πλάτους και μεταβλητής συχνότητας. Τέλος, οι συνάψεις αποτελούν τα σημεία ενώσεως μεταξύ των διακλαδώσεων του άξονα του νευρώνα και των δενδριτών των νευρώνων που ενώνεται. Το πλάτος της σύναψης, η απόσταση της από τον δενδρίτη και η πυκνότητα του ηλεκτροχημικού υλικού επηρεάζουν την ευκολία με την οποία η ηλεκτρική δραστηριότητα διαδίδεται από τον άξονα στον δενδρίτη. Το ποσοστό της ηλεκτρικής δραστηριότητας που μεταδίδεται τελικά στον δενδρίτη ονομάζεται συναπτικό βάρος. Οι συνάψεις χωρίζονται σε ενισχυτικές (Excitatory) και ανασταλτικές (Inhibitory), ανάλογα με το αν το φορτίο που ελκύεται από τη σύναψη διεγείρει τον νευρώνα για να παράγει παλμούς ή αντίθετα τον αναστέλλει εμποδίζοντας τον.

Στους βιολογικούς νευρώνες, οι φορείς των πληροφοριών είναι οι ηλεκτρικοί παλμοί, που ταξιδεύουν στον άξονα κάθε νευρώνα και μέσω των συνάψεων διαδίδονται στους δενδρίτες των νευρώνων. Κάθε νευρώνας συλλέγει όλο το ηλεκτρικό φορτίο που δέχεται από κάθε σύναψη στους δενδρίτες του, σταθμίζοντας το εισερχόμενο φορτίο με το αντίστοιχο συναπτικό βάρος. Έτσι, όσο πιο ισχυρή είναι η συναπτική ζεύξη τόσο πιο πολύ συμμετέχει το συγκεκριμένο φορτίο ο εισόδου στο συνολικό άθροισμα. Αν το άθροισμα αυτό υπερβαίνει κάποιο κατώφλι, ο άξονας του νευρώνα αρχίζει να παράγει ηλεκτρικούς παλμούς με μεγάλη συχνότητα, αν όμως δεν υπερβαίνει το συγκεκριμένο όριο, τότε ο νευρώνας παράγει πολύ αραιά παλμούς σε τυχαίες χρονικές στιγμές (Αδρανής νευρώνας). Τελικά, οι παλμοί που παράγονται ταξιδεύουν κατά μήκος του άξονα και τροφοδοτούν τους άλλους νευρώνες με τους οποίους συνδέεται ο νευρώνας που παρήγαγε τον παλμό [35].

2.2 Το μοντέλο McCulloch-Pitts

Το μοντέλο McCulloch-Pitts αποτελεί το πρώτο μαθηματικό μοντέλο τεχνητού νευρώνα. Προτάθηκε το 1943 από τους Warren McCulloch και Walter Pitts και σχεδιάστηκε για να προσομοιώσει τη λειτουργία του βιολογικού νευρώνα, κάνοντας χρήση λογικών πράξεων. Η κατάσταση του νευρώνα περιγράφεται από ένα δυαδικό αριθμό y .

- $y = 0$, ο νευρώνας είναι αδρανής
- $y = 1$, ο νευρώνας πυροδοτεί παλμούς (Δεν είναι αδρανής)

Οι συνάψεις περιγράφονται από τα συναπτικά βάρη $w_i \in \mathbb{R}$, $i = 1, \dots, n$. Έστω πως $x_1, x_2, \dots, x_n$ οι είσοδοι του νευρώνα, ελέγχουμε εάν το άθροισμα $x_1 w_1 + \dots + x_n w_n$ του φορτίου που δέχεται ο νευρώνας είναι μεγαλύτερο από το κατώφλι θ . Εάν ισχύει τότε ο νευρώνας πυροδοτεί παλμούς. Διαφορετικά ο νευρώνας παραμένει αδρανής. Αυτό είναι ισοδύναμο με το εάν εάν η

ποσότητα

$$u = \sum_{i=1}^n w_i x_i - \theta \quad (2.1)$$


είναι μεγαλύτερη ή μικρότερη από το μηδέν, οπότε η έξοδος του νευρώνα ισούται με

$$y = f(u) = \begin{cases} 1 & \text{εάν } u > 0 \\ 0 & \text{εάν } u \leq 0 \end{cases} \quad (2.2)$$

Η συνάρτηση u καλείται διέγερση του νευρώνα και η $f(\cdot)$ συνάρτηση ενεργοποίησης. Στο μοντέλο McCulloch-Pitts η συνάρτηση ενεργοποίησης είναι η βηματική συνάρτηση 0/1. Η διέγερση u μπορεί να γραφεί επίσης και με την παρακάτω συνοπτική μορφή.

$$u = \bar{w}^\top \bar{x} - \theta \quad (2.3)$$

Όπου $\bar{w} = [w_1, \dots, w_n]^\top$ είναι το διάνυσμα των συναπτικών βαρών και $\bar{x} = [x_1, \dots, x_n]^\top$ το διάνυσμα εισόδου. Το κατώφλι θ αποτελεί πραγματικό αριθμό όπως και τα $w_1, \dots, w_n$. Κατ' αυτήν την έννοια μπορούμε να απλοποιήσουμε την εξίσωση θέτοντας $w_0 = -\theta$, το οποίο θα ονομάζεται πόλωση και θα είναι συνδεδεμένο με μια σταθερή είσοδο $x_0 = 1$ [35].




Σχήμα 2.2.1: Μοντέλο McCulloch και Pitts του νευρώνα

Συνεπώς, η εξίσωση (2.1) παίρνει την ακόλουθη μορφή.

$$u = \sum_{i=0}^n w_i x_i \quad (2.4)$$

2.2.1 Εναλλακτικές συναρτήσεις ενεργοποίησης

Υπάρχουν πολλές διαφορετικές μοντελοποιήσεις του νευρώνα που αποκλίνουν από το μοντέλο McCulloch-Pitts. Η πιο σημαντική διαφορά εντοπίζεται στη μορφή της μη γραμμικής συνάρτησης $f(\cdot)$ που χρησιμοποιείται. Στο 2.2.2 παρουσιάζεται η σχηματική αναπαράσταση της μοντελοποίησης του νευρώνα που περιγράφηκε.



Σχήμα 2.2.2: Σχηματική αναπαράσταση του νευρώνα


Η συνάρτηση ενεργοποίησης μπορεί να πάρει εναλλακτικά μεταξύ τις μορφές που περιγράφονται παρακάτω.

Βηματική συνάρτηση -1/1 (Step Function -1/1)

Η βηματική συνάρτηση -1/1, όπως και η βηματική συνάρτηση 0/1 αποτελούν ειδικές περιπτώσεις μιας οικογένειας συναρτήσεων που ονομάζονται βηματικές συναρτήσεις δύο επιπέδων (Binary Step Functions). Οι συναρτήσεις αυτού του τύπου, παραμένουν ανενεργές για τιμές μικρότερες ή ίσες του κατωφλίου (Στην περίπτωση που δίνεται παρακάτω το κατώφλι είναι ίσο με 0) και ενεργοποιούνται για τιμές μεγαλύτερες από αυτό. Η βηματική συνάρτηση -1/1 με τιμή κατωφλίου ίση με μηδέν δίνεται από την σχέση

$$y = f(u) = \begin{cases} 1 & \text{εάν } u > 0 \\ -1 & \text{εάν } u \leq 0 \end{cases} \quad (2.5)$$

Το σημαντικότερο μειονέκτημα των συναρτήσεων αυτής της οικογένειας είναι ότι σε όλα τα σημεία τους έχουν είτε μηδενική κλίση είτε δεν είναι διαφορίσιμες (Σημείο Κατωφλίου). Αυτό το μειονέκτημα συνιστά σημαντικό εμπόδιο στην εκπαίδευση νευρωνικών δικτύων πολλών στρωμάτων (Κεφάλαιο 2.3.2). Για τον λόγο αυτό, συναρτήσεις της μορφής αυτής χρησιμοποιούνται αποκλειστικά σε νευρωνικά δίκτυα με ένα μόνο στρώμα [36]. Η γραφική μορφή της βηματικής συνάρτησης $-1/1$ δίνεται παρακάτω.



Σχήμα 2.2.3: Γραφική μορφή βηματικής συνάρτησης $-1/1$


Σιγμοειδής συνάρτηση (Sigmoid Function)

Αναφέρεται επίσης ως λογιστική συνάρτηση. Αποτελεί μη γραμμική συνάρτηση, που χρησιμοποιείται συνήθως στα νευρωνικά δίκτυα μιας κατεύθυνσης (Feedforward Neural Networks). Είναι φραγμένη και διαφορίσιμη με θετική παράγωγο για όλα τα σημεία του πεδίου ορισμού της (Γνησίως αύξουσα). Έχει πεδίο ορισμού το $\mathbb{R}$ και σύνολο τιμών το $(0,1)$. Δίνεται από την σχέση

$$f(u) = \frac{1}{1 + e^{-u}} \quad (2.6)$$

Η σιγμοειδής συνάρτηση εμφανίζεται συνήθως στο στρώμα εξόδου των δικτύων βαθιάς μάθησης όταν η έξοδος απαιτείται να είναι υπό μορφή πιθανότητας. Παρά τα πλεονεκτήματά της όπως η ευκολία κατανόησης και η καλή απόδοση της σε δίκτυα μικρού βάθους, παρουσιάζει μερικά σημαντικά μειονεκτήματα. Κάποια από αυτά περιλαμβάνουν την απότομη εξασθένιση των κλίσεων (Gradient) καθώς αυτές μεταφέρονται από τα βαθύτερα προς τα αρχικά στρώματα

κατά την διαδικασία οπισθοδιάδοσης (Backpropagation) (Κεφάλαιο 2.3.2), στον κορεσμό των κλίσεων λόγω των πολύ μικρών τιμών που λαμβάνει η συνάρτηση ενεργοποίησης για μικρές θετικές και μεγάλες αρνητικές τιμές της εισόδου, καθώς και στο πώς δεν είναι κεντραρισμένη στο μηδέν, γεγονός που μπορεί να οδηγήσει τις ανανεώσεις των βαρών να πραγματοποιούνται σε διαφορετικές κατευθύνσεις. Αυτά τα μειονεκτήματα ενδέχεται να προκαλέσουν προβλήματα κατά την διαδικασία της εκπαίδευσης του μοντέλου. Μεταξύ των προβλημάτων αυτών συγκαταλέγονται η αργή σύγκλιση και η αστάθεια εκπαίδευσης. [37]. Η γραφική μορφή της σιγμοειδούς συνάρτησης δίνεται παρακάτω.




Σχήμα 2.2.4: Γραφική μορφή σιγμοειδούς συνάρτησης

Υπερβολική εφαπτομένη (Hyperbolic Tangent)

Για την αντιμετώπιση ορισμένων από τα προβλήματα που εμφανίζονται χρησιμοποιώντας την σιγμοειδή συνάρτηση ως συνάρτηση ενεργοποίησης, προτάθηκε η εναλλακτική χρήση της υπερβολικής εφαπτομένης. Η υπερβολική εφαπτομένη αποτελεί συνάρτηση κεντραρισμένη στο μηδέν, με πεδίο ορισμού το $\mathbb{R}$ και σύνολο τιμών το $(-1,1)$. Αποτελεί προτιμότερη επιλογή σε σχέση με την σιγμοειδή συνάρτηση, καθώς διευκολύνει την εκπαίδευση νευρωνικών δικτύων πολλών στρωμάτων (Κεφάλαιο 2.3) περιορίζοντας φαινόμενα που μπορεί να εμφανιστούν χρησιμοποιώντας την σιγμοειδή συνάρτηση ως συνάρτηση ενεργοποίησης. Ωστόσο, η υπερβολική εφαπτομένη εξακολουθεί να είναι επιρρεπής στο πρόβλημα της εξασθένησης των κλίσεων, το οποίο παραμένει. Το βασικό της πλεονέκτημα αποτελεί πως παράγει έξοδο κεντραρισμένη στο μηδέν, κάτι που συμβάλλει στην διευκόλυνση της διαδικασίας εκπαίδευσης του μοντέλου. Δίνεται από την σχέση

$$f(u) = \tanh(u) = \frac{1 - e^{-u}}{1 + e^{-u}} \quad (2.7)$$

Σημαντικό στοιχείο της αποτελεί πως έχει κλίση ίση με ένα, μόνο όταν η τιμή της εισόδου είναι ίση με μηδέν. Αυτό έχει σαν αποτέλεσμα η συνάρτηση να παράγει "νεκρούς" νευρώνες. Ως "Νεκρός" νευρώνας ορίζεται η κατάσταση κατά την οποία ένας νευρώνας παραμένει ουσιαστικά ανενεργός κατά την διάρκεια της εκπαίδευσης, λόγω των σχεδόν μηδενικών κλίσεων. Μια αποτελεσματική λύση στο πρόβλημα αυτό έδωσε η συνάρτηση ράμπας (ReLU) [37]. Η γραφική μορφή της συνάρτησης υπερβολικής εφαπτομένης δίνεται παρακάτω.



Σχήμα 2.2.5: Γραφική μορφή υπερβολικής εφαπτομένης


Συνάρτηση ράμπας (ReLU)

Η συνάρτηση ράμπας αποτελεί την πιο ευρέως χρησιμοποιημένη συνάρτηση ενεργοποίησης στα μοντέλα βαθιάς μάθησης, παρουσιάζοντας κορυφαία αποτελέσματα. Επιτρέπει γρήγορη εκπαίδευση του μοντέλου και αποτελεί την πιο επιτυχημένη συνάρτηση ενεργοποίησης μέχρι και σήμερα. Έχει παρουσιάσει καλύτερη απόδοση από τη σιγμοειδή συνάρτηση και την συνάρτηση υπερβολικής εφαπτομένης σε μοντέλα βαθιάς μάθησης, ενώ παράλληλα προσφέρει καλύτερη ικανότητα γενίκευσης σε άγνωστα δεδομένα. Έχει πεδίο ορισμού το $\mathbb{R}$ και σύνολο τιμών το $[0, \infty)$. Δίνεται από την σχέση

$$y = f(u) = \begin{cases} u & \text{if } u > 0 \\ 0 & \text{if } u \leq 0 \end{cases} \quad (2.8)$$

Η ReLU χρησιμοποιείται κυρίως στα κρυφά στρώματα βαθιών νευρωνικών δικτύων, ενώ για τα στρώματα εξόδου γίνεται χρήση διαφορετικής συνάρτησης. Το βασικό της πλεονέκτημα αποτελεί πως επιτρέπει πολύ γρήγορους υπολογισμούς λόγω της πολύ μικρής πολυπλοκότητας υπολογισμού της, ενώ παράλληλα εισάγει αραιότητα στο μοντέλο, καθώς για τιμές μικρότερες ή ίσες του μηδενός, η έξοδος του αντίστοιχου νευρώνα μηδενίζεται, απλοποιώντας έτσι τη δομή

του δικτύου. Ωστόσο η συνάρτηση αυτή δεν στερείται μειονεκτημάτων. Η συνάρτηση ράμπας είναι πιο επιρρεπής από την σιγμοειδή συνάρτηση σε υπερπροσαρμογή (Overfitting). Για την αντιμετώπιση αυτού του προβλήματος συχνά χρησιμοποιείται η τεχνική της απενεργοποίησης νευρώνων (Dropout) (Κεφάλαιο 2.3.3). Κατά την διάρκεια της διαδικασίας εκπαίδευσης ενδέχεται, λόγω μηδενισμού της εξόδου, να προκύψουν αρκετοί "νεκροί" νευρώνες, δηλαδή νευρώνες που τα βάρη τους έχουν σταματήσει να ενημερώνονται και δεν συμμετέχουν στην εκπαίδευση [37]. Η γραφική μορφή της συνάρτησης ράμπας δίνεται παρακάτω.



Σχήμα 2.2.6: Γραφική μορφή συνάρτησης ReLU

Μια πιο σύγχρονη παραλλαγή της συνάρτησης ράμπας αποτελεί η Gaussian Error Linear Unit (GELU). Η αυξημένη πολυπλοκότητα των βαθιών μη γραμμικών μοντέλων τα καθιστά ικανά να προσαρμόζονται υπερβολικά καλά στα δεδομένα, οδηγώντας τα σε υπερπροσαρμογή. Αυτό συχνά απαιτεί από τους σχεδιαστές των μοντέλων να κάνουν χρήση επιπλέον τεχνικών κανονικοποίησης, όπως η εισαγωγή θορύβου και η απενεργοποίηση νευρώνων. Οι τεχνικές αυτές δρουν συμπληρωματικά προς τις συναρτήσεις ενεργοποίησης και μπορούν να βελτιώσουν την ικανότητα γενίκευσης του μοντέλου. Η συνάρτηση GELU έχει σχεδιαστεί για να ενσωματώνει αυτή τη στοχαστική συμπεριφορά πιο φυσικά, προσφέροντας μια πιο πιθανοκρατική ερμηνεία της εξόδου του νευρώνα. Στην πράξη, έχει δείξει ίση ή και καλύτερη απόδοση από την ReLU σε ορισμένες εργασίες της όρασης υπολογιστών, της επεξεργασίας φυσικής γλώσσας και της αναγνώρισης ομιλίας. Η συνάρτηση GELU συνδυάζει χαρακτηριστικά της απενεργοποίησης νευρώνων, της συνάρτησης ράμπας και του zoneout. Το zoneout αποτελεί τεχνική κανονικοποίησης που με στοχαστικό τρόπο, διατηρεί κάποιες εξόδους νευρώνων ίδιες με το προηγούμενο πέρασμα. Η όλη ιδέα υλοποιείται πολλαπλασιάζοντας την είσοδο του νευρώνα με μηδέν ή ένα, όπου η επιλογή πραγματοποιείται στοχαστικά και εξαρτάται από την τιμή της εισόδου. Συγκεκριμένα πολλαπλασιάζουμε την τιμή της εισόδου u με την κατανομή $m \sim \text{Bernoulli}(\Phi(u))$, όπου $\Phi(u) = P(X \leq u)$, $X \sim \mathcal{N}(0, 1)$. Επιλέχθηκε αυτή η κατανομή επειδή οι τιμές των εισόδων των νευρώνων τείνουν να ακολουθούν κανονική κατανομή. Στο πλαίσιο αυτό, όσο ελαττώνεται η τιμή της εισόδου, τόσο πιο πιθανό είναι να μηδενιστεί. Η διαδικασία είναι τυχαία, αλλά εξαρτάται από την ίδια την τιμή της εισόδου. Η τεχνική αυτή ουσιαστικά είτε μηδενίζει

την είσοδο είτε την αφήνει αμετάβλητη. Η συνάρτηση GeLU δίνεται από την σχέση

$$f(u) = u \cdot P(X \leq u) = u \cdot \Phi(u) = u \cdot \frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{u}{\sqrt{2}}\right) \right]. \quad (2.9)$$

Όπου $X \sim \mathcal{N}(0, 1)$ και $\operatorname{erf}(\cdot)$ η συνάρτηση σφάλματος, η οποία δίνεται από την σχέση

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt \quad (2.10)$$


Η συνάρτηση GELU προσεγγίζεται μέσω της σχέσης

$$f(u) \approx 0.5u \left(1 + \tanh \left[\sqrt{\frac{2}{\pi}} (u + 0.044715u^3) \right] \right) \quad (2.11)$$

ή μέσω της

$$f(u) \approx u\sigma(1.702u) \quad (2.12)$$

Όπου $\sigma(\cdot)$ η σιγμοειδής συνάρτηση.



Σχήμα 2.2.7: Γραφική μορφή συνάρτησης GeLU


Η προσεγγιστική μορφή της συνάρτησης GELU χρησιμοποιείται σε περίπτωση που ο ταχύτερος υπολογισμός αξίζει το κόστος της ακρίβειας [38]

Γραμμική συνάρτηση (Linear Function)

Η γραμμική ή αλλιώς ταυτοτική (Identity) συνάρτηση έχει πεδίο ορισμού και σύνολο τιμών το $\mathbb{R}$ και δίνεται από την σχέση

$$f(u) = u \quad (2.13)$$

Παρά την απλότητά της, παρουσιάζει σημαντικά μειονεκτήματα. Η χρήση της γραμμικής συνάρτησης ως συνάρτηση ενεργοποίησης περιορίζει το μοντέλο, καθώς λόγω της γραμμικής της μορφής αδυνατεί να εκπαιδευτεί σε πολύπλοκες μη γραμμικές σχέσεις [39]. Παράλληλα, η χρήση οπισθοδιάδοσης (Κεφάλαιο 2.3.2) στην εκπαίδευση του μοντέλου καθίσταται αδύνατη, καθώς η παράγωγος της γραμμικής συνάρτησης είναι σταθερή και δεν σχετίζεται με την τιμή της εισόδου u [40]. Η γραφική μορφή της γραμμικής συνάρτησης απεικονίζεται στο 2.2.8.



Σχήμα 2.2.8: Γραφική μορφή γραμμικής συνάρτησης

Η ειδική περίπτωση τεχνητού δικτύου που αποτελείται από ένα μόνο νευρώνα με συνάρτηση ενεργοποίησης την βηματική συνάρτηση καλείτε δίκτυο Perceptron [41]. Το δίκτυο Perceptron είναι το πιο απλό νευρωνικό δίκτυο που μπορεί να σχεδιαστεί.

2.3 Νευρωνικά δίκτυα πολλών στρωμάτων


2.3.1 Το δίκτυο MLP

Στα γραμμικά μοντέλα όπως το δίκτυο Perceptron οι δυνατότητες αναπαράστασης διαχωριστικών επιφανειών είναι περιορισμένες, επειδή το δίκτυο μπορεί να αναπαραστήσει μόνο επίπεδες

επιφάνειες. Με άλλα λόγια το υπερεπίπεδο $u = 0$, χωρίζει τον χώρο $\mathbb{R}^n$ σε δύο μέρη, όπου στο ένα ισχύει $f(u) = 1$ και στο άλλο $f(u) = 0$ (Χρησιμοποιώντας την βηματική συνάρτηση 0/1). Η κατάσταση που προκύπτει μπορεί να οπτικοποιηθεί καλύτερα στις δύο διαστάσεις. Στον χώρο $\mathbb{R}^2$ η εξίσωση $u = w_1x_1 + w_2x_2 + b = 0$ ορίζει μια ευθεία κάθετη στο διάνυσμα των συναπτικών βαρών $\bar{w} = [w_1, w_2]^T$. Αυτή η ευθεία χωρίζει το επίπεδο σε δύο τμήματα.

- Το τμήμα προς την κατεύθυνση του $\bar{w}$ περιέχει τα $\bar{x}$ για τα οποία ισχύει $u > 0$ (και άρα $f(u) = 1$)
- Το τμήμα προς την αντίθετη κατεύθυνση του $\bar{w}$ περιέχει τα σημεία $\bar{x}$ για τα οποία ισχύει $u < 0$ (και άρα $f(u) = 0$)

Η απόσταση της ευθείας από την αρχή των αξόνων εξαρτάται από την τιμή της πόλωσης $w_0 = b$. Η σχηματική μορφή της ευθείας που περιγράφηκε δίνεται στο Σχήμα 2.3.1.




Σχήμα 2.3.1: Ταξινόμηση στον $\mathbb{R}^2$ μέσω δικτύου Perceptron

Ο περιορισμός αυτός αίρεται με τη χρήση περισσότερων νευρώνων. Η χρήση περισσότερων κρυφών νευρώνων, θα μπορούσε να ορίσει περισσότερες διαχωριστικές ευθείες. Ο συνδυασμός των ευθειών αυτών μπορεί να μας δώσει μεγάλη ποικιλία περιοχών που θα μπορούσαμε να διαχωρίσουμε στην έξοδο. Υπάρχουν άπειρα παραδείγματα τέτοιων σχηματισμών, τα οποία μπορούν να απεικονιστούν σε διαφορετικές διαστάσεις.

Σχηματισμοί αυτού του τύπου καλούνται δίκτυα Perceptron πολλών στρώματων (Multi-Layer Perceptron - MLP). Η γενική αρχιτεκτονική ενός δικτύου MLP με L στρώματα δίνεται παρακάτω. Το χαρακτηριστικό των δικτύων αυτών είναι πως οι νευρώνες του στρώματος l τροφοδοτούν αποκλειστικά τους νευρώνες του επόμενου στρώματος $l+1$ και τροφοδοτούνται

αποκλειστικά από τους νευρώνες του προηγούμενου στρώματος $l-1$.



Σχήμα 2.3.2: Γενική σχηματική μορφή δικτύου Perceptron πολλών στρωμάτων

Ένα δίκτυο MLP μπορεί να υλοποιήσει οποιαδήποτε διαχωριστική επιφάνεια σε n διαστάσεις, σε αντίθεση με το απλό δίκτυο Perceptron που μπορεί να υλοποιήσει μόνο ευθείες επιφάνειες [42]. Πράγματι, αν θέλουμε να προσεγγίσουμε οποιαδήποτε διαχωριστική επιφάνεια στον χώρο $\mathbb{R}^n$ χρησιμοποιώντας ένα MLP, αρκεί να βρούμε μια συνάρτηση $g(x)$ τέτοια ώστε για κάποιο κατώφλι θ , ο χώρος $\mathbb{R}^n$ χωρίζεται σε δύο τμήματα. Στο ένα τμήμα θα ισχύει $g(x) > \theta$, ενώ στο άλλο $g(x) < \theta$ [35].

Ανάκληση

Αποτελεί την διαδικασία υπολογισμού των τιμών όλων των νευρώνων του δικτύου με δεδομένες τις τιμές των εισόδων. Ορίζουμε αρχικά ως

- L το πλήθος των στρωμάτων του δικτύου εκτός του στρώματος εισόδου.
- $N(l)$ είναι το πλήθος των νευρώνων του στρώματος l , $l = 0, \dots, L$.
- $\alpha_i(l)$ είναι οι ενεργοποιήσεις των νευρώνων του στρώματος l .
- $w_{ij}(l)$ είναι το συναπτικό βάρος που συνδέει τον νευρώνα $\alpha_j(l-1)$ του στρώματος $l-1$ με τον νευρώνα $\alpha_i(l)$ του στρώματος l .
- $w_{i0}(l)$ είναι η πόλωση του νευρώνα $\alpha_i(l)$ του στρώματος l .

- $x_i = \alpha_i(0)$ είναι οι είσοδοι του δικτύου.
- $y_i = \alpha_i(L)$ είναι οι έξοδοι του δικτύου.

Οι ενεργοποιήσεις των νευρώνων για κάθε στρώμα δίνονται από την σχέση

$$a_i(l) = f \left(\sum_{j=1}^{N(l-1)} w_{ij}(l) a_j(l-1) + w_{i0}(l) \right) \quad (2.14)$$

2.3.2 Εκπαίδευση νευρωνικών δικτύων

Η εκπαίδευση ενός δικτύου πολλών στρωμάτων αποτελεί την διαδικασία καθορισμού των συναπτικών βαρών του έτσι ώστε να ικανοποιείται κάποιο κριτήριο καταλληλότητας. Αυτός είναι και ο λόγος της εκπαίδευσης σε οποιοδήποτε νευρωνικό δίκτυο. Κυριότερος εκπρόσωπος των αλγορίθμων εκπαίδευσης MLP αποτελεί ο αλγόριθμος οπισθοδιάδοσης. Ο αλγόριθμος οπισθοδιάδοσης προτάθηκε από τον Paul Werbos στη δεκαετία του 1970 στα πλαίσια της ανάλυσης μοντέλων οικονομικής και πολιτικής πρόβλεψης. Στη δεκαετία του 1980 έγινε αντιληπτό πως η μέθοδος μπορούσε να μεταφερθεί αυτούσια στην εκπαίδευση νευρωνικών δικτύων πολλών στρωμάτων και έκτοτε έγινε η πιο γνωστή και η πιο διαδεδομένη μέθοδος για τον σκοπό αυτό.

Βασικό χαρακτηριστικό της μεθόδου αποτελεί η ύπαρξη στόχων. Συνεπώς, το μοντέλο ανήκει στην κατηγορία των δικτύων που εκπαιδεύονται με επίβλεψη. Έστω δίκτυο με L στρώματα, n εισόδους και m εξόδους. Ορίζουμε ως

- $\mathbf{x}^{(p)} = [x_1^{(p)}, \dots, x_n^{(p)}]^T$ το p -οστό διάνυσμα εισόδου
- $\mathbf{y}^{(p)} = [y_1^{(p)}, \dots, y_m^{(p)}]^T$ το p -οστό διάνυσμα εξόδου
- $\mathbf{t}^{(p)} = [t_1^{(p)}, \dots, t_m^{(p)}]^T$ το p -οστό διάνυσμα στόχων

Τα δεδομένα που απαιτούνται για να εκπαιδευτεί το δίκτυο είναι τα ζεύγη διανυσμάτων $\{\mathbf{x}^{(i)}, \mathbf{t}^{(i)}\}$, $i = 1, \dots, P$. Θα ήταν ιδανικό να πετυχαίναμε ταύτιση εξόδων και στόχων για κάθε πρότυπο εισόδου, ωστόσο αυτό μπορεί να μην είναι απολύτως εφικτό. Για αυτό τον λόγο επιζητούμε τη βέλτιστη προσέγγιση της επιθυμητής κατάστασης χρησιμοποιώντας κάποιο κριτήριο κόστους [35]. Το κριτήριο κόστους σύμφωνα με το [43] ορίζεται ως ακολούθως.

Στα προβλήματα μηχανικής μάθησης, στόχος είναι η εκμάθηση μιας συνάρτησης $f : \Phi \rightarrow \mathcal{Y}$. Η συνάρτηση f προσεγγίζεται από ένα παραμετροποιημένο μοντέλο f_Θ , όπου Θ είναι το

σύνολο των παραμέτρων του μοντέλου. Η γενική μορφή της συνάρτησης κόστους είναι

$$L(f_{\Theta}) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(x_i), y_i) \quad (2.15)$$

Όπου $\{(x_i, y_i)\}_{i=1}^N$ το σύνολο δεδομένων εκπαίδευσης και $\mathcal{L}(f_{\Theta}(x_i), y_i)$ συνάρτηση, η οποία υπολογίζει την απόκλιση της πρόβλεψης $f_{\Theta}(x_i)$ από την πραγματική τιμή y_i . Η διαδικασία βελτιστοποίησης στοχεύει στην ελαχιστοποίηση του κόστους μεταβάλλοντας το Θ . Μαθηματικά, αυτό διατυπώνεται ως

$$\min_{\Theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(x_i), y_i) \quad (2.16)$$

Με την εισαγωγή ρυθμιστικού όρου (Regularization Term), το πρόβλημα μετασχηματίζεται σε

$$\min_{\Theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\Theta}(x_i), y_i) + R(\Theta) \quad (2.17)$$

Η συνάρτηση κόστους, όπως και ο ρυθμιστικός όρος έχουν σύνολο τιμών το $\mathbb{R}$. Παρακάτω παρουσιάζονται οι σημαντικότερες συναρτήσεις κόστους για τους σκοπούς τις παρούσας εργασίας.

Συνάρτηση απώλειας διασταυρωμένης εντροπίας (Cross-Entropy Loss Function)

Η συνάρτηση απώλειας διασταυρωμένης εντροπίας αποτελεί συνάρτηση κόστους η οποία χρησιμοποιείται εκτενώς σε προβλήματα ταξινόμησης, ιδιαίτερα σε νευρωνικά δίκτυα που η έξοδος αποτελεί κατανομή πιθανοτήτων πάνω στις διακριτές κλάσεις του προβλήματος. Η μαθηματική της μορφή δίνεται παρακάτω.

$$\mathcal{L}_{CE} = - \sum_{k=1}^K y_k \log(p_k) \quad (2.18)$$

Όπου K ο αριθμός των κλάσεων του προβλήματος ταξινόμησης, $p = (p_1, \dots, p_K)$ η προβλεπόμενη κατανομή πιθανοτήτων και $y = (y_1, \dots, y_K)$ το διάνυσμα στόχος. Το διάνυσμα y είναι συνήθως one-hot κωδικοποιημένο, δηλαδή όλα του τα στοιχεία είναι μηδενικά, εκτός από ένα που είναι ίσο με ένα. Το στοιχείο αυτό υποδεικνύει τη σωστή κλάση.

Για την απόδοση πιθανοτικής μορφής στις εξόδους, στο στρώμα εξόδου εφαρμόζεται η συνάρτηση Softmax. Η μαθηματική μορφή της συνάρτησης ενεργοποίησης Softmax είναι

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \quad (2.19)$$

Όπου z_k η είσοδος της συνάρτησης που αντιστοιχεί στην κλάση k , και K το πλήθος των κλάσεων του προβλήματος ταξινόμησης [44].

Συνάρτηση απώλειας ζαριών (Dice Loss Function)

Η συνάρτηση απώλειας ζαριών αποτελεί μια ευρέως χρησιμοποιημένη επιλογή σε προβλήματα κατάτμησης εικόνας, ιδίως όταν παρατηρείται έντονη ανισορροπία μεταξύ του πλήθους των εικονοστοιχείων των περιοχών της μάσκας που αντιστοιχούν στο "αντικείμενο" ενδιαφέροντος και των υπόλοιπων περιοχών. Με απλά λόγια αποτελεί καλή επιλογή όταν ζητούμενο είναι η ανίχνευση μικρών "αντικειμένων" στην εικόνα. Βασίζεται στον συντελεστή ζαριών (Dice Coefficient), ο οποίος ποσοτικοποιεί το μέγεθος της επικάλυψης του "αντικειμένου" ενδιαφέροντος στην μάσκα πρόβλεψης και στην μάσκα στόχου. Η μαθηματική της μορφή δίνεται παρακάτω.

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i f_{\theta}(\mathbf{x}_i) y_i}{\sum_i f_{\theta}(\mathbf{x}_i) + \sum_i y_i}, \quad (2.20)$$

Όπου $f_{\theta}(\mathbf{x}_i)$ η προβλεπόμενη πιθανότητα το εικονοστοιχείο i να ανήκει στο "αντικείμενο" ενδιαφέροντος και y_i η αντίστοιχη πραγματική τιμή.

Η συνάρτηση απώλειας ζαριών είναι συνεχής και διαφορίσιμη αλλά όχι κυρτή. Χρησιμοποιείται συχνά στην ιατρική σε εφαρμογές κατάτμησης εικόνας, όπου είναι κρίσιμο να εκτιμηθεί με ακρίβεια ο βαθμός επικάλυψης μεταξύ της προβλεπόμενης μάσκας και της μάσκας στόχου [43].

Βελτιστοποίηση (Optimization)

Η συνάρτηση κόστους επιτρέπει την αξιολόγηση της ποιότητας των εκτιμήσεων ενός μοντέλου για οποιοδήποτε σύνολο παραμέτρων. Ο στόχος της διαδικασίας βελτιστοποίησης αποτελεί η ελαχιστοποίηση της συνάρτησης κόστους μέσω της προσαρμογής των παραμέτρων του μοντέλου. Παρακάτω παρουσιάζονται ορισμένες από τις σημαντικότερες μεθόδους βελτιστοποίησης για τους σκοπούς της παρούσας εργασίας.

Στοχαστική κατάβαση δυναμικού (Stochastic Gradient Descent)

Σε αυτή την μέθοδο τα δεδομένα εκπαίδευσης χωρίζονται σε παρτίδες (Batches) (Κεφάλαιο 2.3.3), όπου κάθε μια από αυτές περιλαμβάνει B πρότυπα, συνοδευόμενα από τους αντιστοιχούς τους στόχους. Σε κάθε εποχή εκπαίδευσης γίνεται χρήση όλων των παρτίδων από ακριβώς μια φορά. Η διόρθωση των παραμέτρων του μοντέλου πραγματοποιείται αφού παρουσιαστούν όλα τα πρότυπα κάθε παρτίδας. Έστω $w_{ij}^{(k)}$ το βάρος που αντιστοιχεί στην σύνδεση μεταξύ του νευρώνα j και i κατά την k -οστή επανάληψη, J η συνάρτηση κόστους και β ο ρυθμός μάθησης (Learning Rate), ο οποίος αποτελεί υπερπαραμέτρο της μεθόδου [35]. Η μαθηματική σχέση που εκφράζει την μέθοδο στοχαστικής κατάβασης δυναμικού δίνεται παρακάτω.

$$w_{ij}^{(k+1)} = w_{ij}^{(k)} - \beta \frac{\partial J}{\partial w_{ij}} \quad (2.21)$$

Adaptive Moment Estimation with decoupled Weight decay - AdamW

Η μέθοδος AdamW [45] αποτελεί βελτίωση της ADAM [46]. Η βελτιωμένη αυτή μορφή οδηγεί σε καλύτερη γενίκευση και πιο αξιόπιστα αποτελέσματα σε διάφορες εφαρμογές μηχανικής μάθησης. Η κύρια διαφοροποίηση έγκειται στην εισαγωγή ενός διαφορετικού τρόπου ενσωμάτωσης της αποδυνάμωσης βαρών (Weight Decay), αποσυνδέοντας την από την συνάρτηση κόστους. Στην κλασική ADAM η αποδυνάμωση εφαρμόζεται προαιρετικά στη συνάρτηση κόστους μέσω της ρύθμισης $L2$, στην AdamW εφαρμόζεται ως ξεχωριστό βήμα στο τέλος της ενημέρωσης των παραμέτρων. Η διαδικασία ενημέρωσης των παραμέτρων πραγματοποιείται μέσω των σταδίων υπολογισμού που περιγράφονται στην συνέχεια.

Στο πρώτο στάδιο, η κλίση της συνάρτησης κόστους J προκύπτει από τη σχέση

$$g_k = \nabla J_k(w_{k-1}) \quad (2.22)$$

Όπου w οι παράμετροι του μοντέλου.

Στη συνέχεια υπολογίζονται οι εκθετικά κινητοί μέσοι όροι των παραγώγων, m_k και u_k όπως και οι διορθώσεις μεροληψίας τους, $\hat{m}_k$ και $\hat{u}_k$ αντίστοιχα. Οι τιμές β_1 και β_2 αποτελούν υπερ-παραμέτρους της μεθόδου.

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k, \quad \hat{m}_k = \frac{m_k}{1 - \beta_1^k} \quad (2.23)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2, \quad \hat{v}_k = \frac{v_k}{1 - \beta_2^k} \quad (2.24)$$

Τέλος, εφαρμόζεται η παρακάτω σχέση για την ενημέρωση των παραμέτρων.

$$w_k = w_{k-1} - \beta \left(\frac{\alpha \hat{m}_k}{\sqrt{\hat{v}_k} + \epsilon} + \lambda w_{k-1} \right) \quad (2.25)$$

Η μοναδική διαφορά που έχει η μέθοδος ADAM με την AdamW εντοπίζεται στην μορφή της παραπάνω σχέσης, με τον όρο λw_{k-1} να μην εμφανίζεται.

Οπισθοδιάδοση (Backpropagation)

Στα νευρωνικά δίκτυα με πολλές παραμέτρους, η σχέση μεταξύ της συνάρτησης κόστους και των παραμέτρων του μοντέλου είναι δύσκολο να προσδιοριστεί. Λύση στο πρόβλημα αυτό δίνει ο αλγόριθμος οπισθοδιάδοσης [47], ο οποίος παρέχει ένα αποδοτικό τρόπο για τον υπολογισμό των μερικών παραγώγων της συνάρτησης κόστους ως προς τις παραμέτρους του μοντέλου κάθε στρώματος. Οι εν λόγω παράγωγοι αποτελούν απαραίτητο στοιχείο της διαδικασίας εκπαίδευσης του μοντέλου και χρησιμοποιούνται στις ανανεώσεις των παραμέτρων του μοντέλου μέσω της διαδικασίας βελτιστοποίησης [48]. Η μαθηματική μορφή του αλγορίθμου διατυπώνεται ως

ακολουθώς.

Αρχικά, ορίζεται η συνολική συνάρτηση κόστους της παρτίδας ως το άθροισμα των επιμέρους απωλειών κάθε δείγματος της. Η μαθηματική σχέση που την εκφράζει δίνεται από την εξίσωση

$$J(w) = \sum_{i=1}^m L_i(w) \quad (2.26)$$

Όπου $L_i(w)$ η επιμέρους απώλεια του δείγματος i και m το πλήθος των δειγμάτων της παρτίδας.

Για την ευκολότερη περιγραφή της διαδικασίας οπισθοδιάδοσης, η περιγραφή της μεθόδου θα πραγματοποιηθεί για την ειδική περίπτωση που η συνάρτηση κόστους είναι το μέσο τετραγωνικό σφάλμα (Mean Square Error). Το μέσο τετραγωνικό σφάλμα δίνεται από την σχέση

$$L_i = \frac{1}{2} \sum_k (\hat{y}_{ik} - y_{ik})^2 \quad (2.27)$$

Όπου $\hat{y}_{ik}$ συμβολίζει την έξοδο του νευρώνα k για το δείγμα i της παρτίδας, ενώ y_{ik} τον αντίστοιχο στόχο.

Έστω a_j η είσοδος του νευρώνα j και z_j η αντίστοιχη έξοδος. Ο υπολογισμός τους γίνεται μέσω των σχέσεων που δίνονται παρακάτω.

$$a_j = \sum_i w_{ji} z_i \quad (2.28)$$

$$z_j = h(a_j) \quad (2.29)$$

Όπου h η συνάρτηση ενεργοποίησης του νευρώνα και w_{ij} το συναπτικό από τον νευρώνα j στον νευρώνα i .

Μέσω του κανόνα αλυσίδας και των σχέσεων (2.28) και (2.29) υπολογίζεται η παράγωγος του

L_i ως προς το w_{ij} .

$$\frac{\partial L_i}{\partial w_{ij}} = \frac{\partial L_i}{\partial a_j} \cdot \frac{\partial a_j}{\partial w_{ij}} \quad (2.30)$$

Η μερική παράγωγος της (2.28) ως προς το w_{ij} δίνεται από την σχέση

$$\frac{\partial a_j}{\partial w_{ij}} = z_i \quad (2.31)$$

Στην συνέχεια, ορίζεται η

$$\delta_j = \frac{\partial L_i}{\partial a_j} \quad (2.32)$$

που αποτελεί το σφάλμα του νευρώνα j . Μέσω του κανόνα αλυσίδας το σφάλμα για κάθε νευρώνα πλιν των νευρώνων του στρώματος εξόδου υπολογίζεται μέσω της παρακάτω σχέσης.

$$\delta_j = \frac{\partial L_i}{\partial a_j} = \sum_k \frac{\partial L_i}{\partial a_k} \cdot \frac{\partial a_k}{\partial a_j} = h'(a_j) \sum_k w_{kj} \delta_k \quad (2.33)$$

Για να είναι χρήσιμη η παραπάνω σχέση απαιτείται η γνώση των τιμών των σφαλμάτων κάθε νευρώνα εξόδου. Ο τρόπος υπολογισμού των τιμών αυτών καθορίζεται από την συνάρτηση κόστους που εφαρμόζεται. Ενδεικτικά, εάν η συνάρτηση κόστους του μοντέλου είναι το μέσο τετραγωνικό σφάλμα, τότε οι σχέσεις υπολογισμού των σφαλμάτων των νευρώνων εξόδου έχουν την εξής μορφή.

$$\delta_k = \hat{y}_k - y_k \quad (2.34)$$

Όπου $\hat{y}_k$ δηλώνει την έξοδο του νευρώνα k , ενώ y_k τον αντίστοιχο στόχο.

Τα βήματα του αλγορίθμου οπισθοδιάδοσης μπορούν να συνοψιστούν όπως παρακάτω:

1. Δίνεται είσοδος στο μοντέλο και μέσω των σχέσεων (2.28) και (2.29) υπολογίζονται οι τιμές των εξόδων των νευρώνων.
2. Υπολογίζονται οι τιμές των σφαλμάτων δ_k κάθε νευρώνα εξόδου.
3. Μέσω της σχέσης (2.33) υπολογίζονται οι τιμές των σφαλμάτων όλων των υπόλοιπων νευρώνων.
4. Μέσω της σχέσης $\frac{\partial L_i}{\partial w_{ij}} = \delta_j z_i$ υπολογίζονται όλες οι απαραίτητες παράγωγοι.

Η παράγωγος της συνολικής συνάρτησης κόστους J υπολογίζεται επαναλαμβάνοντας τα παραπάνω βήματα για κάθε δείγμα της παρτίδας και στη συνέχεια αθροίζοντας.

$$\frac{\partial J}{\partial w_{ij}} = \sum_m \frac{\partial L_m}{\partial w_{ij}} \quad (2.35)$$

2.3.3 Ρύθμιση (Regularization)

Ως ρύθμιση [49] ορίζεται οποιαδήποτε πρόσθετη τεχνική που εφαρμόζεται με σκοπό την βελτίωση της ικανότητας γενίκευσης του μοντέλου, δηλαδή την παραγωγή πιο αξιόπιστων προβλέψεων σε άγνωστα δεδομένα. Υπάρχει πλήθος τεχνικών για την εξυπηρέτηση αυτού του σκοπού, οι οποίες δύνανται να ταξινομηθούν ανάλογα με το εάν επηρεάζουν τα δεδομένα εκπαίδευσης, την αρχιτεκτονική του δικτύου, την συνάρτηση κόστους, τον ρυθμιστικό όρο ή την διαδικασία βελτιστοποίησης. Για τις ανάγκες της παρούσας εργασίας παρουσιάζονται μόνο οι σημαντικότερες τεχνικές ρύθμισης για αυτή.

Ρύθμιση L1 (L1 Regularization)

Η ρύθμιση L1 [50] αποτελεί τεχνική η οποία χρησιμοποιείται για την αποτροπή υπερπροσαρμογής και την επίτευξη αραίωσης του μοντέλου. Συγκεκριμένα, ένας όρος ποινής προστίθεται στην συνάρτηση κόστους, μέσω του ρυθμιστικού όρου, ο οποίος είναι ανάλογος με το άθροισμα των απόλυτων τιμών των βαρών και έχει ως σκοπό να τιμωρήσει τα μεγάλα βάρη. Η ρύθμιση L1 ευνοεί την ανάπτυξη μοντέλων στα οποία πολλές παράμετροι μηδενίζονται, οδηγώντας σε "αραιότερα" μοντέλα. Η μαθηματική της μορφή δίνεται παρακάτω.

$$R(w) = \frac{\lambda}{2} \|w\|_1 = \frac{\lambda}{2} \sum_i |w_i| \quad (2.36)$$

Όπου λ υπερπαράμετρος που καθορίζει την βαρύτητα της ποινής, w το διάνυσμα των παραμέτρων (Βαρών) του μοντέλου και $\|\cdot\|_1$ η νόρμα ℓ_1 .

Ρύθμιση L2 (L2 Regularization)

Η ρύθμιση L2 [51] αποτελεί τεχνική που χρησιμοποιείται για την αποτροπή υπερπροσαρμογής κατά την διάρκεια της εκπαίδευσης ενός νευρωνικού δικτύου. Η βασική ιδέα αποτελεί η προσθήκη ενός όρου ποινής στην συνάρτηση κόστους μέσω του ρυθμιστικού όρου, ο οποίος τιμωρεί τα μεγάλα βάρη. Αυτό έχει ως αποτέλεσμα την κατασκευή απλούστερων μοντέλων με βελτιωμένες ικανότητες γενίκευσης σε νέα, άγνωστα δεδομένα. Η μαθηματική της μορφή δίνεται παρακάτω.

$$R(w) = \frac{\lambda}{2} \|w\|_2^2 = \frac{\lambda}{2} \sum_i w_i^2 \quad (2.37)$$

Όπου λ υπερπαράμετρος που καθορίζει την βαρύτητα της ποινής, w το διάνυσμα των παραμέτρων (Βαρών) του μοντέλου και $\|\cdot\|_2$ η Ευκλείδεια νόρμα.

Απόρριψη (Dropout)

Παρά την υψηλή εκφραστικότητα των βαθιών νευρωνικών δικτύων με πολλές παραμέτρους, εξακολουθούν να είναι επιρρεπή σε προβλήματα όπως η υπερπροσαρμογή και η υψηλή υπολογιστική πολυπλοκότητα. Η τεχνική της απόρριψης συνιστά μια αποτελεσματική λύση για την αντιμετώπιση των παραπάνω προβλημάτων. Η κεντρική ιδέα αποτελεί η τυχαία απενεργοποίηση ορισμένων νευρώνων του μοντέλου, μαζί με τις συνδέσεις τους, κατά τη διάρκεια της εκπαίδευσης. Αυτό συνιστά στην αποτροπή της υπερβολικής εξάρτησης των νευρώνων μεταξύ τους, ενισχύοντας έτσι την ικανότητα γενίκευσης του μοντέλου σε νέα δεδομένα.


Κατά την διαδικασία εκπαίδευσης του μοντέλου, η τεχνική ισοδυναμεί με δειγματοληψία από ένα νέο, τυχαία "αραιωμένο" δίκτυο σε κάθε βήμα, καθώς κάθε φορά επιλέγεται διαφορετικό υποσύνολο ενεργών νευρώνων. Ο συνολικός αριθμός των πιθανών "αραιωμένων" δικτύων είναι εκθετικός σε σχέση με το πλήθος των νευρώνων. Η απόρριψη έχει αποδειχθεί εξαιρετικά αποτελεσματική στη μείωση της υπερπροσαρμογής και συχνά υπερτερεί έναντι άλλων μεθόδων κανονικοποίησης. Η εκπαίδευση του μοντέλου πραγματοποιείται κανονικά με χρήση οπισθοδιάδοσης, κατά την οποία σε κάθε επανάληψη μόνο οι νευρώνες που δεν έχουν απενεργοποιηθεί συμμετέχουν στην ενημέρωση των παραμέτρων.

Η μαθηματική διατύπωση της διαδικασίας προώθησης νευρωνικού δικτύου με απόρριψη παρουσιάζεται παρακάτω.

Έστω νευρωνικό δίκτυο με L κρυφά στρώματα και $l \in \{1, \dots, L\}$ οι αντίστοιχοι δείκτες. Έστω $y^{(l)}$ το διάνυσμα των εξόδων του επιπέδου l (Το $y^{(0)}$ είναι η είσοδος του δικτύου). Τα $W^{(l)}$ και $b^{(l)}$ αποτελούν τα βάρη και τις προκαταλήψεις του επιπέδου l . Για $f(\cdot)$ συνάρτηση ενεργοποίησης, p υπερπαραμέτρο και $\mathbf{r}_j^{(l)} \sim \text{Bernoulli}(p)$, η διαδικασία προώθησης κατά την εκπαίδευση του δικτύου έχει την ακόλουθη μορφή

$$y_i^{(l+1)} = f\left(\mathbf{w}_i^{(l+1)} (\mathbf{r}^{(l)} * \mathbf{y}^{(l)}) + b_i^{(l+1)}\right) \quad (2.38)$$

Κατά την φάση πρόβλεψης σε νευρωνικό δίκτυο με απόρριψη, μια θεωρητικά ακριβής προσέγγιση αποτελεί ο υπολογισμός του μέσου όρου των προβλέψεων όλων των πιθανών "αραιωμένων" δικτύων που θα μπορούσαν να προκύψουν. Ωστόσο, κάτι τέτοιο είναι πρακτικά αδύνατο, λόγω του τεράστιου υπολογιστικού κόστους που απαιτείται. Αντί αυτού, χρησιμοποιείται μια απλή και αποδοτική προσέγγιση κατά την οποία αξιοποιείται ένα μόνο πλήρες δίκτυο και συγκεκριμένα το δίκτυο που προκύπτει με το τέλος της εκπαιδευτικής διαδικασίας, με τις παραμέτρους του να έχουν κατάλληλα τροποποιηθεί μέσω μιας ντετερμινιστικής διαδικασίας. Συγκεκριμένα, εάν κατά την διαδικασία εκπαίδευσης κάθε νευρώνας διατηρείται με πιθανότητα p , τότε κατά την πρόβλεψη τα εξερχόμενα βάρη του κλιμακώνονται αναλόγως με τον παράγοντα αυτό. Με αυτό τον τρόπο διασφαλίζεται πως η αναμενόμενη έξοδος του δικτύου κατά την εκπαίδευση ισούται με την αντίστοιχη έξοδο του δικτύου κατά την πρόβλεψη. Ακολουθεί η σχηματική απεικόνιση της τεχνικής απόρριψης που περιγράφηκε παραπάνω, περιορισμένη στο επίπεδο ενός μεμονωμένου νευρώνα [52].



Σχήμα 2.3.3: Απεικόνιση της τεχνικής της απόρριψης: (a) Κατά την εκπαίδευση, κάθε μονάδα διατηρείται με πιθανότητα p . (b) Κατά τη δοκιμή, όλες οι μονάδες είναι ενεργές και τα βάρη κλιμακώνονται κατά p .

Μέγεθος Παρτίδας (Batch Size)

Το μέγεθος παρτίδας αποτελεί υπερπαραμέτρο που καθορίζει τον αριθμό των δειγμάτων που επεξεργάζεται το μοντέλο κατά την εκπαίδευση προτού πραγματοποιηθεί η ενημέρωση των παραμέτρων του. Το σύνολο δεδομένων εκπαίδευσης μπορεί να διαιρεθεί σε μια ή περισσότερες παρτίδες. Διακρίνονται συνολικά τρεις βασικές τεχνικές επιλογής του μεγέθους παρτίδας, οι οποίες παρουσιάζονται στη συνέχεια.

- Όταν το μέγεθος παρτίδας ισούται με το πλήθος των στοιχείων του συνόλου δεδομένων, τότε χρησιμοποιείται κατάβαση κλίσης όλου του συνόλου (Batch Gradient Descent)
- Όταν το μέγεθος παρτίδας ισούται με ένα, τότε χρησιμοποιείται στοχαστική κατάβαση κλίσης (Stochastic Gradient Descent)
- Όταν δεν ισχύει κανένα από τα παραπάνω, χρησιμοποιείται κατάβαση κλίσης μικρών παρτίδων (Mini-Batch Gradient Descent)


Στην κατάβαση κλίσης μικρών παρτίδων τα πιο συνηθισμένα μεγέθη παρτίδων είναι 32, 64 και 128. Σε περίπτωση που το πλήθος των δειγμάτων του συνόλου δεδομένων εκπαίδευσης δεν διαιρείται ακριβώς με το μέγεθος παρτίδας, η τελευταία παρτίδα περιλαμβάνει μικρότερο αριθμό δειγμάτων [53].

Η επιλογή της τιμής της υπερπαραμέτρου αποτελεί κρίσιμο παράγοντα που μπορεί να επηρεάσει τόσο την αποδοτικότητα του μοντέλου όσο και την σταθερότητα της εκπαίδευσης. Από την μια πλευρά, μικρά μεγέθη παρτίδων ευνοούν την ικανότητα γενίκευσης του μοντέλου σε άγνωστα δεδομένα, ωστόσο όμως παρουσιάζουν προβλήματα σταθερότητας και είναι λιγότερο αποδοτικά από άποψη υπολογιστικού κόστους. Από την άλλη, μεγαλύτερα μεγέθη παρτίδων μειώνουν το υπολογιστικό κόστος εκπαίδευσης του μοντέλου αλλά ενδέχεται να οδηγήσουν σε χειρότερη ικανότητα γενίκευσης σε νέα δεδομένα [54].

2.4 Συνελικτικά νευρωνικά δίκτυα

Τα συνελικτικά νευρωνικά δίκτυα (Convolutional Neural Networks - CNNs) αποτελούν δίκτυα πολλών στρωμάτων κατάλληλα για λειτουργίες αναγνώρισης εικόνας. Προτάθηκαν αρχικά από τον LeCun την δεκαετία του 1980 και αποτελούνται από εναλλασσόμενα στρώματα συνέλιξης και υποδειγματοληψίας. Η αλληλουχία αυτή υλοποιεί ουσιαστικά ένα μετασχηματισμό της εικόνας σε χάρτη χαρακτηριστικών (Feature Map). Μετά το τελευταίο στρώμα συνέλιξης ή υποδειγματοληψίας ακολουθούν ένα ή περισσότερα πλήρως συνδεδεμένα στρώματα τα οποία λειτουργούν ως ένα υποδίκτυο ταξινομητή. Η αλληλουχία των στρωμάτων συνέλιξης και

υποδειγματοληψίας υλοποιεί ουσιαστικά ένα μετασχηματισμό της εικόνας εισόδου σε χάρτη χαρακτηριστικών. Κατόπιν, ο χάρτης αυτός εισάγεται ως είσοδος σε ένα ταξινομητή. Η αρχιτεκτονική ενός τυπικού συνελκτικού νευρωνικού δικτύου δίνεται παρακάτω.



Σχήμα 2.4.1: Η αρχιτεκτονική ενός τυπικού συνελκτικού νευρωνικού δικτύου


Η έξοδος ενός συνελκτικού στρώματος ή ενός στρώματος υποδειγματοληψίας αποτελεί μια σειρά από χάρτες χαρακτηριστικών. Κάθε χάρτης χαρακτηριστικών αποτελεί ένα δισδιάστατο πλέγμα από νευρώνες όπου κάθε ένας διεγείρεται από μια μικρή περιοχή του προηγούμενου στρώματος. Αυτή η περιοχή καλείται τοπικό υποδεκτικό πεδίο του νευρώνα. Τα συναπτικά βάρη που συνδέουν ένα νευρώνα με τους νευρώνες του τοπικού του πεδίου είναι συλλογικά γνωστά ως μάσκα. Όλοι οι νευρώνες που βρίσκονται στον ίδιο χάρτη χαρακτηριστικών έχουν την ίδια μάσκα, οπότε προκύπτει επανάληψη βαρών. Η εκπαίδευση των παραμέτρων ενός συνελκτικού δικτύου πραγματοποιείται με την κλασική μέθοδο της οπισθοδιάδοσης. Όσον αφορά την δομή του δικτύου, οι νευρώνες των στρωμάτων συνέλιξης και υποδειγματοληψίας δεν συνδέονται απαραίτητα με όλους τους νευρώνες του προηγούμενου στρώματος. Αυτό έχει δύο βασικές συνέπειες.

- Το πλήθος των παραμέτρων του μοντέλου μειώνεται και η εκπαίδευση γίνεται ταχύτερα.
- Η επίδοση του μοντέλου βελτιώνεται, καθώς καθίσταται δυνατή η αναγνώριση χαρακτηριστικών ανεξάρτητα από τη θέση τους στην εικόνα.

Κάθε συνελκτικό στρώμα αποτελείται από ένα σύνολο χαρτών χαρακτηριστικών, έστω C . Κάθε χάρτης χαρακτηριστικών αποτελεί ένα δισδιάστατο πλέγμα νευρώνων διαστάσεων $N \times N$. Επομένως, κάθε συνελκτικό στρώμα αποτελείται από συνολικά $N \times N \times C$ νευρώνες. Η έξοδος του νευρώνα που αντιστοιχεί στην θέση (i, j) του k -οστού χάρτη χαρακτηριστικών υπολογίζεται μέσω της παρακάτω σχέσης.


$$y_{ij}^k = f \left(\sum_{l=1}^{C'} \sum_{\alpha=1}^m \sum_{\beta=1}^m w_{\alpha,\beta,l}^k x_{i-\alpha,j-\beta}^l + b^k \right) \quad (2.39)$$

Υπολογίζει το άθροισμα των τιμών $x_{i-\alpha,j-\beta}^l$ των νευρώνων για όλους τους χάρτες χαρακτηριστικών $l = 1, \dots, C'$ του προηγούμενου στρώματος.



Σχήμα 2.4.2: Αναπαράσταση υπολογισμού νευρώνα y_{ij}^k του k -οστού χάρτη χαρακτηριστικών και στρώματος L

Ο τρισδιάστατος πίνακας $W^k = [w_{\alpha,\beta,l}^k]$ καλείται μάσκα ή φίλτρο του k -οστού χάρτη χαρακτηριστικών. Η $f(\cdot)$ αποτελεί την συνάρτηση ενεργοποίησης και η παράμετρος b^k την πόλωση του νευρώνα. Η πράξη εντός της παρένθεσης στο δεξιό μέλος της εξίσωσης (2.39) είναι γνωστή ως συνέλιξη. Η συνέλιξη λειτουργεί ως φίλτρο το οποίο σαρώνει όλη την εικόνα εισόδου και δίνει την μέγιστη απόκριση εκεί όπου εμφανίζεται ένα τοπικό χαρακτηριστικό όμοιο με το σχήμα της μάσκας. Αποτελεί ουσιαστικά ένα εξαγωγέα χαρακτηριστικών [35].



Σχήμα 2.4.3: Εξαγωγή χαρακτηριστικών

2.4.1 Συνέλιξη με βήμα

Διάφορες παραλλαγές της κλασικής συνέλιξης έχουν προταθεί. Δημοφιλέστερη εξ αυτών αποτελεί η συνέλιξη με βήμα (Strided Convolution). Σε αυτή την παραλλαγή, η μάσκα w_{ij} δεν εφαρμόζεται σε κάθε δυνατή θέση (i,j) του χάρτη χαρακτηριστικών αλλά μετακινείται με βήμα s_i κατά την κατεύθυνση i και s_j κατά την κατεύθυνση j . Αυτή η παραλλαγή μπορεί να οδηγήσει σε σημαντική μείωση των υπολογισμών, χωρίς ιδιαίτερα μεγάλη μείωση της επίδοσης [35]. Με μαθηματικούς όρους η συνέλιξη με βήμα ορίζεται ως

$$y_{i,j} = f \left(\sum_{a=1}^{f_h} \sum_{b=1}^{f_w} w_{a,b} x_{is_i-\alpha, js_j-b} \right) \quad (2.40)$$

Όπου $f(\cdot)$ συνάρτηση ενεργοποίησης. Ο πυρήνας είναι διαστάσεων $f_h \times f_w$.

Για είσοδο μεγέθους $x_h \times x_w$, πυρήνα διαστάσεων $f_h \times f_w$ και κατακόρυφο και οριζόντιο βήμα ίσο με s_h και s_w αντίστοιχα, προκύπτει έξοδος διαστάσεων $\left\lfloor \frac{x_h - f_h + s_h}{s_h} \right\rfloor \times \left\lfloor \frac{x_w - f_w + s_w}{s_w} \right\rfloor$.

2.4.2 Στρώμα υποδειγματοληψίας

Μετά από κάθε συνελκτικό στρώμα συνηθίζεται η τοποθέτηση ενός στρώματος υποδειγματοληψίας. Σκοπός του στρώματος αποτελεί η μείωση την ευαισθησίας του μοντέλου σε μικρές μετατοπίσεις των αντικειμένων της εικόνας, καθώς και η αφαίρεση των λεπτομερειών χαμηλού επιπέδου, χωρίς ωστόσο την πρόκληση απώλειας της ικανότητας διαχωρισμού των αντικειμένων. Στο στρώμα υποδειγματοληψίας η έξοδος y_{ij} κάθε νευρώνα αποτελεί την σύνοψη των εξόδων των νευρώνων από μια συγκεκριμένη γειτονιά διαστάσεων $m \times m$ του προηγούμενου στρώματος. Μια από τις απλούστερες μορφές υποδειγματοληψίας αποτελεί η υποδειγματοληψία μέσης τιμής. Δίνεται από την σχέση

$$y_{ij} = \frac{1}{m^2} \sum_{a=0}^{m-1} \sum_{b=0}^{m-1} x_{im+\alpha, jm+b} \quad (2.41)$$

Για χάρτη χαρακτηριστικών διαστάσεων $N \times N$ και μάσκα υποδειγματοληψίας διαστάσεων $m \times m$, η εφαρμογή υποδειγματοληψίας μέσης τιμής οδηγεί σε χάρτη χαρακτηριστικών διαστάσεων $\frac{N}{m} \times \frac{N}{m}$. Μια άλλη δημοφιλής επιλογή αποτελεί η υποδειγματοληψία μέγιστης τιμής όπου αντί για τον μέσο όρο, λαμβάνεται η μέγιστη τιμή των τιμών των νευρώνων του υποδεκτικού πεδίου. Δίνεται από την σχέση

$$y_{ij} = \max_{0 \leq a, b \leq m-1} x_{im+\alpha, jm+b} \quad (2.42)$$

Είναι σημαντικό να αναφερθεί πως η διαδικασία υποδειγματοληψίας μπορεί να εφαρμοστεί σε πλήθος από χάρτες χαρακτηριστικών και όχι απαραίτητα σε ένα μόνο χάρτη. Η χρήση υποδειγματοληψίας ταυτόχρονα σε πολλούς χάρτες χαρακτηριστικών από διαφορετικές συνελικτικές μάσκες μπορεί να χρησιμοποιηθεί ώστε τα εξαγόμενα χαρακτηριστικά να μην επηρεάζονται από διάφορους μετασχηματισμούς. Για παράδειγμα, έστω τρεις συνελικτικές μάσκες που εφαρμόζονται στην ίδια εικόνα εισόδου και είναι εκπαιδευμένες να ανιχνεύουν το ίδιο σχήμα σε διαφορετικές γωνίες περιστροφής. Η απόκριση των χαρτών θα είναι υψηλή αν η εικόνα εισόδου εμφανίζει υψηλή συσχέτιση με την αντίστοιχη μάσκα. Κάνοντας χρήση αυτής της τεχνικής και χρησιμοποιώντας υποδειγματοληψία μέγιστης τιμής το στρώμα υποδειγματοληψίας είναι ικανό να αναγνωρίσει την ύπαρξη του σχήματος ανεξάρτητα από την γωνιά περιστροφής [35].

2.4.3 Επέκταση με μηδενικά (Zero-padding)

Η επέκταση με μηδενικά αποτελεί τεχνική που χρησιμοποιείται στα συνελικτικά νευρωνικά δίκτυα και περιλαμβάνει την προσθήκη μηδενικών γύρω από την είσοδο, πριν την εφαρμογή των συνελίξεων. Συμβάλλει στην διατήρηση των χωρικών διαστάσεων των χαρτών χαρακτηριστικών όσο το δίκτυο γίνεται βαθύτερο, ενώ παράλληλα επιτρέπει την εξαγωγή χαρακτηριστικών ακόμη και από τα άκρα της εικόνας. Σύμφωνα με το [55] δίκτυα με επέκταση μηδενικών έχουν μεγαλύτερη εκφραστική ικανότητα, μπορούν δηλαδή να εκπαιδευτούν σε περισσότερα είδη μοτίβων σε σχέση με τα δίκτυα χωρίς επέκταση. Η επέκταση μηδενικών καθιστά τα συνελικτικά δίκτυα ισχυρότερα και καταλληλότερα για πολύπλοκες εφαρμογές. Για είσοδο διαστάσεων $x_h \times x_w$, πυρήνα διαστάσεων $f_h \times f_w$ και κατακόρυφη και οριζόντια επέκταση μηδενικών p_h και p_w αντίστοιχα, παράγεται έξοδος διαστάσεων $(x_h - f_h + 2p_h + 1) \times (x_w - f_w + 2p_h + 1)$.

2.4.4 Κανονικοποίηση τιμών (Normalization)

Η κανονικοποίηση αποτελεί τεχνική η οποία χρησιμοποιείται εκτενώς στην εκπαίδευση βαθιών νευρωνικών δικτύων και έχει σκοπό την σταθεροποίηση και επιτάχυνση της διαδικασίας εκπαίδευσης του μοντέλου. Στην πράξη, πρόκειται για μετασχηματισμό των δεδομένων με στόχο την απόκτηση ορισμένων στατιστικών ιδιοτήτων, όπως μέση τιμή ίση με μηδέν, διασπορά ίση με ένα κ.ο.κ.. Η πιο διαδεδομένη της μορφή αποτελεί η κανονικοποίηση ανά παρτίδα (Batch Normalization), η οποία εφαρμόζεται στις ενεργοποιήσεις των νευρώνων κατά την διάρκεια της διαδικασίας εκπαίδευσης. Υπάρχουν και άλλες τεχνικές κανονικοποίησης, όπως για παρά-

δειγμα η κανονικοποίηση ανά στρώμα (Layer Normalization) και η κανονικοποίηση ανά δείγμα (Instance Normalization), οι οποίες προσαρμόζονται σε διαφορετικές αρχιτεκτονικές και προβλήματα. Η κανονικοποίηση επιτρέπει την αποτελεσματικότερη ρύθμιση των παραμέτρων του δικτύου και συχνά οδηγεί σε βελτίωση της ικανότητας γενίκευσης του μοντέλου [56]. Στη συνέχεια, παρουσιάζονται ορισμένες από τις σημαντικότερες τεχνικές κανονικοποίησης βαθιών νευρωνικών δικτύων.

Κανονικοποίηση ανά παρτίδα (Batch Normalization)

Η κανονικοποίηση ανά παρτίδα [57] αποτελεί τεχνική κατά την οποία τα δεδομένα κανονικοποιούνται ανά μικρή παρτίδα (Mini-batch) κατά την διάρκεια της διαδικασίας εκπαίδευσης του δικτύου. Η διαδικασία αυτή ρυθμίζει τις τιμές ώστε να βρίσκονται σε παρόμοια κλίμακα, αποφεύγοντας ακραία μεγάλες ή πολύ μικρές τιμές [58]. Συγκεκριμένα, για κάθε μικρή παρτίδα υπολογίζεται η μέση της τιμή και η τυπική της απόκλιση και στη συνέχεια κάθε στοιχείο της κανονικοποιείται με βάση αυτά τα στατιστικά. Η μαθηματική σχέση που εφαρμόζεται σε κάθε στοιχείο x_i της παρτίδας είναι η εξής.

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \quad (2.43)$$

Όπου:

- μ_B αποτελεί την μέση τιμή της παρτίδας,
- σ_B^2 αποτελεί την διασπορά της παρτίδας,
- ε αποτελεί μια πολύ μικρή σταθερά για αποφυγή διαίρεσης με το μηδέν.

Στη συνέχεια εφαρμόζεται ένας επιπλέον γραμμικός μετασχηματισμός:

$$y_i = \gamma \hat{x}_i + \beta \quad (2.44)$$

Όπου οι παράμετροι γ και β μαθαίνονται για κάθε μικρή παρτίδα κατά την εκπαίδευση, επιτρέποντας στο δίκτυο να προσαρμόσει τη μορφή της εξόδου αν αυτό είναι απαραίτητο.

Κανονικοποίηση ανά ομάδα (Group Normalization)

Η κανονικοποίηση ανά παρτίδα αποτελεί καθοριστική τεχνική στην εξελικτική πορεία της βαθιάς μάθησης, καθώς συχνά επιτρέπει την ευκολότερη και αποδοτικότερη εκπαίδευση σύνθετων νευρωνικών δικτύων. Ωστόσο, εισάγει ορισμένα προβλήματα. Συγκεκριμένα, για μικρά μεγέθη παρτίδων, η ακρίβεια των στατιστικών που υπολογίζονται μειώνεται, οδηγώντας σε αύξηση του σφάλματος. Ως εκ τούτου, η τεχνική αυτή δεν είναι κατάλληλη σε σενάρια όπου απαιτούνται μικρές παρτίδες, όπως στην εκπαίδευση μοντέλων υπολογιστικής όρασης, όπου οι περιορισμοί μνήμης πολλές φορές δεν επιτρέπουν παρτίδες μεγάλου μεγέθους. Μια λύση στο πρόβλημα αυτό δίνεται μέσω της κανονικοποίησης ανά ομάδα [59], η οποία είναι ανεξάρτητη του πλήθους των δειγμάτων της παρτίδας. Στην τεχνική αυτή, αντί να υπολογίζονται τα στατιστικά κατά μήκος της διάστασης της παρτίδας, τα κανάλια κάθε δείγματος διαιρούνται σε ομάδες και για καθεμία από αυτές υπολογίζεται η μέση τιμή και διασπορά. Η κανονικοποίηση ανά ομάδα παρουσιάζει σταθερή απόδοση σε σενάρια με εξαιρετικά μικρές παρτίδες, γεγονός που την καθιστά ιδανική για εργασίες υπολογιστικής όρασης. Ακολουθεί η μαθηματική περιγραφή της κανονικοποίησης ανά ομάδα.

Έστω είσοδος (Παρτίδα) διαστάσεων (N, C, H, W) , όπου

- N αποτελεί το πλήθος των δειγμάτων της παρτίδας,
- C είναι ο αριθμός καναλιών του δείγματος,
- $H \times W$ είναι οι χωρικές διαστάσεις του δείγματος.

Η κανονικοποίηση ανά ομάδα διαιρεί τα C κανάλια σε G ομάδες. Για κάθε στοιχείο x_i της εισόδου, η κανονικοποιημένη τιμή υπολογίζεται ως

$$\hat{x}_i = \frac{x_i - \mu_i}{\sigma_i} \quad (2.45)$$

Όπου η μέση τιμή μ_i και η τυπική απόκλιση σ_i υπολογίζονται εντός της ομάδας ως:

$$\mu_i = \frac{1}{m} \sum_{k \in S_i} x_k, \quad \sigma_i = \sqrt{\frac{1}{m} \sum_{k \in S_i} (x_k - \mu_i)^2 + \varepsilon} \quad (2.46)$$

Το ε αποτελεί μια πολύ μικρή σταθερά για την αποτροπή της περίπτωσης η διασπορά να ισούται με μηδέν. Το S_i είναι το σύνολο των στοιχείων που ανήκουν στο ίδιο δείγμα και στην ίδια

ομάδα καναλιών με το x_i .

$$S_i = \left\{ k \mid k_N = i_N, \left\lfloor \frac{k_C}{C/G} \right\rfloor = \left\lfloor \frac{i_C}{C/G} \right\rfloor \right\} \quad (2.47)$$

Όπου k_N, i_N είναι οι δείκτες του δείγματος στην παρτίδα για τα στοιχεία k και i αντίστοιχα και k_C, i_C οι αντίστοιχοι δείκτες καναλιών.

Τέλος, εφαρμόζεται μια γραμμική μετατροπή με παραμέτρους που μαθαίνονται για κάθε ομάδα κατά την εκπαίδευση.

$$y_i = \gamma \hat{x}_i + \beta \quad (2.48)$$

Κανονικοποίηση ανά παρτίδα και ομάδα (Batch Group Normalization)

Η κανονικοποίηση ανά παρτίδα παρουσιάζει ικανοποιητική απόδοση σε μεσαίου ή μεγάλου μεγέθους παρτίδες και γενικεύει αποδοτικά σε πληθώρα προβλημάτων υπολογιστικής όρασης. Ωστόσο, η απόδοσή της υποβαθμίζεται σημαντικά για πολύ μικρά ή και εξαιρετικά μεγάλα μεγέθη παρτίδων, γεγονός που αποδίδεται σε θόρυβο κατά τον υπολογισμό των στατιστικών μεγεθών. Η μέθοδος κανονικοποίησης ανά παρτίδα και ομάδα [60] προτείνεται για την αντιμετώπιση του παραπάνω φαινομένου. Ακολουθεί η μαθηματική της περιγραφή.

Έστω είσοδος (Παρτίδα) διαστάσεων (N, C, H, W) . Στο πλαίσιο αυτής της τεχνικής, οι διαστάσεις C, H και W συγχωνεύονται σε μία ενιαία διάσταση.

$$D = C \cdot H \cdot W \quad (2.49)$$

Ως αποτέλεσμα, προκύπτει τανυστής διαστάσεων (N, D) . Η νέα διάσταση D διαιρείται σε G ομάδες, καθεμία από τις οποίες περιέχει $S = \frac{D}{G}$ στοιχεία.

Για κάθε ομάδα $g \in \{1, \dots, G\}$, υπολογίζεται ο μέσος όρος και η διασπορά κατά μήκος όλων των δειγμάτων και των στοιχείων της ομάδας:

$$\mu_g = \frac{1}{N \cdot S} \sum_{n=1}^N \sum_{d=(g-1)S+1}^{gS} f_{n,d} \quad (2.50)$$

$$\delta_g^2 = \frac{1}{N \cdot S} \sum_{n=1}^N \sum_{d=(g-1)S+1}^{gS} (f_{n,d} - \mu_g)^2 \quad (2.51)$$

Κατόπιν, κάθε στοιχείο κανονικοποιείται ως εξής:

$$\hat{f}_{n,d} = \frac{f_{n,d} - \mu_g}{\sqrt{\delta_g^2 + \varepsilon}} \quad (2.52)$$

όπου ε μια μικρή σταθερά για αριθμητική σταθερότητα.

Τέλος, εφαρμόζεται γραμμικός μετασχηματισμός με παραμέτρους που μαθαίνονται για κάθε ομάδα κατά την εκπαίδευση.

$$f'_{n,d} = \gamma \cdot \hat{f}_{n,d} + \beta \quad (2.53)$$

Η επιλογή της υπερπαραμέτρου G γίνεται λαμβάνοντας υπόψη το μέγεθος της παρτίδας.

- Για μικρό μέγεθος παρτίδας, χρησιμοποιείται μικρό G , έτσι ώστε να συμμετέχουν περισσότερα στοιχεία σε κάθε ομάδα και να αποφεύγεται ο θόρυβος στους υπολογισμούς.
- Για μεγάλο μέγεθος παρτίδας, χρησιμοποιείται μεγάλο G , έτσι ώστε να περιορίζεται η σύγχυση από υπερβολικά μεγάλο αριθμό στοιχείων στην ίδια ομάδα.


2.5 Μετασχηματιστές (Transformers)

Οι μετασχηματιστές [61] αποτελούν αρχιτεκτονική βαθιών νευρωνικών δικτύων, η οποία βασίζεται αποκλειστικά σε μηχανισμούς προσοχής (Attention Mechanism). Εισάχθηκαν για πρώτη φορά από τους Vaswani, Shazeer και τους συνεργάτες του το 2017 στα πλαίσια της διεργασίας

μετάφρασης κειμένου μεταξύ διαφορετικών γλωσσών. Σε αντίθεση με τα αναδρομικά νευρωνικά δίκτυα (Recurrent Neural Networks) [62] και τις παραλλαγές του, οι μετασχηματιστές είναι σε θέση να επεξεργαστούν πολλαπλές εισόδους ταυτόχρονα μέσω παράλληλης επεξεργασίας. Οι μετασχηματιστές έχουν αποδειχθεί ιδιαίτερα επιτυχείς σε εργασίες επεξεργασίας φυσικής γλώσσας και όρασης υπολογιστών.

2.5.1 Αρχιτεκτονική

Η αρχιτεκτονική τους αποτελείται από ένα κωδικοποιητή (Encoder) και ένα αποκωδικοποιητή (Decoder). Ο κωδικοποιητής παίρνει ως είσοδο μια ακολουθία $x = (x_1, \dots, x_n)$ από στοιχεία (π.χ. Λέξεις) και την μετατρέπει σε μια ακολουθία $z = (z_1, \dots, z_n)$, όπου $z_i \in \mathbb{R}, \forall i = 1, \dots, n$. Στη συνέχεια, ο αποκωδικοποιητής λαμβάνει ως είσοδο την ακολουθία z και παράγει την έξοδο.



Σχήμα 2.5.1: Αρχιτεκτονική μετασχηματιστή

Οι μετασχηματιστές ακολουθούν την αρχιτεκτονική του σχήματος 2.5.1, χρησιμοποιώντας διαδοχικά επίπεδα από μηχανισμούς αυτό-προσοχής και ανά στοιχείο πλήρως συνδεδεμένων

νευρωνικών δικτύων (Point-wise Fully Connected Neural Networks), τόσο στον κωδικοποιητή όσο και στον αποκωδικοποιητή. Τα ανά στοιχείο πλήρως συνδεδεμένα νευρωνικά δίκτυα εφαρμόζονται ξεχωριστά σε κάθε στοιχείο της ακολουθίας εισόδου, χωρίς να υφίσταται αλληλεπίδραση μεταξύ των στοιχείων. Ο κωδικοποιητής απεικονίζεται στα αριστερά του σχήματος, ενώ ο αποκωδικοποιητής στα δεξιά.

Ο κωδικοποιητής αποτελείται από N πανομοιότυπα διαδοχικά στρώματα. Κάθε στρώμα αποτελείται από δύο υποστρώματα. Το πρώτο αποτελείται από ένα μηχανισμό αυτο-προσοχής πολλών κεφαλών, ενώ το δεύτερο αποτελείται από ένα ανά στοιχείο πλήρως συνδεδεμένο δίκτυο. Σε κάθε υπόστρωμα, αθροίζεται η είσοδος με την έξοδο του αντίστοιχου μηχανισμού. Στην συνέχεια, εφαρμόζεται κανονικοποίηση στρώματος (Layer Normalization). Η μαθηματική μορφή της διαδικασίας που περιγράφηκε δίνεται από την σχέση

$$\text{LayerNorm}(x + \text{Sublayer}(x)) \quad (2.54)$$

Όπου $\text{Sublayer}(x)$ συμβολίζει τον μηχανισμό που αντιστοιχεί στο εκάστοτε υπόστρωμα. Προκειμένου να δύναται να πραγματοποιηθεί άθροιση, απαιτείται τα υποεπίπεδα του κωδικοποιητή καθώς και τα στρώματα ενσωμάτωσης (Embedding Layers) να παράγουν εξόδους ίδιας διάστασης. Στο πρωτότυπο άρθρο, στο οποίο παρουσιάστηκαν για πρώτη φορά οι μετασχηματιστές, η διάσταση αυτή ορίστηκε ως $d_{\text{model}} = 512$, ενώ ο αριθμός των διαδοχικών στρωμάτων ορίστηκε ίσος με $N = 6$.

Ο αποκωδικοποιητής, όπως και ο κωδικοποιητής αποτελείται από N πανομοιότυπα διαδοχικά στρώματα, όπου κάθε ένα από αυτά περιλαμβάνει τρία υποστρώματα. Τα πρώτα δύο είναι κοινά με του κωδικοποιητή, με την μόνη διαφορά πως στο πρώτο από αυτά ο μηχανισμός αυτο-προσοχής εφαρμόζεται αποκλειστικά στα στοιχεία που βρίσκονται σε θέσεις προηγούμενες της θέσης του στοιχείου του οποίου εξετάζουμε. Στο τρίτο υπόστρωμα εφαρμόζεται μηχανισμός προσοχής πολλών κεφαλών. Όπως και στον κωδικοποιητή, έτσι και στον αποκωδικοποιητή η σχέση (2.54) εφαρμόζεται στην έξοδο κάθε υποστρώματος.

Πλήρως συνδεδεμένο δίκτυο

Το ίδιο νευρωνικό δίκτυο εφαρμόζεται ξεχωριστά σε κάθε στοιχείο της ακολουθίας εισόδου του επιπέδου, χωρίς να υπάρχει αλληλεπίδραση μεταξύ των στοιχείων. Αποτελείται από δύο γραμμικούς μετασχηματισμούς, με μια συνάρτηση ενεργοποίησης ReLU ανάμεσα τους. Η μαθηματική του μορφή περιγράφεται μέσω της σχέσης

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2.55)$$

Όπου W_1, W_2 οι πίνακες βαρών, b_1, b_2 τα διανύσματα μεροληψίας και x το διάνυσμα εισόδου.

Παρόλο που ο υπολογισμός είναι ο ίδιος για κάθε στοιχείο του επιπέδου, οι παράμετροι του δικτύου διαφέρουν μεταξύ των επιπέδων. Το δίκτυο περιλαμβάνει 512 νευρώνες στο στρώμα εισόδου, 2048 νευρώνες στο κρυφό, ενδιάμεσο στρώμα και 512 νευρώνες στο στρώμα εξόδου.

Αυτο-προσοχή (Self-Attention)

Αρχικά ορίζονται τρεις πίνακες, ο πίνακας query Q , ο πίνακας key K και ο πίνακας value V , οι οποίοι αρχικοποιούνται και των οποίων οι παράμετροι προσαρμόζονται κατά την διάρκεια της διαδικασίας εκπαίδευσης του μοντέλου. Ο μηχανισμός υπολογίζει το εσωτερικό γινόμενο μεταξύ κάθε γραμμής του πίνακα Q και των αντίστοιχων γραμμών του πίνακα K , παράγοντας με αυτό τον τρόπο ένα πίνακα βαθμών ομοιότητας. Σε κάθε γραμμή του πίνακα που προκύπτει εφαρμόζεται η συνάρτηση Softmax, ώστε τα στοιχεία κάθε μιας από αυτές να αθροίζουν στην μονάδα. Με αυτό τον τρόπο κατασκευάζεται ένας πίνακας βαρών, ο οποίος χρησιμοποιείται στην παραγωγή του τελικού αποτελέσματος ως σταθμισμένος συνδυασμός των στοιχείων των στηλών του πίνακα V . Για την αποτροπή προβλημάτων αστάθειας, το εσωτερικό γινόμενο των γραμμών των πινάκων Q και K διαιρείται με την τετραγωνική ρίζα του πλήθους των στηλών του πίνακα K . Ο μηχανισμός αυτο-προσοχής εκφράζεται με μαθηματικούς όρους μέσω της παρακάτω σχέσης.

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.56)$$

Όπου d_k είναι ο αριθμός των στηλών του πίνακα K .

Έπειτα της περιγραφής του μηχανισμού αυτο-προσοχής μιας κεφαλής, ακολουθεί η γενίκευση του μέσω του αντίστοιχου μηχανισμού πολλαπλών κεφαλών, ο οποίος παρουσιάζεται στην συνέχεια. Ο μηχανισμός αυτο-προσοχής πολλών κεφαλών (Multi Head Self-Attention) επεκτείνει την απλή προσοχή μιας κεφαλής εφαρμόζοντας τον μηχανισμό αυτό σε h διαφορετικούς υπόχωρους. Συγκεκριμένα, οι πίνακες Q , K και V , προβάλλονται σε μικρότερες διαστάσεις

μέσω των πινάκων W_i^Q , W_i^K και W_i^V αντίστοιχα. Ο δείκτης i λαμβάνει τιμές από το ένα μέχρι και το h και αντιστοιχεί στην αντίστοιχη κεφαλή αυτο-προσοχής. Έπειτα, υπολογίζονται h ανεξάρτητοι μηχανισμοί αυτο-προσοχής μέσω παράλληλου υπολογισμού και στη συνέχεια τα αποτελέσματα τους συνενώνονται και προβάλλονται ξανά μέσω του πίνακα W^0 για την παραγωγή της τελικής εξόδου. Η μαθηματική μορφή του μηχανισμού αυτο-προσοχής πολλών κεφαλών δίνεται παρακάτω.

Κάθε κεφαλή αυτο-προσοχής υπολογίζεται μέσω της παρακάτω σχέσης.

$$h_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2.57)$$

Οι πίνακες $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ και $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ αρχικοποιούνται και προσαρμόζονται μέσω της διαδικασίας εκπαίδευσης του μοντέλου.

Οι κεφαλές αυτο-προσοχής συνδυάζονται μέσω της σχέσης

$$\text{MultiHead}(Q, K, V) = \text{Concat}(h_1, h_2, \dots, h_h)W^0 \quad (2.58)$$

Όπου $\text{Concat}(\cdot)$ συνάρτηση συνένωσης και $W^0 \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ πίνακας ο οποίος αρχικοποιείται και προσαρμόζεται κατά την διάρκεια της διαδικασίας εκπαίδευσης του μοντέλου.

Στο πρωτότυπο άρθρο [61] γίνεται χρήση των τιμών $h = 8$ και $d_k = d_v = d_{\text{model}}/h = 64$. Το συνολικό υπολογιστικό κόστος είναι αντίστοιχο με αυτό της προσοχής μίας κεφαλής. Αυτό οφείλεται στο γεγονός ότι η διάσταση κάθε κεφαλής αυτο-προσοχής είναι μειωμένη σε σύγκριση με εκείνη του μηχανισμού αυτο-προσοχής μίας μόνο κεφαλής. Παράλληλα, η χρήση πολλαπλών κεφαλών καθιστά τον μηχανισμό αυτο-προσοχής αποδοτικότερο.

3 Σύνολα δεδομένων και μετρικές αξιολόγησης πανοπτικής κατάτμησης εικόνας

Σε αυτό το κεφάλαιο παρουσιάζονται τα βασικά σύνολα δεδομένων της πανοπτικής κατάτμησης εικόνας, καθώς και ορισμένες από τις καθιερωμένες μετρικές αξιολόγησης που χρησιμοποιούνται. Γίνεται αναφορά στα βασικά χαρακτηριστικά τόσο των δεδομένων όσο και των μετρικών αξιολόγησης, με σκοπό την πληρέστερη κατανόηση της διαδικασίας εκπαίδευσης και αξιολόγησης της πανοπτικής κατάτμησης εικόνας.

3.1 Σύνολα δεδομένων πανοπτικής κατάτμησης εικόνας

Στην σύγχρονη εποχή η όραση υπολογιστών βασίζεται σχεδόν αποκλειστικά σε μεθόδους βαθιάς μάθησης. Γνωρίζουμε πως η λειτουργία τέτοιων μεθόδων απαιτεί ένα πολύ μεγάλο όγκο δεδομένων συνοδευόμενο με τις κατάλληλες επισημειώσεις. Για τον σκοπό αυτό έχουν δημιουργηθεί κατάλληλα σύνολα δεδομένων [10] που έχουν ως σκοπό την εκπαίδευση και ποσοτική αξιολόγηση της απόδοσης αυτών των μοντέλων. Ορισμένα από αυτά παρουσιάζονται στην συνέχεια.

3.1.1 Σύνολο δεδομένων COCO

Το COCO (Common Objects in Context) [18], αποτελεί σύνολο δεδομένων μεγάλου μεγέθους, το οποίο περιλαμβάνει εικόνες σκηνών της καθημερινότητας με ποικιλία "αντικειμένων" στα φυσικά τους περιβάλλοντα. Περιέχει συνολικά περισσότερες από 330.000 εικόνες και είναι διαθέσιμο σε δύο κύριες εκδόσεις, την COCO 2014 και COCO 2017, οι οποίες περιλαμβάνουν κατά μεγάλο βαθμό κοινές εικόνες αλλά διαφοροποιούνται ως προς τον διαχωρισμό τους σε σύνολα εκπαίδευσης και επικύρωσης. Το σύνολο δεδομένων είναι επισημασμένο με 80 κατηγορίες "αντικειμένων" και 91 κατηγορίες "σκηνικών" στοιχείων και χωρίζεται σε δύο μέρη. Από την μια έχουμε τις εικόνες, ενώ από την άλλη τις αντίστοιχες επισημειώσεις. Οι εικόνες είναι οργανωμένες ιεραρχικά σε φακέλους, με τον φάκελο που βρίσκεται στο υψηλότερο επίπεδο να περιλαμβάνει τρεις υποφακέλους, οι οποίοι αντιστοιχούν στα σύνολα δεδομένων εκπαίδευσης, δοκιμής και επικύρωσης [63].

Οι επισημειώσεις είναι οργανωμένες σε JSON αρχεία, με κάθε αρχείο να αντιστοιχεί σε μια εικόνα. Κάθε τέτοιο αρχείο περιέχει:

- Το όνομα του αρχείου
- Το μέγεθος της εικόνας

- 5 ετικέτες που περιγράφουν την σκηνή
- Λίστα των "αντικειμένων" της εικόνας (Για κάθε "αντικείμενο" περιλαμβάνεται η κατηγορία, οι συντεταγμένες του ορθογωνίου που το περιβάλλει, τα εικονοστοιχεία που του αντιστοιχούν και τα σημεία κλειδιά του)

Το σύνολο δεδομένων COCO περιλαμβάνει επίσης την άδεια χρήσης, τις επισημειώσεις των "σκηνικών" στοιχείων και υπερκατηγορίες των "αντικειμένων" (Αποτελούν ευρύτερες κατηγορίες των "αντικειμένων" π.χ. dog $\subset$ animal). Το σύνολο δεδομένων COCO χρησιμοποιείται σε εργασίες όπως η ανίχνευση αντικειμένων, η σημασιολογική κατάτμηση εικόνας, η πανοπτική κατάτμηση εικόνας κ.ο.κ. [63].

Παρακάτω δίνονται όλες οι κατηγορίες "αντικειμένων" που περιέχονται στο σύνολο δεδομένων COCO.

person	fire hydrant	elephant	skis	wine glass	broccoli	dining table	toaster
bicycle	stop sign	bear	snowboard	cup	carrot	toilet	sink
car	parking meter	zebra	sports ball	fork	hot dog	tv	refrigerator
motorcycle	bench	giraffe	kite	knife	pizza	laptop	book
airplane	bird	backpack	baseball bat	spoon	donut	mouse	clock
bus	cat	umbrella	baseball glove	bowl	cake	remote	vase
train	dog	handbag	skateboard	banana	chair	keyboard	scissors
truck	horse	tie	surfboard	apple	couch	cell phone	teddy bear
boat	sheep	suitcase	tennis racket	sandwich	potted plant	microwave	hair drier
traffic light	cow	frisbee	bottle	orange	bed	oven	toothbrush


Σχήμα 3.1.1: Κατηγορίες αντικειμένων συνόλου δεδομένων COCO

Είναι σημαντικό να αναφερθεί πως το σύνολο δεδομένων COCO δεν περιέχει ισορροπημένο αριθμό "αντικειμένων" ανά κατηγορία κάτι που μπορεί να οδηγήσει σε μεροληψία. Όπως προαναφέρθηκε το COCO διατίθεται σε δύο κύριες εκδόσεις. Η COCO 2014 περιλαμβάνει 82783 εικόνες στο σύνολο δεδομένων εκπαίδευσης, 40504 εικόνες στο σύνολο δεδομένων επικύρωσης και 40.775 εικόνες στο σύνολο δεδομένων δοκιμής. Αντίστοιχα, το COCO 2017 περιλαμβάνει 118287, 5000 και 40670 εικόνες στα αντίστοιχα σύνολα. [64].

3.1.2 Σύνολο δεδομένων Cityscapes

Η κατανόηση περίπλοκων αστικών σκηνών αποτελεί καθοριστικό παράγοντα για ένα ευρύ φάσμα εφαρμογών. Ωστόσο, δεν υπάρχουν πολλά σύνολα δεδομένων που να αποτυπώνουν επαρκώς την πολυπλοκότητα των σκηνών που παρουσιάζονται στον πραγματικό κόσμο. Το πρόβλημα αυτό επιχειρεί να αντιμετωπίσει το σύνολο δεδομένων Cityscapes [2].

Το σύνολο δεδομένων Cityscapes δημιουργήθηκε μέσω επιλεγμένων καρέ (Frame), τα οποία εξήχθησαν από στερεοσκοπικές ακολουθίες βίντεο που καταγράφηκαν από κινούμενο όχημα στους δρόμους 50 διαφορετικών πόλεων, κυρίως της Γερμανίας. Από αυτές τις εικόνες, οι 5000 διαθέτουν υψηλής ποιότητας επισημειώσεις σε επίπεδο εικονοστοιχείου, ενώ οι υπόλοιπες 20.000 χαμηλότερης ποιότητας, ώστε να υποστηρίζεται η εκπαίδευση μοντέλων σε μερικώς επισημασμένα δεδομένα (Ασθενώς Επιβλεπόμενη Μάθηση). Από τις 5000 πλήρως επισημασμένες εικόνες, οι 2975 αποτελούν εικόνες του συνόλου δεδομένων εκπαίδευσης, οι 500 του συνόλου δεδομένων επικύρωσης και οι υπόλοιπες 1525 του συνόλου δεδομένων δοκιμής. Οι πλήρως επισημασμένες εικόνες εξήχθησαν χειροκίνητα από 27 από τις 50 πόλεις του συνόλου δεδομένων και συγκεκριμένα από το 20ό καρέ αποσπασμάτων βίντεο διάρκειας 30 καρέ. Αντίθετα, οι ασθενώς επισημασμένες εικόνες εξήχθησαν από τις υπόλοιπες 23 πόλεις του συνόλου δεδομένων, μέσω εξαγωγής μιας εικόνας ανά 20 δευτερόλεπτα λήψης ή ανά 20 μέτρα οδήγησης, ανάλογα με πιο από τα δύο συνέβαινε πρώτο. Όπως μπορούμε να δούμε παρακάτω, το σύνολο δεδομένων Cityscapes περιλαμβάνει συνολικά 30 κατηγορίες "αντικειμένων" ή "σκηνικών" στοιχείων, από τις οποίες μόνο οι 19 χρησιμοποιούνται στην επικύρωση των αποτελεσμάτων [2].



Σχήμα 3.1.2: Αντικείμενα συνόλου δεδομένων Cityscapes


Το σύνολο δεδομένων περιλαμβάνει εικόνες καταγεγραμμένες κατά την διάρκεια της Άνοιξης, του Καλοκαιριού και του Φθινοπώρου καλύπτοντας αρκετούς μήνες του έτους. Ωστόσο, δεν περιλαμβάνει εικόνες σε δυσμενείς καιρικές συνθήκες, όπως έντονη βροχόπτωση ή χιόνι, καθώς οι συνθήκες αυτές απαιτούν την χρήση εξειδικευμένων τεχνικών και συνόλων δεδομένων. Όλες οι εικόνες είναι διαθέσιμες σε 8-bit (Low Dynamic Range) και 16-bit (High Dynamic Range). Πέρα από εικόνες και επισημειώσεις, το σύνολο δεδομένων Cityscapes περιλαμβάνει δεδομένα ως προς την εξωτερική θερμοκρασία, την διαδρομή (GPS) του οχήματος και την οδομετρία του [2].

Το σύνολο δεδομένων Cityscapes χρησιμοποιείται σε εργασίες όπως η σημασιολογική κατάρτιση εικόνας, η πανοπτική κατάρτιση εικόνας, η εκτίμηση βάθους κ.ο.κ. [2], [1], [65].

3.1.3 Σύνολο δεδομένων ADE20K

Σε αντίθεση με την απλή κατανόηση του περιεχομένου μιας εικόνας, η κατανόηση σε επίπεδο εικονοστοιχείου απαιτεί σύνολα δεδομένων με πολύ πιο πυκνές επισημειώσεις και ένα ευρύ σύνολο "αντικειμένων". Ωστόσο, τα περισσότερα σύνολα δεδομένων παρουσιάζουν ένα περιορισμένο αριθμό "αντικειμένων" (π.χ. COCO [18], Pascal VOC [15]) και συχνά είτε περιλαμβάνουν κατηγορίες που δεν είναι συνυφασμένες με τα πιο συνήθη "αντικείμενα" που συναντούμε στον πραγματικό κόσμο είτε καλύπτουν ένα περιορισμένο φάσμα σκηνών (π.χ. Cityscapes [2]). Η ανάγκη δημιουργίας ενός συνόλου δεδομένων, το οποίο να ανταποκρίνεται σε αυτά τα προβλήματα οδήγησε στη δημιουργία του συνόλου δεδομένων ADE20K [16], [66].

Το ADE20K [16] αποτελεί ένα εκτενώς επισημασμένο σύνολο δεδομένων, με την έννοια πως για κάθε εικόνα παρέχονται λεπτομερείς ετικέτες των "αντικειμένων", όπως και σε ορισμένες περιπτώσεις των μερών που τα αποτελούν ("υπο-αντικείμενα"). Αποτελείται από συνολικά 25.210 εικόνες από τις οποίες οι 20.210 ανήκουν στο σύνολο δεδομένων εκπαίδευσης, οι 2000 στο σύνολο δεδομένων επικύρωσης και οι υπόλοιπες 3000 στο σύνολο δεδομένων δοκιμής. Περιλαμβάνει συνολικά 3169 κατηγορίες από τις οποίες οι 2693 αφορούν "αντικείμενα" ή "σκηνικά" στοιχεία, ενώ οι υπόλοιπες 476 μέρη μεγαλύτερων "αντικειμένων". Τα "υπο-αντικείμενα" του συνόλου δεδομένων ADE20K φτάνουν σε επίπεδο βάθους το πολύ τρία. Στο Σχήμα 3.1.3 απεικονίζονται ορισμένα "αντικείμενα" του συνόλου μαζί με τα αντίστοιχα "υπο-αντικείμενα" τους [66].



Σχήμα 3.1.3: Αντικείμενα και υπο-αντικείμενα συνόλου δεδομένων ADE20K

Το 76% των "αντικειμένων" του συνόλου δεδομένων ADE20K διαθέτει "υπο-αντικείμενα" με μέσο όρο πλήθους "υπο-αντικειμένων" ίσο με τρία. Κατά μέσο όρο υπάρχουν 19.5 εμφανίσεις και 10.5 διαφορετικές κατηγορίες "αντικειμένων" σε κάθε εικόνα. Ο ελάχιστος αριθμός εμφανίσεων είναι ίσος με πέντε με ορισμένες εικόνες να έχουν μέχρι και 273, εξαιρουμένων των "υπο-αντικειμένων". Εάν συμπεριληφθούν ο αριθμός αυτός φτάνει μέχρι και 419 [16], [66].

Το σύνολο δεδομένων ADE20K χρησιμοποιείται σε εργασίες όπως η σημασιολογική κατάρτιση εικόνας, η κατάρτιση αντικειμένων, η πανοπτική κατάρτιση εικόνας κ.ο.κ. [16], [1].

3.2 Μετρικές αξιολόγησης πανοπτικής κατάρτισης εικόνας

Οι μετρικές αξιολόγησης αποτελούν βασικό εργαλείο και διαδραματίζουν σημαντικό ρόλο στη σύγκριση της αποτελεσματικότητας διαφορετικών μεθόδων σε διάφορες εργασίες. Η πανοπτική κατάρτιση εικόνας, όπως έχει ήδη οριστεί αποτελεί συνδυασμό της σημασιολογικής κατάρτισης και της κατάρτισης αντικειμένων. Αν και οι υπάρχουσες μετρικές αυτών των εργασιών μπορούν σε κάποιο βαθμό να εφαρμοσθούν στην πανοπτική κατάρτιση εικόνας, δεν αρκούν από μόνες τους. Συνήθως, στην πανοπτική κατάρτιση εικόνας χρησιμοποιούνται μετρικές όπως η πανοπτική ποιότητα (Panoptic Quality - PQ), η ποιότητα κατάρτισης (Segmentation Quality - SQ) και η ποιότητα αναγνώρισης (Recognition Quality - RQ). Ωστόσο, μπορούν να χρησιμοποιηθούν πρόσθετες μετρικές για την αξιολόγηση των μεθόδων αυτών, όσον αφορά την επίδοση τους στην σημασιολογική κατάρτιση και την κατάρτιση αντικειμένων, όπως ο περιορισμός των παραπάνω μετρικών αποκλειστικά σε "αντικείμενα" (Things) ή "σκηνικά" στοιχεία (Stuff). Άλλα ενδεικτικά παραδείγματα μετρικών που μπορούν να αξιοποιηθούν αποτελεί ο μέσος όρος ακρίβειας (Average Precision - AP) και η Intersection over Union (IoU) [19].

3.2.1 Πίνακας σύγχυσης (Confusion Matrix)

Για να δύναται να οριστούν ορισμένες από τις μετρικές που αναφέρθηκαν παραπάνω, απαιτείται πρώτα ο ορισμός του πίνακα σύγχυσης. Ο πίνακας σύγχυσης αποτελεί εργαλείο αξιολόγησης της ικανότητας ταξινόμησης μιας μεθόδου, μέσω των τιμών True positive (TP), True negative (TN), False positive (FP) και False negative (FN). Πρόκειται για πίνακα διαστάσεων $N \times N$, όπου το N αποτελεί το πλήθος των κλάσεων ταξινόμησης. Τα κελιά του πίνακα αποτυπώνουν το πλήθος των δειγμάτων για κάθε συνδυασμό πραγματικής και προβλεπόμενης κλάσης. Για δυαδικό πρόβλημα ταξινόμησης η μορφή που παίρνει ο πίνακας σύγχυσης δίνεται παρακάτω.

		ACTUAL VALUES	
		POSITIVE	NEGATIVE
PREDICTED VALUES	POSITIVE	TP	FP
	NEGATIVE	FN	TN

Σχήμα 3.2.1: Μορφή πίνακα σύγχυσης για δυαδική ταξινόμηση

Οι στήλες αναπαριστούν τις πραγματικές και οι γραμμές τις προβλεπόμενες τιμές. Ακολουθεί η ερμηνεία των TP , FP , FN και TN .

TP : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην θετική κλάση (Positive) και προβλέφθηκαν σωστά.

TN : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην αρνητική κλάση (Negative) και προβλέφθηκαν σωστά.

FP : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην αρνητική κλάση και δεν προβλέφθηκαν σωστά. Αυτή η περίπτωση σφάλματος καλείται σφάλμα τύπου 1.

FN : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην θετική κλάση και δεν προβλέφθηκαν σωστά. Αυτή η περίπτωση σφάλματος καλείται σφάλμα τύπου 2.

Όταν το πρόβλημα ταξινόμησης δεν είναι δυαδικό, η ερμηνεία του πίνακα σύγκρισης διαφοροποιείται. Συγκεκριμένα οι τιμές των TP , FP , FN και TN , υπολογίζονται για κάθε κατηγορία, ενώ κάθε κελί (i, j) του πίνακα αποτυπώνει το πλήθος των δειγμάτων με πραγματική κλάση j και προβλεπόμενη κλάση i , όπου i και j αναπαριστούν αριθμητικούς δείκτες κλάσεων. Ακολουθεί η ερμηνεία των TP_i , FP_i , FN_i , TN_i , $\forall i = 1, \dots, N$.

TP_i : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην κλάση i και προβλέφθηκαν σωστά. Αντιστοιχεί στην τιμή του κελιού (i, i) του πίνακα.

TN_i : Αντιστοιχεί στο πλήθος των δειγμάτων που ούτε η προβλεπόμενη, ούτε η πραγματική τιμή αντιστοιχεί στην κλάση i . Ισούται με το άθροισμα $\sum_{p \neq i}^N \sum_{k \neq i}^N value(p, k)$, όπου $value(i, j)$ η τιμή του πίνακα σύγκρισης στο κελί (i, j) .

FP_i : Αντιστοιχεί στο πλήθος των δειγμάτων που η προβλεπόμενη τιμή αντιστοιχεί στην κλάση i , ενώ η πραγματική όχι. Ισούται με το άθροισμα $\sum_{p \neq i}^N value(i, p)$, όπου $value(i, j)$ η τιμή του πίνακα σύγκρισης στο κελί (i, j) .

FN_i : Αντιστοιχεί στο πλήθος των δειγμάτων που ανήκουν στην κλάση i και δεν προβλέφθηκαν σωστά. Ισούται με το άθροισμα $\sum_{p \neq i}^N value(p, i)$, όπου $value(i, j)$ η τιμή του πίνακα σύγκρισης στο κελί (i, j) .

Η μέθοδος ταξινόμησης είναι αποδοτική εάν το πλήθος των True Positive και True Negative είναι μεγάλο σε σχέση με το συνολικό πλήθος των δειγμάτων [67].

3.2.2 Intersection over Union (IoU)

Η μετρική IoU , γνωστή και ως δείκτης Jaccard αποτυπώνει το ποσοστό επικάλυψης μεταξύ των εικονοστοιχείων της περιοχής ενδιαφέροντος της μάσκας στόχου και της αντίστοιχης περιοχής της μάσκας πρόβλεψης [19]. Υπολογίζεται μέσω της παρακάτω σχέσης.

$$IoU = \frac{target \cap prediction}{target \cup prediction} \quad (3.1)$$

Όπου $target$ τα εικονοστοιχεία της περιοχής ενδιαφέροντος της μάσκας στόχου και $prediction$ τα αντίστοιχα εικονοστοιχεία της μάσκα πρόβλεψης.

Εύκολα μπορούμε να συμπεράνουμε πως $0 \leq IoU \leq 1$.

3.2.3 Μέσος Όρος Ακρίβειας (Average Precision - AP)

Ο μέσος όρος ακριβείας αποτελεί την πιο ευρέως χρησιμοποιούμενη μετρική αξιολόγησης στην κατάτμηση αντικειμένων [68]. Για την διατύπωση της, απαιτείται αρχικά ο ορισμός ορισμένων άλλων μετρικών. Η ακρίβεια (Precision) αποτελεί μετρική, η οποία υπολογίζει το ποσοστό των προβλέψεων που συνάδουν με την πραγματική τιμή. Στην κατάτμηση εικόνας υπολογίζεται για κάθε κλάση ξεχωριστά [69] και δίνεται από την σχέση [70].

$$Precision_k = \frac{TP_k}{TP_k + FP_k} \quad (3.2)$$

Όπου k η αντίστοιχη κλάση.

Έπειτα ορίζεται μια άλλη μετρική, η ανάκληση (Recall). Η ανάκληση υπολογίζει το ποσοστό των δειγμάτων μιας κλάσης τα οποία προβλέφθηκαν σωστά [69]. Δίνεται από την σχέση [70].

$$Recall_k = \frac{TP_k}{TP_k + FN_k} \quad (3.3)$$

Όπου k η αντίστοιχη κλάση.

Στη συνέχεια, ορίζεται η καμπύλη ακριβείας-ανάκλησης (Precision-Recall Curve). Σχηματίζεται απεικονίζοντας τις τιμές ακριβείας και ανάκλησης για όλες τις δυνατές τιμές του βαθμού εμπιστοσύνης. Ο μέσος όρος ακριβείας προκύπτει υπολογίζοντας το εμβαδόν κάτω της καμπύλης και δίνεται από την σχέση

$$AP_k = \int_0^1 Precision(Recall) d(Recall) \quad (3.4)$$

Ο μέσος όρος ακριβείας είναι άμεσα συνδεδεμένος με την μετρική IoU , καθώς επηρεάζεται από την τιμή του κατωφλίου IoU που ορίζεται. Η τιμή αυτή καθορίζει εάν μια πρόβλεψη θεωρείται σωστή ή λανθασμένη. Συγκεκριμένα, όταν το ποσοστό επικάλυψης μεταξύ της μάσκας στόχου και μάσκας πρόβλεψης είναι μεγαλύτερο του κατωφλίου, τότε η πρόβλεψη χαρακτηρίζεται ως σωστή. Αντίστοιχα εάν το ποσοστό επικάλυψης είναι μικρότερο χαρακτηρίζεται ως λανθασμένη [3]. Με αυτό τον τρόπο επηρεάζεται η σύνθεση των συνόλων TP_k , FP_k και FN_k . Κατά συνέπεια, για διαφορετικές τιμές κατωφλίου προκύπτουν διαφορετικές καμπύλες ακριβείας-ανάκλησης.

Η μετρική mAP αποτελεί την μέση τιμή των μέσων όρων ακριβείας (AP) κάθε κλάσης για μια δεδομένη τιμή κατωφλίου της IoU . Υπολογίζεται μέσω της σχέσης

$$mAP = \frac{1}{n} \sum_{k=1}^n AP_k \quad (3.5)$$

Για τον υπολογισμό του τελικού mAP υπολογίζεται η μέση τιμή των mAP για διαφορετικές τιμές του κατωφλίου της IoU . Ενδεικτικά στον διαγωνισμό ανίχνευσης αντικειμένων COCO 2017 [18] η αξιολόγηση βασίστηκε σε συνολικά 10 διαφορετικές τιμές κατωφλίου από 0.5 έως 0.95 με βήμα 0.05, καθώς και σε 101 τιμές βαθμών εμπιστοσύνης από μηδέν μέχρι ένα με βήμα 0.01 [71].


3.2.4 Πανοπτική ποιότητα (Panoptic Quality - PQ)

Σε αντίθεση με τις μετρικές που παρουσιάστηκαν προηγουμένως, η πανοπτική ποιότητα αξιολογεί την πανοπτική κατάτμηση εικόνας στο σύνολο της. Όπως και στον μέσο όρο ακριβείας, έτσι και στην πανοπτική ποιότητα ο καθορισμός σωστών και λανθασμένων προβλέψεων βασίζεται στην ίδια ακριβώς συνθήκη, σύμφωνα με την οποία μια πρόβλεψη θεωρείται σωστή όταν

η επικάλυψη μεταξύ της μάσκας στόχου και της μάσκας πρόβλεψης υπερβαίνει μια προκαθορισμένη τιμή κατωφλίου IoU . Σε αντίθετη περίπτωση χαρακτηρίζεται ως λανθασμένη. Έτσι επηρεάζονται οι τιμές των TP , FP , FN . Η συνθήκη αυτή σε συνδυασμό με την ιδιότητα της μη επικάλυψης εξασφαλίζει μονοσήμαντη αντιστοίχιση μεταξύ των масκών πρόβλεψης και στόχου [3].

Η πιο συνηθισμένη τιμή κατωφλίου που ορίζεται είναι 0.5. Για χαμηλότερες τιμές του κατωφλίου της IoU απαιτούνται διαφορετικές τεχνικές αντιστοίχισης. Ωστόσο, στην πράξη ταιριάσματα με $IoU \leq 0.5$ είναι σπάνια, επομένως χαμηλότερα κατώφλια είναι περιττά.

Η πανοπτική ποιότητα προσδιορίζεται αρχικά για κάθε κατηγορία ξεχωριστά και στη συνέχεια υπολογίζεται ο μέσος όρος κατά μήκος των κατηγοριών. Με αυτό τον τρόπο, καθίσταται ανεπηρέαστη από ανισορροπία μεταξύ των κλάσεων. Στο σύνολο TP_k περιλαμβάνονται τα ζευγάρια πραγματικών και προβλεπόμενων масκών κλάσης k που αντιστοιχίστηκαν μεταξύ τους. Αντίστοιχα, στο σύνολο FP_k περιλαμβάνονται οι προβλεπόμενες μάσκες κλάσης k που δεν αντιστοιχίστηκαν με καμία μάσκα στόχο, ενώ στο σύνολο FN_k περιλαμβάνονται οι μάσκες στόχοι κλάσης k που δεν αντιστοιχίστηκαν με καμία μάσκα πρόβλεψης. Στο Σχήμα 3.2.2 παρουσιάζεται ενδεικτικό παράδειγμα διαχωρισμού των масκών της κατηγορίας "person" στα σύνολα TP , FN και FP .



Σχήμα 3.2.2: Παράδειγμα διαχωρισμού των τμημάτων της κατηγορίας "person" στα σύνολα TP , FP και FN .

Η πανοπτική ποιότητα ορίζεται για κάθε κατηγορία μέσω της παρακάτω σχέσης.

$$PQ = \frac{\sum_{(p,g) \in TP} IoU(p, g)}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|} \quad (3.6)$$

Η τιμή $\frac{\sum_{(p,g) \in TP} IoU(p, g)}{|TP|}$, αποτελεί τον μέσο όρο των τιμών IoU των ταιριασμένων τμημάτων, ενώ ο όρος $\frac{1}{2}|FP| + \frac{1}{2}|FN|$ προστίθεται στον παρονομαστή για την επιβολή ποινής στα τμήμα-

τα που δεν έχουν ταίριασμα. Παρατηρείται πως κάθε αντιστοιχισμένο τμήμα συμβάλλει το ίδιο στον υπολογισμό της πανοπτικής ποιότητας, ανεξάρτητα από τον αριθμό των εικονοστοιχείων που καταλαμβάνει. Πολλαπλασιάζοντας και διαιρώντας την μετρική με $|TP|$, η πανοπτική ποιότητα μπορεί να γραφεί ως το γινόμενο της ποιότητας κατάτμησης (Segmentation Quality - SQ) και της ποιότητας αναγνώρισης (Recognition Quality - RQ) [3].

$$PQ = \underbrace{\frac{\sum_{(p,g) \in TP} \text{IoU}(p, g)}{|TP|}}_{\text{segmentation quality (SQ)}} \times \underbrace{\frac{|TP|}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}}_{\text{recognition quality (RQ)}} \quad (3.7)$$

Προκειμένου να υπολογιστεί η συνολική πανοπτική ποιότητα, υπολογίζεται ο μέσος όρος της πανοπτικής ποιότητας κατά μήκος όλων των κατηγοριών [3].

$$PQ_{\text{overall}} = \frac{1}{C} \sum_{c=1}^C PQ_c \quad (3.8)$$

Περιορίζοντας τις μετρικές PQ , SQ και RQ αποκλειστικά στις κατηγορίες "αντικειμένων", προκύπτουν οι μετρικές PQ_{th} , SQ_{th} και RQ_{th} . Αντίστοιχα, περιορίζοντας στις κατηγορίες "σκηνικών" στοιχείων προκύπτουν οι PQ_{St} , SQ_{St} και RQ_{St} . Οι μετρικές αυτές χρησιμοποιούνται για την αξιολόγηση της απόδοσης στην σημασιολογική κατάτμηση και την κατάτμηση αντικειμένων [19].

Οι κενές ετικέτες (Void Labels) δηλώνουν σε επίπεδο εικονοστοιχείου τις περιοχές της εικόνας που δεν αντιστοιχούν σε κάποιο "αντικείμενο" ή "σκηνικό" στοιχείο. Στις επισημασμένες εικόνες, οι κενές ετικέτες αποδίδονται είτε σε εικονοστοιχεία που είναι ασαφή και είναι δύσκολο να ταξινομηθούν, είτε σε εικονοστοιχεία που δεν υπάγονται σε καμία από τις κατηγορίες "αντικειμένων" ή "σκηνικών" στοιχείων του προβλήματος. Αυτά τα εικονοστοιχεία δεν λαμβάνονται υπόψη στην αξιολόγηση. Συγκεκριμένα, κατά την διαδικασία αντιστοίχισης μεταξύ των масκών πρόβλεψης και στόχου, τα κενά εικονοστοιχεία αφαιρούνται και δεν λαμβάνονται υπόψη στον υπολογισμό της IoU . Επιπλέον, οι μάσκες πρόβλεψης που δεν αντιστοιχίστηκαν με καμία μάσκα στόχο και για τις οποίες το ποσοστό των εικονοστοιχείων τους που αντιστοιχούν σε κενές ετικέτες στην εικόνα αναφοράς υπερβαίνει το κατώφλι IoU , εξαιρούνται και δεν λαμβάνονται υπόψη στην αξιολόγηση. Εκτός από τις επισημασμένες εικόνες, κενές ετικέτες μπορούν να εμφανιστούν και στις προβλέψεις. Η περίπτωση αυτή αντιστοιχεί σε εικονοστοιχεία στα οποία η μέθοδος δεν απέδωσε καμία κατηγορία "αντικειμένου" ή "σκηνικού" στοιχείου. Τα εικονοστοιχεία αυτά εξαιρούνται από τη διαδικασία αξιολόγησης.


Οι ετικέτες ομάδας (Group Labels) δηλώνουν σε επίπεδο εικονοστοιχείου περιοχές της εικόνας όπου υπάρχει πλήθος όμοιων "αντικειμένων" συγκεντρωμένο και είναι δύσκολος ο διαχωρισμός τους σε ξεχωριστά "αντικείμενα". Στην πανοπτική ποιότητα αντιμετωπίζονται με τον ίδιο ακριβώς τρόπο όπως και οι κενές ετικέτες [3].

4 Σχετική έρευνα

4.1 State-of-the-art στο σύνολο δεδομένων COCO

4.1.1 Mask DINO


Το Mask DINO [72] συνιστά μοντέλο βασισμένο στους μετασχηματιστές και αποτελεί επέκταση του DINO [73]. Το DINO είχε αρχικά σχεδιαστεί για ανίχνευση αντικειμένων και δεν αποδείχθηκε ιδιαίτερα αποδοτικό σε εργασίες κατάτμησης εικόνας. Αντίστοιχα, εξειδικευμένα μοντέλα κατάτμησης εικόνας όπως το Mask2Former [1] δεν παρουσίασαν την ίδια αποδοτικότητα σε εργασίες ανίχνευσης αντικειμένων. Σε αντίθεση με αυτά, το Mask DINO επέτρεψε πέρα από την ανίχνευση αντικειμένων, την αποδοτική εκτέλεση εργασιών όπως η σημασιολογική κατάτμηση εικόνας, η κατάτμηση αντικειμένων και η πανοπτική κατάτμηση εικόνας, μέσω μιας ενιαίας αρχιτεκτονικής. Στο πλαίσιο αυτό, το Mask DINO ενσωματώνει ένα μηχανισμό παραγωγής μασκών, ο οποίος δύναται να παράγει μάσκες για κάθε εργασία κατάτμησης εικόνας. Ο μηχανισμός αυτός χρησιμοποιεί τις ενσωματώσεις (Embeddings) του πίνακα query και τις συγκρίνει στη συνέχεια με κάθε χάρτη χαρακτηριστικών που παράγεται από τον εξαγωγέα χαρακτηριστικών. Με αυτό τον τρόπο, για κάθε query κατασκευάζεται μια μάσκα πιθανότητας, η οποία υποδεικνύει ποια εικονοστοιχεία της εικόνας σχετίζονται με την κλάση που εκπροσωπεί. Στην εργασία της πανοπτικής κατάτμησης εικόνας το Mask DINO σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Swin-L [74] πέτυχε πανοπτική ποιότητα ίση με 59.5 στο σύνολο δεδομένων δοκιμής του COCO [18].



Σχήμα 4.1.1: Αρχιτεκτονική μοντέλου Mask DINO

4.1.2 kMaX-DeepLab

Το kMaX-DeepLab [75] αποτελεί μοντέλο βασισμένο στους μετασχηματιστές, το οποίο επαναπροσδιορίζει την σχέση μεταξύ των διανυσμάτων χαρακτηριστικών των εικονοστοιχείων και των queries του πίνακα query, μέσα από την οπτική του αλγόριθμου ομαδοποίησης k-means. Ο επαναπροσδιορισμός αυτός βασίζεται στην ισχυρή ομοιότητα που παρουσιάζεται μεταξύ του αλγορίθμου k-means και της διασταυρούμενης προσοχής (Cross-Attention), εάν θεωρηθούν τα queries ως κέντρα ομάδων. Με βάση αυτή την παρατήρηση, στο kMaX-DeepLab αντικαθίσταται η συνάρτηση Softmax που χρησιμοποιείται στην διασταυρούμενη προσοχή με την συνάρτηση argmax, η οποία εφαρμόζεται στην διάσταση των κέντρων των ομάδων, όπως γίνεται στην ανάθεση ενός στοιχείου σε ομάδα στον αλγόριθμο k-means. Στη συνέχεια, τα κέντρα των ομάδων ενημερώνονται με βάση τα διανύσματα χαρακτηριστικών των εικονοστοιχείων που τους έχουν ανατεθεί, με τρόπο όμοιο με την ενημέρωση των κέντρων στον αλγόριθμο k-means. Η μετα-αρχιτεκτονική του μοντέλου kMaX-DeepLab αποτελείται από ένα κωδικοποιητή εικονοστοιχείων, ένα αποκωδικοποιητή εικονοστοιχείων και τον αποκωδικοποιητή kMaX. Ο κωδικοποιητής εικονοστοιχείων μπορεί να είναι οποιοσδήποτε εξαγωγέας χαρακτηριστικών, ενώ ο αποκωδικοποιητής kMaX αντιστοιχεί στον μηχανισμό που περιγράφηκε παραπάνω. Τέλος, ο αποκωδικοποιητής εικονοστοιχείων προβάλλει τα διανύσματα χαρακτηριστικών σε χώρους μεγαλύτερης διάστασης, βελτιώνοντας με αυτό τον τρόπο την εκφραστικότητα τους. Στα πλαίσια της πανοπτικής κατάτμησης εικόνας, το μοντέλο kMaX-DeepLab σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών ConvNeXt-L [76] πέτυχε πανοπτική ποιότητα ίση με 58.5 στο σύνολο δεδομένων δοκιμής του COCO [18].



Σχήμα 4.1.2: Μετα-αρχιτεκτονική μοντέλου kMaX-DeepLab

4.2 State-of-the-art στο σύνολο δεδομένων Cityscapes


4.2.1 Scaling Wide Residual Networks

Το Scaling Wide Residual Network (SWideRNet) [77] αποτελεί μοντέλο σχεδιασμένο για την εργασία της πανοπτικής κατάτμησης εικόνας και συνιστά παραλλαγή του δικτύου Wide Residual

Network (Wide-ResNet) [78]. Συγκεκριμένα, η αρχιτεκτονική του βασίζεται στο Wide-ResNet-41 [78] στο οποίο ενσωματώνει δύο βελτιώσεις, την Squeeze-and-Excitation η οποία εισάγει προσοχή κατά μήκος των καναλιών του χάρτη χαρακτηριστικών και την συνέλιξη με δυναμικά επιλέξιμη διάτρηση (Switchable Atrous Convolution), η οποία επιτρέπει δυναμική επιλογή της διάτρησης της συνελκτικής πράξης μέσω προσαρμογής του πεδίου αποδοχής του πυρήνα. Η συνέλιξη αυτή, αποτελεί παραλλαγή της κλασικής συνέλιξης, καθώς εισάγει κενά μεταξύ των στοιχείων του πυρήνα, επιτρέποντας την αύξηση του πεδίου αποδοχής χωρίς την προσθήκη επιπλέον παραμέτρων. Από αυτή την βάση, το δίκτυο μπορεί να κλιμακωθεί ανά πλάτος, μεταβάλλοντας τον αριθμό των καναλιών των residual blocks και ανά βάθος, μεταβάλλοντας το πλήθος τους. Η δυνατότητα αυτή δημιουργεί ένα μεγάλο χώρο σχεδιασμού, ο οποίος εξερευνάται μέσω αναζήτησης πλέγματος (Grid Search) με σκοπό τον εντοπισμό των βέλτιστων αρχιτεκτονικών σε δύο διακριτές κατηγορίες. Η πρώτη κατηγορία δίνει μεγαλύτερη προτεραιότητα στην ταχύτητα διατηρώντας παράλληλα υψηλή ακρίβεια, ενώ η δεύτερη επικεντρώνεται στην ακρίβεια του μοντέλου. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας το Scaling Wide Residual Network χρησιμοποιείται ως εξαγωγέας χαρακτηριστικών και σε συνδυασμό με το Panoptic DeepLab [79] έχει πετύχει πανοπτική ποιότητα ίση με 68.5 στο σύνολο δεδομένων δοκιμής του Cityscapes [2].

Στάδιο	Διαστάσεις εισόδου	Διαστάσεις εξόδου	WR-41	SWideRNet-(w_1, w_2, ℓ)
conv1	224×224	112×112	$3 \times 3, 64, \text{stride } 2$	$3 \times 3, 64 \times w_1, \text{stride } 2$
conv2	112×112	56×56	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 3$	$\begin{bmatrix} 3 \times 3, 128 \times w_1 \\ 3 \times 3, 128 \times w_1 \end{bmatrix} \times 3$
			$3 \times 3 \text{ max-pool, stride } 2$	
conv3	56×56	28×28	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 3 \times 3, 256 \times w_2 \\ 3 \times 3, 256 \times w_2 \\ SE \end{bmatrix} \times 3\ell$
conv4	28×28	14×14	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 6$	$\begin{bmatrix} 3 \times 3, 512 \times w_2 \\ 3 \times 3, 512 \times w_2 \\ SE \end{bmatrix} \times 6\ell$
conv5	14×14	7×7	$\begin{bmatrix} 3 \times 3, 1024 \\ 3 \times 3, 1024 \end{bmatrix} \times 3$	$\begin{bmatrix} 3 \times 3, 1024 \times w_2 \\ 3 \times 3, 1024 \times w_2 \\ SE \end{bmatrix} \times 3\ell$
conv6	7×7	7×7	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 1024 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \times w_2 \\ 3 \times 3 \text{ SAC, } 1024 \times w_2 \\ 1 \times 1, 2048 \times w_2 \\ SE \end{bmatrix} \times 3\ell$
	7×7	1×1	average-pool, 1000-d fc, softmax	

Πίνακας 1: Σύγκριση αρχιτεκτονικών Wide-ResNet-41 και SWideRNet



Σχήμα 4.2.1: Αρχιτεκτονικές τεχνικών (a) Squeeze-and-Excitation, (b) Switchable Atrous Convolution


4.2.2 Naive-Student

Η Naive-Student [80] αποτελεί μέθοδο εκπαίδευσης, η οποία αξιοποιεί τόσο δεδομένα με ετικέτες, όσο και δεδομένα χωρίς ετικέτες. Στόχος της αποτελεί η βελτίωση της διαδικασίας εκπαίδευσης στις εργασίες κατάτμησης εικόνας, σε περιπτώσεις που το σύνολο εκπαίδευσης αποτελείται από ακολουθίες βίντεο αστικών σκηνών. Πολλές φορές στα σύνολα δεδομένων βίντεο, μόνο ένα μικρό μέρος των καρέ είναι επισημειωμένο, ενώ ο υπόλοιπος όγκος παραμένει αναξιοποίητος. Η αξιοποίηση αυτού του ανεκμετάλλευτου όγκου δεδομένων μπορεί να βελτιώσει σημαντικά την αποδοτικότητα των μεθόδων. Μια προσέγγιση για την αξιοποίηση τους αποτελεί η Naive-Student. Η μέθοδος ξεκινά με την εκπαίδευση ενός μοντέλου Δασκάλου στα διαθέσιμα επισημειωμένα δεδομένα, το οποίο στη συνέχεια χρησιμοποιείται για την παραγωγή "ψευδο-ετικετών" για τα καρέ τα οποία δεν είναι επισημειωμένα. Έπειτα, ένα μοντέλο Μαθητής, συνήθως με ισχυρότερη αρχιτεκτονική, εκπαιδεύεται αξιοποιώντας ολόκληρο το διαθέσιμο σύνολο δεδομένων και στη συνέχεια βελτιστοποιείται αποκλειστικά με βάση τα επισημειωμένα δείγματα. Στην επόμενη επανάληψη το μοντέλο Μαθητής αντικαθιστά το μοντέλο Δάσκαλος, με στόχο να παράξει βελτιωμένες "ψευδο-ετικέτες" για τα ήδη "ψευδο-επισημειωμένα" δεδομένα. Η διαδικασία αυτή επαναλαμβάνεται, βελτιώνοντας σταδιακά την ποιότητα των επισημειώσεων, όπως και την απόδοση του μοντέλου. Με το πέρας των επαναλήψεων, το τελικό μοντέλο Μαθητής αποτελεί το αποτέλεσμα της μεθόδου. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας η μέθοδος εκπαίδευσης Naive-Student σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Xception-71 [81] ως μοντέλο Δάσκαλο, τον εξαγωγέα χαρακτηριστικών Wide ResNet-41 [77] ως μοντέλο Μαθητή και το Panoptic-DeePLab [79] ως κεφαλή πανοπτικής κατάτμησης πέτυχε πανοπτική ποιότητα ίση με 67.8 στο σύνολο δεδομένων δοκιμής του Cityscapes [2].

4.3 State-of-the-art στο σύνολο δεδομένων ADE20K

4.3.1 OneFormer

Το OneFormer [82] αποτελεί μοντέλο βασισμένο στους μετασχηματιστές, το οποίο είναι σε θέση να εκτελέσει και τις τρεις βασικές εργασίες κατάτμησης εικόνας, μέσω μιας ενιαίας αρχιτεκτονικής, ενός ενιαίου μοντέλου και μιας ενιαίας διαδικασίας εκπαίδευσης. Η ενιαία αυτή διαδικασία εκπαίδευσης και για τις τρεις βασικές εργασίες κατάτμησης εικόνας μειώνει σημαντικά το υπολογιστικό κόστος, όπως και τον απαιτούμενο αποθηκευτικό χώρο. Η αρχιτεκτονική του OneFormer περιλαμβάνει μεταξύ άλλων ένα εξαγωγέα χαρακτηριστικών και ένα αποκωδικοποιητή εικονοστοιχείων, οι οποίοι έχουν ως σκοπό την εξαγωγή χαρακτηριστικών πολλαπλών διαστάσεων από την εικόνα. Αφού πραγματοποιηθεί η εξαγωγή χαρακτηριστικών, παράγονται queries αντίστοιχα τις εργασίες που πραγματοποιείται, τα οποία στη συνέχεια επεξεργάζεται ο αποκωδικοποιητής μετασχηματισμού (Transformer Decoder). Για την τελική πρόβλεψη το μοντέλο παράγει με δυναμικό τρόπο μάσκες και κατηγορίες προσαρμοσμένες στην εκάστοτε εργασία. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας το OneFormer σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών InternImage-H [83] πέτυχε πανοπτική ποιότητα ίση με 54.5 στο σύνολο δεδομένων επικύρωσης του ADE20K [66].




Σχήμα 4.3.1: Αρχιτεκτονική OneFormer

4.3.2 OpenSeeD

Το OpenSeeD [84] αποτελεί μοντέλο βασισμένο στους μετασχηματιστές, σχεδιασμένο με τρόπο που του επιτρέπει την εκτέλεση όλων των βασικών εργασιών κατάτμησης εικόνας, καθώς και ανίχνευση αντικειμένων. Δύναται να εκπαιδευτεί τόσο από δεδομένα ανίχνευσης αντικειμένων όσο και από δεδομένα κατάτμησης εικόνας και βασική του ιδιότητα αποτελεί η δυνατότητα αξιοποίησης των δεδομένων της μιας εργασίας για την εκπαίδευση όχι μόνο της ίδιας αλλά και της άλλης. Η δυνατότητα αυτή επιτρέπει στο μοντέλο την αναγνώριση και τμηματοποίηση στοιχείων της εικόνας, πέρα από το κλειστό λεξιλόγιο του συνόλου εκπαίδευσης. Αποτελείται από ένα κωδικοποιητή εικόνας (Image Encoder), ένα κωδικοποιητή κειμένου (Text Encoder)

και ένα αποκωδικοποιητή, ο οποίος μπορεί να χειριστεί τόσο "αντικείμενα" όσο και "σκηνικά" στοιχεία, ενώ έχει την δυνατότητα παραγωγής δυαδικών масκών για τα "αντικείμενα" που προκύπτουν από τα πλαίσια του συνόλου δεδομένων ανίχνευσης, αξιοποιώντας μηχανισμούς αυτοπροσοχής και διασταυρούμενης προσοχής. Στο πλαίσιο της πανοπτικής κατάτμησης εικόνας το OpenSeeD σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών Swin-L [74] πέτυχε πανοπτική ποιότητα ίση με 53.7 στο σύνολο δεδομένων επικύρωσης του ADE20K [66].




Σχήμα 4.3.2: Αρχιτεκτονική OpenSeed

4.4 Θεμελιώδεις έρευνες στην πανοπτική κατάτμηση εικόνας

4.4.1 Panoptic-DeepLab

Το Panoptic-DeepLab [79] αποτελεί μοντέλο πανοπτικής κατάτμησης εικόνας και μια από τις σημαντικότερες εργασίες του χώρου. Η πλειοψηφία των μοντέλων πανοπτικής κατάτμησης της περιόδου βασίζονταν στην αρχική ανίχνευση αντικειμένων και ακολούθως στην ανάθεση κάθε εικονοστοιχείου της εικόνας σε μια κλάση. Σε αντίθεση με αυτό, το Panoptic-DeepLab δεν προσεγγίζει την εργασία με αυτό τον τρόπο αλλά ξεκινά με την απόδοση σημασιολογικών κατηγοριών σε κάθε εικονοστοιχείο της εικόνας και στη συνέχεια πραγματοποιεί διάκριση μεταξύ των επιμέρους "αντικειμένων" που ανήκουν στην ίδια κατηγορία. Για κάθε επιμέρους "αντικείμενο" της εικόνας προβλέπεται το κέντρο του, ενώ για κάθε εικονοστοιχείο που το απαρτίζει υπολογίζεται το διάνυσμα μετατόπισης προς αυτό. Το πρώτο στάδιο της μεθοδολογίας περιλαμβάνει τον εξαγωγέα χαρακτηριστικών κωδικοποιητή (Encoder Backbone). Ακολούθως, η διαδικασία χωρίζεται σε δύο διακριτές διακλαδώσεις, με την μία να είναι υπεύθυνη για την εκτέλεση της σημασιολογικής κατάτμησης και την άλλη για την εκτέλεση της κατάτμησης αντικειμένων. Κάθε διακλάδωση αποτελείται από ένα μηχανισμό χωρικής υποδειγματοληψίας πυραμίδας με διάτρηση (Atrous Spatial Pyramid Pooling) για την εξαγωγή πολυκλιμακικών χαρακτηριστικών από τις εικόνες, ένα αποκωδικοποιητή που προβάλλει τα χαρακτηριστικά του χάρτη χαρακτηριστικών σε υψηλότερες διαστάσεις και μια κεφαλή πρόβλεψης. Η κεφαλή πρόβλεψης της μιας διακλάδωσης παράγει τον χάρτη σημασιολογικής πρόβλεψης, ενώ η άλλη προβλέπει τα κέντρα


των επιμέρους "αντικειμένων" και υπολογίζει τα διανύσματα μετατόπισης των εικονοστοιχείων που ανήκουν σε αυτά προς τα αντίστοιχα κέντρα τους. Στο τελευταίο στάδιο, τα αποτελέσματα των δύο διακλαδώσεων συνδυάζονται για την παραγωγή της πανοπτικής κατάτμησης.



Σχήμα 4.4.1: Αρχιτεκτονική μοντέλου Panoptic-DeepLab

4.4.2 UPSNet


Το UPSNet [85] αποτελεί μοντέλο και θεμελιώδη εργασία στην πανοπτική κατάτμηση εικόνας. Η πλειοψηφία των μοντέλων πανοπτικής κατάτμησης της περιόδου βασίζονταν στον συνδυασμό των προβλέψεων σημασιολογικής κατάτμησης και κατάτμησης αντικειμένων. Ο συνδυασμός αυτός πραγματοποιείτο μέσω κάποιων προκαθορισμένων κανόνων, οι οποίοι όμως δεν αποτελούσαν μέρος του μοντέλου αλλά εφαρμόζονταν ως ξεχωριστό στάδιο επεξεργασίας. Ως αποτέλεσμα, ο μηχανισμός συνένωσης δεν ήταν δυνατό να βελτιστοποιηθεί από κοινού με το μοντέλο, γεγονός που περιόριζε τις δυνατότητες του συστήματος. Το UPSNet εισήγαγε μια ενιαία αρχιτεκτονική, επιτρέποντας έτσι υψηλότερη απόδοση και ταχύτερη εξαγωγή εκτιμήσεων. Το πρώτο στάδιο της μεθοδολογίας περιλαμβάνει ένα εξαγωγέα χαρακτηριστικών. Ακολούθως, η διαδικασία χωρίζεται σε δύο διακλαδώσεις, στην διακλάδωση σημασιολογικής κατάτμησης και στην διακλάδωση κατάτμησης αντικειμένων. Η διακλάδωση κατάτμησης αντικειμένων αντιστοιχεί στο Mask R-CNN [86]. Ο εξαγωγέας χαρακτηριστικών είναι ενιαίος για τις δύο εργασίες και βασίζεται στις αρχιτεκτονικές των Residual Networks (ResNets) [87] και Feature Pyramid Networks (FPN) [88]. Σκοπός του εξαγωγέα χαρακτηριστικών αποτελεί η παραγωγή πολυκλιμακικών χαρακτηριστικών από την εικόνα. Τα αποτελέσματα των δύο διακλαδώσεων συνδυάζονται μέσω μιας πανοπτικής κεφαλής, η οποία παράγει την πανοπτική κατάτμηση της εικόνας.



Σχήμα 4.4.2: Αρχιτεκτονική μοντέλου UPSNet

4.4.3 Max-DeepLab

Το Max-DeepLab [89] αποτελεί ένα από τα σημαντικότερα μοντέλα στην πανοπτική κατάτμηση εικόνας. Τα κλασικά συστήματα της περιόδου ήταν κυρίως βασισμένα σε διαδικασίες με πολλά ενδιάμεσα βήματα. Αν και κάθε στάδιο μπορούσε να βελτιστοποιηθεί μεμονωμένα, δεν ήταν δυνατή η ταυτόχρονη, συνολική βελτιστοποίηση του συστήματος. Σε αντίθεση με αυτά, το Max-DeepLab εισήγαγε μια ενιαία αρχιτεκτονική κατάτμησης εικόνας, με διαδικασίες χωρίς πολύπλοκα ενδιάμεσα βήματα. Το μοντέλο αποτελείται από δύο διακλαδώσεις, την διακλάδωση των εικονοστοιχείων, η οποία εξάγει πολυκλιμακικά χαρακτηριστικά χαμηλού επιπέδου από την εικόνα όπως σχήματα και ακμές και την διακλάδωση μνήμης, η οποία εξάγει χαρακτηριστικά υψηλού επιπέδου. Οι διακλαδώσεις αλληλεπιδρούν μεταξύ τους μέσω των μετασχηματιστών διπλής διαδρομής. Η διακλάδωση εικονοστοιχείων ενημερώνει την διακλάδωση μνήμης με πιο λεπτομερείς πληροφορίες ενώ η διακλάδωση μνήμης την διακλάδωση εικονοστοιχείων με πληροφορίες υψηλότερου επιπέδου. Ακολούθως, ο αποκωδικοποιητής συνδυάζει τα χαρακτηριστικά της διακλάδωσης εικονοστοιχείων και τα προβάλλει σε μεγαλύτερες διαστάσεις, με σκοπό την αποκατάσταση των λεπτομερειών και τον σαφή διαχωρισμό των σχημάτων και των ορίων τους. Οι κεφαλές εξόδου αποτελούν το τελευταίο στάδιο του μοντέλου και είναι υπεύθυνες για τη μετατροπή της επεξεργασμένης πληροφορίας σε τελικές προβλέψεις. Η μία κεφαλή αξιοποιεί τις ενσωματώσεις της διακλάδωσης μνήμης για την απόδοση κατηγορίας σε κάθε επιμέρους στοιχείο της εικόνας, ενώ η άλλη χρησιμοποιεί τα χαρακτηριστικά που παράγονται από τον αποκωδικοποιητή για τον καθορισμό των εικονοστοιχείων που το αποτελούν. Ο συνδυασμός των εξόδων των δύο κεφαλών οδηγεί στο τελικό αποτέλεσμα.



Σχήμα 4.4.3: Αρχιτεκτονική μοντέλου Max-DeepLab

5 Συμβολή της εργασίας

Η εργασία βασίζεται στον εξαγωγέα χαρακτηριστικών Visual Attention Network (VAN). Για τον λόγο αυτό, αρχικά παρουσιάζεται εκτενώς η αρχιτεκτονική και τα βασικά του στοιχεία, ώστε να γίνει κατανοητή η λειτουργία του. Έπειτα, παρουσιάζονται οι τροποποιήσεις που υλοποιήθηκαν, μέσω των οποίων προέκυψε το προτεινόμενο μοντέλο Visual Attention Network multi-branch.

5.1 Visual Attention Network


Το Visual Attention Network (VAN) [90] αποτελεί εξαγωγέα χαρακτηριστικών (Feature Extractor), σχεδιασμένο να συνδυάζει τα πλεονεκτήματα των συνελκτικών νευρωνικών δικτύων και των μηχανισμών αυτο-προσοχής, αποφεύγοντας τα μειονεκτήματά τους. Δημιουργήθηκε γύρω από έναν νέο μηχανισμό αυτο-προσοχής, τον Large Kernel Attention (LKA). Η αυτο-προσοχή, παρόλο που είχε σχεδιαστεί για την αντιμετώπιση προβλημάτων επεξεργασίας φυσικής γλώσσας, στη συνέχεια χρησιμοποιήθηκε ευρέως σε πολλές εργασίες της όρασης υπολογιστών. Ωστόσο, λόγω της δισδιάστατης φύσης των εικόνων, η εισαγωγή αυτο-προσοχής σε οπτικά δεδομένα συνοδεύτηκε από προβλήματα.

- Η αντιμετώπιση των εικόνων ως μονοδιάστατες ακολουθίες αγνοεί την δισδιάστατη φύση τους.
- Η υπολογιστική πολυπλοκότητα $O(n^2)$ των μηχανισμών αυτο-προσοχής είναι υπερβολικά υψηλή για εικόνες υψηλής ανάλυσης.
- Οι συμβατικοί μηχανισμοί αυτο-προσοχής εστιάζουν αποκλειστικά στη χωρική αλληλεπίδραση μεταξύ των εικονοστοιχείων, αγνοώντας τη σημασία της αλληλεπίδρασης μεταξύ διαφορετικών καναλιών. Συχνά, διαφορετικά κανάλια σε μια εικόνα αναπαριστούν διαφορετικά αντικείμενα.

Λύση στα παραπάνω προβλήματα επιχειρεί να δώσει ο Large Kernel Attention. Ο Large Kernel Attention συνιστά επιμέρους στοιχείο του VAN και παρόλο που αποτελεί μηχανισμό αυτο-προσοχής, δεν κληρονομεί τα αντίστοιχα προβλήματα. Η βασική ιδέα στηρίζεται στη χρήση συνελίξεων μεγάλου πυρήνα, μέσω των οποίων καθίσταται δυνατός ο υπολογισμός της σχέσης μεταξύ των εικονοστοιχείων που έχουν μεγάλη απόσταση μεταξύ τους. Ωστόσο, η χρήση τέτοιας μορφής συνελκτικών πράξεων απαιτεί μεγάλη υπολογιστική ισχύ και σημαντικό αριθμό παραμέτρων. Για την αντιμετώπιση αυτού του προβλήματος ο Large Kernel Attention χρησιμοποιεί μια αποσυντεθειμένη μορφή συνέλιξης, η οποία μειώνει σημαντικά την υπολογιστική πολυπλοκότητα. Ως εκ τούτου, η συνέλιξη διασπάται σε τρία μέρη, μια χωρική συνέλιξη

μικρών διαστάσεων για την καταγραφή των τοπικών συσχετίσεων, μια διευρυμένη χωρική συνέλιξη για την καταγραφή μακρινών σχέσεων και μια σημειακή συνέλιξη για την καταγραφή της αλληλεπίδρασης μεταξύ των καναλιών.

Στην αυθεντική υλοποίηση μια συνελικτική πράξη διαστάσεων $K \times K$ διασπάται σε μια $\lceil \frac{K}{d} \rceil \times \lceil \frac{K}{d} \rceil$ χωρική συνέλιξη με συντελεστή απόστασης d , μια $(2d - 1) \times (2d - 1)$ χωρική συνέλιξη και μια σημειακή συνέλιξη. Η αποσύνθεση αυτή επιτρέπει την λήψη συσχετίσεων μεταξύ των εικονοστοιχείων που έχουν μεγάλη απόσταση μεταξύ τους, χωρίς ουσιαστική επιβάρυνση της υπολογιστικής πολυπλοκότητας ή σημαντική αύξηση του πλήθους των παραμέτρων του μοντέλου.



Σχήμα 5.1.1: Αποσύνθεση συνέλιξης μεγάλου πυρήνα για $K = 7$ και $d = 2$.

Ο μηχανισμός LKA μπορεί να εκφραστεί μαθηματικά ως εξής.


$$Attention = \text{Conv}_{1 \times 1}(\text{DW-D-Conv}(\text{DW-Conv}(F))) \quad (5.1)$$

$$Output = Attention \otimes F \quad (5.2)$$

Όπου $F \in \mathbb{R}^{C \times H \times W}$ ο χάρτης χαρακτηριστικών (Feature Map) και $Attention \in \mathbb{R}^{C \times H \times W}$ ο χάρτης προσοχής (Attention Map). Η τιμή σε κάθε θέση του χάρτη προσοχής εκφράζει την σημασία του αντίστοιχου χαρακτηριστικού. Ο τελεστής $\otimes$ αντιστοιχεί στον πολλαπλασιασμό ανά στοιχείο.

Το VAN αποτελείται από τέσσερα διαδοχικά στάδια. Έστω $H \times W \times C$ οι διαστάσεις της εικόνας εισόδου. Πριν από κάθε στάδιο, οι διαστάσεις της εισόδου μεταβάλλονται μέσω συνελικτικών πράξεων με βήμα. Η μεταβολή των χωρικών διαστάσεων της εισόδου εξαρτάται από το εκάστοτε στάδιο. Στο πρώτο στάδιο οι χωρικές διαστάσεις της εισόδου μεταβάλλονται σε $\frac{H}{4} \times \frac{W}{4}$, στο δεύτερο σε $\frac{H}{8} \times \frac{W}{8}$, στο τρίτο σε $\frac{H}{16} \times \frac{W}{16}$ και στο τέταρτο σε $\frac{H}{32} \times \frac{W}{32}$. Το

VAN διατίθεται σε επτά διαφορετικές παραλλαγές. Ο αριθμός των καναλιών C σε κάθε στάδιο του μοντέλου εξαρτάται από την παραλλαγή του VAN που χρησιμοποιείται. Ενδεικτικά, στην περίπτωση του VAN-B0 το πλήθος των καναλιών ορίζεται ίσο με $C = 32$ στο πρώτο στάδιο, $C = 64$ στο δεύτερο, $C = 160$ στο τρίτο και $C = 256$ στο τέταρτο. Καθ' όλη την διάρκεια του σταδίου, τόσο οι χωρικές διαστάσεις όσο και η διάσταση των καναλιών C παραμένουν σταθερές. Κάθε στάδιο συγκροτείται από μια ακολουθία L πανομοιότυπων διαδοχικών στρωμάτων. Το πλήθος των στρωμάτων διαφέρει ανάλογα με το στάδιο και την παραλλαγή του μοντέλου VAN που χρησιμοποιείται. Ενδεικτικά, στο VAN-B0 ορίζεται η τιμή $L = 3$ για το πρώτο και δεύτερο στάδιο, $L = 5$ για το τρίτο και $L = 2$ για το τέταρτο. Στο Σχήμα 5.1.2 παρουσιάζεται η σχηματική αναπαράσταση της αρχιτεκτονικής ενός σταδίου VAN.




Σχήμα 5.1.2: Αρχιτεκτονική ενός σταδίου του VAN

Στην αυθεντική υλοποίηση χρησιμοποιούνται οι τιμές $K = 21$ και $d = 3$ ως προεπιλογή. Αυτός ο συνδυασμός αντιστοιχεί σε μια 5×5 χωρική συνέλιξη και μια 7×7 χωρική συνέλιξη με συντελεστή απόστασης τρία.

5.2 Visual Attention Network multi-branch

Το Visual Attention Network multi-branch (VANmb) συνιστά εξαγωγέα χαρακτηριστικών βασισμένο στα συνελκτικά νευρωνικά δίκτυα και αποτελεί επέκταση του Visual Attention Network. Ένα βασικό ζήτημα του Visual Attention Network είναι ότι βασίζεται σε μία μόνο διαδρομή επεξεργασίας, γεγονός που περιορίζει την ικανότητά του για ταυτόχρονη εκμετάλλευση διαφορετικών επιπέδων πληροφορίας. Το VANmb προτείνεται ως λύση σε αυτό το πρόβλημα. Η εισαγωγή πολυκλαδικής εκδοχής στον μηχανισμό Large Kernel Attention επιτρέπει την ταυτόχρονη επεξεργασία διαφορετικών όψεων της πληροφορίας, οδηγώντας σε πλουσιότερες αναπαραστάσεις χαρακτηριστικών.

Στην υλοποίηση ο μηχανισμός LKA, αντικαθίσταται από τον μηχανισμό Large Kernel Attention multi-branch (LKAmb), ο οποίος αποτελείται από τρεις κλάδους LKA. Στον πρώτο κλάδο υιοθετούνται οι τιμές $K = 21$ και $d = 3$ του μοντέλου VAN. Στον δεύτερο κλάδο χρησιμοποιούνται οι τιμές $K = 15$ και $d = 3$, ενώ στον τρίτο οι $K = 12$ και $d = 2$.



Σχήμα 5.2.1: Αρχιτεκτονική ενός σταδίου του VANmb

Η έξοδος του μηχανισμού LKAmb δίνεται από την η σχέση

$$output = value_1 \cdot LKA_1 + value_2 \cdot LKA_2 + value_3 \cdot LKA_3 \quad (5.3)$$

Οι τιμές $value_1, value_2, value_3$ αποτελούν τα βάρη που προκύπτουν μετά από κανονικοποίηση των αντίστοιχων παραμέτρων του μοντέλου, μέσω της συνάρτησης Softmax. Έτσι, εξασφαλίζεται πως ισχύουν οι σχέσεις

$$value_i \geq 0, \quad value_1 + value_2 + value_3 = 1 \quad (5.4)$$

Στις πρώτες 20000 επαναλήψεις εκπαίδευσης του μοντέλου, στην συνάρτηση ενσωματώνεται μια παράμετρος θερμοκρασίας, η οποία αρχικοποιείται στο πέντε και μειώνεται εκθετικά στο ένα. Η τιμή της θερμοκρασίας σε κάθε επανάληψη υπολογίζεται μέσω της παρακάτω σχέσης.

$$T = T_{\text{end}} + (T_{\text{start}} - T_{\text{end}}) e^{-T_{\text{start}} \cdot \text{progress}} \quad (5.5)$$

$$\text{progress} = \min\left(\frac{\text{step}}{\text{iterations}}, 1.0\right) \quad (5.6)$$

Όπου T η θερμοκρασία, iterations το πλήθος των επαναλήψεων που απαιτούνται για να φτάσει στην τελική τιμή και step η τρέχουσα επανάληψη εκπαίδευσης. Οι τιμές των $value_1, value_2, value_3$ υπολογίζονται μέσω της παρακάτω σχέσης.

$$value_i = \frac{e^{w_i/T}}{\sum_{j=1}^3 e^{w_j/T}}, \quad i = 1, 2, 3 \quad (5.7)$$

Όπου w_i , οι παράμετροι εκπαίδευσης του μοντέλου, οι οποίες αρχικοποιούνται στη μονάδα.

Σκοπός της παραμέτρου θερμοκρασίας είναι να διασφαλιστεί πως όλοι οι κλάδοι θα έχουν τον απαραίτητο χρόνο εκπαίδευσης και ότι το μοντέλο δεν θα κορεστεί από ένα μόνο από αυτούς.

Τα αντίστοιχα πειραματικά αποτελέσματα του μοντέλου VANmb παρουσιάζονται στο 6.5.

6 Πειραματικά αποτελέσματα

Για την επίτευξη του τελικού μοντέλου πραγματοποιήθηκε πλήθος πειραμάτων για διάφορες παραλλαγές του VAN [90]. Οι παραλλαγές αυτές περιελάμβαναν τροποποιήσεις στην αρχιτεκτονική, όπως και στην αρχικοποίηση των παραμέτρων, με σκοπό την διερεύνηση της επίδρασης τους στην απόδοση. Μέσα από την συγκριτική αξιολόγηση των αποτελεσμάτων εντοπίστηκαν οι πλέον αποτελεσματικές εκδοχές, οι οποίες αξιοποιήθηκαν για τη διαμόρφωση του τελικού μοντέλου. Οι αναλυτικοί πίνακες των αποτελεσμάτων βρίσκονται στο Παράρτημα.

6.1 Γενικό πλαίσιο

Τα πειραματικά αποτελέσματα βασίστηκαν στον πηγαίο κώδικα του Mask2Former [1], το οποίο κάνει χρήση της βιβλιοθήκης Detectron2 [91]. Ο κώδικας του Mask2Former τροποποιήθηκε και ο εξαγωγέας χαρακτηριστικών Swin [74] αντικαταστάθηκε από τον εξαγωγέα χαρακτηριστικών VAN. Τα πειράματα πραγματοποιήθηκαν στο σύνολο δεδομένων επικύρωσης του Cityscapes [2], με αποκλειστική χρήση της παραλλαγής VAN-B0 του VAN.


6.1.1 Παράμετροι εκπαίδευσης

Στην αυθεντική υλοποίηση χρησιμοποιούνται οκτώ κάρτες γραφικών και μέγεθος παρτίδας ίσο με 16. Ωστόσο, λόγω περιορισμένης υπολογιστικής ισχύος, στην παρούσα υλοποίηση χρησιμοποιήθηκε μια κάρτα γραφικών και μέγεθος παρτίδας ίσο με δύο. Η κάρτα γραφικών που χρησιμοποιήθηκε είναι η NVIDIA GeForce RTX 4070. Στην αυθεντική υλοποίηση ο ρυθμός μάθησης είναι ίσος με 10^{-5} με αποδυνάμωση βαρών ίση με 0.05. Ωστόσο, λόγω της μείωσης του μέγεθους παρτίδας σε δύο, ο ρυθμός μάθησης ορίστηκε ίσος με 3535×10^{-8} . Ως βελτιστοποιητής χρησιμοποιήθηκε ο AdamW [45], ενώ για την ρύθμιση του ρυθμού μάθησης εφαρμόστηκε ο poly [92]. Όλα τα μοντέλα εκπαιδεύτηκαν στο σύνολο δεδομένων Cityscapes για συνολικά 148800 επαναλήψεις ή αντίστοιχα 100 εποχές εκπαίδευσης. Εξάιρεση αποτελεί το τελικό μοντέλο το οποίο εκπαιδεύτηκε για συνολικά 297600 επαναλήψεις ή αντίστοιχα 200 εποχές εκπαίδευσης. Στην αυθεντική υλοποίηση τα πειράματα ήταν ορισμένα για 90000 επαναλήψεις, αριθμός που δεν υιοθετήθηκε λόγω περιορισμένης υπολογιστικής ισχύος. Στο τελικό μοντέλο εξετάστηκε η χρήση μιας επιπλέον τιμής ρυθμού μάθησης, συγκεκριμένα της 10^{-5} .

6.2 Αρχικοποίηση παραμέτρων

Εξετάζεται η χρήση προεκπαιδευμένων βαρών στην απόδοση του μοντέλου. Συγκεκριμένα, αξιοποιήθηκαν βάρη που είχαν προκύψει από εκπαίδευση του VAN στο σύνολο δεδομένων ImageNet-1K [23] στην εργασία της ταξινόμησης εικόνας για 300 εποχές εκπαίδευσης. Στόχος αποτελεί η διερεύνηση του κατά πόσο αυτή η αρχικοποίηση προσφέρει πλεονέκτημα έναντι της τυχαίας αρχικοποίησης βαρών. Η σύγκριση των δύο περιπτώσεων, ως προς την πανοπτική

ποιότητα, παρουσιάζεται γραφικά στο Σχήμα 6.2.1.



Σχήμα 6.2.1: Σύγκριση πανοπτικής ποιότητας για διαφορετικές αρχικοποιήσεις των βαρών του εξαγωγέα χαρακτηριστικών.

Παρατηρείται πως η αρχικοποίηση του εξαγωγέα χαρακτηριστικών με βάρη προεκπαιδευμένα στο ImageNet-1K επιφέρει καλύτερα αποτελέσματα συγκριτικά με την τυχαία αρχικοποίηση του.

Μοντέλο	Επαναλήψεις	PQ	PQ_{th}	PQ_{St}
Mask2former (VAN-B0 [†])	148800	57.101	44.91	65.967
Mask2former (VAN-B0)	148800	38.726	20.307	52.122

Πίνακας 2: Σύγκριση αποτελεσμάτων για διαφορετικές αρχικοποιήσεις των βαρών του VAN-B0. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K, ενώ η απουσία του τυχαία αρχικοποίηση παραμέτρων.

6.3 Εναλλακτικές μέθοδοι κανονικοποίησης τιμών


Στο πλαίσιο των δοκιμών που πραγματοποιήθηκαν για την επιλογή του τελικού μοντέλου, πραγματοποιήθηκαν πειράματα κατά τα οποία η κανονικοποίηση παρτίδας αφαιρέθηκε και αντικαταστάθηκε με διαφορετικές μεθόδους κανονικοποίησης. Οι μέθοδοι κανονικοποίησης που δοκιμάστηκαν είναι η κανονικοποίηση ανά ομάδα και η κανονικοποίηση ανά παρτίδα και ομάδα.

Η ανάγκη για δοκιμή διαφορετικών μεθόδων κανονικοποίησης προέκυψε από το μέγεθος παρτίδας, το οποίο λόγω της περιορισμένης μνήμης της κάρτας γραφικών έπρεπε να μειωθεί

σημαντικά. Το γεγονός αυτό καθιστά την κανονικοποίηση παρτίδας λιγότερο αποτελεσματική, καθώς δεν αποδίδει το ίδιο καλά για μικρά μεγέθη παρτίδων [58]. Για αυτό τον λόγο κρίθηκε σκόπιμο να δοκιμαστούν επιπλέον μέθοδοι κανονικοποίησης.

Η αρχικοποίηση με βάρη προεκπαιδευμένα στο ImageNet-1K επιφέρει βελτιωμένα αποτελέσματα. Για τον λόγο αυτό, σε όλα τα μοντέλα που δοκιμάστηκαν εφαρμόστηκε μεταφορά μάθησης (Transfer Learning). Στην μεταφορά μάθησης, μεταφέρονται οι τιμές των παραμέτρων για όλα τα συμβατά μέρη, ενώ για τα επιπλέον στοιχεία που προστέθηκαν εφαρμόζεται τυχαία αρχικοποίηση παραμέτρων.

Στο 6.3.1 παρουσιάζεται γραφικά η συγκριτική αναπαράσταση της πανοπτικής ποιότητας του VAN για διαφορετικές μεθόδους κανονικοποίησης.



Σχήμα 6.3.1: Σύγκριση πανοπτικής ποιότητας για διαφορετικές μεθόδους κανονικοποίησης. BN: Κανονικό VAN-B0. GN: Παραλλαγή VAN-B0 με κανονικοποίηση ανά ομάδα. BGN: Παραλλαγή VAN-B0 με κανονικοποίηση ανά παρτίδα και ομάδα.

Παρατηρείται πως η κανονικοποίηση ανά παρτίδα επιφέρει καλύτερα αποτελέσματα σε σχέση με τις δύο άλλες μορφές κανονικοποίησης.

Μοντέλο	Επαναλήψεις	PQ	PQ_{th}	PQ_{St}
Mask2former (VAN-B0 [†] με BN)	148800	57.101	44.91	65.967
Mask2former (VAN-B0 [†] με GN)	148800	47.351	30.98	59.258
Mask2former (VAN-B0 [†] με BGN)	148800	39.38	24.001	50.565

Πίνακας 3: Σύγκριση αποτελεσμάτων VAN-B0 με διαφορετικές μεθόδους κανονικοποίησης. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.

6.4 Αντικατάσταση σημειακής συνέλιξης με MLP


Εξετάζεται η αντικατάσταση της σημειακής συνέλιξης του LKA με ένα δίκτυο MLP δύο κρυφών στρωμάτων. Η σχέση (5.1) παίρνει την ακόλουθη μορφή.

$$Attention = MLP(DW-D-Conv(DW-Conv(F))) \quad (6.1)$$

Η ιδέα για αντικατάσταση της σημειακής συνέλιξης με ένα δίκτυο Perceptron πολλών στρωμάτων, προέκυψε λόγω της γραμμικής φύσης της συνελικτικής πράξης. Η ενσωμάτωση μη γραμμικότητας μπορεί να οδηγήσει σε βελτιωμένη ικανότητα αναπαράστασης του μοντέλου.

Το πλήθος των νευρώνων εισόδου και εξόδου του MLP ταυτίζεται και είναι ίσο με το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Για τον προσδιορισμό του πλήθους των νευρώνων κάθε κρυφού στρώματος, πραγματοποιήθηκαν πειράματα, στα οποία εξετάστηκε πλήθος νευρώνων ίσο με το τριπλάσιο, τετραπλάσιο και πενταπλάσιο του πλήθους των καναλιών του χάρτη χαρακτηριστικών. Η συνάρτηση ενεργοποίησης που χρησιμοποιείται είναι η GELU.

Στο Σχήμα 6.4.1 παρουσιάζεται με γραφικό τρόπο η συγκριτική αναπαράσταση της πανοπτικής ποιότητας για διαφορετικά πλήθη νευρώνων.



Σχήμα 6.4.1: Σύγκριση πανοπτικής ποιότητας για διαφορετικά πλήθη νευρώνων σε κάθε κρυφό στρώμα του MLP. MLP3: Πλήθος νευρώνων ίσο με το τριπλάσιο του πλήθους των καναλιών του χάρτη χαρακτηριστικών. MLP4: Τετραπλάσιο MLP5: Πενταπλάσιο.

Όλες οι παραλλαγές του VAN που εξετάστηκαν πέτυχαν παρόμοια αποτελέσματα. Ωστόσο,


η υψηλότερη πανοπτική ποιότητα καταγράφηκε στο MLP-4.

Μοντέλο	Επαναλήψεις	PQ	PQ _{th}	PQ _{St}
Mask2former (VAN-B0 [†] με MLP3)	148800	54.022	39.707	64.432
Mask2former (VAN-B0 [†] με MLP4)	148800	55.365	43.467	64.017
Mask2former (VAN-B0 [†] με MLP5)	148800	55.25	43.348	63.907

Πίνακας 4: Σύγκριση αποτελεσμάτων για διαφορετικά πλήθη νευρώνων σε κάθε κρυφό στρώμα του MLP. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.

Κατόπιν, εξετάζεται ο συνδυασμός της παραλλαγής MLP4 του VAN με εναλλακτικές μεθόδους κανονικοποίησης. Εξετάστηκαν τρεις μέθοδοι κανονικοποίησης, η κανονικοποίηση ανά παρτίδα, η κανονικοποίηση ανά ομάδα και η κανονικοποίηση ανά παρτίδα και ομάδα.

Στο Σχήμα 6.4.2 απεικονίζεται η συγκριτική αναπαράσταση της πανοπτικής ποιότητας της παραλλαγής MLP4 του VAN για διαφορετικές μεθόδους κανονικοποίησης.



Σχήμα 6.4.2: Σύγκριση πανοπτικής ποιότητας της παραλλαγής MLP4 του VAN για διαφορετικές μεθόδους κανονικοποίησης. MLP4-BN: Παραλλαγή MLP4 με κανονικοποίηση ανά παρτίδα. MLP4-GN: Παραλλαγή MLP4 με κανονικοποίηση ανά ομάδα. MLP4-BGN: Παραλλαγή MLP4 με κανονικοποίηση ανά παρτίδα και ομάδα.

Παρατηρείται πως η παραλλαγή MLP4 με κανονικοποίηση ανά παρτίδα επιφέρει καλύτερα αποτελέσματα σε σχέση με τις δύο άλλες μεθόδους.


Μοντέλο	Επαναλήψεις	PQ	PQ _{th}	PQ _{St}
Mask2former (VAN-B0 [†] με MLP4-BN)	148800	55.365	43.467	64.017
Mask2former (VAN-B0 [†] με MLP4-GN)	148800	42.495	24.658	55.467
Mask2former (VAN-B0 [†] με MLP4-BGN)	148800	38.686	21.997	50.823

Πίνακας 5: Σύγκριση αποτελεσμάτων της παραλλαγής MLP4 του VAN για διαφορετικές μεθόδους κανονικοποίησης. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.

6.5 Χρήση LKA πολλαπλών κλάδων

Εξετάζεται η αντικατάσταση του μηχανισμού LKA του Visual Attention Network, με τον μηχανισμό LKAmb. Μέσω αυτής της τροποποίησης λαμβάνεται το μοντέλο VANmb που παρουσιάστηκε στο κεφάλαιο 5.2. Για την βελτιστοποίηση των παραμέτρων του μοντέλου εξετάστηκαν δύο διαφορετικές τιμές των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας, συγκεκριμένα οι τιμές 20000 και 40000.

Στο Σχήμα 6.5.1 παρουσιάζεται με γραφικό τρόπο η συγκριτική αναπαράσταση της πανοπτικής ποιότητας, για διαφορετικές τιμές των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας.




Σχήμα 6.5.1: Σύγκριση πανοπτικής ποιότητας για διαφορετικές τιμές των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας. VAN-20000: Πλήθος επαναλήψεων ίσο με 20000. VAN-40000: Πλήθος επαναλήψεων ίσο με 40000.

Παρατηρείται πως η παραλλαγή του VANmb με συνολικά 20000 επαναλήψεις προσαρμογής της θερμοκρασίας, επιφέρει καλύτερα αποτελέσματα, σε σχέση με την εναλλακτική παραλλαγή που εξετάζεται.

Μοντέλο	Επαναλήψεις	PQ	PQ _{th}	PQ _{st}
Mask2former (VANmb-B0 [†] με 20000)	148800	55.436	43.282	64.322
Mask2former (VANmb-B0 [†] με 40000)	148800	55.123	41.681	64.898

Πίνακας 6: Σύγκριση αποτελεσμάτων του VANmb για διαφορετικές τιμές των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας. Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.

Ακολουθώς, εξετάζεται το VANmb-20000 για μια εναλλακτική τιμή του ρυθμού μάθησης, συγκεκριμένα 10^{-5} . Στο Σχήμα 6.5.2 παρουσιάζεται η συγκριτική αναπαράσταση της πανοπτικής ποιότητας του μοντέλου Mask2Former [1] σε συνδυασμό με τον εξαγωγέα χαρακτηριστικών VANmb-20000, για διαφορετικές τιμές του ρυθμού μάθησης.



Σχήμα 6.5.2: Σύγκριση πανοπτικής ποιότητας για διαφορετικές τιμές του ρυθμού μάθησης.

Μοντέλο: Mask2former (VANmb-20000 [†] , $lr : 10^{-5}$) Επαναλήψεις: 297600			
	PQ	SQ	RQ
All	47.085	78.559	58.510
Things	27.782	77.410	35.986
Stuff	61.123	79.394	74.891

Πίνακας 7: Αποτελέσματα Mask2former (VANmb-20000[†]) για 297600 επαναλήψεις εκπαίδευσης και ρυθμό μάθησης ίσο με 10^{-5} . Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.

<i>Μοντέλο: Mask2former (VANmb-20000[†], $lr : 3535 \times 10^{-8}$) Επαναλήψεις: 297600</i>			
	<i>PQ</i>	<i>SQ</i>	<i>RQ</i>
All	59.795	80.468	73.093
Things	49.835	78.936	62.602
Stuff	67.039	81.583	80.722

Πίνακας 8: Αποτελέσματα Mask2former (VANmb-20000[†]) για 297600 επαναλήψεις εκπαίδευσης και ρυθμό μάθησης ίσο με 3535×10^{-8} . Το [†] συμβολίζει χρήση βαρών προεκπαιδευμένων στο ImageNet-1K.

Παρατηρείται πως ο ορισμός του ρυθμού μάθησης ίσου με 3535×10^{-8} επιφέρει καλύτερα αποτελέσματα σε σχέση με τον αντίστοιχο ορισμό με 10^{-5} .

7 Συμπεράσματα και μελλοντικές επεκτάσεις

Ολοκληρώνοντας την εργασία, τα πειραματικά αποτελέσματα ανέδειξαν την δυναμική των σύγχρονων αρχιτεκτονικών στην πανοπτική κατάτμηση εικόνας. Η τροποποίηση του εξαγωγέα χαρακτηριστικών VAN [90], μέσω της επέκτασης του με επιπρόσθετα στοιχεία ανέδειξε τις πλέον αποτελεσματικές τεχνικές, η οποίες αξιοποιήθηκαν για την εισαγωγή του νέου τροποποιημένου εξαγωγέα χαρακτηριστικών VANmb. Ο εξαγωγέας χαρακτηριστικών VANmb, στην παραλλαγή του VANmb-B0, σε συνδυασμό με την πανοπτική κεφαλή Mask2Former [1] έχει πετύχει πανοπτική ποιότητα ίση με 59.795 στο σύνολο δεδομένων επικύρωσης του Cityscapes [2]. Αν και αξιόλογη επίδοση δεν κατάφερε να προσεγγίσει τις επιδόσεις των state-of-the-art μοντέλων. Στον πίνακα 9 παρουσιάζονται οι τιμές πανοπτικής ποιότητας της πανοπτικής κεφαλής Mask2Former για διαφορετικούς εξαγωγείς χαρακτηριστικών.

<i>Μοντέλο</i>	<i>Εξαγωγέας χαρακτηριστικών</i>	<i>PQ</i>
Mask2Former	R50 [87]	62.1
Mask2Former	Swin-B [74]	66.1
Mask2Former	Swin-L [74]	66.6

Πίνακας 9: Απόδοση του Mask2Former [1] με διαφορετικούς εξαγωγείς χαρακτηριστικών στο σύνολο δεδομένων επικύρωσης του Cityscapes [2]

Παρόλο που ο εξαγωγέας χαρακτηριστικών VANmb-B0 δεν κατάφερε να επιτύχει αντίστοιχες επιδόσεις, δεν ήταν κάτι απρόσμενο. Οι εξαγωγείς χαρακτηριστικών που παρουσιάζονται στον πίνακα 9 διαθέτουν πολλαπλάσιο πλήθος παραμέτρων και κατασκευάστηκαν από μεγάλες ερευνητικές ομάδες με πρόσβαση σε πολύ μεγαλύτερους υπολογιστικούς πόρους. Το μικρό πλήθος παραμέτρων ωστόσο, μπορεί να αποτελέσει πλεονέκτημα καθώς το μοντέλο δεν απαιτεί ιδιαίτερα απαιτητικό υλικό εξοπλισμό και μπορεί να εφαρμοσθεί σε συσκευές χαμηλής ενεργειακής κατανάλωσης, όπως φορητές συσκευές και μικρά μη επανδρωμένα οχήματα. Παράλληλα, η χαμηλή πολυπλοκότητα του μοντέλου το καθιστά ελκυστική επιλογή για εφαρμογές πραγματικού χρόνου.

Πέραν των συμπερασμάτων, το μοντέλο παρουσιάζει αρκετά περιθώρια βελτίωσης. Ως εκ τούτου, δύναται να διερευνηθούν επιπλέον προσεγγίσεις που σχετίζονται τόσο με την αρχιτεκτονική του μοντέλου όσο και με την διαδικασία εκπαίδευσης. Παράλληλα, κρίνεται χρήσιμη η εκτέλεση επιπρόσθετων πειραμάτων για την περαιτέρω κατανόηση της λειτουργίας και των δυνατοτήτων του μοντέλου. Παρακάτω, παρουσιάζονται ενδεικτικές μελλοντικές επεκτάσεις της παρούσας εργασίας.

1. Εξέταση του μοντέλου VANmb σε επιπρόσθετες εργασίες ανάλυσης εικόνας, όπως η εκτίμηση πόζας, η ταξινόμηση εικόνας, η σημασιολογική κατάτμηση κ.ο.κ.
2. Συνδυασμός του μοντέλου VANmb με περισσότερες κεφαλές πανοπτικής κατάτμησης εικόνας, καθώς και αξιολόγηση του σε διαφορετικά σύνολα δεδομένων, όπως για παράδειγμα τα σύνολα δεδομένων COCO [18] και ADE20K [16].
3. Εξέταση πρόσθετων διαμορφώσεων του μηχανισμού LKAmb, όπως διαφορετικά πλήθη κλάδων, χρήση πυρήνων διαφορετικών διαστάσεων και αξιοποίηση εναλλακτικών ρυθμίσεων στην προσαρμογή της θερμοκρασίας.
4. Αξιολόγηση του μοντέλου VANmb σε περισσότερους τομείς, όπως η επεξεργασία φυσικής γλώσσας και η επεξεργασία ομιλίας και ήχου.
5. Εξέταση χρήσης πολυκλιμακωτής δομής στον μηχανισμό LKAmb, με κάθε κλάδο να αξιοποιεί περισσότερα από ένα μεγέθη πυρήνων.
6. Εξέταση χρήσης προεκπαιδευμένων βαρών, σε όλα τα τμήματα του εξαγωγέα χαρακτηριστικών VANmb και όχι τμηματικά. Για την αντίστοιχη εκπαίδευση θα μπορούσε να αξιοποιηθεί το σύνολο δεδομένων ImageNet [23].
7. Αξιολόγηση και των υπόλοιπων παραλλαγών του VANmb, οι οποίες λόγω περιορισμένης υπολογιστικής ισχύος, δεν ήταν δυνατό να εξεταστούν.

Βιβλιογραφική αναφορά

- [1] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, “Masked-attention mask transformer for universal image segmentation,” 2022.
- [2] M. Cordts, M. Omran, S. Ramos, T. Rehfeld, M. Enzweiler, R. Benenson, U. Franke, S. Roth, and B. Schiele, “The cityscapes dataset for semantic urban scene understanding,” *CoRR*, vol. abs/1604.01685, 2016.
- [3] A. Kirillov, K. He, R. Girshick, C. Rother, and P. Dollar, “Panoptic segmentation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.
- [4] K. Gao, G. Mei, F. Piccialli, S. Cuomo, J. Tu, and Z. Huo, “Julia language in machine learning: Algorithms, applications, and open issues,” *Computer Science Review*, vol. 37, p. 100254, Aug. 2020.
- [5] A. Esteva, K. Chou, S. Yeung, N. Naik, A. Madani, A. Mottaghi, Y. Liu, E. Topol, J. Dean, and R. Socher, “Deep learning-enabled medical computer vision,” *npj Digital Medicine*, vol. 4, no. 1, p. 5, 2021.
- [6] X. Dong and M. Cappuccio, “Applications of computer vision in autonomous vehicles: Methods, challenges and future directions,” 11 2023.
- [7] M. T. Shahria, M. S. Sunny, I. Islam, J. Ghommam, S. Ahamed, and M. Rahman, “A comprehensive review of vision-based robotic applications: Current state, components, approaches, barriers, and potential solutions,” *Robotics*, vol. 11, 12 2022.
- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems* (F. Pereira, C. Burges, L. Bottou, and K. Weinberger, eds.), vol. 25, Curran Associates, Inc., 2012.
- [9] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, “Imagenet large scale visual recognition challenge,” 2015.
- [10] E. Chris, J. Kate, and A. Juliet, “The evolution of computer vision: From pixels to perception,” 12 2025.
- [11] G. Boesch, “Computer vision tasks (comprehensive 2025 guide),” October 2024.
- [12] L. Zhou, G. Wu, Y. Zuo, X. Chen, and H. Hu, “A comprehensive review of vision-based 3d reconstruction methods,” *Sensors*, vol. 24, p. 2314, April 2024.

- [13] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, “Image segmentation using deep learning: A survey,” *CoRR*, vol. abs/2001.05566, 2020.
- [14] G. Csurka, R. Volpi, and B. Chidlovskii, “Semantic image segmentation: Two decades of research,” 2023.
- [15] M. Everingham, L. V. Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The pascal visual object classes (voc) challenge,” *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.
- [16] B. Zhou, H. Zhao, X. Puig, S. Fidler, A. Barriuso, and A. Torralba, “Scene parsing through ade20k dataset,” in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5122–5130, 2017.
- [17] A. M. Hafiz and G. M. Bhat, “A survey on instance segmentation: state of the art,” *International Journal of Multimedia Information Retrieval*, vol. 9, p. 171–189, July 2020.
- [18] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays, P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár, “Microsoft coco: Common objects in context,” 2015.
- [19] O. Elharrouss, S. Al-Maadeed, N. Subramanian, N. Ottakath, N. Almaadeed, and Y. Himeur, “Panoptic segmentation: A review,” 2021.
- [20] S. Kholin and A. Bitkina, “Image classification: 6 industries & 26 use cases you can try,” 2024.
- [21] A. Singh and P. Singh, “Image classification: A survey,” *Journal of Informatics Electrical and Electronics Engineering (JIEEE)*, vol. 1, pp. 1–9, 11 2020.
- [22] O. Rainio, J. Teuho, and R. Klén, “Evaluation metrics and statistical tests for machine learning,” *Scientific Reports*, 2024.
- [23] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet: A large-scale hierarchical image database,” in *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255, 2009.
- [24] Z. Zou, K. Chen, Z. Shi, Y. Guo, and J. Ye, “Object detection in 20 years: A survey,” 2023.
- [25] A. Rohan, M. J. Hasan, and A. Petrovski, “A systematic literature review on deep learning-based depth estimation in computer vision,” 2025.
- [26] A. Geiger, P. Lenz, C. Stiller, and R. Urtasun, “Vision meets robotics: The KITTI dataset,” *The International Journal of Robotics Research*, vol. 32, no. 11, pp. 1231–1237, 2013.
- [27] C. Zheng, W. Wu, C. Chen, T. Yang, S. Zhu, J. Shen, N. Kehtarnavaz, and M. Shah, “Deep learning-based human pose estimation: A survey,” 2023.

- [28] D. Mehta, O. Sotnychenko, F. Mueller, W. Xu, S. Sridhar, G. Pons-Moll, and C. Theobalt, “Single-shot multi-person 3d pose estimation from monocular rgb,” 2018.
- [29] S. Anwar, S. Khan, and N. Barnes, “A deep journey into super-resolution: A survey,” 2020.
- [30] M. Bevilacqua, A. Roumy, C. Guillemot, and M.-L. Alberi-Morel, “Low-complexity single image super-resolution based on nonnegative neighbor embedding,” 09 2012.
- [31] J.-B. Huang, A. Singh, and N. Ahuja, “Single image super-resolution from transformed self-exemplars,” in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5197–5206, 2015.
- [32] L. Zhou, G. Wu, Y. Zuo, X. Chen, and H. Hu, “A comprehensive review of vision-based 3d reconstruction methods,” *Sensors*, vol. 24, no. 7, 2024.
- [33] N. Gählert, N. Jourdan, M. Cordts, U. Franke, and J. Denzler, “Cityscapes 3d: Dataset and benchmark for 9 dof vehicle detection,” 2020.
- [34] J. Zhang, “Basic neural units of the brain: Neurons, synapses and action potential,” 2019.
- [35] Δ. Μπότσης, Κ. Διαμαντάρας, *Μηχανική μάθηση*. Εκδόσεις Κλειδάριθμος. Χρησιμοποιήθηκαν τα Κεφάλαια 4, 5 και 7.
- [36] A. Navlani, “Activation functions,” 2022.
- [37] C. Nwankpa, W. Ijomah, A. Gachagan, and S. Marshall, “Activation functions: Comparison of trends in practice and research for deep learning,” 2018.
- [38] D. Hendrycks and K. Gimpel, “Gaussian error linear units (gelus),” 2023.
- [39] S. M. K, “Linear activation function,” 2023.
- [40] P. Baheti, “Activation functions in neural networks [12 types & use cases],” 2021.
- [41] F. Rosenblatt, “The perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [42] K. Hornik, M. Stinchcombe, and H. White, “Multilayer feedforward networks are universal approximators,” *Neural Networks*, vol. 2, no. 5, pp. 359–366, 1989.
- [43] L. Ciampiconi, A. Elwood, M. Leonardi, A. Mohamed, and A. Rozza, “A survey and taxonomy of loss functions in machine learning,” 2024.
- [44] C. Hughes, “A brief overview of cross entropy loss,” 2024.
- [45] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” 2019.

- [46] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” 2017.
- [47] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [48] C. F. Higham and D. J. Higham, “Deep learning: An introduction for applied mathematicians,” 2018.
- [49] J. Kukačka, V. Golkov, and D. Cremers, “Regularization for deep learning: A taxonomy,” 2017.
- [50] M. Schmidt, G. Fung, and R. Rosaless, “Optimization methods for ℓ_1 -regularization,” tech. rep., University of British Columbia, 2009.
- [51] A. Lewkowycz and G. Gur-Ari, “On the training dynamics of deep networks with l_2 regularization,” 2021.
- [52] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
- [53] J. Brownlee, “What is the difference between a batch and an epoch in a neural network,” *Machine learning mastery*, vol. 20, no. 1, pp. 1–15, 2018.
- [54] F. Sarikaya, “Batch size selection in deep learning: A comprehensive analysis of training dynamics and performance optimization,” 11 2024.
- [55] Z. Han, B. Liu, S.-B. Lin, and D.-X. Zhou, “Deep convolutional neural networks with zero-padding: Feature extraction and learning,” 2023.
- [56] J. Sun, X. Cao, H. Liang, W. Huang, Z. Chen, and Z. Li, “New interpretations of normalization methods in deep learning,” 2020.
- [57] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” 2015.
- [58] X. Lian and J. Liu, “Revisit batch normalization: New understanding from an optimization view and a refinement via composition optimization,” 2018.
- [59] Y. Wu and K. He, “Group normalization,” 2018.
- [60] X.-Y. Zhou, J. Sun, N. Ye, X. Lan, Q. Luo, B.-L. Lai, P. Esperanca, G.-Z. Yang, and Z. Li, “Batch group normalization,” 2020.
- [61] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2023.

- [62] J. L. Elman, “Finding structure in time,” *Cognitive Science*, vol. 14, no. 2, pp. 179–211, 1990.
- [63] D. Shah, “Coco dataset: All you need to know to get started,” 2023.
- [64] Z. Fan, Y. Wang, Y. Zhu, and J. Zhao, “Preparing state-of-the-art models for classification and object detection with nvidia tao toolkit,” February 2021. Accessed: 2025-06-24.
- [65] P. Taghavi, R. Langari, and G. Pandey, “Swinmtl: A shared architecture for simultaneous depth estimation and semantic segmentation from monocular camera images,” 2024.
- [66] B. Zhou, H. Zhao, X. Puig, T. Xiao, S. Fidler, A. Barriuso, and A. Torralba, “Semantic understanding of scenes through the ade20k dataset,” 2018.
- [67] A. Bhandari, “Confusion matrix in machine learning,” 2025.
- [68] V. Kookna, “Semantic vs. instance vs. panoptic segmentation,” 2022.
- [69] B. T., “Comprehensive guide to multiclass classification metrics,” 2021.
- [70] M. Grandini, E. Bagli, and G. Visani, “Metrics for multi-class classification: an overview,” 2020.
- [71] D. Shah, “Mean average precision (map) explained: Everything you need to know,” 2022.
- [72] F. Li, H. Zhang, H. xu, S. Liu, L. Zhang, L. M. Ni, and H.-Y. Shum, “Mask dino: Towards a unified transformer-based framework for object detection and segmentation,” 2022.
- [73] H. Zhang, F. Li, S. Liu, L. Zhang, H. Su, J. Zhu, L. M. Ni, and H.-Y. Shum, “Dino: Detr with improved denoising anchor boxes for end-to-end object detection,” 2022.
- [74] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, “Swin transformer: Hierarchical vision transformer using shifted windows,” 2021.
- [75] Q. Yu, H. Wang, S. Qiao, M. Collins, Y. Zhu, H. Adam, A. Yuille, and L.-C. Chen, “kmax-deeplab: k-means mask transformer,” 2023.
- [76] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, “A convnet for the 2020s,” 2022.
- [77] L.-C. Chen, H. Wang, and S. Qiao, “Scaling wide residual networks for panoptic segmentation,” 2021.
- [78] S. Zagoruyko and N. Komodakis, “Wide residual networks,” 2017.
- [79] B. Cheng, M. D. Collins, Y. Zhu, T. Liu, T. S. Huang, H. Adam, and L.-C. Chen, “Panoptic-deeplab: A simple, strong, and fast baseline for bottom-up panoptic segmentation,” 2020.

- [80] L.-C. Chen, R. G. Lopes, B. Cheng, M. D. Collins, E. D. Cubuk, B. Zoph, H. Adam, and J. Shlens, “Naive-student: Leveraging semi-supervised learning in video sequences for urban scene segmentation,” 2020.
- [81] F. Chollet, “Xception: Deep learning with depthwise separable convolutions,” 2017.
- [82] J. Jain, J. Li, M. Chiu, A. Hassani, N. Orlov, and H. Shi, “Oneformer: One transformer to rule universal image segmentation,” 2022.
- [83] W. Wang, J. Dai, Z. Chen, Z. Huang, Z. Li, X. Zhu, X. Hu, T. Lu, L. Lu, H. Li, X. Wang, and Y. Qiao, “Internimage: Exploring large-scale vision foundation models with deformable convolutions,” 2023.
- [84] H. Zhang, F. Li, X. Zou, S. Liu, C. Li, J. Gao, J. Yang, and L. Zhang, “A simple framework for open-vocabulary segmentation and detection,” 2023.
- [85] Y. Xiong, R. Liao, H. Zhao, R. Hu, M. Bai, E. Yumer, and R. Urtasun, “Upsnet: A unified panoptic segmentation network,” 2019.
- [86] K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask r-cnn,” 2018.
- [87] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” 2015.
- [88] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, “Feature pyramid networks for object detection,” 2017.
- [89] H. Wang, Y. Zhu, H. Adam, A. Yuille, and L.-C. Chen, “Max-deeplab: End-to-end panoptic segmentation with mask transformers,” 2021.
- [90] M.-H. Guo, C.-Z. Lu, Z.-N. Liu, M.-M. Cheng, and S.-M. Hu, “Visual attention network,” 2022.
- [91] Y. Wu, A. Kirillov, F. Massa, W.-Y. Lo, and R. Girshick, “Detectron2.” <https://github.com/facebookresearch/detectron2>, 2019.
- [92] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. L. Yuille, “Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs,” 2017.

Παράρτημα

Ακολουθεί αναλυτική παρουσίαση των πειραματικών αποτελεσμάτων που εξήχθησαν στο πλαίσιο της παρούσας εργασίας. Η αξιολόγηση πραγματοποιήθηκε χρησιμοποιώντας τις μετρικές αξιολόγησης PQ , PQ_{th} , PQ_{St} , SQ , SQ_{th} , SQ_{St} , RQ , RQ_{th} και RQ_{St} με καταγραφή αποτελεσμάτων ανά 10000 επαναλήψεις. Όλα τα πειράματα πραγματοποιήθηκαν χρησιμοποιώντας την πανοπτική κεφαλή Mask2Former [1].

Α' Αρχικοποίηση παραμέτρων

Στον πίνακα 10 παρουσιάζονται τα πειραματικά αποτελέσματα που εξήχθησαν χρησιμοποιώντας τον εξαγωγέα χαρακτηριστικών VAN-B0 με τυχαία αρχικοποίηση βαρών. Στον πίνακα 11 παρουσιάζονται τα αντίστοιχα αποτελέσματα με χρήση βαρών προεκπαιδευμένων στο ImageNet-1K [23].

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	18.032	1.311	30.193	40.395	23.521	52.668	22.723	1.952	37.829
20k	21.664	3.200	35.093	54.158	30.858	71.104	27.069	4.663	43.365
30k	24.341	4.967	38.432	55.503	31.862	72.696	30.419	7.184	47.317
40k	26.180	6.141	40.753	56.550	33.068	73.627	32.664	8.721	50.077
50k	27.919	7.764	42.577	56.696	33.237	73.758	35.049	11.099	52.467
60k	30.096	9.470	45.096	61.151	42.357	74.819	37.830	13.327	55.651
70k	30.920	10.138	46.033	61.215	42.270	74.994	38.729	14.147	56.606
80k	32.213	10.866	47.738	70.090	63.191	75.108	40.579	15.142	59.08
90k	33.981	14.043	48.482	70.740	64.488	75.288	42.903	19.201	60.141
100k	34.560	15.724	48.260	70.075	62.833	75.342	43.620	21.452	59.743
110k	35.707	14.655	51.018	71.075	63.870	76.316	44.981	20.071	63.097
120k	36.559	17.335	50.541	71.202	64.616	75.992	46.091	23.416	62.582
130k	38.058	19.563	51.509	72.245	74.041	76.120	48.025	26.310	63.818
140k	37.658	18.005	51.952	71.643	65.122	76.386	47.412	24.224	64.275
148800	38.726	20.307	52.122	71.522	64.964	76.292	48.726	27.015	64.516

Πίνακας 10: Αποτελέσματα VAN-B0 με τυχαία αρχικοποίηση βαρών.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	31.605	5.653	50.478	54.521	33.447	69.848	39.543	8.053	62.445
20k	37.295	10.728	56.617	64.412	45.369	78.261	46.481	14.695	69.598
30k	40.977	15.855	59.247	69.304	56.251	78.798	51.061	21.234	72.754
40k	43.928	20.937	60.648	78.155	76.751	79.176	54.719	27.811	74.289
50k	46.333	24.865	61.947	74.494	67.515	79.570	57.483	32.276	75.814
60k	48.678	28.734	63.182	79.458	78.403	80.226	59.970	36.670	76.915
70k	49.528	30.716	63.209	79.039	77.453	80.192	61.401	39.919	77.024
80k	51.870	35.158	64.024	79.633	78.591	80.390	63.824	44.455	77.911
90k	52.549	35.280	65.108	79.482	77.584	80.862	64.821	45.374	78.963
100k	52.877	36.745	64.609	79.481	77.906	80.627	65.222	47.033	78.450
110k	53.375	38.845	63.942	79.814	78.510	80.762	65.629	49.384	77.443
120k	55.076	41.693	64.810	80.036	78.838	80.908	67.595	52.627	78.480
130k	55.206	40.564	65.854	80.089	78.859	80.983	67.678	51.075	79.754
140k	55.917	42.707	65.525	80.065	79.007	80.834	68.640	53.698	79.507
148800	57.101	44.910	65.967	80.203	79.171	80.954	69.995	56.295	79.959

Πίνακας 11: Αποτελέσματα VAN-B0 με βάρη προεκπαιδευμένα στο ImageNet-1K.

Β' Εναλλακτικές μέθοδοι κανονικοποίησης τιμών

Στον πίνακα 12 δίνονται τα πειραματικά αποτελέσματα που εξήχθησαν χρησιμοποιώντας το VAN-B0 με αντικατάσταση της κανονικοποίησης ανά παρτίδα από την κανονικοποίηση ανά ομάδα. Στον πίνακα 13 παρουσιάζονται τα αντίστοιχα αποτελέσματα για την αντίστοιχη αντικατάσταση από την κανονικοποίηση ανά παρτίδα και ομάδα. Σε όλα τα μοντέλα που εξετάστηκαν χρησιμοποιήθηκαν βάρη προεκπαιδευμένα στο ImageNet-1K, τα οποία όμως δεν είναι απολύτως συμβατά, καθώς έχουν παραχθεί από εκπαίδευση του VAN-B0.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	19.128	1.723	31.787	37.187	15.731	52.792	23.924	2.486	39.514
20k	24.220	4.717	38.404	56.313	33.910	72.607	30.136	6.623	47.237
30k	27.131	6.824	41.900	57.489	34.263	74.381	33.940	9.449	51.751
40k	31.212	10.057	46.597	61.732	42.674	75.592	39.281	13.974	57.686
50k	33.639	13.234	48.479	66.692	53.894	75.999	42.270	18.005	59.917
60k	36.611	15.450	52.002	70.902	63.669	76.163	46.233	21.090	64.518
70k	37.814	15.906	53.747	71.922	64.987	76.965	47.679	21.709	66.566
80k	38.252	15.808	54.576	72.553	65.839	77.436	48.055	21.484	67.380
90k	41.089	20.307	56.204	73.467	67.127	78.079	51.425	26.910	69.254
100k	44.176	27.705	56.155	77.291	76.216	78.074	55.231	36.245	69.038
110k	43.870	25.205	57.444	73.202	66.366	78.173	54.905	33.129	70.742
120k	45.593	28.297	58.172	77.969	77.363	78.410	56.923	36.642	71.673
130k	45.527	27.664	58.517	76.946	74.287	78.881	56.929	36.495	71.791
140k	47.159	30.533	59.250	78.221	77.245	78.931	58.791	39.543	72.789
148800	47.351	30.980	59.258	78.292	77.412	78.932	58.995	40.013	72.800

Πίνακας 12: Αποτελέσματα VAN-B0 με αντικατάσταση της κανονικοποίησης ανά παρτίδα από την κανονικοποίηση ανά ομάδα. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	16.301	1.439	27.110	36.772	15.982	51.891	20.817	2.060	34.458
20k	21.250	3.811	33.932	54.059	31.748	70.286	26.884	5.484	42.448
30k	23.765	5.090	37.347	56.045	32.846	72.916	29.805	7.195	46.248
40k	25.811	7.666	39.007	56.662	33.392	73.586	32.399	10.865	48.059
50k	28.184	8.800	42.281	60.154	41.283	73.879	35.383	12.581	51.966
60k	29.496	10.337	43.430	64.893	52.003	74.268	37.245	14.724	53.624
70k	31.246	11.869	45.339	65.239	52.390	74.584	39.495	16.568	56.169
80k	31.833	12.811	45.667	65.937	54.109	74.540	40.201	17.581	56.652
90k	33.474	14.112	47.557	70.652	63.913	75.553	42.230	19.345	58.874
100k	34.992	17.321	47.844	70.336	63.238	75.499	44.363	23.738	59.362
110k	36.562	19.751	48.788	75.859	74.916	76.545	46.045	26.788	60.051
120k	37.492	20.809	49.625	74.674	72.905	75.960	47.471	28.315	61.402
130k	37.886	22.271	49.242	75.435	74.267	76.285	47.705	29.727	60.779
140k	39.363	24.010	50.530	75.893	75.259	76.354	49.515	31.666	62.496
148800	39.380	24.001	50.565	75.692	74.797	76.343	49.678	32.019	62.521

Πίνακας 13: Αποτελέσματα VAN-B0 με αντικατάσταση της κανονικοποίησης ανά παρτίδα από την κανονικοποίηση ανά παρτίδα και ομάδα. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Γ' Αντικατάσταση σημειακής συνέλιξης με MLP

Δίνονται τα πειραματικά αποτελέσματα που προέκυψαν από την αντικατάσταση της σημειακής συνέλιξης του LKA με δίκτυο Perceptron πολλών στρώματων. Εξετάστηκαν διαφορετικά πλήθη νευρώνων για τα κρυφά στρώματα του MLP. Στους πίνακες 14, 15 και 16 παρουσιάζονται τα αντίστοιχα αποτελέσματα. Σε όλα τα μοντέλα που εξετάστηκαν χρησιμοποιήθηκαν βάρη προεκπαιδευμένα στο ImageNet-1K, τα οποία όμως δεν είναι απολύτως συμβατά, καθώς έχουν παραχθεί από εκπαίδευση του VAN-B0.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	29.863	6.086	47.155	56.993	33.488	74.087	37.885	8.799	59.039
20k	33.800	10.210	50.956	63.397	44.206	77.354	42.204	14.339	62.469
30k	38.090	12.621	56.613	63.927	44.139	78.318	47.553	17.346	69.521
40k	40.060	15.753	57.738	73.869	67.029	78.843	49.958	21.307	70.795
50k	44.079	22.774	59.574	74.054	66.855	79.290	54.662	29.669	72.838
60k	44.751	22.481	60.946	74.507	67.808	79.379	55.570	29.480	74.545
70k	44.781	22.268	61.154	74.639	67.743	79.654	55.621	29.319	74.750
80k	47.903	28.369	62.109	74.769	67.729	79.888	59.188	36.455	75.721
90k	50.297	33.422	62.570	78.891	77.141	80.163	62.240	43.179	76.102
100k	50.076	32.838	62.612	77.986	75.102	80.084	62.075	42.635	76.214
110k	51.407	35.164	63.220	78.627	76.420	80.233	63.835	45.893	76.885
120k	52.439	36.892	63.746	79.561	78.435	80.380	64.678	47.019	77.520
130k	52.849	37.715	63.856	79.304	77.502	80.614	65.148	48.328	77.381
140k	53.423	38.795	64.061	79.371	77.747	80.551	65.923	49.690	77.728
148800	54.022	39.707	64.432	79.272	77.439	80.604	66.777	51.080	78.193

Πίνακας 14: Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τριπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	29.215	4.478	47.206	58.089	33.257	76.148	36.659	6.508	58.588
20k	34.636	10.691	52.050	62.956	43.747	76.926	43.709	15.057	64.547
30k	38.009	14.017	55.457	63.841	44.554	77.868	47.792	19.406	68.436
40k	40.211	16.270	57.622	68.940	56.322	78.118	50.498	21.989	71.232
50k	43.680	21.512	59.803	73.892	66.794	79.055	54.492	28.451	73.432
60k	45.705	25.494	60.404	74.677	68.315	79.305	56.641	32.843	73.949
70k	46.752	27.601	60.679	74.328	67.400	79.367	58.186	35.811	74.458
80k	49.964	33.304	62.081	78.128	75.867	79.773	62.122	43.310	75.804
90k	50.461	32.998	63.162	79.063	77.117	80.478	62.291	42.570	76.634
100k	52.189	38.024	62.491	78.444	76.250	80.039	64.653	48.893	75.115
110k	53.035	39.238	63.068	79.248	77.745	80.340	65.508	50.162	76.668
120k	53.473	39.298	63.782	79.272	77.651	80.451	66.026	50.230	77.514
130k	53.686	39.957	63.671	79.360	77.512	80.704	66.195	51.106	77.169
140k	54.690	42.304	63.697	79.396	77.665	80.656	67.474	53.948	77.312
148800	55.365	43.467	64.017	79.714	78.269	80.764	68.114	55.070	77.599

Πίνακας 15: Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τετραπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	28.783	5.297	45.863	57.333	33.161	74.913	36.071	7.689	56.713
20k	34.502	10.206	52.172	63.207	44.112	77.093	43.291	14.422	64.288
30k	38.152	12.847	56.556	63.767	43.929	78.195	47.835	17.809	69.672
40k	40.500	16.500	57.956	68.952	55.927	78.425	50.717	22.250	71.421
50k	44.968	24.422	59.911	74.284	67.461	79.247	55.861	31.949	73.252
60k	44.886	24.320	59.844	74.311	67.537	79.237	55.690	31.528	73.262
70k	47.229	28.727	60.685	77.861	75.685	79.444	58.672	37.413	74.133
80k	49.045	31.326	61.931	74.283	66.604	79.868	60.856	40.606	75.583
90k	50.992	35.332	62.381	78.787	76.905	80.156	62.964	45.200	75.884
100k	51.409	35.671	62.855	78.742	76.933	80.057	63.477	45.319	76.684
110k	53.810	40.164	63.735	79.168	77.508	80.376	66.480	51.348	77.486
120k	54.479	41.072	64.230	79.536	78.098	80.582	67.043	52.042	77.954
130k	55.314	43.731	63.739	79.463	78.043	80.496	68.128	55.464	77.337
140k	54.591	41.891	63.827	79.666	78.410	80.579	67.106	52.960	77.393
148800	55.250	43.348	63.907	79.539	78.307	80.435	68.014	54.781	77.639

Πίνακας 16: Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων πενταπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Από τα πειράματα που πραγματοποιήθηκαν, η παραλλαγή του VAN-B0 με πλήθος νευρώνων ίσο με το τετραπλάσιο του πλήθους των καναλιών του χάρτη χαρακτηριστικών εμφάνισε την καλύτερη απόδοση. Ως εκ τούτου, εξετάζεται περαιτέρω για διαφορετικές μεθόδους κανονικοποίησης. Στον πίνακα 17, η κανονικοποίηση ανά παρτίδα αντικαθίσταται από την κανονικοποίηση ανά ομάδα, ενώ στον πίνακα 18 από την κανονικοποίηση ανά παρτίδα και ομάδα.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	17.495	1.669	29.005	36.617	15.696	51.831	21.869	2.437	36.002
20k	21.852	4.257	34.648	55.722	32.727	72.446	27.184	6.028	42.570
30k	24.983	5.349	39.261	56.378	41.434	67.247	31.059	7.603	48.119
40k	28.493	7.958	43.427	60.006	41.485	73.475	35.759	11.215	53.610
50k	30.031	9.721	44.802	60.692	41.692	74.510	37.754	13.595	55.324
60k	31.725	10.457	47.192	61.869	43.457	75.260	40.116	14.634	58.649
70k	33.570	13.057	48.488	71.852	66.280	75.903	42.264	17.742	60.099
80k	36.308	17.377	50.076	70.996	64.015	76.073	45.768	23.493	61.968
90k	38.035	18.776	52.041	71.773	64.631	76.967	47.754	25.123	64.213
100k	38.881	19.451	53.013	72.056	65.313	76.960	48.976	25.907	65.753
110k	39.043	20.581	52.470	72.408	66.050	77.032	48.844	27.110	64.651
120k	40.559	23.684	52.832	72.411	66.271	76.876	51.008	31.247	65.380
130k	40.719	21.960	54.361	72.572	66.265	77.159	51.195	29.043	67.304
140k	41.802	23.685	54.979	72.528	65.729	77.472	52.516	31.315	67.936
148800	42.495	24.658	55.467	72.579	66.045	77.330	53.470	32.551	68.685

Πίνακας 17: Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP και κανονικοποίησης ανά παρτίδα με κανονικοποίηση ανά ομάδα. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τετραπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	15.946	1.404	26.522	39.968	23.058	52.266	20.008	2.069	33.054
20k	21.153	3.394	34.068	53.982	31.128	70.604	26.462	4.938	42.116
30k	23.849	5.022	37.541	52.159	32.854	66.199	30.009	7.062	46.697
40k	27.126	7.086	41.701	60.726	43.357	73.358	34.004	9.965	51.487
50k	28.461	7.644	43.601	59.476	40.399	73.350	35.866	10.827	54.077
60k	29.909	9.798	44.535	61.214	42.660	74.707	37.635	13.695	55.045
70k	31.500	10.748	46.592	65.804	53.150	75.006	39.637	14.970	57.578
80k	31.553	12.409	45.476	70.174	64.163	74.546	39.710	17.150	56.118
90k	34.980	15.698	49.004	70.614	63.912	75.489	44.281	21.683	60.716
100k	35.932	17.493	49.341	70.799	64.321	75.510	45.482	23.801	61.251
110k	35.798	16.973	49.489	70.000	62.555	75.415	45.628	23.490	61.729
120k	37.162	19.102	50.295	70.998	64.399	75.798	46.892	25.582	62.389
130k	37.507	20.427	49.928	73.994	71.664	75.688	47.578	27.647	62.074
140k	38.563	22.252	50.425	73.678	70.995	75.630	49.050	30.296	62.690
148800	38.686	21.997	50.823	74.245	71.938	75.922	49.042	29.570	63.204

Πίνακας 18: Αποτελέσματα VAN-B0 με αντικατάσταση σημειακής συνέλιξης με MLP και κανονικοποίησης ανά παρτίδα με κανονικοποίηση ανά παρτίδα και ομάδα. Κάθε κρυφό στρώμα του MLP έχει πλήθος νευρώνων τετραπλάσιο από το πλήθος των καναλιών του χάρτη χαρακτηριστικών. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Δ' Χρήση LKA πολλαπλών κλάδων

Στον πίνακα 19 παρουσιάζονται τα πειραματικά αποτελέσματα που εξήχθησαν μέσω της αντικατάστασης του μηχανισμού LKA του VAN [90], με τον μηχανισμό LKAmb που παρουσιάζεται στο κεφάλαιο 5.2. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 40000.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	26.641	3.817	43.241	53.209	33.432	67.591	33.226	5.414	53.453
20k	33.573	10.009	50.710	62.091	42.329	76.464	42.246	14.045	62.755
30k	37.123	11.999	55.396	62.982	42.824	77.643	46.480	16.703	68.135
40k	39.929	15.986	57.342	63.790	44.419	77.878	50.228	21.901	70.829
50k	43.482	21.752	59.286	74.359	67.889	79.064	54.044	28.591	72.556
60k	46.132	27.031	60.024	78.805	78.111	79.309	57.097	34.641	73.428
70k	47.324	28.875	60.741	78.649	77.584	79.424	58.754	37.457	74.243
80k	47.998	27.452	62.940	74.809	67.692	79.984	59.386	35.472	76.779
90k	50.388	34.305	62.084	78.921	77.653	79.843	62.438	44.091	75.781
100k	52.798	38.188	63.423	79.748	78.882	80.377	65.074	48.445	77.169
110k	53.952	40.004	64.095	79.616	78.481	80.441	66.423	50.635	77.905
120k	51.160	40.384	64.179	79.602	78.548	80.368	66.769	51.125	78.146
130k	53.751	39.250	64.297	78.990	76.848	80.547	66.394	50.316	78.087
140k	55.172	43.100	63.952	79.687	78.284	80.708	68.000	54.790	77.607
148800	55.123	41.681	64.898	79.911	78.779	80.734	67.708	52.521	78.752

Πίνακας 19: Αποτελέσματα VANmb-B0. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 40000. Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Ακολούθως, στους πίνακες 20 και 21 παρουσιάζονται τα αντίστοιχα αποτελέσματα για πλήθος συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ίσο με 20000 και ρυθμό μάθησης ίσο με 10^{-5} και 3535×10^{-8} αντίστοιχα.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	21.000	1.201	35.400	40.977	15.744	59.328	25.971	1.737	43.595
20k	24.703	3.134	40.390	52.069	32.023	66.648	30.634	4.672	49.516
30k	27.099	4.814	43.307	53.067	32.767	67.831	33.770	7.052	53.201
40k	29.802	6.694	46.607	61.240	42.757	74.682	37.446	9.603	57.696
50k	32.218	7.791	49.983	61.588	41.871	75.928	40.575	11.194	61.942
60k	33.954	9.583	51.679	61.992	42.742	75.991	43.017	13.706	64.335
70k	35.093	10.307	53.118	62.673	43.100	76.908	44.190	14.599	65.712
80k	35.969	10.390	54.571	62.856	43.330	77.056	45.374	14.623	67.739
90k	37.093	11.933	55.348	68.044	55.349	77.277	46.756	16.753	68.576
100k	38.446	15.552	55.096	67.861	54.858	77.317	48.356	21.058	68.210
110k	39.013	14.895	56.554	67.619	53.776	77.687	49.201	20.734	69.904
120k	40.059	17.006	56.825	73.598	67.004	78.393	50.114	22.940	69.876
130k	40.379	16.860	57.484	73.032	65.771	78.312	50.592	22.749	70.841
140k	41.056	18.060	57.780	73.277	66.519	78.191	51.413	23.971	71.371
148800	41.973	19.453	58.350	73.291	66.531	78.207	52.633	25.907	72.070
150k	40.983	17.480	58.076	72.714	65.212	78.170	51.494	23.724	71.690
160k	42.294	19.872	58.601	72.981	65.551	78.385	53.055	26.626	72.277
170k	42.856	20.208	59.328	73.502	66.566	78.547	53.551	26.562	73.180
180k	43.448	21.821	59.176	73.607	66.898	78.485	54.259	28.633	72.896
190k	44.755	24.248	59.670	77.726	76.586	78.555	56.029	31.899	73.579
200k	44.382	23.067	59.884	78.206	77.162	78.965	55.261	30.101	73.560
210k	45.032	24.446	60.004	78.012	76.813	78.884	56.250	32.095	73.817
220k	45.442	25.278	60.107	73.310	65.536	78.964	56.853	33.413	73.900
230k	44.685	23.009	60.450	74.099	66.813	79.398	55.538	30.117	74.026
240k	45.507	24.853	60.529	78.455	77.368	79.245	56.565	32.346	74.179
250k	45.308	24.159	60.690	73.616	66.088	79.091	56.525	31.802	74.505
260k	46.244	26.682	60.470	77.992	76.200	79.296	57.617	34.940	74.110
270k	46.295	26.718	60.532	78.296	76.644	79.497	57.560	34.975	73.986
280k	46.995	28.164	60.691	78.447	77.359	79.238	58.453	36.519	74.405
290k	46.776	27.290	60.947	78.622	77.625	79.346	58.076	35.253	74.674
297600	47.085	27.782	61.123	78.559	77.410	79.394	58.510	35.986	74.891

Πίνακας 20: Αποτελέσματα VANmb-B0. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 20000 και ο ρυθμός μάθησης με 10^{-5} . Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.

Επαναλήψεις	PQ	PQ_{th}	PQ_{St}	SQ	SQ_{th}	SQ_{St}	RQ	RQ_{th}	RQ_{St}
10k	27.592	4.816	44.157	57.233	33.342	74.608	34.432	6.835	54.504
20k	33.733	9.704	51.208	62.247	42.257	76.785	42.455	13.882	63.234
30k	37.147	11.504	55.797	63.643	44.479	77.581	46.519	15.684	68.945
40k	39.815	15.407	57.566	64.593	44.858	78.947	49.635	21.041	70.431
50k	43.020	21.194	58.893	73.872	66.846	78.982	53.548	27.883	72.213
60k	44.141	22.730	59.712	74.218	67.678	78.975	54.820	29.660	73.118
70k	47.438	28.447	61.249	78.919	77.944	79.629	58.736	36.680	74.777
80k	48.528	30.771	61.443	78.122	75.876	79.755	60.202	39.957	74.925
90k	52.355	38.495	62.434	78.995	77.494	80.087	64.711	49.164	76.018
100k	51.566	35.145	63.510	79.518	78.169	80.500	63.456	44.636	77.143
110k	52.528	38.763	62.540	78.768	77.170	79.931	65.068	49.796	76.176
120k	53.524	39.612	63.643	79.675	78.499	80.531	65.921	50.444	77.178
130k	55.573	44.024	63.973	79.646	78.383	80.565	68.418	55.713	77.658
140k	55.288	43.287	64.017	79.499	77.925	80.643	68.186	55.199	77.631
148800	55.436	43.282	64.322	80.000	78.729	80.924	68.051	54.730	77.739
150k	56.119	44.588	64.504	79.992	78.771	80.880	68.862	56.141	78.113
160k	55.293	42.695	64.455	79.650	78.286	80.641	68.143	54.382	78.152
170k	56.983	45.562	65.289	79.979	78.589	80.989	70.027	57.677	79.009
180k	56.976	44.737	65.877	79.659	77.754	81.044	70.132	56.993	79.688
190k	57.630	47.105	65.285	80.098	78.508	81.255	70.678	59.546	78.774
200k	58.470	48.538	65.693	79.919	78.291	81.102	71.787	61.270	79.435
210k	58.398	47.996	65.964	79.820	78.030	81.122	71.820	60.868	79.784
220k	58.395	48.013	65.945	80.266	79.108	81.107	71.467	60.194	79.666
230k	58.688	48.666	65.976	80.175	78.725	81.229	71.936	61.279	79.686
240k	58.229	47.472	66.051	80.206	78.777	81.245	71.412	59.935	79.759
250k	58.999	49.145	66.166	80.223	78.777	81.275	72.279	61.868	79.850
260k	59.007	48.913	66.348	80.264	78.779	81.344	72.241	61.500	80.053
270k	59.337	49.383	66.576	80.373	78.852	81.479	72.585	62.113	80.202
280k	59.307	49.684	66.305	80.110	78.450	81.317	72.742	62.793	79.977
290k	59.360	49.611	66.450	80.360	78.868	81.446	72.636	62.406	80.077
297600	59.795	49.835	67.039	80.468	78.936	81.583	73.093	62.602	80.722

Πίνακας 21: Αποτελέσματα VANmb-B0. Το πλήθος των συνολικών επαναλήψεων προσαρμογής της θερμοκρασίας ορίστηκε ίσο με 20000 και ο ρυθμός μάθησης με 3535×10^{-8} . Οι παράμετροι αρχικοποιήθηκαν με βάρη προεκπαιδευμένα στο ImageNet-1K.